

分 类 号 TP391

密 级

U D C

编 号 10486

武汉大学

硕 士 学 位 论 文

基于小样本的医学图像分割算法研究

研 究 生 姓 名：刘棣

学 号：2020202210002

指导教师姓名、职称：陈刚 教授

专 业 名 称：网络空间安全

研 究 方 向：医学图像分割

二〇二三年六月

Research on Few-shot Medical Image Segmentation Algorithm

By
Yan Liu

Supervised by
Prof. Gang Chen

Wuhan University

June, 2023

摘 要

医学图像语义分割是医学图像智能分析里的一项关键任务,为临床医生诊断和治疗病情提供了重要的基础信息。如今,基于深度学习的医学图像分割的精度越来越高,但其训练过程需要大量的数据和标注支撑,且训练出的模型对于新任务的泛化能力较差。为了解决上述问题,一些医学图像小样本分割方法相继被提出,并取得了一定的成果。然而,这些小样本分割方法仍存在以下局限:第一,由于医学图像背景空间占比通常很大,前景空间占比较小,导致模型不能有效地提取支撑图像和查询图像的关联特征,降低了模型对识别新器官类别的泛化能力。此外,忽略了查询集分割图像的边界信息的重要性,没有充分利用查询集分割目标具有空间拓扑结构这一知识。第二,由于样本集有限,未能很好解决分割目标在支撑集与查询集中的大小、形状等空间不一致性问题。

针对上述问题,本文进行了深入研究并提出了具体的解决方案,主要研究内容以及成果如下:

1. 针对模型对于新类别泛化能力较低、边界信息利用不充分等问题,本文提出并构建了一种新型的基于先验信息的小样本语义分割模型。该模型通过计算查询特征和支撑特征之间的余弦相似度来生成具有前景先验信息的先验掩码,使模型能够更好的对查询集上的分割目标进行识别。再通过特别设计的活动轮廓优化模块,实现了器官轮廓的逐步调整并最终收敛于目标的真实边界,有效地利用了查询集分割目标的边界信息,保留了分割目标的空间拓扑结构,并提高了最终分割结果的准确性。

2. 针对查询集和支撑集分割目标的空间不一致性问题,本文在基于先验信息的小样本语义分割模型基础上,提出了一种基于多分辨率特征融合的小样本语义分割模型 **MFA-SnakeNet** (**Multi Path Feature Aggregation Snake Net**)。该模型设计了一种多分辨率特征融合模块。该模块在多个分辨率层级内整合了查询图像特征、支撑图像的特征和包含先验信息的先验掩码多种信息,减少了两个集合分割目标的语义特征差异。并采用自顶向下的方式,从分辨率高的细致特征中抽取关键信息,用以丰富低分辨率的粗略特征,并将不同分辨率特征进行整合,有效地解决了查询集的空间特征信息与支撑集的空间不一致问题,提高了分割结果的准确性。

为了验证基于先验信息的小样本语义分割模型以及 **MFA-SnakeNet** 的分割性能,本文在 **ABD-30** 以及 **CHAOST-MRI** 两种不同模态的医学数据集上,进行了相关实验,并与目前已有的医学图像小样本分割方法进行比较。实验结果表明,基于先验信息的模型和 **MFA-SnakeNet** 均取得较好的分割结果。其中,结合所有模块的 **MFA-SnakeNet** 在评估指标中表现最好,在 **ABD-30** 数据集上的平均分割精度达到 76.33%,在 **CHAOST-MRI** 数据集上的平均分割精度达到 82.26%,有效地提升了小样本分割的准确性。

关键词：小样本学习；医学图像分割；先验信息；活动轮廓算法；多分辨率特征融合

ABSTRACT

Medical image semantic segmentation serves as a crucial task in intelligent medical image analysis, providing invaluable foundational information for clinical diagnosis and treatment. Currently, the accuracy of medical image segmentation utilizing deep learning techniques has progressively improved; however, the training process necessitates substantial data and annotations, resulting in limited generalization ability of the trained models when faced with novel tasks. To address these issues, some medical image few-shot segmentation methods have been proposed and achieved certain results. However, these few-shot segmentation methods still have the following limitations: first, since the background space in medical images is usually much larger than the foreground space, the model cannot effectively extract the associated features between the support and query images, which reduces the model's ability to recognize new organ categories. In addition, the importance of the boundary information of the query set images is ignored, and the spatial topology structure knowledge of the query segmentation target is not fully utilized. Second, due to the limited sample set, it has not been able to solve the inconsistency in size, shape, and other spatial characteristics of the segmentation targets between the support set and the query set.

In view of the above problems, we have conducted extensive research and proposes specific solutions to these issues. The main research content and achievements are as follows:

1. To address the problems of poor generalization ability of the model for new categories and insufficient use of boundary information, this paper proposes and constructs a prior information-based few-shot semantic segmentation model. The model generates prior masks that provide foreground prior information by calculating the cosine similarity between query features and support features, enabling the model to better recognize segmentation targets in the query set. In addition, a specially designed active contour optimization module is used to gradually adjust the organ contour and ultimately converge to the true boundary of the target. The module effectively utilizes the boundary information of the query set segmentation target, and preserves the spatial topology structure of the segmentation target. It has improved the accuracy of the final segmentation result.

2. To address the problem of inconsistent spatial segmentation targets between the query set and the support set, this paper proposes a new type of few-shot semantic segmentation model called MFA-SnakeNet (Multi Path Feature Aggregation Snake Net) based on the prior information few-shot segmentation model. This model includes a multi-resolution feature fusion mod-

ule. The module integrates multiple types of information, such as query image features, support image features and a prior masks containing a prior information within multiple resolution levels. It reduces the semantic feature differences between two ensemble segmentation targets. Moreover, it adopts a top-down approach to extract key information from high-resolution fine features and enrich low-resolution coarse features, and aggregates different resolution features to effectively solve the spatial inconsistency problem between the query and support sets, thereby improving the accuracy of segmentation results.

To validate the segmentation performance of the a prior information-based few-shot segmentation model and MFA-SnakeNet, experiments are conducted on two different modalities of medical datasets, ABD-30 and CHAOST-MRI, and compared with the existing methods for few-shot segmentation of medical images. The experimental results show that both the prior information-based model and MFA-SnakeNet have achieved satisfactory segmentation results. Notably, the comprehensive MFA-SnakeNet, incorporating all modules, exhibits the best performance in evaluation metrics, achieving an average segmentation accuracy of 76.33% on the ABD-30 dataset and 82.26% on the CHAOST-MRI dataset, effectively enhancing the accuracy of few-shot segmentation.

Key words: Few-shot Learning; Medical Image Segmentation; Prior Information; Active Contour Algorithm; Multi-scale Feature Aggregation

目 录

1 绪论.....	1
1.1 研究工作背景及意义.....	1
1.2 国内外研究现状.....	3
1.2.1 传统医学图像语义分割.....	3
1.2.2 基于深度学习的语义分割.....	4
1.2.3 基于小样本学习的语义分割.....	5
1.3 本文主要研究内容.....	7
1.4 本文章节安排.....	7
2 相关技术原理	9
2.1 神经网络概述.....	9
2.1.1 神经元模型及神经网络.....	9
2.1.2 卷积神经网络.....	11
2.2 小样本学习.....	15
2.3 活动轮廓算法以及循环卷积	16
2.4 多分辨率特征融合.....	18
2.5 本章小结.....	21
3 基于先验信息的小样本语义分割模型	22
3.1 引言.....	22
3.2 医学图像小样本语义分割任务描述	23
3.3 基于先验信息的小样本语义分割模型网络结构	24
3.3.1 特征编码器模块.....	25
3.3.2 先验掩码生成模块.....	26
3.3.3 活动轮廓优化模块.....	27
3.3.4 损失函数.....	30
3.4 实验与分析.....	30
3.4.1 数据集以及预处理.....	30
3.4.2 实验环境.....	32
3.4.3 对比模型设计.....	32
3.4.4 实验超参数设置.....	32
3.4.5 评价指标.....	33
3.4.6 实验结果.....	33
3.5 本章小结.....	38
4 基于多分辨率特征融合的小样本语义分割模型	39
4.1 引言.....	39

4.2 基于多分辨率特征融合的小样本语义分割模型网络结构	40
4.3 多分辨率特征融合模块.....	41
4.4 实验与分析.....	44
4.4.1 实验说明	44
4.4.2 实验结果.....	45
4.5 本章小结.....	48
5 总结与展望.....	50
5.1 总结	50
5.2 展望.....	51
参考文献.....	52

图片索引

2.1	MP 神经元模型·····	9
2.2	包含多个隐藏层的前馈神经网络 ·····	10
2.3	VGG16 卷积神经网络结构·····	11
2.4	卷积过程示意图·····	12
2.5	最大池化操作过程示意图·····	12
2.6	ReLU 激活函数及其导数·····	13
2.7	转置卷积操作过程图 ·····	15
2.8	2-way 5-shot 小样本学习模型示例 ·····	16
2.9	Snake 模型迭代过程示例·····	18
2.10	循环卷积过程计算示意图·····	19
2.11	金字塔池化模型网络结构·····	20
2.12	空洞金字塔池化模型网络结构 ·····	20
3.1	基于先验信息的小样本分割模型网络结构 ·····	24
3.2	基于 U-Net 的特征编码器模块网络结构 ·····	25
3.3	支撑特征、查询特征以及先验掩码特征信息融合过程 ·····	27
3.4	动态轮廓优化单元网络结构·····	28
3.5	活动轮廓优化流程示意图·····	29
3.6	先验掩码生成结果展示 ·····	35
3.7	动态轮廓单元在 ABD-30 数据集上的迭代过程结果展示·····	37
3.8	动态轮廓单元在 CHAOST-MRI 数据集上的迭代过程结果展示 ·····	37
4.1	基于多分辨率特征融合的小样本语义分割模型网络结构·····	40
4.2	多分辨率特征融合模块具体网络结构·····	42
4.3	不同分辨率层级之间的特征融合模块 P 的具体网络结构·····	44
4.4	MFA-SnakeNet 在数据集上的分割结果展示·····	48

表格索引

3.1	特征编码器网络层部分参数	26
3.2	小样本语义分割任务训练集、测试集类别构成	31
3.3	超参数配置表	33
3.4	基于先验信息的小样本分割模型在 ABD-30 数据集上的实验结果	33
3.5	基于先验信息的小样本分割模型在 CHAOST-MRI 数据集上的实验结果	34
3.6	特征编码器对模型分割性能的影响	36
3.7	迭代次数对分割性能的影响	36
4.1	超参数配置表	45
4.2	MFA-SnakeNet 小样本分割模型在 ABD-30 数据集上的实验结果	45
4.3	MFA-SnakeNet 小样本分割模型在 CHAOST-MRI 数据集上的实验结果	46
4.4	不同分辨率融合模块对基于先验信息的小样本意义分割模型的性能影响测试 ..	47

1 绪论

1.1 研究工作背景及意义

随着国民经济的不断发展和全民教育水平的日益提升，人们对健康生活的渴望更加强烈，这也意味着对医疗技术的发展提出了更高的要求。医学影像几乎贯穿于整个医疗诊疗的全过程，包括对疾病的筛查、诊断、治疗及疗效评估等方面，是医疗诊断中不可或缺的技术。据统计，医院存储的信息超过 90% 来源于医学影像^[1]。尤其随着医学影像数据生成设备和存储通信平台的建立，医学影像数据具备了数据规模庞大、数据更新频繁、数据类型多样、数据价值巨大及数据处理复杂等特质^[2]。常见的医学影像包括，X-射线（X-ray）、计算机断层扫描图像（Computed Tomography, CT）、磁共振成像（Magnetic Resonance Imaging, MRI）等，这些海量数据为医学影像未来的发展提供了更多的可能性。因此，如何对医学影像大数据做进一步分析和挖掘、如何从医学图像高维度数据中提取有价值的信息、如何将现代医学影像的发展与精准医疗紧密结合，成为医学影像未来发展的重要课题^[3]。近年来，随着大数据、云计算、深度学习等领域的新理论、新技术、新应用取得了突破性进展，人工智能技术再次迎来质的进步，国务院也在新一代人工智能发展规划中指出：“要推广应用人工智能治疗新模式新手段，建立快速精准的智能医疗体系”。医学影像数据的理解是实现智能医疗的基础，对医学影像数据的研究因此也具有十分重要的含义。

作为智能医疗研究领域中的关键组成部分，医学图像语义分割不仅构成智能医疗的基石，还是医学图像理解的关键步骤。此外，它也被认为是医学图像处理中最具挑战性的问题之一。医学图像语义分割是指根据分割数据集中类别的设定，依据医学图像的颜色、空间纹理、灰度、几何形状等特征，将图像中的各个区域划分为不同的区域。这些区域之间互不重叠，同一类别的区域通常表现出一致性，而不同类别的区域则会呈现出非一致性。作为智慧医疗不可分割的一部分，医学图像语义分割属于上游任务，为计算机辅助诊断提供重要的先验知识。以乳腺癌良恶性诊断为例^[4]，医学分割图像分割的质量不仅会直接影响到后续特征的提取与分析，也会影响到最终医生制定合适的医疗方案。近年来随着深度学习研究在学术界和工业界的广泛应用，越来越多的方法选择神经网络来解决医学图像语义分割问题。其中，卷积神经网络已成为了主流方法，其在准确率和效率上都超越了绝大多数基于传统算法的方法。对于医学图像语义分割而言，它是一个从局部到整体的推理过程：首先基于图像特征对每个像素进行分类预测，其次利用真实标签做监督（真实标签提供了类别的空间位置的附加信息），最后是输出对整个图片的预测。

在医学图像语义分割任务的发展过程中，传统的医学图像语义分割算法主要依赖于

图像的低级特征，这些方法通过滤波、变换等操作分析和提取医学图像的底层特征信息，并利用不同区域的颜色、形状、纹理等特征，将具有相似属性的像素划分为一类，以此获得初步的分割结果。在此基础上，采用数学算法进行优化以获得更精确的结果。尽管如此，这些传统算法存在一定的局限性。由于它们依赖人工设计的特征和优化方法，因此难以处理相邻组织之间的重叠噪声和器官组织之间模糊边界等问题，这导致它们难以准确地分割每个类别。

从 2015 年开始，深度学习技术在医学图像语义分割中的应用已经成为主流^[5]。神经网络，如深度卷积网络（Fully Convolutional Networks, FCN）能够学习医学图像数据中的底层局部特征和高级语义特征，并将它们融合起来以进行分割预测。与传统方法相比，这些基于神经网络的方法不再严重依赖人工设计的特征，能够挖掘更多深层次的语义特征，从而使网络更具有鲁棒性，并极大地提升了模型的泛化能力。为了构建这些模型，研究人员联合临床医生花费了大量的精力和财力构建包含大量像素级标注的医学图像数据集，并利用这些数据进行训练。然而，尽管基于神经网络的深度学习在医学图像语义分割过程中减少了对底层特征的依赖，挖掘出了更多深层次的语义特征，使网络在语义分割的过程中具有更强的鲁棒性，但这些分割方法仍面临两个亟待解决的问题：

（1）深度学习模型的训练需要大量带有真实标签的数据。然而，获取真实数据的分布非常困难，目前大部分方法采用经验风险最小化来搜索神经网络的最优参数，而不是期望风险最小化。这意味着模型需要大量的数据及其标签，以尽可能接近真实分布，防止训练数据的分布偏差导致模型无法实现全局最优。然而，在医学图像语义分割这类的稠密预测分割任务中，获得一个包含准确标注的医学图像数据集的时间和人力成本非常高昂，因为医学图像的标注需要由专业的临床医生完成。

（2）现有的语义分割模型对于未知类别的器官或病灶时泛化能力较弱。这些模型在训练阶段根据样本分布建立了输入图像与真实标签之间的非线性映射关系。然而，在模型的测试过程中，如果模型遇到了和训练数据样本分布有差异的未知类别图像，网络的分割性能通常会受到影响。

为了克服现有医学图像语义分割模型的不足，学术界和工业界的研究人员将当时热门的小样本学习技术引入到语义分割领域，提出了基于小样本的语义分割任务。该任务在语义分割的基础上，采用小样本学习的方法，在仅有少量带注释的支撑图像可用的情况下，通过分割已知类别的目标来学习可迁移的知识，从而将模型的分割能力推广到新的类别上^[6]。

现有的小样本语义分割模型大多基于双分支网络结构，该结构包括查询分支和支撑分支，支撑分支负责处理支持特征和其相对应的像素级真实标签交互，生成包含指导信息的支撑特征；查询分支则利用查询特征和支持特征生成分割结果。在医学图像小样本语义分割研究中，这种结构的网络模型在小样本语义分割任务上已取得一定成效。然而，在查询集分割目标边界知识利用、支撑集和查询集之间的关联特征信息利用不足、

查询集和支撑集分割目标之间存在空间不一致性方面仍存在问题。

因此,本文聚焦于医学图像小样本语义分割,针对前文提出的“分割任务先验知识的利用”、“关联特征信息利用不足”和“减少空间不一致性”三个方面,对现有方法和理论进行研究和分析,提出了具体的解决方案。

1.2 国内外研究现状

1.2.1 传统医学图像语义分割

早在上世纪七十年代,国内外学者就已开始对医学图像分割算法的研究,这些算法可概括为以下三类方法:基于像素信息的方法、基于区域的方法,基于先验形状的方法。

基于像素信息的方法仅仅依赖图像本身信息,其中最为常见的是基于灰度阈值的分割。该方法实现简单,计算简单,其核心思想在于设置一个或多个灰度阈值。根据像素的灰度值将图像中的像素划分为不同的类别。算法中使用的阈值可以自动获取,也可以进行人为设置。常见的阈值选择方法有:自适应阈值法^[7],迭代阈值法^[8]等。若图像仅包含目标和背景两个主要类别,那么只需要选取一个阈值进行分割,这种方法被称为单阈值分割,例如 OTSU 算法^[9]。若图像中有多个需要识别的目标,这种情况下就需要选取多个阈值以将各个目标分隔开,这种分割方法称为多阈值分割,如 NCut 算法^[10]。由于该类算法只考虑了像素点本身的灰度特征,受图像质量的影响较大,因此对噪声比较敏感,鲁棒性不高。

基于区域的方法的主要思想是依据分割对象内部特征的相似性,通过聚类算法将同类别的像素聚合成不同的区域。该类方法常见的算法有区域生长法 (Region Growing)^[11]和分裂合并法 (Split and Merge)^[12]等。区域生长算法的核心思想是首先从待分割区域选取一个或多个种子生长点,基于一定的相似性准则,将临近的具有相似特征的像素加入到生长区域中,并作为新的种子点。当所有种子点的领域像素均不满足相似性时,区域生长过程结束。该方法对初始种子点的选择敏感,且存在计算和存储开销大的问题。分裂合并法克服了区域生长法的缺点,不需要选择种子点,将待分割图像划分成若干个互不重叠的子区域,然后根据一定的分裂合并准则确定子区域进行分裂或合并操作,但依旧存在计算量过大以及算法复杂等问题。

基于先验形状约束的方法的主要思想是将形状先验知识加入到交互式图像分割算法中,使算法包含更多的约束信息,限制目标的搜索范围,从而分割出更加准确的目标图像。该类方法最为常见的是活动轮廓模型 (Active Contour Model, ACM) Snake,该模型由 Kass 等人^[13]提出并应用于医学图像分割领域。该算法通过一组控制曲线形状(轮廓线)的控制点,通过轮廓的弹性形变,与图像的局部特征匹配达到调和,即某种能量函数的最小化,具备计算效率高和便于实时应用的优点。然而,该方法存在对初始位置较为敏感和容易陷入局部极值等问题。

尽管基于传统技术的医学图像语义分割方法已经有多年的发展历史,但这类方法仅

仅使用人工选择的底层图像特征和先验信息进行分割,无法准确地表示器官以及病灶区域信息,同时易受到噪音的干扰,导致分割效果较差。随着语义分割技术的不断发展,更多具有挑战性和复杂性的医学图像分割任务也在不断提出,传统的语义分割算法在这些新任务上的分割性能已逐渐被基于深度学习的方法超越。

1.2.2 基于深度学习的语义分割

随着深度学习技术和的发展和计算能力的增强,卷积神经网络(Convolutional Neural Network, CNN)等深度学习模型在医学图像语义分割领域的应用也越来越广泛。通过对输入图像进行多层次特征提取和处理,深度学习模型可以有效地提取底层特征和高层次语义特征,并将它们结合起来以生成更准确的分割结果。相比于传统的基于手工设置特征的方法,基于深度学习的语义分割方法具有更高的准确性和泛化性,因为它们能够自动学习适合于不同任务的特征表示,从而有效地解决了医学图像分割中的许多问题。

2015年,Long等人^[14]提出了基于卷积神经网络的全卷积网络模型(Fully Convolutional Networks, FCN),用于语义分割,该方法将传统网络中用于分类的全连接层用卷积层代替,并使用转置卷积层进行上采样,以输出精确的预测结果。基于“编码器-解码器”结构的FCN显著推进了医学图像分割领域的发展。Avi等人^[15]利用了FCN模型实现了对肝脏病变区域的分割,实验结果证明在精确率和召回率上FCN比传统医学图像语义分割方法要优越。Holger等人^[16]将FCN引入到3D医学图像分割的领域中,并提出了包含两个级联FCN的3D-FCN网络,其中第一个FCN用于提取感兴趣区域,第二个FCN负责输出预测结果,并在多标签分割比赛中上取得了第一名。尽管全卷积网络取得了显著的精度提升,但在利用池化层扩大卷积层感受野的过程中,底层特征的局部细节信息被丢失,导致上采样的输出结果过于粗糙。因此,Ronneberger等人^[17]在FCN的基础上提出了U-Net模型,使其更适用于医学图像分割任务。U-Net由完全对称的编码器和解码器组成,形状类似于“U”型,在解码过程中通过将底层特征和高级语义特征通过跳跃连接的方式按通道拼接。这样浅层特征的细节信息传递给了高层语义特征,弥补了上采样过程缺少的空间信息,从而改善了最终的分割结果。在U-Net的基础上,Ahmed^[18]提出了应用于三维医学图像分割的3D-UNet。与U-Net相比,3D-UNet只采用了三次下采样操作,增加了上采样和下采样的通道数以突破性能瓶颈,并在每个卷积层后添加了U-Net没有的批正则化层。在2018年MICCAI脑肿瘤分割挑战赛(BRATS)^[19]中,Ahmed的团队使用3D U-Net,仅做了少量的改动,就取得了该挑战赛第二名的成绩。为了突出特定局部区域的显著特征,Schlemper等人^[20]在软注意力机制的基础上提出了Attention U-Net,利用注意力模块来调整编码器的输出特征。然而,由于卷积运算的固有局部性,U-Net在明确建模远程依赖关系方面通常存在局限性。2021年Chen等人^[21]提出了一种关注局部特征和全局上下文关系的模型TransUNet。该模型将语义特征切分成块,利用自然语言处理中的Transformer结构^[22]建立块之间的全局依赖关系,

并利用卷积神经网络补充块内的局部空间信息。在多器官分割数据集上的实验结果表明,与 Attention U-Net 相比, TransUNet 具有更高的分割精度。

以上的神经网络模型均需要带有大量带标注的医学图像数据进行训练才能达到高的精度,并且待模型训练完成后,这些模型也很难对在训练集类别之外的新类别图像进行分割。由于医学图像数据集高昂的制作成本和获取成本,为不同任务制作数据集也不切实际。因此,基于小样本学习的语义分割任务被研究人员所提出,旨在解决模型在数据有限场景下的泛化能力低的问题。

1.2.3 基于小样本学习的语义分割

小样本学习 (Few-shot Learning, FSL) 是解决上述问题的主流解决方法。小样本学习采用元学习的方式,在易获得的监督数据集上构造一批利用极小样本学习的任务,训练模型学习如何解决实现该类任务,使得模型迁移到新数据集上时仍能在小样本场景下取得较好效果。

小样本分割是小样本学习在图像分割领域的推广。学者们在自然图像上提出了许多小样本语义分割模型并取得了良好的效果^[23, 24]。现有的主流方法是建立一个双分支的网络结构,由支撑集所在的分支提供指导特征信息,在两个分支之间建立交互模块,实现对查询集的有效分割。按照 Chen 等人^[25]的总结,现有的小样本语义分割模型可分为基于参数的模型和基于原型结构的模型。

(1) 基于参数的方法

基于参数的方法通常采用卷积网络层作为特征之间的度量工具,通过在训练集上进行学习,让卷积层学习到一个恰当的参数。这类方法的语义分割模型可分为三个步骤:首先利用特征编码器对查询图像和支撑图像进行编码获得特征图,其次利用特征比较模块将查询图片中的目标特征“增强”,最后利用特征解码器解码“增强”后的比较结果,最终得到预测结果。Shaban 等人^[26]提出的 OSLSM 模型奠定了小样本语义分割模型的双分支架构,其中支撑分支用于生成强化权重,查询分支在提取查询图像的特征之后,与支持分支生成的强化权重进行对应点,从而乘得到最终的分割结果。Zhang 等人^[27]在 OSLSM 的基础上提出了与类别无关的 CANet 模型,该模型由稠密特征比较模块和迭代优化模块组成。CANet 通过多级特征比较模块增强分支之间的特征交互,通过迭代更新模块来进行改善优化每个模块的预测结果,从而达到最佳解码效果。不同于上述模型, Liu 等人^[28]提出了一种基于交叉参考的 CRNet 模型,该模型不仅可以对查询图像进行预测,还可以对支撑图像进行预测。不同于传统双分支模型中支撑图像单方面引导查询图像分割,在 CRNet 中支撑和查询图像互相引导分割,通过交叉参考机制,更好地找出两张图片共同出现的对象。

(2) 基于原型的方法

基于原型的方法是一种利用原型网络来进行训练的方法。在这种方法中,每个类别

被表示为一个高维向量，也被称为原型或类别中心点。通过使用深度神经网络将图像映射成向量，并对同一类别的样本进行均值计算，得到该类别的原型。在不断训练的过程中，同一类别的样本向量距离会更加接近，不同类别样本的向量距离会更加远离。基于原型网络的小样本分割模型可分为三个步骤：首先利用特征编码器对查询图像和支撑图像进行编码获得特征图，其次利用掩膜平均池化计算支撑图像前景和背景的原型，最后利用度量函数（欧氏距离，余弦相似度等）计算每个像素与原型的距离，从而完成分割。Wang 等人^[29]提出一种原型对齐的模型 PANet。该模型在前向传播得到查询图片的预测图后，将其作为查询图像的伪标签，交换查询图像和支撑图像的位置，再进行一次前向传播得到支撑图像的预测结果，计算两个过程的损失值。在原有任务的基础上，通过交换支撑图像和查询图像的位置生成新的任务，这便是原型对齐的过程，增强了单个原型的表达能力。由于全局的类别原型在生成过程会损失许多局部特征信息和空间信息，因此部分工作提出生成多个原型的方法来增强单个原型的表达能力。Li 等人^[30]提出了一种生成多个局部原型的 ASGNet 模型，该方法首先利用传统语义分割算法 SLIC 生成多个感兴趣区域，进而得到多个局部原型，然后利用余弦相似度计算这些局部原型与查询特征元素之间的相似性生成概率图，最后将概率图与原始特征拼接提供引导信息，经过分类器获得最终的分割结果。

目前，医学图像领域中只有少量关于小样本学习的应用。Roy 等人^[31]提出了首个医学图像小样本语义分割网络模型 SE-Net，属于基于参数的方法。模型使用“挤压-激励”模块对支撑特征之间通道依赖性进行建模，并将该信息传递给查询图像所在的分支，增强了支撑集与查询集之间的特征交互。Chen 等人^[32]在论文中提出了一种新颖的医学图像自监督框架 SSL-ALPNet。该方法通过在未标注的数据集上生成基于超像素的伪标签来进行模型的自监督训练。同时，作者在原型网络中插入了局部原型池化模块，解决了医学图像分割中前景和背景类别不平衡的问题。Tang 等人^[33]提出的 RP-Net 目前是医学图像小样本分割领域中分割精度最高的模型，该模型提出了上下文关系编码模块（CRE）来建模前景和背景特征的关系，利用 CRE 和原型网络进行多次迭代，完善分割结果。

尽管小样本语义分割模型在自然图像领域上取得了巨大成就，但该技术运用在医学图像领域上尚处于起步阶段，究其原因，在于上述方法在解码过程中，忽视了分割目标在查询集上的边界分布信息，即没有利用到分割目标具有空间拓扑结构的先验知识，导致最终分割结果可能出现空洞，从而降低分割性能。而且，医学图像的背景空间占比通常很大而前景空间占比较小，导致模型在学习类别的特征表示时会丢失掉大量的局部信息，这降低了模型对于新类别的泛化能力。此外，同一器官的不同切片的形状和大小差异很大，这导致医学图像中的查询集和支撑集上的分割目标存在空间不一致性。

1.3 本文主要研究内容

本文以多模态医学图像为研究对象，以对器官进行分割识别为研究目标，研究任务为在小样本场景下的医学图像分割问题，具体研究内容包括：

1. 医学图像背景空间占比通常很大而前景空间占比较小，导致模型不能有效地提取支撑图像和查询图像的关联特征，降低了模型对于识别新的器官类别的泛化能力。本文针对该问题构建了基于计算特征相似度的先验掩码生成模块，通过计算查询特征和支撑特征之间的余弦相似度来生成提供前景先验信息的先验掩码，使得模型能够更好的对查询集上的分割目标进行识别。

2. 目前已有的医学小样本图像分割方法，忽略了查询集分割图像的边界信息的重要性，没有充分利用查询集分割目标具有空间拓扑结构这一知识。本文针对该问题构建了活动轮廓优化模块，该模块利用查询集边界特征信息以及先验掩码信息，通过对器官边界进行建立轮廓，有效地保留了分割目标的空间拓扑结构，对轮廓完善优化并获得器官目标的最终分割结果。本文在先验掩码生成模块和活动轮廓优化模块的基础上，提出了基于先验信息的小样本语义分割模型，并在两种不同模态的医学图像数据集上进行了相关实验。与目前已有的医学图像小样本语义分割模型相比，基于先验信息的模型取得了更好的效果。

3. 本文针对查询集和支撑集上分割目标存在空间不一致性问题，提出了基于多分辨率特征融合的小样本语义分割模型 **MFA-SnakeNet** 模型。该模型将基于先验信息的小样本语义分割模型与特殊设计的多分辨率特征融合模块相结合，通过水平路径和垂直路径两种特征丰富方式，减少了两个集合分割目标的语义特征差异，解决了查询集的空间特征信息与支撑集的空间不一致问题，提高了查询集特征的表达能力。**MFA-SnakeNet** 模型同样在两种不同模态的医学图像数据集上进行了相关实验，并与基于先验信息的小样本语义分割模型以及其余 4 种已有方法进行了对比。实验表明，**MFA-SnakeNet** 取得更好的实验结果。

1.4 本文章节安排

本文总共包含五大部分内容，具体的章节内容安排如下：

第一章，绪论部分。从研究背景以及研究意义的角度，阐述了医学影像数据对于智慧医疗体系建立的重要性，医学图像语义分割的基本知识以及其在计算机辅助诊断中的重要地位。同时，阐述了深度学习的医学图像分割方法面临的瓶颈以及小样本学习技术的迫切需要和实际意义。接下来，以国内外研究现状和语义分割的发展趋势为方向，介绍了小样本语义分割的发展进程。最后，概述了本文研究所要解决的问题、思路，以及各个部分的主要内容和章节脉络。

第二章，相关技术原理部分。首先，概述了神经元模型及卷积神经网络的相关知识

和技术原理，简要介绍了本文所涉及的卷积神经网络结构，包括 VGG、ResNet 等。其次，对小样本学习的概念进行了简要介绍，并提供了一些示例。接着，介绍了活动轮廓算法的核心思想，以及循环卷积的基本原理，为后续的研究提供理论基础。最后，阐述了多分辨率特征融合的背景，并介绍了两种多分辨率特征融合方法：PPM 模块和 ASPP 模块。

第三章，基于先验信息的小样本语义分割模型部分。在引言内容首先分析了现有的小样本语义分割方法存在的局限，并针对这些问题提出了本文的解决思路，设计了基于先验信息的小样本语义分割模型。本章详细介绍了该模型的三个模块：特征编码器模块、先验掩码生成模块、活动轮廓优化模块的设计思路，以及整个模型的网络结构。同时，介绍了本研究使用的两种医学图像数据集 ABD-30 和 CHAOST-MRI，并重点讲解了实验输入数据的预处理过程。此外，简要介绍了评价分割性能的指标 Dice 系数。为验证本文所设计的基于先验信息的小样本语义分割模型的有效性，进行了多组实验，同时与其他四种基准模型进行了实验结果的对比，以及衡量本文各个模块的有效性。

第四章，基于多分辨率特征融合的小样本语义分割模型部分。首先分析了第三章提出的基于先验信息的小样本语义分割模型存在的缺陷，即基于单一特征学习，以及查询集和支撑集的分割目标存在空间不一致性问题。因此，本章设计了一种基于多分辨率特征融合的小样本语义分割模型 MFA-SnakeNet，该模型由第三章提出的基于先验信息的小样本语义分割模型的基础上融合了多分辨率特征融合模块得到。在该章节中，将 MFA-SnakeNet 与第三章提出的基于先验信息的小样本语义分割模型以及其他基准模型进行了比较，并使用第三章提出的 Dice 系数来衡量模型的分割性能。

第五章，总结与展望部分。本章总结了本文中提出的两种基于小样本学习的医学图像分割模型的效能，并对当前小样本学习任务的研究热点进行了思考和分析，提出了本研究的优化方向，并展望了未来的研究发展方向。

2 相关技术原理

深度学习的本质是由多个层次组成的神经网络，本节主要介绍神经元模型的形式化描述，神经网络模型以及卷积神经网络的原理和特点。

2.1 神经网络概述

2.1.1 神经元模型及神经网络

神经网络是一种计算模型，它模仿生物神经网络的结构和功能。生物神经网络由许多神经元相互连接而成。这些神经元能够传递复杂的电信号，其中神经元的树突接收来自其他神经元的输入信号，并对信号进行处理，然后通过轴突向其他神经元输出信号。

受到生物神经元的启发，McCulloch 和 Pitts^[34] 提出了神经元的形式化数学描述和网络结构方法，并提出了神经网络的数学模型，称为 MP 模型。该模型描述了神经元的输入输出关系，并证明了单个神经元可以实现逻辑功能。其结构如图2.1所示




图 2.1 MP 神经元模型

在该模型中，神经元接受从其他神经元发送过来的输入信号 $x_1, x_2, \dots, x_n$ ，每个输入都有一个相关的权值，该权值是根据该输入对当前神经元的贡献程度来确定的。将所有输入加权求和后，如果总和大于阈值 θ_i （也称偏置），则神经元处于兴奋状态，其输出经过激活函数 f 处理后得到输出结果 y_i 。反之，如果总和小于等于阈值 θ_i ，则神经元处于抑制状态，不会输出结果。

F.Rosenblatt 在 MP 模型的基础上提出了感知机模型^[35]，用于二分类问题的线性判别模型。感知机由输入和输出两层神经元组成，其中输入层接收特征向量作为输入，输

出层输出 +1 和-1 两种状态，分别代表两个类别。感知机模型可以表示为式 (2.1)：

$$y = f(x) = \text{sign}(w \cdot x + b) \quad (2.1)$$

其中 w , x , b 分别为神经元的连接权重，输入，以及偏置， sign 为激活函数，当 $w \cdot x + b$ 大于零时输出 +1，小于零时输出-1。

然而，感知机模型仅对于线性问题具有分类问题，对于非线性问题无能为力。为了解决该问题，研究人员提出了具有多层神经元的网络结构多层感知机（Multilayer Perceptron）。由于该模型是一种信息单向传递的网络结构，所以又被称为前馈神经网络。多层感知机由输入层、隐藏层、输出层构成，接受输入信号的层为输入层，输出信号的层为输出层。隐藏层可有多个层次。每层有若干个神经元，且每一层都全连接到下一层。除了输入神经元，每个神经元都是一个带有非线性激活函数的神经元，这使得整个网络具备了非线性表达的功能。如图 2.2所示为包含多个隐藏层的感知机。




图 2.2 包含多个隐藏层的前馈神经网络

虽然增加网络的层数可以增强其表达能力，但随之增长网络参数的训练制约着多层神经网络的发展。因此，Werbos 在他的研究中提出了误差反向传播算法^[36]，为多层神经网络的实现和训练提供了一种切实有效的方法。误差反向传播算法主要包含计算误差和误差反向传播两个阶段。在计算误差阶段，网络接受输入信号，信号经过网络层前向传播后得到模型的输出结果，然后使用损失函数度量模型输出结果与真实标签之间的差异。在误差反向传播阶段，首先计算输出层的误差，然后利用链式法则直接计算直接传导层的误差，并将新误差传播到上一层。然后，利用新误差计算更前一层的误差，按照这种方式可以计算出所有层的误差。各层的神经元参数可以通过使用梯度更新法根据各层误差进行更新。

2.1.2 卷积神经网络

传统的全连接神经网络在处理大尺寸图像时，会将图像展开成高维向量，导致像素之间的空间信息丢失，也使得网络参数过多，难以训练。为了解决这个问题，研究人员开展了卷积神经网络的研究。卷积神经网络的设计灵感来自于动物视觉皮层中的一种特殊神经元，它能够对视觉输入空间的局部区域刺激产生兴奋。这种神经元被称为感受野，感受野以某种方式覆盖整个视觉输入空间。由于其对局部空间的敏感性，因此能够更好地挖掘存在于自然图像中的强烈的空间局部相关性。基于这个思想，LeCun 等人提出了第一个基于局部卷积计算的神经网络^[37]，名为 LeNet-5，用于手写数字识别和英文字母识别。

LeNet-5 虽具备卷积神经网络的所有模块，但其设计方式并不具备普适性。随后 VGG-16 和残差神经网络 ResNet 的出现，将卷积神经网络的发展带到了一个新的高度。VGG-16^[38] 的结构如图 2.3 所示，采用一系列大小为 3x3 的小尺寸卷积核和池化层构造深度卷积神经网络，并取得了优秀的效果。而 ResNet^[39] 则在 VGG 的基础上引入了残差连接，使得 ResNet 能够训练比 VGG 更深的网络结构。这两种卷积神经网络模型由于应用性极强而广受研究者欢迎，尤其是它们的网络结构设计方法，为后来构建深度神经网络提供了重要的指导方向




图 2.3 VGG16 卷积神经网络结构

如今，研究人员们普遍使用的卷积神经网络除了包含卷积层、池化层，ReLU 层、批正则化层还包含转置卷积层，下面本文将逐一进行介绍其原理及功能。

(1) 卷积层

卷积层由一系列二维矩阵的组成的滤波器组成，这些滤波器也被叫做卷积核。卷积操作是卷积核在输入矩阵上以一定步长进行滑动，通过卷积运算（卷积核与输入矩阵对应的区域进行点乘）获取局部特征。卷积核的个数代表了输出矩阵的通道数。当计算时，该层的每个卷积核都与整个输入矩阵进行卷积操作，最后相加得到单个滤波器卷积运算后的特征。将每个卷积核的卷积结果按通道拼接，就能得到最终该层卷积计算的特征。如图 2.4 所示，输入的矩阵图大小为 $N \times N \times 3$ ，该层卷积核的个数为 2，最终输出的矩阵图大小 $M \times M \times 2$ 。

输出矩阵的大小由卷积核大小 K （kernel size）、步长 S （Stride）、填充宽度 P




图 2.4 卷积过程示意图

（Padding）决定。卷积核大小指的是图中卷积核的矩阵大小。步长大小表示卷积核每次移动的像素距离，默认步长大小为 1。填充宽度表示卷积核对输入矩阵四周进行填零补充。输出矩阵的大小 O 可以通过公式（2.2）计算得到。

$$O = \frac{I - K + 2P}{S} + 1 \quad (2.2)$$

其中 I 表示输入矩阵的大小， P 表示在图像周围填充的像素数。

（2）池化层

池化层是卷积神经网络中一种常用组件，也被称为下采样层。通常，池化层被放置在连续的卷积层之间，用于压缩数据和参数量。以图像为例，如果输入是图像数据，则池化层能够有效地降低输入矩阵的大小，从而减少后续网络层的参数量，有效地避免网络出现过拟合现象。在池化层中，通常采用的是最大池化或平均池化的操作方式，即选取区域内的最大值或平均值作为该区域的输出值。最大池化通常可以有效地保留图像的边缘和纹理等细节信息，而平均池化则对图像的整体特征进行压缩。池化层的输出结果通常被作为下一层的输入，或者被用于输出预测结果。




图 2.5 最大池化操作过程示意图

池化层在卷积神经网络中具有两个主要作用：首先是保持特征的不变性，这种不变性类似于平移、旋转、尺度不变性等。在图像特征的池化过程中，丢弃的信息不包含重要的信息，保留的是能够表达图像语义的重要特征。其次是实现图像特征的降维。池化层通过池化操作，保留输入矩阵的主要特征，同时减少了后续网络层的参数和计算量，防止了过拟合的发生，并提高了模型的泛化能力。

(3) ReLU 层

ReLU 层是一种激活函数层，其作用是在卷积神经网络中增强模型的非线性特性。激活函数将神经元的输出转换为非线性激活信号，从而使得神经网络能够学习复杂的非线性函数。卷积层中的 ReLU 激活函数通过将小于 0 的输入映射为 0，将大于 0 的输入保留不变。这样做的目的是为了在输出中去除无关紧要的特征区域，从而降低噪声的影响。由于 ReLU 函数的导数在输入为 0 时为 0，因此具有稀疏性，使得一些神经元被强制关闭，可以强制关闭一些神经元，从而减少网络中的参数数量。这些性质都有助于提高模型的泛化性能和训练速度。




图 2.6 ReLU 激活函数及其导数

卷积神经网络中常见的非线性函数层包括 Sigmoid、Tanh、ReLU、Leaky ReLU、ELU 和 GeLU 等。本文将介绍其中常用的 ReLU 函数。如图所示，ReLU 函数在输入信号小于 0 时输出为 0，在输入信号大于 0 时输出等于输入。ReLU 函数的优点在于其收敛速度快，由于其在正值区域的梯度为常数，可以缓解训练中的梯度问题。相比于 Sigmoid、tanh 等激活函数，ReLU 函数只需要一个阈值就可以获得激活值，不涉及成本更高的指数运算，从而具有更低的时间和空间复杂度。然而，ReLU 函数的缺点在于其输出不以 0 为中心，在负值区域没有梯度，因此当输入信号小于 0 时，神经元会保持非激活状态，且在反向传播过程中梯度会消失。这样权重无法得到更新，网络无法学习。

(4) 批归一化层

随着神经网络训练的进行，除了输入层之外的每一层输入数据分布都在不断变化。这个问题的根源在于网络反向传播更新参数后，前面网络层神经元参数发生了变化，导致后面网络层输入数据分布发生了改变。以第二层输入为例，它由第一层神经元的参数和输入数据计算得到，由于第一层数据的参数在网络训练过程中不断变化，因此必然会影响到后面每一层的输入数据分布。随着网络层数的增加，这种内部数据分布偏移现象会变得越来越明显。因此，在训练过程中，需要确保每个神经元的输入特征分布保持一致。批归一化层的引入就是为了解决这个问题。

批归一化层是一种常见的神经网络层，用于解决神经网络训练过程中的内部协变量偏移问题，其通常设置在非线性激活函数之前。给定一个包含 M 个样本的小批量样本集合，第 l 层神经元的净输入 $z^{(1,l)}, \dots, z^{(M,l)}$ 的均值和方差可通过公式 (2.3) 以及公式 (2.4) 计算得到^[40]：

$$\mu_B = \frac{1}{M} \sum_{m=1}^M z^{(m,l)} \quad (2.3)$$

$$\sigma_B^2 = \frac{1}{M} \sum_{m=1}^M (z^{(m,l)} - \mu_B) \odot (z^{(m,l)} - \mu_B) \quad (2.4)$$

如式 (2.5) 所示，对神经网络的净输入 $z^{(l)}$ 的标准归一化后，其分布会接近于正态分布。但是，标准归一化后的数据仍然会受到缩放和平移的影响。因此，为了使得归一化不对网络的表示能力造成负面影响，可以通过添加缩放和平移参数来改变数据的取值范围，从而提高网络的表征能力。具体地，批归一化层中引入了两个可学习的参数 γ 和 β ，其中 γ 用于缩放标准化后的数据， β 用于平移标准化后的数据。这样，缩放和平移参数可以调整标准归一化后的数据的取值范围，使其适合于后续的非线性变换，同时也可以提高网络的表征能力。

$$\hat{z}^{(l)} = \frac{z^{(l)} - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} \odot \gamma + \beta \quad (2.5)$$

(5) 转置卷积层

在卷积神经网络中，将低分辨率的特征转换为高分辨率的操作称为上采样。在图像处理中常见的一些上采样操作有最近邻差值，双线性插值等插值方法，这些方法就像是人工特征工程一样，并没有给神经网络学习的余地，神经网络不能自己学习如何更好地进行插值，这个显然是不够理想的。如果想要网络可以学习到最好地上采样的方法，可采用转置卷积 (Transposed Convolution)。这个方法不会使用预先定义的插值方法，它具有可以学习的参数，通常运用在语义分割的解码器中将编码器提取的特征恢复为原先的尺寸。

输出矩阵的大小由转置卷积核大小 K (kernel size)、步长 S (stride)、填充宽度 P (padding) 决定。转置卷积的运算步骤如下：第一步，在输入特征图元素间填充 $s-1$ 行、列 0 元素；第二步，在输入特征图四周填充 $k-p-1$ 行 0 元素；第三步，将卷积核上下、




图 2.7 转置卷积操作过程图

左右翻转；第四步，输入特征图与卷积核做正常卷积运算。设输入矩阵的大小为 I ，输出矩阵的大小 O 可通过公式 (2.6) 计算得到。

$$m = (n - 1)s - 2p + k \quad (2.6)$$

2.2 小样本学习

作为具有高智能的生物，人类拥有出色的学习能力，能够通过有限的样本迅速掌握新物体的特征。例如，儿童仅需在家中浏览含有“老虎”和“长颈鹿”图片的卡片，就能在动物园轻松识别出这些动物。这种迅速学习的能力激发了研究人员的兴趣，期望机器学习模型在掌握大量一定类别数据后，面对新类别时仅需少量样本即可快速学习。这正是小样本学习旨在解决的问题。

在机器学习领域，小样本学习具有重要意义和挑战性。与人类智能相比，机器学习算法需要大量监督样本来保证泛化能力，而人类却能通过极少的示例轻松建立对新事物的认知。小样本学习可以看作是监督学习领域中元学习的应用。元学习，即学会如何学习 (Learning to learn, L2L)，是机器学习领域的一项前沿研究方向，旨在让模型自主学习。元学习的目标是希望模型学会一种学习能力，这种学习能力能启发模型任务中学习到包含本质规律的知识，也就是所谓的元知识。在小样本学习场景中，元学习通常在众多的先验任务中学习元知识，并借助在先验任务上学到的元知识指导模型在最新任务（即小样本任务）中更快地学习，实现模型泛化。小样本学习包含元训练阶段和元测试阶段。在元训练阶段中，小样本学模型将数据集划分为不同的元任务，以便学习类别变化时的泛化能力。在元测试阶段，小样本学习模型面对全新的类别时，无需要修改已有的模型即可完成给定任务。

在小样本学习的正式描述中，训练集和测试集各自包含许多不同的类别数据，同时训练集和测试集所含的数据类别不相同。每个类别里有众多样本。在训练过程，从训练集中随机选取 N 个类别，每个类别挑选 K 个样本，共计 $N \times K$ 个数据，作为模型的支撑

集 (support set) 输入; 然后从这 C 个类中剩下的数据中抽取一部分样本作为模型的预测对象, 称为查询集 (query set) 输入, 支撑集输入和查询集输入共同构成一个元任务。该过程要求模型从这 $N \times K$ 个数据中学会区分这 N 个类别, 这种学习任务被称为 N -way K -shot 任务。

在小样本学习的训练阶段, 模型会在训练数据集中不断采样, 以获取不同的元任务。这样做使得模型能学习到不同任务类别组合的共性, 例如提取查询集和支撑集的关键信息以及比较样本相似性等。通过这种学习机制, 模型不仅仅针对某一个具体任务进行训练, 而是学会了面对不同任务的学习能力。因此, 在元测试阶段, 即使模型遇到全新的未见过的元任务, 也能较好地完成任务。

为了便于直观理解小样本学习的流程, 图2.8中展示了一个自然图像上的 2-way 5-shot 任务示例, 每个元任务中包含了两种不同类别的数据。在元训练阶段中, 构建了一系列的元任务让模型学习如何根据支撑集预测查询集中样本标签; 而在元测试阶段中, 输入数据的格式与元训练阶段相同 (2-way 5-shot), 但会在全新的类别上构建支撑集和查询集。




图 2.8 2-way 5-shot 小样本学习模型示例

2.3 活动轮廓算法以及循环卷积

将分割目标的空间分布特性与图像特征进行有效融合正是 Snake 活动轮廓算法的长处。Snake 活动轮廓模型的基本思想是使用使用一些控制点构成的连续曲线来表达目标边缘, 通过模板自身的弹性形变与图像局部特征相匹配达到调和。具体来说, 该算法通过最小化某种能量函数的方式实现进行分割, 从而实现对图像的理解和识别^[41]。

Snakes 模型的设计旨在融合轮廓知识和底层图像特征, 并解决它们之间的矛盾。由

于各种图像特征，如亮度、梯度、角点、纹理和光流，都是局部的，因此图像中某一点的特征只取决于其周围邻域，而与物体的形状无关，这是基于像素的语义分割方法的核心思想。然而，人们对物体的认识主要来自于其轮廓形状。**Snakes** 模型通过使用一组控制点构成连续的曲线来表示目标轮廓，定义能量函数，并将图像分割问题转化为求解能量函数的极值问题，从而有效地融合了上层知识和底层图像特征。控制点的曲线变形受到能量函数的影响，因此具有最小能量的闭合曲线就是目标轮廓。能量函数的内部力和图像力分别代表了 **Snakes** 模型中的轮廓知识和底层特征的融合。

Kass 等人提出的 **Snake** 模型的数学过程如下^[13]：

首先，假设图像中包含一个感兴趣的物体，并且该物体的边界是平滑且连续的曲线，目标是找到这条曲线。**Snake** 模型使用一条连续的曲线来表示目标物体的边界，该曲线可以通过一些控制点来确定。这些控制点可以在感兴趣区域附近手动选择，或者通过自动检测算法自动确定。曲线上的控制点表示为 $v(s) = [x(s), y(s)]$, $s \in [0, 1]$ ，其中 s 是以傅里叶变换形式描述边界的自变量， $x(s)$ 和 $y(s)$ 分别表示每个控制点在图像中的坐标位置。

接下来，**Snake** 模型定义一个能量函数，如式 (2.7) 所示，该函数由三部分组成：弹性能量、弯曲能量和外部能量。这三个能量部分的加权和构成了 **Snake** 模型的总能量，最小化总能量可以得到最佳曲线。

$$E_{total} = \int \left(\alpha \left| \frac{\partial}{\partial s} \vec{v} \right|^2 + \beta \left| \frac{\partial^2}{\partial s^2} \vec{v} \right|^2 + E_{ext}(\vec{v}(s)) \right) ds \quad (2.7)$$

公式 (2.7) 中的第一项是弹性能量，其表示轮廓线上的相邻控制点之间的距离，即轮廓线的张力，用来约束轮廓线的形状不发生剧烈变化，通过一阶导数的模来描述，弹性能量可以使得曲线具有一定的张力和柔性，避免曲线过于僵硬或松弛；第二项是弯曲能量，用来约束轮廓线的曲率，避免轮廓线出现锐角，通过二阶导数的模来描述；第三项是外部能量，即从图像中提取的信息，用于推动轮廓线向目标轮廓靠拢，在图像分割中通常取控制点所在位置的梯度值，如公式 (2.8) 所示。外部能量可以使得曲线向着图像中目标轮廓的高梯度位置移动，从而更好地适应目标形状的变化。

$$E_{ext}(\vec{v}(s)) = P(\vec{v}(s)) = -|\nabla I(v)|^2 \quad (2.8)$$

为了最小化总能量，**Snake** 模型使用一种迭代方法，每次迭代中，曲线上的每个点都会发生变化，从而改变曲线的形状。这些变化是通过内部能量和外部能量的相互作用来实现的。在每次迭代后，曲线将更接近目标轮廓，直到达到最优解。如图 2.9 所示，其中蓝色部分点代表设定的初始轮廓，不同颜色的点代表初始轮廓的变化过程，图中的轮廓经过了 300 次迭代过程。

2020 年，Peng 等人在上述传统 **Snake** 算法的基础上提出了基于神经网络的活动轮廓模型 **DeepSnake**^[42]，该模型通过目标检测获得物体的初始轮廓，并利用深度学习的




图 2.9 Snake 模型迭代过程示例

方式从图像特征中学习控制点坐标的偏移，替代了能量函数，使初始轮廓逐渐优化为分割目标的边界。DeepSnake 提出的循环卷积更符合轮廓控制点的周期性性质，与通常的卷积方法不同，循环卷积不仅可以编码每个控制点的特征，还能编码临近控制点间的关系，具有更强的表达能力，更好地利用了轮廓的控制点间的信息。

Peng 提出的循环卷积的定义如下：

对于轮廓中的 N 个控制点 $\{x_i | i = 1, \dots, N\}$ ，计算控制点在特征图上的特征 $f(x_i)$ ，对控制点的特征的循环卷积过程表示为：

$$(f_N * k)_a = \sum_{b=-r}^r (f_N)_{a+b} k_b \quad (2.9)$$

公式 (2.9) 中 $k : [-r, r] \rightarrow \mathbb{R}^D$ 表示卷积核函数，操作符 $*$ 表示标准卷积操作， r 表示卷积核的大小。图 2.10 是循环卷积的计算过程，位于图下方的深蓝色椭圆节点表示轮廓上控制点的输入特征，与输入特征紧邻的四个黄色节点表示循环卷积核，上方的深绿色节点表示控制点经循环卷积输出的新特征，虚线表示输入特征与循环卷积核做内积。

2.4 多分辨率特征融合

当人们在进行深度卷积神经网络的语义分割任务时，往往会面临一个难题：随着卷积神经网络的深度的增加，输入图像前景和背景的边界特征会逐渐消失。传统的语义分割模型采用直接相连的方式在“编码”层和“解码”层之间进行特征图和信息的传递。因此在“编码”阶段，特征图上的各个像素位置均以相同的感受野获取输入图像的信息。但是在不同的图像中，获取尺寸、体积大小不同的物体特征信息所需要感受野往往是不一样的。例如，识别飞机和汽车需要相对较大的感受野以获取足够的语义信息，而对于




图 2.10 循环卷积过程计算示意图

人和其他小物体，则需要较小的感受野^[43]。完全一致的单一感受野难以适应真实场景下各类物体大小不同的分割问题，因此，为了解决这个问题，多分辨率特征融合技术被广泛地应用于语义分割任务中。

多尺度特征融合的主要目的是为了在编码阶段获取不同尺度下的特征并进行融合，以使编码器能够获取不同感受野大小的特征。多尺度特征融合通常采用图像金字塔和特征金字塔模式两种方式。图像金字塔技术能够生成具有不同分辨率的多个图像。这些图像的大小和清晰度逐渐降低，但是它们都包含着原始图像的特征信息。金字塔的形状类似于塔，从底部到顶部逐渐缩小，因此也称为图像塔。图像金字塔可以捕获图像的多个尺度特征，在解决不同分辨率的图像处理问题中更为常用。然而，图像金字塔的并行网络结构会导致模型内存消耗较大。

特征金字塔模型通过利用不同分辨率大小的特征图进行融合来解决图像金字塔内存消耗过大的问题，以获取不同感受野大小的特征。带有跳跃连接的 U 型网络是一种常用的利用不同层特征图信息的结构。在语义分割领域，特征金字塔模型被广泛采用，包括金字塔池化模型（Pyramid Pooling Module, PPM）和空洞卷积金字塔池化模块（Atrous Spatial Pyramid Pooling, ASPP）等。

金字塔池化模型最早由 Zhao 等人^[44]在 PSPNet 中提出，如图 2.11 所示，其“编码器”首先通过四个池化分支对输入特征图进行不同尺度的池化操作，从而得到不同分辨率的特征图。这些特征图通过 1×1 卷积和上采样恢复到相同的尺度，并通过堆叠的方式进行特征融合，生成最终的特征表示。PPM 模块在语义分割领域得到广泛应用，具有良好的性能和效果。

如图 2.12 所示，ASPP 模块^[45]采用和金字塔模块类似的方式，它利用四种不同膨胀




图 2.11 金字塔池化模型网络结构

率的空洞卷积对特征图进行卷积操作，以获取不同感受野大小的特征图，然后将它们按通道拼接。空洞卷积是一种增加感受野的方法，提出的目的是为了解决传统全卷积网络中利用解决传统卷积在感受野大小和计算复杂度之间的平衡问题。传统卷积在计算时只考虑局部邻域的特征，因此随着卷积层数的增加，感受野会不断扩大，但计算量也会呈指数级增长，导致模型的训练和推理效率变得低下。而空洞卷积通过在卷积核中引入一定的空洞（或称为膨胀率），在不增加计算复杂度的情况下，能够增加卷积层的感受野，从而提升模型的性能。此外，空洞卷积还可以应用于处理稀疏特征图的场景，如语义分割中处理高分辨率图像时，空洞卷积能够有效地减少特征图的尺寸，使得模型更加轻量化和高效。因此，空洞卷积技术在计算机视觉领域得到了广泛的应用和研究。




图 2.12 空洞金字塔池化模型网络结构

2.5 本章小结

本章介绍了本文所涉及到的理论知识和技术。首先，介绍了神经元模型的数学原理及其结构，并介绍了其他以神经元模型为基础的经典模型。接着，以卷积神经网络为起点，介绍了常用的卷积神经网络模型 VGG16 和 ResNet，并引出了卷积神经网络的主要组成部分，包括卷积层、池化层、激活函数层、批归一化层和转置卷积层等理论知识。

针对小样本学习，介绍了其定义和基本原理，以及在图像分类任务中的小样本学习任务描述。

介绍了活动轮廓算法的基本原理，并解释了为什么活动轮廓算法适用于医学图像语义分割的原因。对活动轮廓的算法流程进行了数学化描述，并简单介绍了基于活动轮廓算法的研究。此外，还介绍了目前基于深度学习的活动轮廓算法中较常用的循环卷积，包括其定义和优势。

本章介绍了本文所涉及到的理论知识和技术。首先，介绍了神经元模型的数学原理及其结构，以及其他以神经元模型为基础的经典模型。接着，从卷积神经网络为起点，介绍了常用的卷积神经网络模型 VGG16 和 ResNet，并引出了卷积神经网络的主要组成部分，包括卷积层、池化层、激活函数层、批归一化层和转置卷积层等理论知识。

针对小样本学习，介绍了其定义和基本原理，以及在图像分类任务中的小样本学习任务描述。

进一步介绍了活动轮廓算法的基本原理，并解释了为什么活动轮廓算法适用于医学图像语义分割的原因。对活动轮廓的算法流程进行了数学化描述，并简单介绍了基于活动轮廓算法的研究。此外，还介绍了基于深度学习的活动轮廓算法中较常用的循环卷积，包括其定义和优势。

最后，简要介绍了多分辨率特征融合的基本概念，并阐述了常用的多分辨率融合的定义和分类。重点介绍了多分辨率特征融合的原理，并介绍了目前较常使用的多分辨率特征融合模块，如 PPM 和 ASPP 等。

3 基于先验信息的小样本语义分割模型

3.1 引言

现有的医学图像小样本语义分割方法采用卷积神经网络作为特征提取器，提取查询图像和支撑图像的特征，并利用原型网络的思路，将支撑图像特征中的每个前景类别转化为类别原型。在预测分割时，通过比较查询特征中的像素与类别原型的距离，完成分类并得到最终预测分割结果。但是这些方法忽视了分割目标在查询集上的边界分布信息，没有充分利用到查询集分割目标具有空间拓扑结构这一先验知识。同时，由于医学图像的背景空间占比通常很大，前景空间占比较小，同一器官的不同切片的形状和结构差异很大^[32]，使得模型不能有效的提取支撑图像和查询图像的关联特征，从而导致模型对于新类的泛化性降低。

经过对现有方法进行分析后，结合现有的医学图像分割方法以及小样本学习技术，本章将提出一种基于先验信息的小样本分割模型。该模型由特征编码器、先验掩码生成和活动轮廓优化三个模块组成，分别对应小样本语义分割的三个步骤：提取支撑集和查询集图像特征，提取支撑集包含的标签特征与查询集未知类的关系，解码查询集特征获得分割结果。特征编码器模块使用卷积神经网络提取查询集图像和支撑集图像的特征信息。先验掩码生成模块无需参数训练，通过计算查询集和支撑集特征之间的相似度生成先验掩码，为模型确认查询集上的分割目标提供包含前景感兴趣区域的先验信息，降低了分割目标在查询集上的泛化损失。活动轮廓优化模块利用查询集边界特征信息，通过对器官边界进行建立轮廓，保留了分割目标的空间拓扑结构，对轮廓完善优化并获得未知类的最终分割结果。

本章对 CT 图像和 MRI 图像两种不同模态的数据进行了预处理，转化成统一的输入数据格式，并划分好训练集和测试集。在特征提取模块中，本文设计了一种类似 U-Net 的卷积网络结构，可以融合浅语义特征和深层语义特征，能够学习到分割器官的精确细节。在先验掩码生成模块中，本章充分利用了卷积网络提取的高层次语义特征，生成包含分割目标的先验信息的掩码，从而有效的提取查询集图像与支撑集图像的关联特征丰富信息，增强了模型面对新类的泛化能力。此外，该先验信息掩码中在活动轮廓优化模块中，我们借鉴了 Snake 活动轮廓算法的核心思想，通过对器官边界进行建立轮廓，保留了分割目标的空间拓扑结构，利用循环卷积建立轮廓优化单元对初始轮廓完善优化，经过多次迭代获得未知类的最终分割结果。

为检验本章设计的基于先验信息的小样本分割模型的有效性，本章进行了相关实验，将该模型与章节 1.2.3 中介绍的四种基准模型进行对比实验。使用文献^[31-33]提出的医学图像小样本分割指标来评估模型的分割效果。实验结果表明，基于先验信息的小

样本医学分割模型的在 CT 图像数据集 ABD-30 上的分割结果达到 74.26, 在 MRI 图像数据集 CHAOST-MRI 上的分割结果达到 79.99, 高于其他的对比基准模型。此外, 对先验掩码模块进行了可视化, 表明了先验信息的有效性。同时也对轮廓迭代过程进行了可视化, 表明了本文提出的活动轮廓优化模块的有效性。最后, 探讨了不同的特征编码器对分割性能的影响。

3.2 医学图像小样本语义分割任务描述

医学图像小样本语义分割采用元学习的方式, 在易获得的监督数据集上构造一批利用极小样本学习的任务, 训练模型学习如何解决实现该类任务, 使得模型迁移到新数据集上时仍能在小样本场景下取得较好效果。小样本语义分割既可以解决现有的深度学习模型需要大量人工标注数据训练的局限, 也可以使模型学会快速学习的能力。

按照小样本语义分割任务的定义, 设数据集 D 共包含 $C_1, C_2, \dots, C_n$ 个类别。我们需要根据类别划分为训练集和测试集, 其中 $C_{train} = C_1, C_2, \dots, C_{k-1}$, $C_{test} = C_k, C_{k+1}, \dots, C_n$ 。训练集和测试集的类别没有交集, 即 $C_{train} \cap C_{test} = \emptyset$ 。训练数据集 D_{train} 由 C_{train} 所包含的样本构成, 测试数据集 D_{test} 由 C_{test} 所包含的样本构成。小样本语义分割模型在训练数据集 D_{train} 上进行训练, 在测试数据集 D_{test} 上进行测试。

传统的深度学习方法通过 epoch 机制来训练网络, 即在一个 epoch 中将整个训练数据集遍历一遍。而小样本语义分割方法采取 Vinyals^[46] 提出的 Episode 机制来训练网络模型。

在 Episode 机制中, 小样本语义分割模型以单元 (Episode) 作为训练单位, 即在训练阶段和测试阶段输入到网络模型的数据都是以多个不同的数据单元组成的。每个单元由一个支撑集和一个查询集组成, 表示为 $D_{train} = \{S_i, Q_i\}_{i=1}^{N_{train}}$ 和 $D_{test} = \{S_i, Q_i\}_{i=1}^{N_{test}}$, N_{train} 和 N_{test} 表示训练集和测试集样本的数量。一个单元会具象化为一个 N-way K-shot 分割任务, 即随机从数据集 C_{train} 中抽取 N 个类别, 从每个类别中随机抽取 K 个图像, 抽取出的 $N \times K$ 张图像组成支撑集, 在再从这 N 个类别中抽取若干张图片作为查询集。以 1-way 1-shot 为例, 随机从数据集 C_{train} 中抽取 1 个类别 c , 建立支撑集 S 和查询集 Q 。支撑集 S 由 1 张支撑集图像 I 和其对对应真实标签 M 组成, 表示为 $S = \{(I_1, M_1)\}$ 。查询集中只有一张查询图像及其真实标签, 表示为 $Q = \{I_Q, M_Q\}$ 。查询集支持集对 $\{Q, S\}$ 组成训练测试的批处理数据, 且查询图像的标签 M_Q 对于模型是不可见的。在训练阶段, 模型从支撑集中学习各个类别的知识, 然后将知识应用到查询集 I_Q 上输出对于 I_Q 的预测, 利用查询图像标签 M_Q 计算损失并反向传播。在测试阶段, 对于每个测试单元, 在查询集上对模型进行评估。

3.3 基于先验信息的小样本语义分割模型网络结构

医学图像数据首先经过数据预处理模块，此模块本文放到章节 3.4.1 介绍。经过预处理后得到形如 (I_S, M_S, I_Q) 的单元数据，其中 I_S 为支撑集图像， M_S 为支撑集图像对应的标签数据， I_Q 为对应的查询集图像，作为网络模型的输入。

该网络模型如图 3.1 所示。




图 3.1 基于先验信息的小样本分割模型网络结构

该网络结构由三部分组成：特征编码器模块，先验掩码生成模块和活动轮廓优化模块。输入数据首先经过特征编码器模块，该模块由卷积神经网络组成，主要用来提取输入查询集图像和支撑集图像的语义特征，具体结构在 3.3.1 章节详细描述。其次，先验掩码生成模块利用提取的图像特征生成查询集特征和支撑集特征之间的相关性掩码，具体过程在 3.3.2 章节详细描述。最后活动轮廓优化模块接受查询集图像和支撑集图像的语义特征、先验掩码作为输入，得到 I_Q 的预测分割结果，具体结构在 3.3.3 章节详细描

述。

3.3.1 特征编码器模块

如图 3.2 所示, 本章设计的特征编码器模块类似于 U-Net 结构, 但在原始 U-Net 的基础上, 在每层卷积层后增加了批归一化层。整个特征提取器分为收缩路径和扩张路径。收缩路径遵循卷积网络的典型结构, 交替进行卷积和池化运算, 并逐步减少特征图的分辨率, 同时增加每层特征图的数量。扩张路径中的每一层都由特征映射的上采样和卷积组成。收缩路径扩张路径之间通过跳跃连接结构连接, 将高层次级别的语义信息和低层次语义信息结合起来。




图 3.2 基于 U-Net 的特征编码器模块网络结构

特征编码器网络总共 13 个卷积层, 8 个卷积块。每个卷积层的卷积核大小为 3×3 , 步长为 1。每个卷积层之后紧跟着一个批归一化层 (BN) 和非线性激活函数层 (ReLU)。每个卷积层都对输入数据进行填充操作, 保证卷积操作后特征图的分辨率不会发生变化。特征编码器接受经过预处理后的支撑集图像数据 $I_S \in \mathbb{R}^{h \times w \times 3}$ 和查询集图像数据 $I_Q \in \mathbb{R}^{h \times w \times 3}$ 输入。输入数据首先经过第一个卷积块, 然后经过下采样输出支撑特征 $I_S \in \mathbb{R}^{\frac{h}{2} \times \frac{w}{2} \times 64}$ 和查询特征 $I_Q \in \mathbb{R}^{\frac{h}{2} \times \frac{w}{2} \times 64}$ 。整个收缩路径包含 5 个卷积块和四次下采样操作。每经过一个卷积模块, 特征的通道数翻倍一次。在经过整个收缩路径后, 最终特征图的通道数会变为 512。为减少计算开销和节省显存, 本章提出的特征编码器并未模仿 U-Net 将特征上采样到和输入数据的分辨率相同, 去掉了原 U-Net 结构中最后两个上采样模块。整个扩张路径包含 3 个卷积块, 3 次上采样操作, 通过转置卷积层扩大特征分

分辨率，转置卷积层后紧跟着一个批归一化层（BN）和和非线性激活函数层（ReLU）。在扩张路径上，每经过一个卷积模块，特征的通道数减少一半。在经过整个扩展路径后，支撑特征 X_S 和查询特征 X_Q 的大小变为 $\frac{h}{4} \times \frac{w}{4} \times 256$ 。

卷积层的参数设置具体如表 3.1：

表 3.1 特征编码器网络层部分参数

网络路径	网络层	卷积/池化核 大小	激活函数	池化/转置卷 积	步长
收缩路径	卷积层	3×3	ReLU	-	S=1
	池化层	2×2	-	最大池化	S=2
扩张路径	卷积层	3×3	ReLU	-	S=1
	池化层	3×3	ReLU	转置卷积	S=2

3.3.2 先验掩码生成模块

本模块通过计算特征之间的余弦相似度来有效提取支撑集和查询集之间的相关特征，从而捕捉查询集图像和支撑集图像之间的关系，为模型确认查询集上的分割目标提供了先验信息，增强了模型面对新类的泛化能力，并为下文活动轮廓优化模块提供初始轮廓。该模块接受输入查询特征 X_Q 、支撑特征 X_S ，输出对应的相关性掩码 Y_Q 。本模块设计思路如下：如果 X_Q 中的像素对应在 Y_Q 的值较高，那么我们可以认为该像素与支撑特征 X_S 上至少一个像素有很高的相关性，因此该像素可能是查询集图像需要分割出的未知类。在模型的实现过程中，本文使支撑特征 X_S 上的背景特征像素都为零，使得查询集上的像素不会与背景特征像素产生相关系数，确保 X_Q 只会与 X_S 的前景特征相关联。

Y_Q 的生成过程如式 (3.1)： X_Q 和 X_S 分别表示输入的支撑集图像和查询集图像经过特征编码器 f_θ 生成的特征， $X_Q, X_S \in \mathbb{R}^{h' \times w' \times c'}$ ， M_S 表示支撑集图像标签数据。首先计算 $X_S = X_S \odot M_S$ ， $\odot$ 的含义为 Hadamard 乘积，表示矩阵的对应元素的点乘，Hadamard 乘积的目的是将支撑集图像背景特征置为零。其次计算对于每个像素特征 $x_q \in X_Q$ 与所有像素特征 $x_s \in X_S$ 的余弦相似度 $\cos(x_q, x_s)$ ：

$$\cos(x_q, x_s) = \frac{x_q^T x_s}{\|x_q\| \cdot \|x_s\|} \quad q, s \in \{1, 2, \dots, hw\} \quad (3.1)$$

对于每个像素特征 $x_q \in X_Q$ ，取该向量与支撑集所有向量计算的余弦相似度最大值为：

$$c_q = \max_{s \in \{1, 2, \dots, hw\}} (\cos(x_q, x_s)) \quad (3.2)$$

$$C_Q = [c_1, c_2, \dots, c_{hw} \in \mathbb{R}^{hw \times 1}] \quad (3.3)$$

$Y_Q \in \mathbb{R}^{h \times w \times 1}$ 由 $C_Q \in \mathbb{R}^{h \times w \times 1}$ 更改维度得到, 最后对 Y_Q 进行最大最小正则化, 得到最终的 Y_Q , 其中 ϵ 是一个常量, 在后续的实验环节中, 令其为 $1e-7$ 。最大最小正则化过程如公式 (3.4) 所示:

$$Y_Q = \frac{Y_Q - \min(Y_Q)}{\max(Y_Q) - \min(Y_Q) + \epsilon} \quad (3.4)$$

3.3.3 活动轮廓优化模块

文献^[47]提出基于像素层级的网络模型并未考虑到医学图像分割目标具有空间拓扑结构这一先验知识, 也没有充分利用查询集和支撑集上的分割目标边界信息, 从而导致最终分割的结果可能出现空洞。因此本章节提出了基于循环卷积的活动轮廓优化模块, 该模块从活动轮廓算法的核心思想出发, 有效的利用了医学图像分割的先验知识。本模块将不同层级的信息融合、降维, 再建立包含查询集分割目标边界信息的初始轮廓, 并输入到优化单元中获得预测分割轮廓, 该轮廓经过多次迭代优化获得最终分割结果。




图 3.3 支撑特征、查询特征以及先验掩码特征信息融合过程

首先, 为了充分利用来自支撑集的引导信息, 本模块对查询特征 X_Q 、支撑特征 X_S 以及先验掩码 Y_Q 采用了如图 3.3 所示的融合方式。在融合之前, 使用掩膜平均池化来提取支撑图像的前景类别的高维向量, 该向量包含了该类别的高级语义特征信息。在融合过程中, 本模块将该向量和先验掩码 Y_Q 扩展到与查询特征 X_Q 相同的空间分辨率大小 ($\frac{H}{4} \times \frac{W}{4}$), 并与查询特征 X_Q 按通道进行级联 (Concatenation), 并经过一个卷积核大小

为 1×1 的卷积层 F ，输出融合的新特征 $X_{Q,new}$ ，该过程可表示为公式 (3.5)：

$$X_{Q,new} = F_{1 \times 1}(X_Q \oplus X_S \oplus Y_Q) \quad (3.5)$$

最后输出的新特征 $X_{Q,new}$ 通道数为 256。

其次，由于活动轮廓算法需要给定初始轮廓，而先验掩码指示了查询集分割目标的位置信息，因此本文利用先验掩码 Y_Q 生成包含查询集分割目标边界信息的初始轮廓。初始轮廓的生成过程为：定义一个阈值 ϕ ，当先验掩码 Y_Q 中的像素值大于阈值 ϕ 时，可以认为该像素属于未知类。取出 Y_Q 中大于阈值 ϕ 的最上、最下、最左、最右四个像素，并记录这四个点为极值点。以这四个极值点构建出八边形，在八边形上采样 N 个点获得初始轮廓坐标集合 $x_{vertex} \in \mathbb{N}^{N \times 2}$ 。在实验中， ϕ 设置为 0.75，即两个特征之间相关性大于 0.75 的像素点属于分割目标。检索出 Y_Q 中大于阈值 ϕ 像素后，需要去除异常点以保持初始轮廓的鲁棒性。这些异常点与目标类的像素点群距离较远，因此本文使用 KNN 算法去除掉异常点，以保证生成的初始轮廓区域不会很大。




图 3.4 动态轮廓优化单元网络结构

由于轮廓是一组有序的、首尾相连的控制点，其拓扑结构可以看作是一种环形结构。因此，为保证控制点的空间拓扑结构不被破坏，本文在活动轮廓优化单元的实现过程中引入了循环卷积（章节 2.3 中已介绍其原理），并以其为基础构建了用于提取空间特征的循环卷积层，该卷积层接受轮廓的特征 $X \in \mathbb{R}^{N \times C}$ ，其中 N 为控制点的数量， C 表示每个特征点上的特征通道数，输出轮廓新的特征 $X \in \mathbb{R}^{N \times C}$ 。在本文的实现过程中，为保证内存开销和分割效果的平衡，本文采样的控制点个数为 128。

最后，将初始轮廓 x_{vertex} 以及新特征 $X_{Q,new}$ 输入到轮廓优化单元，经过多次迭代优化，最终变形至分割结果。本文基于循环卷积设计的活动轮廓优化单元的网络结构如图 3.4 所示，包括主干（Backbone），融合（Fusion），预测（Prediction）三个部分。初始轮廓 x_{vertex} 依次经过主干、融合、预测三个模块，输出控制点的预测偏移量 $Y_{offset} \in \mathbb{R}^{N \times 2}$ ，并根据此偏移量对轮廓中的控制点坐标进行更新，从而生成新的轮廓。通过堆叠多个活动轮廓优化单元迭代优化得到最终的预测分割 $\hat{M}_S$ 。主干部分由 8 个“CirConv-BN-ReLU”层组成，其中 CirConv 表示使用循环卷积。循环卷积层后，紧跟着一个批正则化层，和一个非线性激活函数层 ReLU，并使用残差连接，使用残差连接的目的便于网络参数的优化，增强梯度传播。融合部分拼接了来自主干部分的各级特征，保留了传播过程中的低级语义特征和高级语义特征，并将这些特征向前传播到卷积层和池化层。预测部分由三个 1×1 卷积层组成，输出网络对坐标偏移量的预测结果。




图 3.5 活动轮廓优化流程示意图

整个活动轮廓优化模块的优化过程如图 3.5 所示。首先，模块利用先验掩码 Y_Q 生成一个初始轮廓（流程图（a）中蓝色线条表示的八边形，黄色点代表生成初始轮廓的种子点），该初始轮廓包含 128 个点。然后，将初始轮廓和融合后的新查询特征 $X_{Q,new}$ 输

入到以循环卷积为核心的轮廓优化单元，该单元输出轮廓上每个控制点的坐标偏移量。在流程图中。这表现为（b）中原始的控制点（黄色）坐标经过坐标偏移量修正后变为新的轮廓上的控制点（红色）。在经过多次迭代过程后，得到如流程图中（c）所示的最终轮廓，并填充该轮廓获得最终分割结果。

3.3.4 损失函数

为了训练基于先验信息的小样本语义分割模型，本文采用文献^[48]提出的 L1 光滑损失。与 L2 损失相比，L1 光滑损失对离群点和异常值不敏感，梯度变化较小，易于训练。公式（3.6）中 $\tilde{x}_i$ 表示模型最终输出的预测控制点坐标， x_i^{gt} 表示标签上的真实控制点坐标， N 表示轮廓上控制点的个数，最后模型的总 loss 为所有迭代过程的 loss 和。

$$L_{iter} = \sum_{i=1}^N L_1(\tilde{x}_i - x_i^{gt}) \quad (3.6)$$

$$L_1 = \begin{cases} 0.5x^2, & \text{if } |x| < 1 \\ |x| - 0.5, & \text{else} \end{cases} \quad (3.7)$$

$$Loss = \sum L_{iter} \quad (3.8)$$

3.4 实验与分析

3.4.1 数据集以及预处理

本文在 ABD-30 数据集和 CHAOS-MRI 数据集上开展了相关的实验，分析评估本章提出的模型分割性能。ABD-30 数据集是国际医学图像计算和计算机辅助干预协会（MICCAI）2015 年腹部 CT 多器官分割挑战赛的公开数据集，包含 30 张结直肠癌和腹腔癌患者的腹部 3D CT 扫描图像。这些 CT 扫描图像的体素大小（Volume Size）、视野大小（Field of View）、平面分辨率（In-plane Resolution）、层厚大小（Slice Thickness）各不相同。CHAOST-MRI 数据集是国际生物成像会议（ISBI）2019 年腹部 MRI 多器官分割挑战赛的公开数据集，包含了 20 张 3D T2-SPIR 的腹部 MRI 扫描图像。与 ABD-30 中 CT 扫描图像类似，这些 MRI 图像的扫描参数也有所差异。本章将分别介绍对两种不同模态数据的预处理方法。

CT 图像的预处理主要分为三个步骤：首先是对 CT 图像进行窗宽处理，窗宽是 CT 图像上所包含的 CT 值范围，旨在通过设置一个 CT 值窗口来突出分割器官的组织结构，减少其他组织的对比度和亮度。由于人体各组织结构不同，对 X 线吸收程度各异，在成像时会形成不同的 CT 值。通过设置合适的窗宽，能够提高器官组织结构细节的展示。本文参照了文献^[17]的处理方法，在读取原始图像数据后将 CT 值大于 275 的像素 CT 值置为 275，将 CT 值小于 -125 的像素 CT 值置为 275，得到处理后的新 CT 图像。其次是对 CT 图像进行剪裁和重采样，这一步的目的在于去掉 CT 图像中的无关区域以扩大感

兴趣区域的占比，并统一各模态数据的大小。在剪裁过程中，由于头尾两端的 30 张切片包含的腹部器官种类太少，将其舍弃掉，只保留 CT 图像的中间 75 张切片。由于不同由于 ABD-30 数据集和 CHAOST-MRI 数据集的医学图像切片空间分辨率不一致，因此为统一各模态数据的大小，在重采样过程中将 CT 图像的切片空间分辨率重采样到和 MRI 图像分辨率相同的 256×256 。同理，标签数据也进行相应的剪裁和重采样操作。最后将 CT 图像按通道切片并保存。为了使切片数据在输入到网络时为三通道格式，使每个切片的在通道维度上与自身进行组合，得到一张 $256 \times 256 \times 3$ 的图像，并与标签数据一起储存为 npz 格式。

MRI 图像的预处理主要分为三个步骤：首先是对 MRI 图像数据的转化。CHAOST-MRI 数据集的 MRI 图像的数据格式是标准的 DCIOM3.0 格式，无法利用 Python 的库文件读取，因此需要利用 dcm2niix 工具将 dcm 格式的数据转化为 nii 格式的数据。此外，标签数据的格式为 PNG 图像，需要将其转化为标准 nii 格式数据，并按照扫描编号进行保存。其次是对 MRI 图像进行剪裁和重采样。剪裁的目的是减少成像的主磁场中的不均匀性（偏共振）导致的图像伪影。本文参照了文献^[32]的处理办法，在读取转化的 nii 图像数据后将密度值最大的 0.5% 的体素舍弃掉。重采样的目的是统一不同扫描面之间的体素间距，以保证在输入分割网络时每个图像数据具有统一的分辨率大小。在处理过程中，本文令数据集中以的所有 MRI 图像数据以固定的同构分辨率为 [1.25, 1.25, 7.70] 重新采样。同理，标签数据也进行相应的剪裁和重采样操作。最后将 MRI 图像按通道切片并保存。为了使切片数据在输入到网络时为三通道格式，使每个切片的在通道维度上与自身进行组合，得到一张 $256 \times 256 \times 3$ 的图像，并与标签数据一起储存为 npz 格式。

在预处理完后，ABD-30 数据集共得到 2178 张 npz 形式的切片数据，CHAOST-MRI 共得到 558 张 npz 形式的切片数据，这两种数据集都包含脾、左肾、右肾、肝四种器官。本文在这四种器官类别上建立四个小样本语义分割任务，并采取 5 折交叉验证来评估模型的合理性。为方便与如果选择一个类作为未知类别的测试集，那么其余三个类作为已知类别的训练集。比如：在 ABD-30 数据集的脾分割任务中，使用脾作为测试的未知类，其余 3 个类别的作为训练集。小样本语义分割的四种任务构成如表 3.2 所示。

表 3.2 小样本语义分割任务训练集、测试集类别构成

小样本语义分割任务	训练集类别	测试集类别
脾	左肾、右肾、肝	脾
左肾	脾、右肾、肝	左肾
右肾	脾、左肾、肝	右肾
肝	脾、左肾、右肾	肝

3.4.2 实验环境

硬件环境: CPU: Intel(R) Xeon(R) CPU E5-2698 v4 @ 2.20GHz, 内存: 32GB, 显卡: Tesla V100 DGXS 32GB

软件环境: Linux Ubuntu 18.04 操作系统, Python 3.7, Pytorch 1.1.0, Cuda 9.0 框架开发环境。

3.4.3 对比模型设计

本文分别基于以下 4 个小样本语义分割模型以及传统的全监督模型进行实验对比, 由于部分模型原文作者并未开源, 因此基准模型的分割结果来自于原作者论文:

PANet^[29] 是基于原型语义对齐网络的模型, 使用残差神经网络 VGG16 来提取支撑集和查询集的图像特征, 并使用 ImageNet 数据集上的预训练权重来初始化网络参数。

SE-Net^[31] 第一个针对医学图像分割提出小样本分割模型。SE-Net 由分割分支和条件分支组成, 每个分支是一种类似于 U-Net 的编码器-解码器结构, 两个分支之间中间特征通过“挤压-激励”模块进行交互。

SSL-ALP^[32] 是以原型网络为基础, 使用自监督学习进行训练的小样本分割模型。使用残差神经网络 ResNet101 来提取支撑集和查询集的图像特征, 并使用 MS-COCO 数据集上的预训练权重来初始化网络参数。

RP-Net^[33] 目前是医学图像小样本分割领域中分割精度最好的一种模型。使用相关性模块来捕捉前景区域和背景区域的边界关系, 并设计了循环完善模块来迭代完善分割结果。

在 ABD-30 数据集上的全监督模型为腹部 CT 多器官分割挑战赛排行榜分割精度最高的 PaNN 网络^[49], 该模型假设腹部器官的大小分布近似于其经验分布, 并将该知识应用到分割过程中指导网络进行训练。在 CHAOST-MRI 数据集上的全监督模型为 nnU-Net 模型^[50], 该模型由多个类似 U-Net 的网络组成并设置了多个动态参数来匹配不同的分割任务。

3.4.4 实验超参数设置

本文使用特征编码器网络使用 ImageNet 数据集上预训练权重, 并冻结特征编码器网络的参数, 在反向传播时不进行更新, 其他参数使用随机初始化。在模型的训练过程中, 本文使用 Pytorch 框架建立的网络结构超参数如表所示:

为方便与目前现有的模型进行比较, 本文构建的医学图像小样本语义分割任务为 1-way 1-shot 任务, 表示在支撑集中只有一个样本, 查询集中的未知类只有一种。本文在训练过程中采取了 5 折交叉验证来评估模型的准确性 (5-fold cross validation), 具体实现过程如下: 由于数据集中包含来自 30 张腹部 3D CT 扫描图像, 以及 20 张腹部 MRI 扫描图像, 将这些扫描图像按病人的编号进行整理, 并平均划分为 5 个集合, 每个集合

表 3.3 超参数配置表

超参数	配置值
Optimizer	Adam
Epoch for training	100
Batchsize	8
Learning rate	1e-4 with decay
Regularization strategy	EarlyStopping
Contour iteration	3
threshold θ	0.75

包含的扫描图像数量相同。在实验过程中，选定一个集合作为测试集，其余四个集合作为训练集数据放入网络模型训练。每次选取不同的集合作为测试集，重复五次实验，并取这 5 次实验分割结果的平均值作为最终的结果。

3.4.5 评价指标

本文采用了文献^[31-33]中提出的衡量指标 Dice 系数评估模型的分割效果，Dice 系数是一种集合相似度度量指标，通常用以计算两个样本的相似度。在医学图像分割中，分割结果越好，Dice 系数越高。给定预测的结果 m 以及真实标签 g ，Dice 系数的定义如下：

$$DSC(m, g) = \frac{2|m \cap g|}{|m| + |g|} \quad (3.9)$$

3.4.6 实验结果

表 3.4 基于先验信息的小样本分割模型在 ABD-30 数据集上的实验结果

基准模型	测试集各器官分割结果 (%)				
	脾	左肾	右肾	肝	平均
SE-Net	0.23	32.83	14.34	0.27	11.91
PANet	25.59	32.34	17.37	38.42	29.42
SSL-ALPNet	60.25	63.34	54.82	73.65	63.02
RP-Net	69.85	70.48	70.00	79.62	72.48
基于先验信息的小样本分割模型	62.85±1.52	77.75±2.43	73.89±1.34	82.49±0.21	74.26
全监督模型	96.8	95.3	92.0	97.4	95.4

本章展示了基于先验信息的小样本语义分割模型在 ABD-30 数据集以及 CHAOST-MRI 数据集上的实验结果。实验结果使用章节 3.4.5 中的提出的评价指标评估各个模型的分割结果。为了公平比较，各类小样本分割基准模型设计中均无利用到类似于本章的

先验知识。

本文提出的基于先验信息的小样本语义分割模型与 PANet、SE-Net、SSL-ALPNet 以及 RPNNet 等方法在 ABD-30 数据集上的分割结果如表3.4所示。可以看到，所有的小样本分割模型的 Dice 系数都要比全监督模型的结果要差，这是由于全监督模型训练集和测试集包含的类别相同，但全监督模型面对新的未知类时泛化能力较差。

本文提出的基于先验信息的小样本语义分割模型与 PANet 相比，各器官平均的分割结果高出 PANet 44.84 个百分点。与 SE-Net 相比，各器官的平均分割结果高出 SE-Net 62.35 个百分点。与使用自监督学习进行训练的 SSL-ALPNet 相比，各器官的平均分割结果高出 SSL-ALPNet 11.24 个百分点。从平均结果上来看，本文提出的小样本语义分割模型相比各类基线模型在各类分割任务上表现都较好，侧面证明了分割目标的边界信息以及医学图像分割先验知识语义分割中的重要性。基于先验信息的小样本语义分割模型相比目前分割精度最高的 RP-Net 在左肾、右肾、肝种器官上的分割结果都比 RP-Net 要好，左肾的分割结果高出 RP-Net 7.27 个百分点，右肾的分割结果高出 3.89 个百分点，肝的分割结果高于 2.87 个百分点。然而，在从实验结果中，我们发现脾脏的分割结果低于 RP-Net 7 个百分点，导致此结果的出现的原因可能有两点：第一，不同个体的脾脏在 CT 图像中的形态和实质密度差异较大，因此相较于其他三个器官，脾脏的分割难度更高。第二，本章采取了掩膜平均池化来提取支撑集上的类别有效特征，导致对于特征池化后查询集特征对于支撑集上的目标大小、形状信息不敏感，而脾脏部位在 CT 图像的形状较小，类别样本较少，因此解码结果可能出现误差。

表 3.5 基于先验信息的小样本分割模型在 CHAOST-MRI 数据集上的实验结果

基准模型	测试集各器官分割结果 (%)				
	脾	左肾	右肾	肝	平均
SE-Net	51.80	62.11	61.32	27.43	50.66
PANet	50.90	53.45	38.64	42.26	46.33
SSL-ALPNet	67.02	73.63	78.39	73.05	73.02
RP-Net	76.35	81.40	85.78	73.51	79.26
基于先验信息的小样本分割模型	72.62±3.65	84.75±1.98	86.82±0.82	79.77±0.56	79.99
全监督模型	-	-	-	-	94.6

为了进一步验证的基于先验信息的小样本语义分割模型在不同模态的医学图像数据的分割效果，本文还在 CHAOST-MRI 数据集的核磁共振图像数据上与各基准模型进行了对比实验。实验结果如表3.5所示。从平均结果来看，基于先验信息的小样本语义分割模型取得相比其他基准模型取得了最高的分割精度，达到 79.99。进一步证明基于先验信息的小样本语义分割模型在处理不同模态的医学图像数据时仍然能取得良好效果。具体来看各个任务，本文提出的模型相比较于以自监督学习进行训练的小样本分割

基准模型 SSL-ALPNet，在四种小样本分割任务中的表现均比 SSL-ALPNet 高。其中脾脏的分割结果比 SSL-ALPNet 高出 5.60 个百分点，左肾的分割结果比 SSL-ALPNet 高出 11.12 个百分点，右肾的分割结果比 SSL-ALPNet 高出 8.43 个百分点，肝脏的分割结果比 SSL-ALPNet 高出 6.72 个百分点。从 CHAOST-MRI 数据集的实验结果来看，本文提出的基于先验信息的小样本语义分割模型不仅在以 CT 图像上表现较好，在 MRI 图像上表现依旧稳定。

为了验证先验掩码模块的有效性，本文对先验掩码生成模块的输出结果的进行可视化。如图 3.6 所示，每一行都代表一个训练中的子任务，第一列是查询集中的查询图像 I_Q ，第二列是先验掩码 Y_Q 的灰度图表示，相关性越高的像素在灰度图里的亮度越高，第三列是查询图像的真实标签 M_Q 。从图中可以看到对比第二列和第三列图像，先验掩码 Y_Q 中相对明亮的区域与真实标签大致重合，表明先验掩码能够为查询集提供未知类的形状大小和位置信息，增强了模型对于未知类的泛化性。同时，在活动轮廓优化模块，该结果还为初始轮廓生成的合理性提供了支持。




图 3.6 先验掩码生成结果展示

为了研究不同特征编码器的对模型分割效果的影响，本文还在 ABD-30 数据集上使用了另外两种不同的特征编码器 VGG-16 和 ResNe-t18。为确保公平比较，我们保留了 VGG16 和 ResNet18 卷积神经网络中的前两个卷积块，使所有特征编码器输出的特征信息保持在输入原始图像空间分辨率的 1/4。在实验过程中，仅改变特征编码器，其余网络

结构保持不变。如表3.6所示，VGG-16 在三种特征编码器的表现结果最差，比 ResNet 低了 9.58 个百分点。本文设计的以 U-Net 为基础的特征编码器表现结果要优于 ResNet-18，高出 2.34 个百分点，这主要是因为 U-Net 的跳跃连接能很好的融合低级特征和高级特征，增强了输出特征信息的表达能力。此外，实验数据显示，本文提出的基于先验信息的小样本语义分割模型可以与不同的特征编码器兼容。在具体应用时，可以根据不同的任务选择合适的特征编码器效果从而表现出更好的效果。

表 3.6 特征编码器对模型分割性能的影响

特征编码器	测试集各器官分割结果（%）				
	脾	左肾	右肾	肝	平均
VGG16	55.23	71.79	54.08	68.26	62.34
ResNet	57.47	75.38	69.03	80.31	71.92
基于 U-Net 的编码器	62.85	77.75	73.89	82.49	74.26

本文还研究了轮廓优化单元中轮廓迭代次数对分割性能的影响。在实验过程中，本文选择 ABD-30 数据集上的脾脏分割任务作为研究对象。结果如表3.7所示。可以看到当迭代次数为 3 时，基于先验信息的小样本分割模型表现最好，达到 62.85。同时也注意到当迭代次数增加时，模型的分割性能并不会显著改善，导致的原因可能是随着迭代次数增多，网络的参数的增多使得模型过拟合。

表 3.7 迭代次数对分割性能的影响

	iter 1	iter 2	iter 3	iter 4	iter 5
脾	61.76	62.65	62.85	62.34	61.98

图3.7展示了在 ABD-30 数据集上，基于先验信息的小样本语义分割模型如何在迭代过程中优化初始轮廓。每一行对应一个测试时的元任务，每行的第一张图片展示了查询集中的查询图像，红色部分表示需要分割出的目标区域；第二张图片展示了支撑集中的支撑图像，红色的部分表示支撑图像的对应标签；第三、四、五幅图片是活动轮廓优化模块每个活动轮廓优化单元的输出结果。观察每一行的三、四、五张图片，并与第一张图片的目标区域进行对比，可以看到活动轮廓优化单元能逐渐改善初始轮廓，使其向真实的边界收敛，从而证明了本文提出的活动轮廓优化模块的有效性。此外，由于少量切片中部分器官存在其他组织，使得分割目标的轮廓中类别不单一，本文提出的方法暂时不能处理该类情形。

图3.8展示了基于先验信息的小样本语义分割模型在 CHAOST-MRI 数据集上如何在迭代过程中优化初始轮廓。从结果中可以看出，该模型在 MRI 图像上同样具有适用性。




图 3.7 动态轮廓单元在 ABD-30 数据集上的迭代过程结果展示

每当输入轮廓经过活动轮廓优化单元后，都能得到改善，使得最终轮廓逐渐靠近器官的真实边界。




图 3.8 动态轮廓单元在 CHAOST-MRI 数据集上的迭代过程结果展示

3.5 本章小结

本章从现有的小样本医学图像语义分割模型存在的问题出发,从有效利用查询集边界分布信息和增强模型对于未知类的泛化性两个方面入手,提出了基于先验信息的小样本分割模型。本文提出的模型,在以 CT 图像为主的 ABD-30 数据集和以 MRI 图像为主的 CHAOST-MRI 数据集上与多个模型进行了对比实验。实验过程中,本文使用小样本医学图像分割的公共评价指标 Dice 系数来评估基于先验信息的小样本分割模型以及其他基准模型。

从实验结果来看,基于先验信息的小样本分割模型在两个数据集上都取得了较好的表现,在大部分的分割任务如:左肾、右肾、肝上都有较好的表现。相较于其他对比模型,该模型在医学图像小样本分割指标 Dice 系数上取得了较好的结果,这也侧面证明了本文提出的以特别设计的计算先验信息为基础,通过活动轮廓迭代优化的小样本医学图像分割模型具备胜任此类任务的能力。相较于目前已有的解决方案,基于先验信息的小样本分割模型通过以下三个模块提高了预测分割结果的精度:第一,设计类似 U-Net 的特征编码器增强了输出图像特征信息的表达能力;第二,设计无需参数训练的先验掩码生成模块,增强了模型对于未知类的泛化能力,并为下个模块提供初始论口,第三,设计以循环卷积为基础的活动轮廓优化模块,迭代优化输出结果,充分利用了医学图像的分割任务以及查询集分割目标的边界信息。

虽然基于先验信息的小样本分割模型取得了较好的分割效果,但是从实验结果可以看到模型面对对于脾脏这种分割目标较小,形状大小多变的分割任务仍有不足。本文认为,由于医学图像器官的待分割目标区域会由于切片的位置不同存在尺度变换大、形态大小不固定,器官边界信息不突出,以及目标区域与周围组织强度不均匀等因素,导致在元任务中支撑集和查询集的语义特征差异较大。基于上述问题,本文在本章设计的基于先验信息的小样本分割模型的基础上,探求一种多分辨率语义特征融合的方法。

4 基于多分辨率特征融合的小样本语义分割模型

4.1 引言

第三章提出的基于先验信息的小样本分割模型在执行分割任务时,采用生成包含先验信息的先验掩码模块来增强模型的表达能力,提取更有效的边界特征信息,进而输入到轮廓优化模块中输出预测结果,取得了较好的效果。然而该模型存在以下局限:在具体场景中,查询图像上的分割区域可能比支撑图像上的分割区域较大或者较小,导致查询集的空间特征信息与支撑集的空间特征信息存在不一致的问题。

一种解决方法是添加 PPM 模块或者是 ASPP 模块来为查询集特征提供不同分辨率的空间特征信息,但这些方法存在以下局限:(1) 这些模块只提供了合并不同分辨率的查询特征,却忽视了包含丰富信息的支撑特征以及先验掩码信息(2) 这些模块没有考虑到不同分辨率特征之间的层级关系,仅进行了简单的聚合。

针对上述问题,本文在第三章的基础上提出了一种基于多分辨率特征融合的小样本语义分割模型 MFA-SnakeNet。MFA-SnakeNet 在每个分辨率层级内整合查询图像特征、支撑图像的特征和包含先验信息的先验掩码多种信息,从而减少了两个集合分割目标的语义特征差异,解决了查询集与支撑集的空间特征不一致的问题。该模型采用自顶向下的方式,从精细特征中提取关键信息去与丰富粗糙特征。与常见的多分辨率融合方法如 PPM, ASPP 相比,本文提出的方法在每个分辨率层级上都进行了具体的细化处理,并考虑不同分辨率特征之间的层级关系。

MFA-SnakeNet 模型中,本文主要设计并构建了四个模块,分别是:基于第三章内容设计的特征提取模块、先验掩码生成模块、活动轮廓优化模块,以及本章提出的多分辨率特征融合模块。特征提取模块、先验掩码生成模块、活动轮廓优化模块在第三章中已经证明了有效性,因此本文选择将它们与多分辨率特征融合模块进行组合以获得最佳效果。多分辨率特征融合模块采用水平路径和垂直路径两种方式进行了特征的整合。在水平路径中,本文在同一分辨率层级中将查询图像特征和支撑图像特征以及先验掩码按通道级联,并通过卷积网络融合成新的特征,能够有效的解决。在垂直路径中,本文采取了自顶向下的路径,使不同的分辨率层级之间的特征依据层级路径进行交互,并通过卷积网络融合成新的特征。最后本文将每个层级交互后的新特征进行信息聚合得到总特征输入到第三章提出的活动轮廓优化模块获得预测结果。

为验证本文提出的 MFA-SnakeNet 模型的有效性,将 MFA-SnakeNet 模型和第三章提出的基于先验信息的小样本分割模型以及其他的基准模型进行了比较实验,并使用章节 3.4.5 的评价指标来评估本文提出的 MFA-SnakeNet 的分割效果。实验结果表明基于多分辨率特征融合的小样本语义分割模型相较于第三章提出的先验信息的小样

本分割模型在分割指标上有了进一步的提高，取得了良好的实验效果。

4.2 基于多分辨率特征融合的小样本语义分割模型网络结构




图 4.1 基于多分辨率特征融合的小样本语义分割模型网络结构

如图4.1所示，MFA-SnakeNet 模型主要由四部分网络构成：特征编码器模块，多分辨率特征融合模块，先验掩码生成模块，活动轮廓优化模块。

医学图像数据首先经过数据预处理，此模块和章节 3.4.1 的数据预处理步骤相同。经过预处理后得到形如 (I_S, M_S, I_Q) 的单元数据，其中 I_S 为支撑集图像， M_S 为支撑集图像对应的标数据， I_Q 为对应的查询集图像，作为基于多分辨率融合的小样本语义分

割模型网络模型的输入。

如图4.1所示，在步骤一阶段中，输入数据首先经过特征编码器模块，将预处理后的支撑图像和查询图像输入到特征编码器模块中，输出语义特征 X_Q ， X_S 。语义特征 X_Q ， X_S 后续将输入到多分辨率融合模块中以及先验掩码生成模块中。

如图4.1所示，在步骤二阶段中，先验掩码生成模块接受输入 X_Q ， X_S ，输出包含询集特征和支撑集特征之间的相关性的先验掩码 Y_Q ，其生成过程与章节 3.3.2 中所介绍的先验模块相同。然后，多分辨率特征融合模块接受上一步特征编码器输出的 X_Q ， X_S 以及先验掩码生成模块输出的 Y_Q 作为输入，输出融合多分辨率的特征信息的精炼查询特征。丰富过程如下：首先，该模块在每个分辨率的层级内将支撑特征和查询特征以及先验掩码按通道拼接，通过卷积神经网络将它们融合合并得到新特征；其次，是将不同的分辨率的合并特征按分辨率层级自顶向下的传递信息，让包含丰富几何细节信息的高分辨率特征丰富低分辨率的粗糙特征。最后，将每个分辨率层级的信息上采样到同一大小后进行聚合，获得新的查询特征 $X_{Q,new}$ 。

如图4.1所示。在步骤三阶段中，模型将新的查询特征 $X_{Q,new}$ ，以及先验掩码 Y_Q 输入到章节 3.3.3 提出的活动轮廓优化模块中，获得 I_Q 的预测分割结果。

4.3 多分辨率特征融合模块

目前，医学图像小样本语义分割模型通常采用卷积神经网络逐层提取查询图像和支撑图像的语义特征。在卷积神经网络的特征提取过程中，高层网络具有较大的感受野和较强的语义信息表征能力，但特征图分辨率较低，几何信息表征能力较弱（空间几何特征细节缺失）。这类特征图能捕捉到大尺度器官的语义信息，但对器官形状等精细语义信息不够敏感。相反，低层网络感受野较小，几何细节信息表征能力较强，分辨率较高，但语义信息表征能力较弱。这类特征图能捕捉到较小尺度器官的语义信息，并保留了器官形状等几何特征细节，但无法识别出大尺度的器官目标。鉴于样本集较小，查询集与支撑集源自同一器官的不同切片，形状、大小等空间信息存在较大差异。针对单一分辨率的特征学习，无法很好地解决这一局限。为解决这一问题，本文提出了一种多分辨率特征融合模块，以整合查询图像、支撑图像和先验信息，减少两个集合分割目标的语义特征差异，并自顶向下提取关键信息，从分辨率高的精细特征中提取关键信息去丰富分辨率低粗糙特征，并将不同分辨率特征进行聚合，有效地解决了查询集的空间特征信息与支撑集的空间不一致问题，提高了分割结果的准确率。

如图4.2所示，多分辨率特征融合模块接受查询特征 $X_Q \in \mathbb{R}^{h' \times w' \times c}$ ，支撑特征 $X_S \in \mathbb{R}^{1 \times 1 \times c}$ ，以及先验掩码 $Y_Q \in \mathbb{R}^{1 \times 1 \times c}$ 为输入。多分辨率特征融合模块的过程主要分为三个阶段：第一个阶段是多个来源的特征信息进行融合。在这个阶段中，模型将查询特征 X_Q 下采样到不同分辨率层级上，并在每个分辨率层级内将查询特征 X_Q 与支撑特征 X_S 、先验掩码 Y_Q 融合获得每个分辨率层级的融合特征。第二个阶段是将融合特征按分




图 4.2 多分辨率特征融合模块具体网络结构

分辨率层级自顶向下的与其他分辨率层级的特征进行交互，每个分辨率层级的融合特征会进行更新。第三个阶段是将所有分辨率层级的特征采样到同一分辨率中进行聚合获得融合所有分辨率的特征 $X_{Q,new}$ 。

(1) 第一个阶段的过程如图4.2所示。规定 $L = \{L^1, L^2, \dots, L^n\}$ 为平均池化函数输出的 n 个空间分辨率大小，并将这些分辨率大小按降序排列，即 $L^1 > L^2 > \dots > L^n$ 。输入的查询特征 $X_Q \in \mathbb{R}^{h' \times w' \times c}$ 首先经过自适应平均池化函数产生 n 个分辨率层级的子查询特征 $X_Q^{MFA} = [X_Q^1, X_Q^2, \dots, X_Q^n]$ ，这些子查询特征对应着上文的 n 个不同的空间分辨率大小： $X_Q^i \in \mathbb{R}^{L^i \times L^i \times c}$ 。同样的，将经过全局掩模平均池化处理后的支撑特征 $X_S \in \mathbb{R}^{1 \times 1 \times c}$ 同样扩展到这 n 个不同空间分辨率上，得到 n 个不同的支撑特征图 $X_S^{MFA} = [X_S^1, X_S^2, \dots, X_S^n]$ ，这些子支撑特征对应着上文的 n 个不同的空间分辨率大小： $X_S^i \in \mathbb{R}^{L^i \times L^i \times c}$ 。并将先验掩码 Y_Q 进行同样的扩展处理获得 $Y_Q^{MFA} = [Y_Q^1, Y_Q^2, \dots, Y_Q^n]$ ，其中 $Y_Q^i \in \mathbb{R}^{L^i \times L^i \times 1}$ 。

在每个分辨率层级内，本文将查询特征 X_Q^i 、支撑特征 X_S^i 以及先验掩码 Y_Q^i 在通道

维度上进行拼接，并将每个分辨率内拼接后的特征经过一个卷积核大小为 1×1 的卷积层，目的是将拼接的特征进行融合产生新的特征 $X_{Q,m}^i \in \mathbb{R}^{L^i \times L^i \times c}$ ，整个过程可表述为式 (4.1)：

$$X_{Q,m}^i = \mathcal{F}_{1 \times 1}(X_Q^i \oplus X_S^i \oplus Y_Q^i) \quad (4.1)$$

最终卷积层输出的融合特征通道维度为 256。

(2) 第二个阶段的过程如图4.2所示。Tian 等人^[51] 经过实验后认为，特征图在经过多次下采样之后，尺度较小的物体特征可能会在这个过程中消失。因此本文认为，采取一个按照分辨率大小层级自顶而下的信息传递路径，将包含丰富几何细节局部信息的高分辨率特征信息传递到语义信息表征能力强的低分辨率特征中，有助于增强查询特征的表达能力，从而改善模型的输出结果。

在图4.2中，展示了不同分辨率的特征自顶向下的交互路径。在获得各个分辨率的融合特征之后，模块 P 代表高分辨率的融合特征与低分辨率的融合特征之间的进行特征信息融合。这个过程可表述为式 (4.2)：

$$X_{Q,new}^i = \mathcal{P}(X_{Q,m}^{low}, X_{Q,m}^{high}) \quad (4.2)$$

其中 $X_{Q,m}^{low}$ 表示第 i 个分辨率层级的融合特征，在特征信息融合的过程中代表分辨率较小的特征，等待包含丰富特征信息的高分辨率融合特征 $X_{Q,m}^{high}$ 与其进行交互。在本文的实现过程中，本文使其与上一个分辨率层级的融合特征进行交互，即 $X_{Q,m}^{low} = X_{Q,m}^i$ ， $X_{Q,m}^{high} = X_{Q,m}^{i-1}$ ，其中 $B^{i-1} > B^i, i \geq 2$ 。

不同分辨率层级的之间特征融合模块 P 的具体网络结构如图4.3所示。该模块在接受输入 $X_{Q,m}^i$ 、 $X_{Q,m}^{i-1}$ 之后，首先将高分辨率层级的融合特征 $X_{Q,m}^{i-1}$ 下采样到与低分辨率特征 $X_{Q,m}^i$ 同样的空间大小。然后，将特征矩阵 $X_{Q,m}^i$ 、 $X_{Q,m}^{i-1}$ 在通道维度进行拼接并输入到卷积核大小为 1×1 的卷积层中。卷积层的作用是从高分辨率的特征 $X_{Q,m}^{i-1}$ 中提取出有效的空间细节信息并传递到当前分辨率的特征 $X_{Q,m}^i$ 中。在获得卷积层输出的特征后，将其输入到两个卷积核大小为 3×3 的卷积层，该卷积层的目的是进一步使不同分辨率层级的特征完成交互并输出最终特征。本文在两个卷积模块中设置了残差连接，一方面是利用残余连接切割了整个模块的特征映射关系，使得 P 模块只会学习到传递有效信息的参数，不会对输入特征进行更改，保证了当前分辨率特征 $X_{Q,m}^i$ 的完整性；另一方面，设置残余连接能简化学习过程，增强梯度的传播。对于处于分辨率层级顶部的特征 $X_{Q,m}^1$ ，在输入进 P 模块时，由于没有比其更高分辨率特征，因此在 P 模块中本文不将其与其他分辨率的特征进行拼接，只经过两个卷积层输出最终特征 $X_{Q,new}^1$ 。

(3) 第三个阶段的过程如图4.2所示。在输入数据经过第二个阶段后，生成 n 个包含融合不同分辨率层级的特征图 $X_{Q,new}^i, i \in \{1, 2, \dots, n\}$ 。本文将不同分辨率层级的特征图 $X_{Q,new}^i, i \in \{1, 2, \dots, n\}$ 采取双线性插值，上采样到与原始查询特征 $X_Q \in \mathbb{R}^{h' \times w' \times c}$ 同样的大小，并将这些特征图按通道进行拼接输入到一个卷积核大小为 1×1 的卷积层




图 4.3 不同分辨率层级之间的特征融合模块 P 的具体网络结构

实现各个分辨率特征信息的聚合，这个过程可表述为式（4.3）：

$$X_{Q,new} = F_{1 \times 1}(X_{Q,new}^1 \oplus X_{Q,new}^2, \dots, \oplus X_{Q,new}^n) \quad (4.3)$$

在获得最终融合 n 个分辨率等级的查询特征 $X_{Q,new}$ 后，将其输入到章节 3.3.3 提出的活动轮廓优化模块中，模块将其作为查询图像的特征图并在其上采样轮廓点的控制特征用于活动轮廓优化，最终输出预测分割结果。

4.4 实验与分析

4.4.1 实验说明

在本章中，实验所使用的数据集为以 CT 图像为主的 ABD-30 数据集以及以 MRI 图像为主的 CHAOST-MRI 数据集。数据集的具体介绍请见章节 3.4.1。

实验环境的配置如下：

（1）硬件环境：CPU：Intel(R) Xeon(R) CPU E5-2698 v4 @ 2.20GHz，内存：32GB，显卡：Tesla V100 DGXS 32GB

（2）软件环境：Linux Ubuntu 18.04 操作系统，Python 3.7，Pytorch 1.1.0，Cuda 9.0 框架开发环境。

对比模型的设置，本文在章节 3.3.3 提出的对比模型基础上，增加了第三章提出的基于先验信息的小样本分割模型。

MFA-SnakeNet 训练所需的超参数配置表如表4.1所示，并使用 Pytorch 搭建框架完成相关实验。第四章的实验过程中本文增加了分辨率层级超参数，表示在多分辨率特征融合过程中将图像特征下采样到层级中的各个分辨率大小。

本章实验所使用指标与第三章实验中的使用的评价指标相同，具体计算过程请见章节 3.4.5。

表 4.1 超参数配置表

超参数	配置值
Optimizer	Adam
Epoch for training	100
Learning rate	1e-4 with decay
Regularization strategy	EarlyStopping
Contour iteration	3
Scale	64, 32, 16, 8

4.4.2 实验结果

本章展示了基于多分辨率特征融合的小样本语义分割模型 MFA-SnakeNet 在 ABD-30 数据集以及 CHAOST-MRI 数据集上的实验结果。实验结果使用章节 3.4.5 中的提出的评价指标评估各个模型的分割结果。

表 4.2 MFA-SnakeNet 小样本分割模型在 ABD-30 数据集上的实验结果

基准模型	测试集各器官分割结果 (%)				
	脾	左肾	右肾	肝	平均
SE-Net	0.23	32.83	14.34	0.27	11.91
PANet	25.59	32.34	17.37	38.42	29.42
SSL-ALPNet	60.25	63.34	54.82	73.65	30.89
RP-Net	69.85	70.48	70.00	79.62	72.48
基于先验信息的小样本分割模型	62.85±1.52	77.75±2.43	73.89±1.34	82.49±0.21	74.26
MFA-SnakeNet	64.46±2.43	79.63±1.55	75.36±0.79	85.87±1.12	76.33

本章提出的基于多分辨率特征融合的小样本语义分割模型 MFA-SnakeNet 与在 ABD-30 数据集上与其他基准模型的对比实验结果如表4.2所示。从实验结果来看，第三章提出的基于先验信息的小样本语义分割模型的平均分割精度达到了 74.26，优于基于像素分割为基础的对比模型。将本文第三章提出的基于先验信息的小样本语义分割模型与本章提出的进阶模型 MFA-SnakeNet 相比，平均分割指标提高了 2.07 个百分点，达到最高的 76.33。从各类器官的小样本任务来看，MFA-SnakeNet 相比较第三章提出的基于先验

信息的小样本语义分割模型，在采用了本章提出的多分辨率特征融合模块后，各类器官的小样本分割任务分割精度均有一定提高。其中，对于左肾分割任务，MFA-SnakeNet 比起第三章提出的基于先验信息的小样本分割模型的分割精度提高了 1.88 个百分点。从右肾分割任务方面，MFA-SnakeNet 比起基于先验信息的小样本分割模型的分割精度提高了 1.47 个百分点，左肾和右肾提升的分割性能大致相同。对于分割难度相对较低的肝脏分割，MFA-SnakeNet 比起基于先验信息的小样本分割模型的分割精度提高了 2.38 个百分点。而对于分割难度较大的脾脏，MFA-Snake 的实验结果相比较基于先验信息的小样本语义分割模型提高了 1.61 个百分点，证明了本文提出的多分辨率特征融合方法能有效的提取不同分辨率特征之间的关键信息，并利用这些关键信息去丰富查询集的特征从而提高特征的表达能力，解决查询集分割目标和支撑集分割目标空间信息不一致的问题。

表 4.3 MFA-SnakeNet 小样本分割模型在 CHAOST-MRI 数据集上的实验结果

基准模型	测试集各器官分割结果 (%)				
	脾	左肾	右肾	肝	平均
SE-Net	51.80	62.11	61.32	27.43	50.66
PANet	50.90	53.45	38.64	42.26	46.33
SSL-ALPNet	67.02	73.63	78.39	73.05	73.02
RP-Net	76.35	81.40	85.78	73.51	79.26
基于先验信息的小样本分割模型	72.62±3.65	84.75±1.98	86.82±0.82	79.77±0.56	79.99
MFA-SnakeNet	76.24±0.64	85.42±2.31	87.14±0.56	80.23±1.63	82.26

为了更全面地评估基于多分辨率特征融合的小样本语义分割模型 MFA-SnakeNet 对于不同模态的医学图像数据的分割能力，本文在以 MRI 图像为主的 CHAOST-MRI 数据集上对基准模型以及 MFA-SnakeNet 进行了对比实验，实验结果如表4.3所示。从实验结果来看，MFA-SnakeNet 取得了最高的平均分割结果，达到 82.26，并在各个器官的小样本分割任务中高于第三章提出的基于先验信息的小样本分割模型以及其他对比模型。从每个器官的小样本分割任务具体来看，在脾脏分割任务中，MFA-SnakeNet 相较于第三章提出的基于先验信息的小样本分割模型要高出 3.62 个百分点，接近于分割精度最高的 RP-Net。这说明本章提出的多尺度特征分辨率模块能关注支撑集上的分割目标和查询集上的分割目标之间的形状、大小等空间信息差异，通过水平路径和垂直路径两种信息聚合方式能够有效地减小空间不一致性，从而提高最终分割性能。从左肾分割任务来看，MFA-SnakeNet 比起基于先验信息的小样本分割模型，分割性能提高了 0.67 个百分点，比起目前分割精度最先进的模型 RP-Net，分割性能提高了 4.02 个百分点。这说明了基于先验信息的小样本模型和设计的多分辨率模块的结合，能有效的提高左肾器官的分割精度。从右肾的分割结果来看，MFA-SnakeNet 比起基于先验信息的小样本

模型高出 0.32 个百分点，相较于前两个分割任务来说上升得不太多。从总的来说，从 CHAOST-MRI 数据集的实验结果来看，MFA-SnakeNet 模型能够有效的利用特征空间中不同分辨率的特征信息，提高分割的准确率。

本文将第四章提出的多分辨率特征融合方法与目前已有的多分辨率特征融合方法进行了比较实验。本文选取 PPM，ASPP 两种常见的多分辨率特征融合方法与本文提出的多尺度融合模块进行对比，并在 ABD-30 数据集上进行了相关实验。实现过程中，本文以基于先验信息的小样本分割模型为主要网络结构，分别增加 PPM 模块和 ASPP 模块。在 ASPP 模块的实现过程中，本文参照原文将空洞卷积的扩张率设置为设置为 1, 6, 12, 18。由于 PSPNet 的作者在实验结果中指出，特征金字塔模块在空间分辨率为 6, 3, 2, 1 时表现最好，因此本文在 PPM 模块的实现过程中参照了原文的设置，将金字塔特征模块的下采样分辨率设置为 6, 3, 2, 1。实验结果如表4.4所示。从实验结果中可以看到，基于 ASPP 模块的小样本语义分割模型与基于 PPM 模块的小样本语义分割模型在分割指标上的差异不大，达到了几乎相同的分割性能。这说明 PPM 和 ASPP 是从不同的角度实现了扩大感受野的目的，最终取得了相同的效果。从表中可以看到本文提出的多尺度融合方法在各器官的小样本分割任务中均优于 PPM 和 ASPP 两种特征优化方法，相比较基于 PPM 模块的小样本语义分割模型提升了 1.46 个百分点，相比较基于 ASPP 模块的小样本语义分割模型提升了 1.66 个百分点。究其原因，在于本文提出的多尺度融合方法相较于 PPM 和 ASPP 两种方法，充分利用了来自支撑集的标签特征信息、先验掩码的引导信息用于丰富查询集的特征表达。此外，本文提出的多尺度融合方法还充分考虑了不同分辨率层级的特征所包含的语义信息也有所差异，引入了自顶向下的特征交互路径，使得高分辨率的特征为低分辨率的特征补充了关键的局部细节信息，解决了查询集的空间特征信息与支撑集的空间特征信息存在不一致的问题。

表 4.4 不同分辨率融合模块对基于先验信息的小样本意义分割模型的性能影响测试

基准模型	测试集各器官分割结果 (%)				
	脾	左肾	右肾	肝	平均
基于先验信息的小样本分割模型	62.85	77.75	73.89	82.49	74.26
基于先验信息的小样本语义分割 +PPM	64.03	78.18	73.66	83.62	74.87
基于先验信息的小样本语义分割 +ASPP	63.76	78.60	74.57	81.75	74.67
MFA-SnakeNet	64.46	79.63	75.36	85.87	76.33

图4.4是 MFA-SnakeNet 模型在 ABD-30 数据集以及 CHAOST-MRI 数据集下的可视化结果。图中前三行是 MFA-SnakeNet 在 ABD-30 数据集上对于查询集的预测分割，第四第五行是 MFA-SnakeNet 在 CHAOST-MRI 数据集上对于查询集的预测分割。可以看到本文提出的 MFA-SnakeNet 在面对查询图像和支撑图像存在的空间不一致现象，通过多分辨率特征融合模块来产生强化的查询集特征表示，缩小了支撑和查询图像上分割目

标形状和大小之间的差距。




图 4.4 MFA-SnakeNet 在数据集上的分割结果展示

4.5 本章小结

本章从基于先验信息的小样本医学图像语义分割模型存在的问题出发，从增强查询集特征的表达能力和利用不同分辨率的特征的上下文信息两个方面入手，提出了基于多分辨率特征融合的小样本分割模型 MFA-SnakeNet。该模型，在以 CT 图像为主的 ABD-30 数据集和以 MRI 图像为主的 CHAOST-MRI 数据集上与多个模型进行了对比实

验。

MFA-SnakeNet 在第三章设计的基于先验信息的小样本语义分割模型基础上,设计了一种多分辨率特征融合方法应用于丰富查询集特征,有效的解决了查询集的空间特征信息与支撑集的空间特征信息存在不一致的问题。在整个多分辨率特征融合模块中,本文利用了来自不同分辨率的支撑集特征信息以及先验掩码的先验信息来丰富查询特征的表达能力,在先验掩码和支撑集的标签数据的指导下,模型能够自主学习利用支撑集上每个像素的特征信息来自适应的丰富查询特征信息,减少了查询集分割目标和支撑集分割目标的空间不一致性。在第二个阶段中,不同分辨率的特征按照自顶向下的路径与其他分辨率的特征进行交互,使得高分辨率的特征为低分辨率的特征补充了关键信息。

从实验结果来看, MFA-SnakeNet 与基于先验信息的小样本语义分割模型比较结果说明, MFA-SnakeNet 通过多分辨率特征融合模块,有效的利用了支撑集标签特征信息以及先验掩码相关性信息,并结合了不同分辨率特征之间的上下文信息,进一步的提高了分割结果。MFA-SnakeNet 在 ABD-30 数据集上的平均分割指标达到 76.33, 在 CHAOST-MRI 数据集上平均分割指标达到 82.26, 在所有对比模型中取得了最好的分割效果。此外, 本文经过对比实验证明了本章提出多分辨率特征融合模块的优越性, 与 PPM, ASPP 方法相比取得了最好效果。总结, MFA-SnakeNet 通过第三章设计基于先验信息的小样本语义分割网络增强了模型对于查询集分割目标边界信息的利用, 并结合特别设计的多分辨率特征融合模块有效的利用了不同分辨率之间的特征关系, 提供了一种有效的医学图像小样本分割方法。

5 总结与展望

5.1 总结

医学图像分割是一项重要的任务，可以帮助医生更好地理解病变部位和解决临床问题。然而，在实际应用中，医学图像通常存在数据量小、标注困难等问题，因此基于小样本的医学图像分割算法研究是一个研究热点。医学图像小样本语义分割意义重大，具体体现在以下几个方面。首先，医学图像小样本语义分割能够更好地适应现实应用场景。基于深度学习的医学图像语义分割方法通常需要大量的数据来训练模型，但在实际应用中，获取大量标注数据非常困难。因此，针对小样本情况下的医学图像分割问题进行研究，可以更好地适应实际场景需求，提高模型的实际可用性。其次，小样本医学图像分割的研究能够促进罕见病例分割和个性化医疗技术的发展，提高了医学图像分析的效率和准确性。在罕见病例分割方面，对于一些罕见的病例，由于数据集较少，医生难以准确地进行分割和诊断。小样本图像分割技术可以通过利用其他类似病例的数据进行学习，提高对于罕见病例的分割和诊断的准确性。在个性化医疗方面，由于不同人的解剖结构差异较大，因此需要对不同的患者进行个性化的医疗诊断。小样本图像分割技术可以通过利用个体化数据进行学习，提高对于不同患者的分割准确性。基于以上研究意义，本文将基于小样本的医学图像分割算法作为主要的研究对象。

本文分别使用了基于先验信息的小样本语义分割方法和基于多分辨率特征融合的 MFA-SnakeNet 模型，给出了基于小样本的医学图像分割算法，总结本文主要工作如下：

首先设计并实现了一种基于先验信息的小样本语义分割方法。在该方法中，本文使用了两种不同模态的医学图像数据集作为实验数据，分别为以 CT 图像为主的 ABD-30 数据集以及以 MRI 图像为主的 CHAOTST-MRI 数据集。在进行实验之前，本文对两种不同模态的数据分别进行了预处理，包括去掉无关切片，剪裁感兴趣区域，转换切片统一分辨率等操作，总共获得 2178 张 CT 切片数据和 558 张 MRI 切片数据。基于先验信息的小样本语义分割方法针对现有的小样本语义分割方法所存在的问题进行设计，包含主要三个模块：分别是特征提取器模块、先验掩码生成模块和活动轮廓优化模块。其中特征提取器模块是以 U-Net 为基础，通过批归一化层加以改进，提取了有效的图像特征。在先验掩码生成模块中，通过计算查询集和支撑集特征之间的余弦相似度生成关系掩码，为查询集未知类的分割提供先验信息，降低了分割目标在查询集上的泛化损失，使得模型在测试阶段面对未知类时具备更强的泛化能力。在活动轮廓优化模块中，利用了查询集特征中包含的丰富边界信息，通过对器官边界进行建立初始轮廓，保留了分割目标的空间拓扑结构，对初始轮廓完善优化并获得了未知类的最终分割结果。通过相关实验，验证了基于先验信息的小样本语义分割方法在小样本医学图像分割任务中的分割

性能。

在基于先验信息的小样本语义分割方法的基础上更进一步,设计并实现了基于多分辨率特征融合的 MFA-SnakeNet 分割方法。在该分割方法中,本文针对查询集和支撑集分割目标空间信息的不一致性,设计了多分辨率特征融合模块,并与基于先验信息的小样本语义分割方法相结合。多分辨率特征融合模块首先在各个分辨率层级内融合了查询特征、支撑特征和包含先验信息的先验掩码多种信息,减少了两个集合分割目标的语义特征差异。其次,考虑了不同特征之间的分辨率层级关系,从高分辨率的精细特征中提取关键信息去丰富低分辨率的粗糙特征,并将不同分辨率特征进行聚合,有效地解决了查询集的空间特征信息与支撑集的空间不一致问题,提高了分割结果的准确率。在 ABD-30 数据集和 CHAOST-MRI 数据集进行了小样本语义分割实验,并与其他现有方法进行比较,实验结果表明, MFA-SnakeNet 取得了更好的分割性能,证明了其在小样本医学图像分割任务中的优越性能和有效性。

5.2 展望

本文设计并实现了两个小样本学习模型对医学图像数据集进行了语义分割,所提出的方法虽然能够完成分割任务并且在分割性能上有一定的提升,但依旧存在可以改善和进一步提升的地方:

首先,在基于先验信息的小样本语义分割模型中,目前采用的生成单个初始轮廓的方式对分割目标进行识别,并输入到轮廓优化模块中进行迭代优化,输出最终的预测轮廓。但对于极少部分切片来说,存在分割器官不是一个完整个体的情况,由两部分组成,又或者是极少量切片中部分器官存在其他组织,使得分割目标的轮廓中类别不单一。本文提出的模型并不能很好的适用于这类情况,因此针对具体应用,能否改良该模型使其能针对多个目标生成多个初始轮廓,使其应用于更加复杂的现实场景,是一个值得研究的方向。

其次,在基于多分辨率特征融合的小样本语义分割模型中,现有方法主要是先在多个分辨率层级内融合查询特征、支撑特征和先验掩码信息,再下采样至不同分辨率进行特征融合。尽管这种方法提高了分割效果,但本文认为查询集与支撑集分割目标的空间不一致性问题具有等价性。由于查询集和支撑集分割目标在大小和形状上存在差异,反之亦然,交换支撑集和查询集的位置也会导致支撑集分割目标与查询集分割目标存在类似问题。因此,是否可以鼓励分割模型在反方向上实施小样本学习流程,利用查询集及预测分割掩码指导基于多分辨率特征融合的小样本语义分割模型对支撑集进行分割,利用两个集合上的预测损失训练模型,以提高模型分割性能,这也是一个值得探讨的研究方向。

参考文献

- [1] 金征宇. 前景与挑战: 当医学影像遇见人工智能[J]. 协和医学杂志, 2018, 9(01): 2-4.
- [2] 董孟杰, 黄钢. 医学影像与人工智能[J/OL]. 国际放射医学核医学杂志, 2020(01): 2-4. <https://rs.yiigle.com/CN121381202001/1197634.htm>.
- [3] 李赞铎, 宫恩浩, 李睿, 等. 深度学习技术与医学影像——现状及未来[J/OL]. 中华放射学杂志, 2018(5): 321-326. <https://rs.yiigle.com/CN112149201805/1038681.htm>.
- [4] KAUSAR T. 基于深度学习方法的乳腺组织病理学图像分析研究[D]. 哈尔滨工业大学, 2019.
- [5] ZHOU T, YE X, LU H, et al. Dense convolutional network and its application in medical image analysis[J]. BioMed Research International, 2022, 2022.
- [6] 张珉, 杨娟, 汪荣贵. 基于语义对齐的小样本语义分割模型[J/OL]. 计算机系统应用, 2022, 31(12): 203-210. <https://kns.cnki.net/kcms/detail/11.2854.TP.20221114.1329.024.html>.
- [7] THANH D N, ERKAN U, PRASATH V S, et al. A skin lesion segmentation method for dermoscopic images based on adaptive thresholding with normalization of color models[C]//2019 6th International Conference on Electrical and Electronics Engineering (ICEEE). IEEE, 2019: 116-120.
- [8] FENG Y, ZHAO H, LI X, et al. A multi-scale 3d otsu thresholding algorithm for medical image segmentation[J]. Digital Signal Processing, 2017, 60: 186-199.
- [9] OTSU N. A threshold selection method from gray-level histograms[J]. IEEE transactions on systems, man, and cybernetics, 1979, 9(1): 62-66.
- [10] SHI J, MALIK J. Normalized cuts and image segmentation[J]. IEEE Transactions on pattern analysis and machine intelligence, 2000, 22(8): 888-905.
- [11] BAJWA I S, ASGHAR M N, NAEEM M A. Learning-based improved seeded region growing algorithm for brain tumor identification: Improved seeded region growing algorithm for brain tumor identification[J]. Proceedings of the Pakistan Academy of Sciences: A. Physical and Computational Sciences, 2017, 54(2): 127-133.
- [12] RUNDO L, MILITELLO C, VITABILE S, et al. Combining split-and-merge and multi-seed region growing algorithms for uterine fibroid segmentation in mrgfus treatments[J]. Medical & biological engineering & computing, 2016, 54: 1071-1084.
- [13] KASS M, WITKIN A, TERZOPOULOS D. Snakes: Active contour models[J]. International journal of computer vision, 1988, 1(4): 321-331.

- [14] LONG J, SHELHAMER E, DARRELL T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 3431-3440.
- [15] BEN-COHEN A, DIAMANT I, KLANG E, et al. Fully convolutional network for liver segmentation and lesions detection[C]//Deep Learning and Data Labeling for Medical Applications: First International Workshop, LABELS 2016, and Second International Workshop, DLMIA 2016, Held in Conjunction with MICCAI 2016, Athens, Greece, October 21, 2016, Proceedings 1. Springer, 2016: 77-85.
- [16] ROTH H R, ODA H, ZHOU X, et al. An application of cascaded 3d fully convolutional networks for medical image segmentation[J]. Computerized Medical Imaging and Graphics, 2018, 66: 90-99.
- [17] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015: 18th International Conference, Munich, Germany, October 5-9, 2015, Proceedings, Part III 18. Springer, 2015: 234-241.
- [18] ÇİÇEK Ö, ABDULKADIR A, LIENKAMP S S, et al. 3d u-net: learning dense volumetric segmentation from sparse annotation[C]//Medical Image Computing and Computer-Assisted Intervention–MICCAI 2016: 19th International Conference, Athens, Greece, October 17-21, 2016, Proceedings, Part II 19. Springer, 2016: 424-432.
- [19] GHAFFARI M, SOWMYA A, OLIVER R. Automated brain tumor segmentation using multimodal brain scans: a survey based on models submitted to the brats 2012–2018 challenges[J]. IEEE reviews in biomedical engineering, 2019, 13: 156-168.
- [20] SCHLEMPER J, OKTAY O, SCHAAP M, et al. Attention gated networks: Learning to leverage salient regions in medical images[J]. Medical image analysis, 2019, 53: 197-207.
- [21] CHEN J, LU Y, YU Q, et al. Transunet: Transformers make strong encoders for medical image segmentation[J]. arXiv preprint arXiv:2102.04306, 2021.
- [22] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [23] ZHANG X, WEI Y, YANG Y, et al. Sg-one: Similarity guidance network for one-shot semantic segmentation[J]. IEEE transactions on cybernetics, 2020, 50(9): 3855-3865.
- [24] LU Z, HE S, ZHU X, et al. Simpler is better: Few-shot semantic segmentation with classifier weight transformer[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 8741-8750.
- [25] 陈琼, 杨咏, 黄天林, 等. 小样本图像语义分割综述[J]. 数据与计算发展前沿, 2021, 3(6): 17-34.

- [26] SHABAN A, BANSAL S, LIU Z, et al. One-shot learning for semantic segmentation[C]// 2017.
- [27] ZHANG C, LIN G, LIU F, et al. Canet: Class-agnostic segmentation networks with iterative refinement and attentive few-shot learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 5217-5226.
- [28] LIU W, ZHANG C, LIN G, et al. Crnet: Cross-reference networks for few-shot segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 4165-4173.
- [29] WANG K, LIEW J H, ZOU Y, et al. Panet: Few-shot image semantic segmentation with prototype alignment[C]//proceedings of the IEEE/CVF international conference on computer vision. 2019: 9197-9206.
- [30] LI G, JAMPANI V, SEVILLA-LARA L, et al. Adaptive prototype learning and allocation for few-shot segmentation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 8334-8343.
- [31] ROY A G, SIDDIQUI S, PÖLSTERL S, et al. ‘squeeze & excite’ guided few-shot segmentation of volumetric images[J]. Medical image analysis, 2020, 59: 101587.
- [32] OUYANG C, BIFFI C, CHEN C, et al. Self-supervision with superpixels: Training few-shot medical image segmentation without annotation[C]//Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XXIX 16. Springer International Publishing, 2020: 762-780.
- [33] TANG H, LIU X, SUN S, et al. Recurrent mask refinement for few-shot medical image segmentation[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 3918-3928.
- [34] MCCULLOCH W S, PITTS W. A logical calculus of the ideas immanent in nervous activity[J]. The bulletin of mathematical biophysics, 1943, 5: 115-133.
- [35] ROSENBLATT F. The perceptron: a probabilistic model for information storage and organization in the brain.[J]. Psychological review, 1958, 65(6): 386.
- [36] WERBOS P J. Backpropagation through time: what it does and how to do it[J]. Proceedings of the IEEE, 1990, 78(10): 1550-1560.
- [37] LECUN Y, BENGIO Y, et al. Convolutional networks for images, speech, and time series [J]. The handbook of brain theory and neural networks, 1995, 3361(10): 1995.
- [38] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[C]//International Conference on Learning Representations (ICLR). 2015: 1-14.
- [39] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//

- Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [40] 邱锡鹏. 神经网络与深度学习[M/OL]. 北京: 机械工业出版社, 2020. <https://nndl.github.io/>.
- [41] 李天庆, 张毅, 刘志, 等. Snake 模型综述[J]. 计算机工程, 2005(09): 1-3.
- [42] PENG S, JIANG W, PI H, et al. Deep snake for real-time instance segmentation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 8533-8542.
- [43] 项凯特. 面向交通场景感知的语义分割技术研究[D]. 浙江大学, 2021.
- [44] ZHAO H, SHI J, QI X, et al. Pyramid scene parsing network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2881-2890.
- [45] CHEN L C, PAPANDREOU G, KOKKINOS I, et al. Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 40(4): 834-848.
- [46] VINYALS O, BLUNDELL C, LILICRAP T, et al. Matching networks for one shot learning[J]. Advances in neural information processing systems, 2016, 29.
- [47] 董阳, 潘海为, 崔倩娜, 等. 面向多模态磁共振脑瘤图像的小样本分割方法[J]. 计算机应用, 2021, 41(4): 1049-1054.
- [48] GIRSHICK R. Fast r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1440-1448.
- [49] ZHOU Y, LI Z, BAI S, et al. Prior-aware neural network for partially-supervised multi-organ segmentation[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 10672-10681.
- [50] ISENSEE F, JAEGER P F, KOHL S A, et al. nnu-net: a self-configuring method for deep learning-based biomedical image segmentation[J]. Nature methods, 2021, 18(2): 203-211.
- [51] TIAN Z, ZHAO H, SHU M, et al. Prior guided feature enrichment network for few-shot segmentation[J]. IEEE transactions on pattern analysis and machine intelligence, 2020, 44(2): 1050-1065.