

分类号 TP391

密级

U D C

编号 10486

武汉大学

硕士学位论文

基于改进 U-Net 的医学
图像分割方法研究

研究生姓名：邓希泉

学号：2020202210110

指导教师姓名、职称：陈刚 教授

专业名称：网络空间安全

研究方向：医学图像分割

二〇二三年五月

Research of Medical Image Segmentation Based on Improved U-Net

By

Deng Xiquan

Supervised by

Prof. Chen Gang

Wuhan University

May, 2023

摘 要

在医学图像处理领域，图像分割是一个关键环节，它在辅助诊断、手术指导和术后康复等阶段发挥着不可或缺的作用。然而，由于医学图像中待分割结构之间的重叠程度较高（例如肺和锁骨），或者待分割结构的边界模糊、形状和大小多变（例如腹部 CT 图像中的肝脏等器官），传统分割方法很难实现准确分割。近年来，随着深度学习的迅速发展，现有的 U-Net 医学图像分割模型在一定程度上解决了这些分割难点，但仍存在以下不足：首先，这些模型不能获得更为全面和准确的局部-整体关系，导致重叠部位的分割不够准确；其次，尽管跳跃连接保存了低层特征，但没有加强对边缘细节信息的关注，同时引入了冗余信息，导致模型难以准确识别轮廓；另外，虽然连续的卷积操作逐渐扩大了感受野，但忽略了不同感受野大小对分割效果的影响。

针对上述不足，本文结合 U-Net 网络进行深入研究并提出了具体的解决方案，主要研究内容如下：

（1）针对现有 U-Net 模型不能获得更为全面和准确的局部-整体关系导致不能有效地对重叠部位准确分割的问题，本文提出了基于 U-Net 和胶囊网络的医学图像分割模型 ConvUCaps。该模型引入胶囊网络对 U-Net 的编码器部分进行改进，使用卷积模块学习低层特征，并建模局部关系，然后通过胶囊模块学习高层特征，并建模局部与整体之间的关系，从而保存目标的位置、姿态等信息，缓解了重叠程度高带来的分割困难。在 JSRT 数据集上的实验结果表明，该模型在 Dice 相似系数（Dice Similarity Coefficient, DSC）和平均交并比（Mean Intersection over Union, MIoU）上分别达到了 94.35% 和 90.84%，与其他医学图像分割方法相比，显著提高了分割效果。

（2）针对现有 U-Net 模型缺少对边缘细节信息的关注以及忽略了不同感受野大小对分割效果的影响导致不能有效地对边界模糊、形状和大小多变的待分割结构准确分割的问题，本文提出了基于多尺度特征和注意力机制的医学图像分割模型 RAE-U-Net。该模型以 U-Net 网络为基础，并采用残差卷积模块代替 U-Net 网络中的普通卷积模块，以提高特征信息的利用率。本文设计了多尺度通道注意力模块（Multi-scale Channel Attention Module, MCAB），通过结合高低层多尺度特征信息生成注意力权重，对跳跃连接过来的低层特征进行加权，增强对边缘细节信息的关注并抑制无关信息的干扰。此外，本文通过改进的密集空洞空间金字塔池化模块（Densely connected Atrous Spatial Pyramid Pooling, DenseASPP），采用不同空洞率的密集空洞卷积获得不同大小的感受野，来捕获多尺度上下文信息，从而更好地应对待分割结构在形状和大小上的变化。在 LiTS 2017 数据集上的实验结果表明，该模型在 Dice 相似系数、体积重叠误差（Volume Overlap Error, VOE）以及相对体积差异（Relative Volume Difference, RVD）三个评价指标上分别达到了 96.6%、6.5% 和 1.45%，与其他医学图像分割方法相比，取得了更好的结果。

关键词：医学图像分割；深度学习；U-Net 网络；胶囊网络；注意力机制

ABSTRACT

In the field of medical image processing, image segmentation is a crucial step that plays an indispensable role in various stages such as assisting diagnosis, guiding surgery, and postoperative recovery. However, due to the high degree of overlap between structures to be segmented in medical images (such as lungs and clavicles), or the blurry boundary, and varying shapes and sizes of the structures to be segmented (such as liver and other organs in abdominal CT images), traditional segmentation methods struggle to achieve accurate segmentation. In recent years, with the rapid development of deep learning, existing U-Net medical image segmentation models have to some extent solved the above difficulties, but there are still the following shortcomings: firstly, these models cannot obtain more comprehensive and accurate local-whole relationships, leading to inaccurate segmentation of overlapping areas; Secondly, although skip connections preserve low-level features, they do not pay more attention to edge detail information and bring redundant information, resulting in the model's inability to accurately identify contours; In addition, although the continuous convolution operations gradually expand the receptive field, they ignore the influence of different receptive field sizes on the segmentation effect.

In response to the above shortcomings, this paper conducts in-depth research and proposes specific solutions based on the U-Net network. The main research content is as follows:

(1) To address the issue of existing U-Net models not being able to obtain more comprehensive and accurate local-whole relationships, which leads to the inability to effectively segment the overlapping parts, this paper proposes a medical image segmentation model ConvUCaps based on U-Net and capsule network. This model introduces capsule network to improve the encoder part of U-Net. The convolutional module is used to learn low-level features and model local relationships. Then, the capsule module is used to learn high-level features and model the local-whole relationships, thereby preserving the position, posture, and other information of the target, alleviating the segmentation difficulties caused by high overlap. The experimental results on the JSRT dataset show that the model achieves 94.35% and 90.84% respectively on the Dice Similarity Coefficient (DSC) and Mean Intersection over Union (MIoU), significantly improving segmentation effect compared with other medical image segmentation methods.

(2) To address the issue of existing U-Net models lacking the attention to the edge details and ignoring the influence of different receptive field sizes on the segmentation effect, which leads to the inability to effectively segment the structures to be segmented with blurry boundaries, varying shapes and sizes, this paper proposes a medical image segmentation model

RAE-U-Net based on multi-scale features and attention mechanism. This model is based on the U-Net network and uses residual convolution modules instead of ordinary convolution modules to improve the utilization of feature information. This paper designs a Multi-scale Channel Attention Module (MCAB), which generates attention weights by combining high and low level multi-scale feature information, and weights the low-level features connected by skip connection to enhance attention to edge details and suppress irrelevant information. Additionally, the model employs an improved Densely connected Atrous Spatial Pyramid Pooling (DenseASPP) module to capture multi-scale contextual information by using dense atrous convolution with different dilation rates to obtain different receptive fields, better dealing with changes in shape and size of the structures to be segmented. The experimental results on the LiTS 2017 dataset show that the model achieved 96.6%, 6.5%, and 1.45% in the Dice similarity coefficient, Volume Overlap Error (VOE), and Relative Volume Difference (RVD) evaluation indicators, respectively. Compared with other medical image segmentation methods, it achieved better results.

Keywords: Medical Image Segmentation; Deep Learning; U-Net Network; Capsule Network; Attention Mechanism

目 录

1 绪论.....	1
1.1 研究背景与研究意义.....	1
1.2 国内外研究现状.....	2
1.2.1 传统医学图像分割方法.....	2
1.2.2 基于深度学习的医学图像分割方法.....	3
1.3 主要研究内容.....	5
1.4 论文组织结构.....	6
2 相关基础知识	8
2.1 经典医学图像分割模型.....	8
2.1.1 全卷积网络.....	8
2.1.2 U-Net 网络.....	8
2.1.3 Attention U-Net 网络.....	9
2.1.4 UNet++网络.....	10
2.2 胶囊网络.....	11
2.3 注意力机制.....	13
2.4 本章小结.....	15
3 基于卷积胶囊网络的医学图像分割模型	16
3.1 引言.....	16
3.2 ConvUCaps 网络模型.....	16
3.2.1 网络结构设计.....	16
3.2.2 卷积胶囊网络分析.....	18
3.2.3 损失函数设计.....	20
3.3 实验结果分析.....	20
3.3.1 实验环境与配置.....	20
3.3.2 数据集与预处理.....	21
3.3.3 评价指标.....	22
3.3.4 不同网络模型分割结果对比.....	22
3.3.5 不同网络模型性能分析.....	27
3.3.6 实验结论.....	29
3.4 本章小结.....	30
4 基于多尺度特征和注意力机制的医学图像分割模型	31
4.1 引言.....	31
4.2 RAE-U-Net 网络模型	31
4.2.1 整体网络结构设计	31

4.2.2 残差卷积模块—Res-block	33
4.2.3 多尺度通道注意力模块—MCAB.....	35
4.2.4 密集空洞空间金字塔池化模块—Dense ASPP	37
4.2.5 加权损失函数设计	41
4.3 实验结果与分析.....	42
4.3.1 实验环境与配置.....	42
4.3.2 数据集与预处理.....	42
4.3.3 评价指标.....	43
4.3.4 消融实验.....	44
4.3.5 与经典网络模型对比.....	46
4.3.6 与其他网络模型对比.....	48
4.4 本章小结.....	49
5 总结与展望.....	50
5.1 工作总结.....	50
5.2 未来工作展望.....	50
参考文献.....	52

1 绪论

1.1 研究背景与研究意义

近年来,随着科技的进步,医学成像技术得到了快速的发展和广泛的应用。X 射线成像、计算机断层扫描等成像技术可以帮助医生观察人体内部的结构、器官和病变情况,从而制定更精确、有效的诊断和治疗方案。利用医学成像技术进行医疗诊断已经成为医生不可或缺的方法。而要实现这个目标,需要先借助图像分割的方法将待分析的器官或组织从图像中分割出来。

医学图像分割主要是对骨结构、器官以及一些解剖标记点等关键部位进行分割和识别,是医学图像处理和精确量化诊断的关键技术,在临床中具有十分广泛的应用。例如在胸部 X 片中,肺部、心脏和锁骨是主要的解剖结构,准确对其进行分割,在诊断肺气肿、心脏肿大以及其他一些疾病时起到了重要的帮助。又例如在肝肿瘤的分割和诊断中,CT 图像中的肝脏分割是不可或缺的一步,其分割精度的高低直接决定后续肝肿瘤分割的准确性。

在医学图像分割的早期阶段,通常需要依靠经验丰富的医生手动分割,但是这种方法非常费时低效,且容易出现误差和偏差。随着计算机技术的发展,医学图像的自动分割成为了医学图像分割领域的焦点,并逐步取代了手动分割。其中传统的分割方法^[1,2]依靠图像的灰度、颜色、纹理等浅层特征,提高了分割效果,但面对稍微复杂的医学图像时,无法达到理想的分割效果,这限制了传统的自动分割方法在临床中的应用。

随着深度学习的最新进展,特别是卷积神经网络可以从训练数据中提取所需要的特征信息,具有效果好、泛化能力强等优势,在图像处理领域的目标检测^[3]、图像分类^[4]和图像分割^[5]等任务中,表现出了优异的性能。不少研究者利用深度学习的方法在医学图像分割上展开了研究,推动了医学图像分割在临床实践中的应用^[6-9]。其中,U-Net 网络^[7]采用编码-解码结构,并引入跳跃连接,可以有效地融合来自不同层级的特征信息,在医学图像分割方面表现出色,并且 U-Net 网络结构简单,具有很强的通用性,因此备受关注 and 广泛使用,成为了医学图像分割领域的基准模型。然而,基于 U-Net 的医学图像分割方法还存在一些不足:一方面,医学图像中待分割结构之间会存在重叠的情况,这使得模型难以对重叠部位准确分割;另一方面,待分割结构往往具有边界模糊、形状不规则、大小不一等复杂特点,这也导致了模型分割精度不高。

综上所述,基于 U-Net 模型进行医学图像分割,能提高医学图像的分割效果,帮助医生进行更准确的诊断和治疗,但是仍然存在一些分割难点需要解决。因此,研究基于 U-Net 模型的医学图像分割方法,解决该方法中存在的不足,实现对医学影像中目标区域快速而准确的分割,具有重要的意义。

1.2 国内外研究现状

医学图像分割是医学图像处理中的关键步骤之一，医学图像分割任务针对各器官的不同有许多的种类，常见的分割任务有肺分割^[10]、肝脏分割^[11]、视网膜血管分割^[12]、脑肿瘤分割^[13]以及胰腺分割^[14]等。针对这些任务的分割方法主要包括传统分割方法以及基于深度学习的分割方法。

1.2.1 传统医学图像分割方法

（1）基于阈值的分割方法

基于阈值的分割方法是最基础的分割算法，具有计算简单、分割速度快的特点。它主要根据设定的阈值将图像中的每个像素点划分为若干个类别，故其关键点在于阈值的确定。阈值的确定主要是根据图像的灰度、纹理等特征信息，可以手动设置，也可以获得自适应阈值。根据阈值确定算法的不同，阈值分割法可以分为固定阈值分割、迭代阈值分割、自适应阈值分割和最佳阈值分割等。自适应阈值分割中最经典的是 OTSU 算法^[1]，该算法将图像分成目标和背景两个部分，高于阈值的为背景部分，反之为目标区域，两者之间的类间方差越大，说明差别越大，以此得到的阈值能使得错分概率最小，从而实现较好的分割。

（2）基于区域的分割方法

基于区域的分割方法是利用像素间的相似性，将具有相似性质的像素归为同一类，从而实现图像分割。该方法主要包括区域生长算法、区域分裂合并算法和分水岭算法。区域生长算法是一种从单个像素开始，根据特定标准逐步加入周围像素来扩展区域的算法，当满足终止条件时，区域生长算法会停止。该算法的分割结果取决于初始点的选择、生长准则以及终止条件。Bajwa 等^[15]利用区域生长算法用于脑部图像分割，在脑肿瘤分割中取得了很好的效果。区域分裂合并算法中，对图像中特征不一致的区域均分成四个子区域，对特征一致的区域则进行合并，直至所有区域不再产生新的分裂与合并为止。分水岭算法是利用分水岭的构成特点来对图像进行分割，它是基于拓扑结构的形态学分割算法，如 Benson 等^[16]利用分水岭算法实现了脑肿瘤的自动分割。

（3）基于边缘检测的分割方法

通常在不同区域的边界处，图像的灰度、纹理以及颜色等特征变化比较剧烈，基于边缘检测的分割算法利用以上特性检测不同区域的边缘来实现分割。图像中的边缘检测可以通过不同的微分算子计算来实现，常用的微分算子包括 Roberts 算子、Canny 算子以及 Laplace 算子等。Mahmood 等^[17]利用边缘检测算法对患者的膝关节软骨进行了边缘提取，Martel 等^[18]通过随机森林分类器算法识别图像中的边缘，实现了对乳腺组织的分割。当图像出现对比度低以及边界模糊等特点时，这在医学图像中很常见，基于边缘检测的分割方法得到的分割结果并不理想，此时需要结合一些后处理措施来提高分割精度。

（4）基于聚类的分割方法

基于聚类的分割方法是结合机器学习算法实现对图像的分割。聚类算法在图像分割中应用广泛，它分为硬聚类和软聚类。**K-means** 算法^[19]属于硬聚类，它通过计算每个像素点到类别中心点的距离确定类别，再依此计算各个类别像素点的均值来更新中心点，反复迭代直至分割出目标区域。**Kumbhar** 等^[20]利用 **K-means** 算法对白质和灰质进行分割，取得了较好的分割精度。模糊 C 均值聚类算法^[21]（**Fuzzy C Means, FCM**）属于软聚类，样本点可以划分至多个簇，与普通的聚类算法相比，更适合于医学图像分割。**Adhikari** 等^[22]利用 **FCM** 算法，并结合局部和全局空间信息，能有效解决 **MRI** 数据对噪声的敏感性问题。基于聚类的分割方法属于无监督分割方法，速度快，能应用于复杂的医学图像分割，但其分割效果会受到初始聚类中心的影响。

传统的图像分割方法除了上面提到的，还包括基于模型的分割方法^[2]、基于图谱的分割方法^[23]、图割法^[24]等。传统的分割方法通常需要利用专家的先验知识，并且主要依赖于图像的浅层特征，如灰度、颜色、形状以及纹理等特征，对于复杂的医学图像无法达到预期的分割效果。

1.2.2 基于深度学习的医学图像分割方法

与传统方法相比，基于深度学习的方法能自动提取数据中的高级抽象特征，自动化程度高并且能达到较高的准确率。其中，卷积神经网络可以提取分层特征进行分割，对噪声、模糊、对比度低等图像退化具有较强的鲁棒性，能够提高医学图像的分割效果。卷积神经网络早在 1995 年用于医学图像分割，由 **Lo** 等^[25]将其用于肺部的分割，但由于客观环境等因素限制，未能在医学图像分割领域得到普及。随着 **AlexNet** 网络^[26]出现以及全卷积神经网络实现像素级别图像分割任务，卷积神经网络开始快速发展并成为图像处理领域中的主流算法^[27]。

Long 等^[6]在卷积神经网络基础上，提出了全卷积网络 **FCN**（**Fully Convolutional Network, FCN**）。**FCN** 是端到端的分割模型，采用全卷积化实现逐像素分割。它与以往网络模型最大的区别之一是使用了跳跃连接结构，能够将浅层特征信息与深层语义信息进行融合，实现精准分割，是图像语义分割的开山之作。在医学图像分割领域，使用更广泛的是 **U-Net** 网络结构。**U-Net** 网络以其 U 型对称结构而得名。它将右侧上采样路径的特征图与对应左侧下采样路径得到的特征图在通道维度上拼接，这样可以很好地利用图像的浅层信息和上下文信息，减少对数据量的依赖。该网络结构简单，可在少量图像数据上进行端到端训练，且分割效果良好。因此，**U-Net** 成为了医学图像分割领域的基准模型，并催生了许多基于其改进的医学图像分割模型。

基于 **U-Net** 网络改进的医学图像分割模型主要可以分为连接方式的改进、卷积模块的改进以及整体结构的改进等。

（1）改进连接方式的 U-Net 网络

U-Net 网络中的跳跃连接只是简单地将特征图在通道维度进行拼接，不能有效利用特征图信息。许多研究者在原有模块的基础上，引入 Dense 模块、残差模块、Attention 模块等经典网络模块，以及它们的组合来提高网络的分割效果。受 DenseNet 网络^[28]启发，Zhang 等^[29]改进了 U-Net 网络并引入了 Dense 模块以增强特征图像的融合，从而提出了一种新的网络架构—MDU-Net 网络。Xiao 等^[30]借鉴残差连接的思想，设计了一种基于残差连接的 U-Net 网络，该网络在视网膜血管分割方面表现出色。Oktay 等^[8]提出基于栅格的注意力门，将下采样过程中得到的特征图经过注意力门过滤后再与上采样特征图进行拼接，从而过滤掉低层特征图中存在的噪声。Zhou 等^[9]则对跳跃连接进行了重新设计提出了 UNet++网络，该网络可以看成是多个 U-Net 网络的集成，能更好地利用多尺度特征图信息，在多个医学图像数据集上取得了很好的分割性能。Huang 等^[31]则是提出了全尺度跳跃连接网络 UNet3+用于医学图像分割，能够将包含低层次细节信息的特征图与不同尺度的高层次语义特征图结合起来，提高模型的分割效果。

（2）改进卷积模块的 U-Net 网络

改进 U-Net 网络中的卷积模块是目前最为常见的改进方式，其主要是利用可变形卷积、循环卷积以及空洞卷积等对常规卷积进行替换，充分提取特征信息，促进特征融合，从而提升模型的分割效果。Jin 等^[32]受 Deformable-ConvNet 网络^[33]的启发，在编解码器中使用可变形卷积替换原有卷积，提出了 DUNet 网络。Alom 等^[34]利用循环卷积和循环残差卷积的思想改进了 U-Net 网络的编解码器部分，提出了循环卷积网络 RU-Net 以及循环残差卷积网络 R2U-Net 两种网络模型，在肺部、视网膜等医学图像数据上取得了良好的表现。Chen 等^[35]在网络中引入空洞卷积用于多个分支，提出 DMFNet 网络，能够从不同感受野范围内学习更重要的信息，提高了网络的分割精度。

Lou 等^[36]提出的 DC-UNet 网络同时对连接方式和卷积模块进行改进，该网络在跳跃连接中使用残差连接方式，并在编解码器部分设计双通道残差连接模块，能有效提取多尺度特征信息。Ibtehaz 等^[37]受残差连接以及 Inception 模块的启发，分别对跳跃连接以及编解码器部分进行改进，提出 MultiResUNet 网络，通过多尺度的卷积核大小提取不同尺度的空间信息，提高了分割效果。

（3）改进整体结构的 U-Net 网络

目前，还有一些研究者从整体结构出发，通过多种方式重复使用 U-Net 网络结构以提高分割效果。Albishi 等^[38]将两个 U-Net 网络进行级联，在脑肿瘤分割中取得了较好的分割效果。Chen 等^[39]提出的 Bridged U-Net 网络模型，也是采用级联的方式将两个 U-Net 网络进行连接，在前列腺 MRI 图像分割中能较好的分割出目标。Johansen 等^[40]提出的 DoubleU-Net 网络在级联两个 U-Net 网络的同时加入了空间金字塔池化模块，在多个医学图像数据集上相比 U-Net 网络性能显著提升。Liu 等^[41]在对心脏图像进行分割时，先用 U-Net 网络分割出整个心脏，再将得到的结果送入多个并行的 U-Net 网络进行细分

割，从而实现了对心脏各部位的准确分割。

以上这些方法主要是对 U-Net 网络的连接方式、卷积模块以及整体结构做出改进，在相应的医学图像数据集上取得了较好的分割效果，分割性能显著优于传统的医学图像分割方法。但这些基于 U-Net 的医学图像分割模型中，还存在一些不足：

1) 这些模型本质上是全卷积神经网络模型，编码器部分的多次卷积与池化操作，虽然提取了丰富的特征，但对位置、姿态等信息提取不足，不能很好地建模局部与整体之间的关系。而局部与整体之间的关系在处理重叠问题时至关重要，若网络模型可以很好地建模局部-整体关系，则其可以根据各分割结构在图像中的位置，更好地判断重叠部分的像素属于哪一个类别。因此，这些模型难以准确分割出重叠程度高的待分割结构；

2) 虽然跳跃连接操作保存了低层特征，但是并没有加强对边缘细节信息的关注，同时带来了大量的冗余信息，这使得模型在分割边界模糊的待分割结构时难以准确识别其轮廓；

3) 虽然这些模型通过连续卷积操作，逐步增大了感受野，但是忽略了不同感受野大小对分割效果的影响。因此，在分割形状和大小变化较大的结构时，这些模型难以准确判断图像中像素所属的类别，导致分割效果不佳。

综合上述分析可知，当医学图像中待分割结构之间存在重叠程度高（例如肺和锁骨）或者待分割结构具有边界模糊、形状和大小多变（例如腹部 CT 图像中的肝脏等器官）的特点时，基于 U-Net 模型的分割效果还有待提高。因此，本文针对这两个医学图像分割中的难点，对 U-Net 网络进行改进，提出针对性的网络模型，并通过实验验证所提网络模型的有效性。

1.3 主要研究内容

本文针对医学图像分割中的难点，以 U-Net 网络为基准模型并进行改进，经过在胸部 X 片以及腹部 CT 图像的分割上进行实验，验证了提出的分割方法能有效解决医学图像分割中存在的难点。本文的主要研究内容及创新点如下：

（1）针对医学图像中待分割结构之间重叠程度高而导致的分割困难问题，本文利用胶囊网络对 U-Net 模型进行改进，提出一种基于卷积胶囊网络的医学图像分割模型 ConvUCaps，使其能更好地捕获局部和整体之间的关系。该网络首先通过卷积模块学习低层特征，并建模局部关系，再通过胶囊模块学习高层特征，并建模局部与整体之间的关系，从而保存目标的位置、姿态等信息。ConvUCaps 网络在 JSRT 数据集上进行验证，结果表明该模型能高效实现对各器官组织的分割，特别是显著提高了锁骨和肺部重叠区域的分割效果，证明了 ConvUCaps 网络能够解决分割部位之间重叠程度高导致的分割困难问题。

（2）针对医学图像中待分割结构边界模糊以及形状和大小多变导致的分割困难问

题,本文提出一种基于多尺度特征和注意力机制的医学图像分割模型 RAE-U-Net。该模型以 U-Net 网络为基础,首先使用残差卷积模块代替普通卷积模块,避免梯度消失或爆炸,并提高特征信息的利用率;其次设计多尺度通道注意力模块 Multi-scale Channel Attention Module, MCAB),在该模块中,利用上采样生成的高层特征图与对应下采样部分的低层特征图得到注意力权重,用来调整低层特征图中各个通道的权重,从而加强对边缘细节信息的关注;最后使用改进的密集空洞空间金字塔池化模块(Densely connected Atrous Spatial Pyramid Pooling, DenseASPP)加强多尺度特征信息的提取,在该模块中,采用不同空洞率的密集空洞卷积获得不同大小的感受野,从而捕获不同尺度的上下文信息,解决待分割结构形状和大小多变带来的分割困难问题。在 LiTS 2017 数据集上的实验结果表明,RAE-U-Net 网络具有最好的分割效果,能有效解决待分割部位边界模糊以及形状和大小多变导致的分割困难问题。

1.4 论文组织结构

本文共分为五个章节,组织结构如图 1-1 所示。各章节的内容安排如下:




图 1-1 论文组织结构

第一章是绪论。首先论述了本文研究的背景与意义，其次对医学图像分割的国内外研究现状进行了总结，最后概述了本文的主要研究内容。

第二章是基础理论部分。首先对经典医学图像分割模型 FCN、U-Net、Attention U-Net 以及 UNet++网络进行了介绍，然后详细阐述了本文使用到的胶囊网络以及注意力机制，为后续研究提供相关理论基础。

第三章主要介绍基于卷积胶囊网络的 U-Net 模型分割方法 (ConvUCaps)。详细介绍了本文提出的网络结构、胶囊层使用的动态路由算法、加权损失函数，最后在 JSRT 数据集上的实验表明，该模型具有更高的分割精度与收敛速度，有效解决了医学图像中待分割结构之间重叠程度高带来的分割困难问题。

第四章主要介绍基于多尺度特征和注意力机制的 U-Net 模型分割方法 (RAE-U-Net)。详细介绍了本文提出的分割方法的具体结构以及其中的各个模块，最后在 LiTS 2017 数据集上进行消融实验分析，并与经典分割网络模型以及其他先进模型进行定量与定性对比分析，证明了本文提出的分割算法的鲁棒性，能有效解决医学图像中待分割结构边界模糊、形状和大小多变带来的分割困难问题。

第五章是总结与展望，总结了本文的主要研究内容，并对其中的不足进行思考与展望。

2 相关基础知识

2.1 经典医学图像分割模型

2.1.1 全卷积网络

全卷积网络 FCN 是一种用于语义分割任务的深度学习模型，是用深度学习来完成语义分割任务的开山之作，在图像处理领域中具有广泛的应用。FCN 网络结构如图 2-1 所示，它的主要特点是去除了全连接层，并采用了一系列的卷积、上采样和跳跃连接等技术，从而使得输入图像可以直接映射到输出分割结果。首先，FCN 将输入图像通过一系列卷积和池化操作，得到一组特征图。接着，它使用反卷积操作将这些特征图恢复到原始图像大小，FCN-8s、FCN-16s 以及 FCN-32s 分别代表不同倍数的上采样，其中效果最好的是 FCN-8s。最后，FCN 通过交叉熵等损失函数来优化模型，从而实现图像的语义分割任务。FCN 的核心思想是将原本输出为一维向量的全连接层替换为输出二维图像的卷积层，这样，FCN 可以直接接收图像作为输入，并输出与输入图像大小相同的像素级别的分割结果。同时，为了解决上采样时丢失的细节信息，FCN 使用了跳跃连接技术，将卷积神经网络的不同层的特征图进行连接，从而提高了分割的精度。FCN 是在图像分割任务中第一个实现像素级别分类的网络，由此揭开了深度学习应用在语义级别分割研究的序幕。




图 2-1 FCN 网络结构

2.1.2 U-Net 网络

U-Net 是一种用于图像分割的深度卷积神经网络，由 Ronneberger 等^[7]在 2015 年提出来的，它基于全卷积网络 FCN，采用了编码器-解码器结构，与 FCN 网络不同的是，U-Net 的左右结构是对称的，左侧是收缩路径在不同尺度上提取特征信息，右侧是扩张路径用于上采样特征图到输入图像大小，左右结构合并起来形成了 U 型结构，能有效保

留图像中的信息。U-Net 网络结构如图 2-2 所示，主要由下采样和上采样两个阶段组成。下采样阶段通过一系列卷积层和池化层对输入图像进行下采样，从而得到图像的低层次特征。上采样阶段则通过一系列的上采样和卷积操作将低层次特征逐步合成高层次特征，并最终输出分割结果。在 U-Net 的下采样过程中，由于不断地使用池化操作，图像的分辨率不断降低，但特征通道数不断增加，从而使得网络在不同层次都可以获得不同的特征信息。在上采样过程中，网络采用反卷积或上采样加卷积的方式逐步恢复图像分辨率，并使用跳跃连接将下采样阶段得到的特征与上采样阶段的特征进行拼接，使得网络可以同时利用不同层次的特征进行分割，更好地适应各种分割任务。




图 2-2 U-Net 网络结构

U-Net 在不同尺度上进行特征提取，并能有效融合高分辨率的浅层特征和低分辨率的深层特征，在医学图像分割领域得到了广泛的应用，并取得了较好的效果。U-Net 的网络结构简单，易于理解和实现，并且具有较强的通用性，在本文中，主要是基于 U-Net 模型进行改进以解决目前医学图像分割中存在的难点。

2.1.3 Attention U-Net 网络

Attention U-Net 是一种基于 U-Net 的深度学习模型，用于医学图像分割任务。Attention U-Net 的整体结构与 U-Net 类似，分为编码器和解码器两个部分，并使用跳跃连接技术将不同层的特征进行融合。与 U-Net 不同的是，它引入了注意力机制来提高模型对感兴趣区域的关注程度并抑制不相关区域，从而提高图像分割的精度。Attention U-Net 中使用的注意力机制叫做注意力门（Attention Gate），如图 2-3 所示，解码器部分的每一层都包含一个注意力门，编码器部分的特征图在与对应上采样层进行拼接前，都需要先通过注意力门，这样减少了噪声和无用信息的干扰，能使网络的性能得到提升，并

且计算开销小，简单方便。




图 2-3 Attention U-Net 网络结构

图 2-4 为注意力门的具体结构，注意力门的输入为解码器部分的特征图和他上一层编码器部分的特征图，分别通过 $1 \times 1 \times 1$ 的卷积并相加，然后再依次经过 ReLU 激活函数、 $1 \times 1 \times 1$ 卷积、Sigmoid 激活函数以及一个网格重采样器，得到注意力系数 α 。最后，将重采样器得到的注意力系数与编码器部分的原始输入进行相乘，从而提高对应区域的权重。




图 2-4 Attention Gate 结构

2.1.4 UNet++网络

UNet++是基于 U-Net 的改进模型，具体结构如图 2-5 所示。UNet++可以看作是一个深度可变的内置 U-Net 的集合体，可以根据具体分割任务的不同进行调整，它们共享同一个编码器，而解码器则通过重新设计的跳跃连接进行密集连接，并且通过深度监督的方式进行共同学习。

UNet++在 U-Net 的基础上引入了多尺度特征融合和特征重复利用的机制，能够更好地处理图像分割任务。在 U-Net 网络模型中，只有每个下采样层的输出与上采样层的同一层级进行连接，没有跨层级的连接。而在 UNet++中，每个下采样层的输出都与上采样层的同一层级进行连接，同时也和上采样层的较高层级进行连接，实现了不同尺度

特征的融合，这有助于提高分割精度。同时在 UNet++中，每个下采样层的输出都被传递给下一个下采样层，并且也与上采样层的同一层级进行连接，从而使得重要特征在网络中被多次使用，提高了特征的利用率。




图 2-5 UNet++网络结构

2.2 胶囊网络

胶囊网络是 Hinton 等^[42]在 2011 年提出的一种新型神经网络模型，并在 2017 年提出了更深刻的算法和胶囊网络架构^[43]。胶囊是一组神经元的集合，胶囊网络的输入和输出都是以向量的形式，从而能够对物体各部分之间的位置、方向、姿态等信息进行编码，更好地保存整个对象及其部分之间的空间关系。

胶囊网络包含初始卷积层、PrimaryCaps 层以及 DigitCaps 层，结构如图 2-6 所示。初始卷积层使用 256 个 9×9 的卷积核对手写数字图片进行特征提取，采用 ReLU 激活函数，步长为 1。初始卷积层结束后，输出特征图大小为 20×20 ，作为 PrimaryCaps 层的输入。PrimaryCaps 层是包含 32 个通道的卷积胶囊层，进行 8 次卷积操作，卷积核大小为 9×9 ，步长为 2，得到 $32 \times 6 \times 6$ 个胶囊，每个胶囊是一个 8 维向量。最后一层是 DigitCaps 层，每个胶囊代表一个数字类别，其向量维度为 16，两个胶囊层之间通过动态路由算法来更新。




图 2-6 胶囊网络结构图

胶囊之间的工作原理如图 2-7 所示，包含仿射变换、输入加权、累加求和以及非线性变换四个步骤。图 2-7 中 u_i 代表输入向量，将其乘上对应的权重矩阵 W_{ij} 得到向量 u_j ，权重矩阵 W_{ij} 包含了高层特征与低层特征之间的关系，由反向传播算法更新，乘以 W_{ij} 即实现了仿射变换，公式如式(2-5)所示：

$$\hat{u}_{j|i} = W_{ij}u_i \quad (2-5)$$

其中 $\hat{u}_{j|i}$ 为预测胶囊，表示低层胶囊 i 对高层胶囊 j 的预测。第二步是对得到的向量 $\hat{u}_{j|i}$ 进行输入加权，第三步是进行累加求和，两步的操作如式(2-6)所示：

$$s_j = \sum_i c_{ij}\hat{u}_{j|i} \quad (2-6)$$

其中 c_{ij} 是耦合系数，表示低层胶囊 i 与高层胶囊 j 之间的连接概率，由 *softmax* 函数计算获得，如式(2-7)所示：

$$c_{ij} = \text{softmax}(b_{ij}) = \frac{\exp(b_{ij})}{\sum_k b_{ik}} \quad (2-7)$$

其中 b_{ij} 代表底层胶囊 i 连接至高层胶囊 j 的先验概率，耦合系数 c_{ij} 由动态路由算法更新，它决定了一个低层胶囊会送往哪一个高层胶囊。最后一步是对累加求和得到的 s_j 通过 *squash* 函数进行非线性变换，如式(2-8)所示：

$$v_j = \text{squash}(s_j) = \frac{|s_j|^2}{1 + |s_j|^2} \frac{s_j}{|s_j|} \quad (2-8)$$

squash 函数能将向量的长度压缩到 0~1 之间，并且不改变向量的方向。通过非线性变换之后得到的向量即为最终胶囊的输出结果。




图 2-7 胶囊工作过程图

动态路由算法是胶囊网络的核心，用来更新胶囊之间的耦合系数，从而更好地组合各个胶囊。它可以理解为一种迭代计算过程，通过多次迭代计算，得出输入数据中不同部分之间的关系，最终输出各个部分的位置和特征。动态路由算法通过动态计算每个前向传递的权重来加权部分对整个对象的贡献，可以结合期望最大化^[44]、变分贝叶斯^[45]等方法对动态路由过程进行改进。

胶囊网络最初主要用于数字识别和自然图像分类，但其通过保留更多的信息进行姿态推理以及学习部分-整体关系加强特征学习，同样适用于医学图像领域。如研究人员在肺癌筛查^[46]、左心室分割^[47]上结合胶囊网络取得了较好的效果。Lalonde 等^[48]首次将胶囊网络原理扩展到医学图像分割上，其编码器与解码器均是使用胶囊网络，在二分类分割任务上取得了较优的效果，但通过改进应用到多类别分割任务上时准确率却大幅下降。Bonheur 等^[49]使用矩阵代替向量进行编码，相比于以往只对姿态信息进行编码，该网络同时将外观信息和姿态信息表示为矩阵，并通过双路由机制结合这两种信息，但由于整个网络层都有动态路由的迭代计算，最终推理时间远高于其他分割网络，目前基于胶囊网络的分割模型都会有此缺点。

2.3 注意力机制

注意力机制源于对人类视觉系统的研究，当人脑接收到外部信息后，人类视觉系统能够自然高效地将关注重点集中在重要的或者感兴趣的区域，并不会对所有信息进行处理，受此启发，注意力机制被应用到计算机视觉系统中。在计算机视觉中，注意力机制的基本思想是让系统关注图像中最重要的信息而忽略无关的信息。近年来，注意力机制在计算机视觉中应用广泛，本节从注意力域的角度来对注意力机制进行分析，主要介绍空间域注意力机制、通道域注意力机制以及前两者结合的混合域注意力机制。

（1）空间域注意力机制

图像中不同区域对任务的贡献是不一样的，空间域注意力机制主要关注图像在空间层面的特征，其目标是寻找图像中“哪里”需要关注。空间域注意力机制为每个位置生成权重掩码来加强感兴趣的特定区域并弱化不相关的其他区域。空间域注意力机制在深度学习中应用广泛，近年来，很多基于空间注意力的算法被提出。空间变换神经网络（Spatial Transformer Networks, STN）^[50]是经典的基于空间域注意力机制的网络模型，其核心空间变换（Spatial Transformer, ST）模块主要包含定位网络（Localisation net）、网格生成器（Grid generator）以及采样器（Sampler）三个部分，如图 2-8 所示，能够对各种形变数据进行转换并自动提取到重要区域特征，在图像经过旋转、平移、裁剪等操作后，依然能获得对重点区域的关注。Wang 等^[51]提出的 Non-Local Neural Networks 是建立在自注意力机制上的一种空间注意力网络模型，其中 Non-Local 模块通过捕获每个像素和图像中其他像素之间的关系来获得注意力权重，但当特征图很大时，会存在计算量过大的问题。除了以上提到的，GENet^[52]、EMANet^[53]等也是基于空间域注意力机制的网络模型。




图 2-8 空间变换模块结构图

（2）通道域注意力机制

在神经网络中，不同的通道通常代表着不同的对象，通道域注意力机制就是要在通道层面寻找图像中的“什么”是有意义的，通过网络计算出各个通道的权重，对包含关键信息的通道赋予更高的权重，对没什么重要信息的通道赋予较低的权重，从而提高特征表示能力，关注更有价值的特征。2017 年，Hu 等^[54]首次提出了通道注意力，并基于此提出了一个挤压和激励网络（Squeeze-and-Excitation Networks, SENet）。SENet 的核心部分是挤压-激励（Squeeze-and-Excitation, SE）模块，SE 块如图 2-9 所示，该模块由挤压模块和激励模块两部分组成。挤压模块通过全局平均池化操作来获取全局空间信息，激励模块包含两次全连接操作，并分别使用 ReLU 函数和 Sigmoid 函数，得到一个值域在 0~1 之间的一维的注意力权重来激活每一层通道，最后一步是放缩过程，将输入特征的每个通道与得到的注意力权重对应相乘，从而达到加强重要通道和抑制冗余信息的效果。通道注意力模块在增加少量参数数量和计算量的情况下，显著提高了性能，而且模块具有通用性，可以嵌入到其他网络模型中来提高性能。在此之后，基于通道域注意力机制的网络模型相继被提出，如 GSoP-Net^[55]、ECA-Net^[56]等。




图 2-9 挤压-激励模块结构图

（3）混合域注意力机制

混合域注意力机制是以上两种注意力机制通过串联或并联的方式进行结合，来加强对图像中重要信息的关注。混合域注意力机制中经典的模型是 Woo 等^[57]提出的卷积块注意力模块（Convolution Block Attention Module, CBAM），如图 2-10 所示。在 CBAM 中，首先是通道注意力模块，并且同时使用了全局平均池化和最大池化操作，可以有效

突出包含关键信息的区域。然后将得到的通道注意力图与输入特征图对应相乘后，再送入空间注意力模块生成空间注意力图。CBAM 将两种注意力机制进行顺序组合，相互补充，进一步提高了网络的特征提取和表示能力。与 CBAM 模块不同，scSE 模块^[58]和 BAM 模块^[59]是将两种注意力模块进行并联，同时对两者进行建模再加以融合，同样提升了网络的性能。




图 2-10 卷积块注意力模块结构图

2.4 本章小结

本章首先详细介绍了 FCN、U-Net、Attention U-Net 以及 UNet++ 等经典医学图像分割模型；随后，介绍了胶囊网络的结构、原理以及动态路由算法；最后，从空间域、通道域以及混合域三个方面阐述了注意力机制的基本概念与原理，为后续研究提供了相关理论知识。

3 基于卷积胶囊网络的医学图像分割模型

3.1 引言

在一些医学图像中，待分割结构之间会存在重叠程度过高的情况，例如胸部 X 片中的锁骨和肺部。这导致以 U-Net 为基础的卷积神经网络模型在分割重叠区域时面临挑战。这些模型虽然在编码器部分经过多次卷积与池化操作，提取了丰富的特征信息，但对位置、姿态等信息提取不足，不能很好地建模局部-整体关系。因此，在分割重叠部位时，这些模型难以进行准确区分，导致分割效果不佳。

胶囊网络以向量的形式来表示局部与整体之间的关系，包括目标的位置、姿态等信息，并通过动态路由算法动态地调整各个部分对整个对象的贡献，在建模局部-整体关系时具有更好的鲁棒性。因此，本章结合 U-Net 和胶囊网络，对 U-Net 的编码器部分进行改进，提出一种医学图像分割模型 ConvUCaps，先使用卷积模块学习低层特征，并建模局部关系，然后通过胶囊模块学习高层特征，并建模局部与整体之间的关系，充分结合两者的优势，解决待分割部位重叠带来的分割困难，提高网络模型的分割效果。

3.2 ConvUCaps 网络模型

3.2.1 网络结构设计

ConvUCaps 使用包含 21 层的网络结构，过多的网络层数会导致计算参数量太大甚至出现过拟合，过少的网络层数则会使模型缺乏泛化能力，无法充分提取特征而欠拟合，效果不佳。本文把 ConvUCaps 设计为一个编码器-解码器架构，包含 3 次下采样和 3 次上采样。在编码器部分，ConvUCaps 同时继承了卷积块和胶囊块的优点，先使用卷积模块提取不同尺度的局部特征，再通过胶囊模块学习高层特征，建模局部与整体之间的关系。网络解码器部分与 U-Net 类似，采用卷积操作和上采样将特征图逐步恢复到原图像大小。

ConvUCaps 网络结构如图 3-1 所示，整个结构主要包含三个部分，依次是卷积编码模块、胶囊编码模块以及卷积解码模块，模块与模块之间通过 reshape 操作连接。前两个模块共同组成网络编码器，逐步抽象提取到的特征，来获取更高级的语义信息。胶囊编码模块如图 3-1 中虚线框所示，其左侧是卷积编码模块，右侧是卷积解码模块。




图 3-1 ConvUCaps 网络模型结构图

(1) 卷积编码模块

卷积编码模块通过多次连续卷积操作来提取低层特征，并建模局部关系，卷积核大小均为 3×3 ，并使用 ReLU 函数作为激活函数。为了更加适应医学图像数据集小的特点，本文对原始 U-Net 网络进行优化，减少了网络深度以及特征图数量，以防止过拟合并减少参数量。输入图像首先经过 2 次步长为 1 的卷积，得到通道数为 32 的特征图，其尺寸大小与输入图像保持一致。在下采样时，使用步长为 2 的卷积操作代替最大池化，以保留更多的信息。在后续的卷积层中，通道数增加的同时，特征图大小减半，最终输出大小为 $H/4 \times W/4 \times 128$ 的特征图。

(2) 胶囊编码模块

本文使用胶囊模块来提取更高级别的特征。在进入卷积胶囊层之前，ConvUCaps 先将上一模块输出的特征图 reshape 为 $H \times W \times N \times D$ ，其中 N 为胶囊组的数量， D 为每个胶囊的维度大小，在本网络中设置为 $H/4 \times W/4 \times 8 \times 16$ 。然后通过步长为 2 的卷积胶囊操作，将特征图大小进一步缩小，同时增加胶囊的维度。整个卷积胶囊模块，卷积核大小为 3×3 ，并且路由迭代次数为 3 时，能达到最好的分割效果。

(3) 卷积解码模块

由于在上采样中使用胶囊网络所产生的效果可以忽略不计，同时胶囊与胶囊之间的动态路由会产生较高的计算成本以及时间成本，因此，在解码器部分只使用了卷积层。同样地，需要先对胶囊层最后的输出进行 reshape。卷积解码器部分的操作与 U-Net 网络上采样过程类似，每个上采样层中的上采样倍数为 2×2 ，卷积核大小为 2×2 ，在上采样运算之后，使用跳跃连接操作在通道维度与对应低层特征图进行拼接，使得网络同时

保留低层卷积的特征信息与高层胶囊的信息。解码部分的最后接有一个 1×1 的卷积层，特征图个数为 6，对应类别个数，用来得到最终的分割结果。

表 3-1 ConvUCaps 网络参数设置

Block Type	Layer Type	Kernel	Stride	Output Size
Input	Data	-	-	128×128×1
Encoder	Conv-block1	3×3	1	128×128×32
	Down sample1	3×3	2	64×64×32
	Conv-block2	3×3	1	64×64×64
	Down sample2	3×3	2	32×32×64
	Conv-block3	3×3	1	32×32×128
	Reshape1	-	-	32×32×8×16
	Down sample3	3×3 Routing=3	2	16×16×8×32
	Conv1	3×3 Routing=3	1	16×16×4×64
	Conv2	3×3 Routing=3	1	16×16×6×32
	Reshape2	-	-	16×16×192
Decoder	Upsample1	2×2	2	32×32×128
	Conv-block4	3×3	1	32×32×128
	Upsample2	2×2	2	64×64×64
	Conv-block5	3×3	1	64×64×64
	Upsample3	2×2	2	128×128×32
	Conv-block6	3×3	1	128×128×32
Output	Conv3	1×1	1	128×128×6

3.2.2 卷积胶囊网络分析

在传统胶囊网络中，上一层的每一个胶囊都会与下一层的每一个胶囊通过权重矩阵进行两两连接，上一层的胶囊会通过 $squash$ 函数进行非线性变换得到标准值，再通过耦合系数得到下一层胶囊的具体值。如果直接将传统胶囊网络应用到图像分割任务上，胶囊之间两两连接的方式会导致网络参数非常庞大，不利于网络训练并且会导致过拟合，为此，本文提出的 ConvUCaps 使用局部动态路由算法来代替原本的路由算法，其核心思想是采用滑动窗口的方式选取上一层的胶囊来对下一层的胶囊进行更新。

ConvUCaps 网络在进入卷积胶囊层之前，需要先对上一模块的输出进行 reshape，reshape 之后形成了网络的第一组胶囊，其中包含 8 个胶囊组，每个胶囊是一个 16 维向

量, 然后进入第一个卷积胶囊层, 我们将这个过程推广到网络中任意给定的卷积胶囊层。在卷积胶囊层 ℓ , 包含多个大小相等的胶囊组 $T^\ell = \{t_1^\ell, t_2^\ell, \dots, t_n^\ell \mid n \in \mathbb{N}\}$, 定义核大小 $k_h \times k_w$ (即滑动窗口)。对于每一个父胶囊 s_j , 都会收到一组预测向量 $\{\hat{u}_{j|t_1^\ell}, \hat{u}_{j|t_2^\ell}, \dots, \hat{u}_{j|t_n^\ell}\}$, 此操作通过权重矩阵 M 与子胶囊之间的矩阵乘法完成, M 的维度为 $k_h \times k_w \times d^\ell \times |T^{\ell+1}| \times d^{\ell+1}$, 通过反向传播算法更新, 并且不同胶囊组之间共享权重矩阵, 其中 d^ℓ 代表第 ℓ 层胶囊的维度, $d^{\ell+1}$ 代表第 $\ell+1$ 层胶囊的维度, $|T^{\ell+1}|$ 代表第 $\ell+1$ 层中胶囊组的个数, 然后通过局部动态路由算法调整各个预测向量的权重得到最终的结果。局部动态路由过程如表 3-2 所示。

表 3-2 局部动态路由算法过程

局部动态路由算法:	
输入:	$\hat{u}_{j t_i^\ell}, r, \ell, k_h, k_w$
输出:	v_j
1:	对第 ℓ 层胶囊位于 $k_h \times k_w$ 范围内的胶囊组 t_i^ℓ , 以及在第 $\ell+1$ 层上对应的胶囊 j :
	$b_{t_i^\ell j} \leftarrow 0$
2:	循环 r 次:
3:	对所有第 ℓ 层的胶囊组 t_i^ℓ : $c_{t_i^\ell} \leftarrow \text{softmax}(b_{t_i^\ell})$
4:	对所有第 $\ell+1$ 层的胶囊 j : $s_j \leftarrow \sum_i c_{t_i^\ell j} \hat{u}_{j t_i^\ell}$
5:	对所有第 $\ell+1$ 层的胶囊 j : $v_j \leftarrow \text{squash}(s_j)$
6:	对第 ℓ 层的胶囊组 t_i^ℓ 以及对第 $\ell+1$ 层的胶囊 j : $b_{t_i^\ell j} \leftarrow b_{t_i^\ell j} + \hat{u}_{j t_i^\ell} \cdot v_j$

接下来对单个胶囊层需要的参数量和计算量进行分析, 并和常规卷积层进行对比, 如表 3-3 所示。假定输入特征图的维度为 $H_{in} \times W_{in} \times C_{in}$, 卷积核大小为 $k_h \times k_w$, 输出特征图维度为 $H_{out} \times W_{out} \times C_{out}$, 在胶囊层中, 需要对特征图进行分组, 即输入特征图维度为 $H_{in} \times W_{in} \times N_{in} \times D_{in}$, 输出特征图维度为 $H_{out} \times W_{out} \times N_{out} \times D_{out}$, 其中, N_{in} 、 N_{out} 分别代表输入和输出中胶囊组的个数, D_{in} 、 D_{out} 分别代表输入和输出中胶囊的维度。在忽略偏置的情况下, 对于常规卷积层, 需要的参数量为 $k_h \times k_w \times C_{in} \times C_{out}$, 计算量为 $(2C_{in} \times k_h \times k_w - 1) \times C_{out} \times H_{out} \times W_{out}$ 。对于胶囊层, 如上面分析, 训练的参数量为权重矩阵 M 的大小, 即 $k_h \times k_w \times D_{in} \times N_{out} \times D_{out}$, 对于每一个父胶囊 s_j , 得到预测向量产生的计算量为 $(2D_{in} \times k_h \times k_w - 1) \times N_{in} \times D_{out}$, 然后通过局部动态路由算法得到最终结果产生的计算量 (忽略 softmax 函数以及非线性变换函数 squash 产生的计算量) 为 $(3N_{in} \times D_{out} + N_{in} - D_{out}) \times r$, 其中, r 代表动态路由迭代次数。因此, 胶囊层产生的总的计算量为 $(2D_{in} \times k_h \times k_w - 1) \times N_{in} \times D_{out} \times H_{out} \times W_{out} \times N_{out} + (3N_{in} \times D_{out} + N_{in} - D_{out}) \times r \times H_{out} \times W_{out} \times N_{out}$ 。

表 3-3 卷积层和胶囊层参数量和计算量对比

类型	参数量	计算量
卷积层	$k_h \times k_w \times C_{in} \times C_{out}$	$(2C_{in} \times k_h \times k_w - 1) \times C_{out} \times H_{out} \times W_{out}$
胶囊层	$k_h \times k_w \times D_{in} \times C_{out}$	$(2D_{in} \times k_h \times k_w - 1) \times N_{in} \times H_{out} \times W_{out} \times C_{out}$ $+ (3N_{in} \times D_{out} + N_{in} - D_{out}) \times r \times H_{out} \times W_{out} \times N_{out}$

以上分析可知，与卷积层相比，胶囊层所需参数量是卷积层的 $1/N_{in}$ ，而胶囊层计算量的增加主要来自于动态路由的迭代过程，在胶囊网络中，每一个父胶囊都需要通过动态路由算法确定，对于纯胶囊网络计算量更大，训练推理时间更长。与 U-Net 网络相比，本文提出的 ConvUCaps 网络通过使用胶囊模块，减少了参数量，使得模型更加简洁。胶囊模块虽然会带来一定计算量的增加，但通过有效建模局部与整体之间的关系，弥补了 U-Net 网络的不足，显著提高了模型的分割精度。后续实验部分展示了定量结果。

3.2.3 损失函数设计

ConvUCaps 使用加权交叉熵损失函数（Weighted Cross-Entropy Loss Function）来监督训练，它是对交叉熵损失函数的改进，可以在样本不平衡的情况下更好地处理问题。在交叉熵损失函数中，每个样本的损失函数都是一样的，这意味着在样本分布不平衡的情况下，较少的类别可能会被忽略或分类不准确，例如在胸部 X 片中，肺部的像素占比就显著高于其他部分，而锁骨相对来说就显得微乎其微。为了解决这个问题，加权交叉熵损失函数引入了样本权重，以使得在训练过程中更关注少数类别。加权交叉熵损失函数定义如下：

$$L_{wce} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^m (\omega_j y_{ij} \log(p_{ij})) \quad (3-1)$$

其中， m 表示类别个数； y_{ij} 是实际标签，如果像素 i 属于类别 j ，则取值为 1，否则取值为 0； p_{ij} 代表像素 i 被预测为类别 j 的概率； $\omega = \{\omega_1, \omega_2, \dots, \omega_m\}$ 代表预测图中每个类别的权重，用于加权在预测图中占比较小的类别对损失函数的贡献，本文根据不同类别所占像素比例作为权重项，占比越小，则系数越大，计算公式如式(3-2)所示：

$$\omega_j = \frac{N - \sum_i \hat{y}_{ij}}{N} \quad (3-2)$$

3.3 实验结果分析

3.3.1 实验环境与配置

本文使用的实验环境软硬件配置具体如表 3-4 所示，网络训练的超参数具体如表 3-

5 所示，其中学习率按照公式(3-3)进行衰减：

$$lr = initial_lr \times \gamma^{epoch/step_size} \tag{3-3}$$

其中 $initial_lr$ 的值为表 3-5 中设置的学习率，即 0.001， γ 的值设为 0.5， $step_size$ 的值设为 200，并且每迭代 200 次，在验证集上进行一次测试。

表 3-4 实验环境具体配置	
名称	值
CPU	Intel Xeon E5-2698 v4 @ 2.20GHz
内存	256 GB
显卡	NVIDIA TESLA V100 SXM 32 GB
操作系统	Ubuntu 18.04.3
python 版本	3.6.13
CUDA 版本	10.0
深度学习框架	TensorFlow 1.13.1

表 3-5 网络训练超参数	
名称	值
批次(Epoch)	40000
批量(Batch Size)	4
学习率(Learning Rate)	0.001
优化器(Optimizer)	Adam
动量(Momentum)	0.9
权重衰减(Weight Decay)	0

3.3.2 数据集与预处理

本文使用日本放射技术学会（Japanese Society of Radiological Technology, JSRT）数据集^[60]来评估各个网络模型。JSRT 数据集由 247 张标准数字图像组成，其中包含 154 张带结节的与 93 张不带结节的图像。图像分辨率为 2048×2048 像素，像素尺寸为 0.175mm。Ginneken 等^[61]对该数据集的左右肺、左右锁骨以及心脏进行了手动标注，从而得到了包括背景在内的六个标签。数据集图像与标签图像如图 3-2 所示。本文对数据集以及标签做了以下预处理：

- 1) 将各个标签进行融合处理汇总到一张图上，并通过不同灰度进行区分（如图 3-2 右所示），以方便直观观察分割效果，而在训练阶段，则需要对各个标签值依次赋值 0 到 5，分别代表：背景、左肺和右肺、左锁骨和右锁骨、心脏，以方便计算机处理；
- 2) 将图像与标签均压缩至 128×128 像素，并对输入图像进行重新缩放，使每个图

像的像素值在-1 和 1 之间；

3) 将数据集大致按照 2:1:1 的比例随机划分成训练集、验证集以及测试集；

4) 由于训练数据有限，为了防止过拟合，对输入图像进行随机数据增强，包括平移、缩放、旋转等变换形式。




图 3-2 JSRT 数据集原始图像(左)和标签图像(右)

3.3.3 评价指标

为了能够定量地评价各个网络模型对 JSRT 数据集的分割效果，本文选用医学图像分割领域最常见的评价指标 Dice 相似系数（Dice Similarity Coefficient, DSC）和交并比（Intersection over Union, IoU）进行评估。

Dice 相似系数是一种用于评估真实分割区域与预测分割区域之间相似程度的指标，取值范围是 0 到 1，并且值越大，表示预测分割区域与真实分割区域之间的相似度越高，分割效果越好，其计算公式如下所示：

$$DSC = \frac{2|T \cap P|}{|T| + |P|} \quad (3-4)$$

其中，T 代表真实分割结果，P 代表网络模型分割出来的预测结果。

交并比是另一个常用的相似度指标，也被广泛应用于分割任务的准确性评估，反映了预测分割区域和真实分割区域的重合程度，取值范围是 0 到 1，同样也是值越大，分割的效果越好，其计算公式如下所示：

$$IoU = \frac{|T \cap P|}{|T \cup P|} \quad (3-5)$$

3.3.4 不同网络模型分割结果对比

本文将 ConvUCaps 网络模型与以下网络从分割准确率、分割难点、收敛速度等多方面进行实验对比：

1) U-Net 网络，U-Net 网络是基准模型，使用加权交叉熵损失函数；

2) UNet++网络，基于 U-Net 网络模型，使用密集的跳跃连接，已在第 2.1.4 小节详细介绍，同样使用加权交叉熵损失函数；

3) Matwo-CapsNet 网络，基于胶囊网络的医学图像分割模型，该网络采用矩阵代替向量编码，并使用动态双路由方法。




图 3-3 ConvUCaps 网络对测试集样本分割结果

图 3-3 是 ConvUCaps 网络对测试集样本 JPCLN050 和 JPCLN060 的分割结果，依次是原始图像、标签图像和预测分割结果。可以看出，本文提出的 ConvUCaps 网络模型能够准确地分割出各个器官组织，特别是对于分割难点锁骨和心脏，能准确识别其位置并精准分割出来，展示了对医学图像分割的鲁棒性。

U-Net、UNet++、Matwo-CapsNet、ConvUCaps 网络在测试集样本上的分割结果对比（Dice 相似系数）如表 3-6 所示，表中 InvertedNet 网络展示的是文献^[62]中对 JSRT 数据集的分割结果，InvertedNet 网络也是基于 U-Net 网络的分割模型，该论文把数据集分成肺、锁骨、心脏还有背景四部分，不区分左右锁骨以及左右肺。所有网络模型对肺部的分割效果最好，主要是因为肺部在各个器官组织中，占比是最大的，并且位置相对固定；其次是心脏，心脏在图像中的位置相对变化较大；而对锁骨部分的分割是最难的，因为锁骨占比最小，并且与肺部高度重叠，只有 ConvUCaps 网络的 Dice 相似系数超过了 90%。U-Net 网络的平均 Dice 相似系数为 90.39%，在对各个器官组织的分割中，左右肺的分割精度是最高的，例如右肺达到了 96.73%，对于心脏的分割精度也达到了 92.87%，但是对于锁骨的分割明显低于其他部分，例如右锁骨的分割精度只有 82.92%。UNet++网络是基于 U-Net 网络的改进模型，相比于 U-Net 网络，其平均 Dice 相似系数提高了 1.71 个百分点，各个分割部分的 Dice 相似系数均得到了提高。Matwo-CapsNet

网络是基于胶囊网络的分割模型，其平均 Dice 相似系数与 UNet++网络模型差别不大，比其高 0.49 个百分点，在左右肺、左右锁骨的分割上高于 UNet++，在心脏的分割上略低于 UNet++。ConvUCaps 网络的平均 Dice 相似系数为 94.35%，显著高于其他各个网络模型，具体到各个分割部位，左右肺的分割精度与其他网络模型差别不大，而左右锁骨的分割精度则提升了很多，相比于基准模型 U-Net 网络，分别提高了 7.87 和 8 个百分点。

表 3-6 不同网络模型分割结果(Dice 相似系数)

网络模型	Dice 相似系数(%)					
	左肺	右肺	左锁骨	右锁骨	心脏	平均
U-Net	95.96	96.73	83.48	82.92	92.87	90.39
UNet++	96.79	97.01	86.91	86.13	93.65	92.10
Matwo-CapsNet	96.93	97.16	88.03	87.22	93.61	92.59
ConvUCaps	97.20	97.74	91.32	90.92	94.57	94.35
InvertedNet	96.60		88.90		94.00	93.17

表 3-7 是以交并比 IoU 为评价指标的各个网络模型在测试集样本上的分割结果对比。本文提出的 ConvUCaps 网络模型的分割精度最高，平均交并比为 90.84%，比基准模型 U-Net 网络高 3.24 个百分点。各网络模型在左右肺上的平均交并比均超过了 90%，最高为 95.58%；对于锁骨的分割，所有网络模型分割得到的平均交并比均没有超过 90%，最高为 ConvUCaps 网络对左锁骨的分割结果，其交并比为 87.03%，而最低分割精度是 U-Net 网络对右锁骨的分割结果，为 82.01%；对于心脏的分割，只有 ConvUCaps 网络的分割精度超过了 90%，为 90.12%，而最低为 87.69%，具体分割结果见表 3-7。

表 3-7 不同网络模型分割结果(交并比 IoU)

网络模型	交并比(%)					
	左肺	右肺	左锁骨	右锁骨	心脏	平均
U-Net	92.23	93.67	82.39	82.01	87.69	87.60
UNet++	93.78	94.19	85.38	85.03	88.66	89.41
Matwo-CapsNet	94.04	94.48	86.37	85.65	88.31	89.77
ConvUCaps	94.55	95.58	87.03	86.92	90.12	90.84

图 3-4 是各个网络模型对测试集样本 JPCLN020 的可视化分割结果，其中图 3-4 (a) 是原始图像，图 3-4(b)到图 3-4(f)是标签图像以及各个网络模型预测分割结果与原始图像叠加显示的效果图。在 JPCLN020 测试样本中，U-Net 网络对左肺、右肺、左锁骨、右锁骨以及心脏分割的 Dice 相似系数依次为 97.02%、97.13%、86.71%、86.92%、90.12%，

平均 Dice 相似系数为 91.58%；UNet++网络分割结果依次为 97.23%、97.55%、87.69%、88.28%、91.01%，平均 Dice 相似系数为 92.35%；Matwo-CapsNet 网络分割结果依次为 97.93%、98.02%、88.93%、88.32%、91.54，平均 Dice 相似系数为 92.95%；ConvUCaps 网络分割结果依次为 98.15%、98.62%、91.52%、91.13%、94.67%，平均 Dice 相似系数为 94.82%。在该测试样本中，各网络模型除了在分割细节上有差别，均实现了对各个部分的基本准确分割。




图 3-4 各网络模型对 JPCLN020 样本分割结果

接下来展示不同网络模型对部分测试样本的分割效果，并结合可视化分割结果分析各网络模型的不足。图 3-5 是 U-Net 网络对 JPCNN078 测试样本的分割结果，U-Net 网络作为医学图像分割模型的基准模型，可以基本实现分割任务，但与胶囊网络相比，对位置、姿态等特征信息提取不足，难以依靠位置信息来提高分割效果，特别是在器官重叠部分难以准确找到其区域轮廓，而在胸部 X 片图像中各个器官组织都有相对固定的位置，故如图 3-5 中红框框出所示，U-Net 网络对锁骨以及肺顶部分割效果较差。



图 3-5 U-Net 网络对 JPCNN078 样本分割结果

图 3-6 是 UNet++网络对 JPCLN148 测试样本的分割结果。UNet++网络是对不同深度的 U-Net 网络的高效集成，并对跳跃连接进行了重新设计。与 U-Net 网络相比，各个部分的分割效果均得到了提高。但与 U-Net 网络一样，UNet++本质上也是全卷积网络模型，同样对位置、姿态等特征提取不足，无法准确建立好局部与整体之间的关系，故虽然有所改善，但同样无法实现对锁骨的准确分割，如图 3-6 中红框框出所示，会出现一些独立地分割区域，把属于肺部的区域错误地分割成了锁骨。




图 3-6 UNet++网络对 JPCLN148 样本分割结果

Matwo-CapsNet 网络是基于胶囊网络的分割模型，通过胶囊机制与动态路由算法可以有效建模局部与整体之间的关系，故能准确找到各个器官在图像中的位置。Matwo-CapsNet 网络与基于 U-Net 网络的全卷积网络模型相比，同一类别的待分割区域基本会连成一个整体，较少会出现断开而形成了多个独立区域的情况。但是由于 Matwo-CapsNet 网络更注重位置关系的提取，对细节信息如边缘特征提取不充分，会存在各器官组织分割边缘不平滑的问题，同时偶尔由于心脏和左肺相邻部分位置差异大导致对左肺底部分割效果较差，如图 3-7 对 JPCLN070 测试样本分割结果所示。



图 3-7 Matwo-CapsNet 网络对 JPCLN070 样本分割结果

本文提出的 ConvUCaps 网络模型，将 U-Net 网络和胶囊网络进行结合，既保留了卷积块在不同尺度下提取局部特征的优势，又能通过胶囊模块在高层特征上提取目标的位置、姿态等特征信息，建模局部与整体之间的关系，如图 3-8 对 JPCNN070 测试样本分割结果所示，对各器官组织结构均实现了准确的分割。




图 3-8 ConvUCaps 网络对 JPCNN070 样本分割结果

3.3.5 不同网络模型性能分析

图 3-9 展示了不同训练次数下各个网络模型的平均分割准确率（Dice 相似系数）迭代曲线。在训练初期，各个网络模型都能快速收敛，然后趋于平稳，具体而言，最慢的是 U-Net 网络，然后依次是 UNet++网络和 Matwo-CapsNet 网络，最快的是本文提出的 ConvUCaps 网络。U-Net 网络在训练初期，平均分割准确率曲线起伏比较大，但整体呈快速上升趋势，在大约 13000 次迭代后，平均分割准确率上升趋于平稳。UNet++网络平均分割准确率迭代曲线整体在 U-Net 网络的上面，曲线的起伏变化趋势与 U-Net 网络接近。Matwo-CapsNet 网络平均分割准确率迭代曲线在后半部分与 UNet++网络的大致上接近重合，而在训练初期，曲线基本在 UNet++网络上面，收敛速度明显快于 UNet++网络，这得益于胶囊网络机制能够快速、准确地定位各个器官组织的位置，从而实现较快收敛。本文提出的 ConvUCaps 网络的收敛速度明显快于其他网络模型，在训练初期能迅速收敛，大约在 7000 次迭代时，就能将平均分割准确率提升到 90%。从平均分割准确率迭代曲线不难看出，将 U-Net 网络和胶囊网络进行结合，充分发挥各自优势，能大幅度提高网络模型分割准确率以及收敛速度。




图 3-9 不同网络模型平均分割准确率迭代曲线

接下来对分割难点锁骨和心脏进行单独分析，图 3-10 展示了在不同训练次数下各个网络模型对锁骨和心脏分割准确率（Dice 相似系数）的迭代曲线。锁骨是胸部 X 片中最难分割的部分，因为锁骨在整个胸部 X 片中占比最小，并且与肺部高度重叠，就算凭借肉眼也难以准确将其分割出来。从图 3-10(a)可以看出，U-Net 网络和 UNet++网络在训练初期曲线大致重合，在训练后期 UNet++网络的锁骨分割准确率高于 U-Net 网络。Matwo-CapsNet 网络的收敛速度快于 U-Net 网络和 UNet++网络，而在训练后期迭代曲线与 UNet++网络迭代曲线大致重合。综合来看，U-Net、UNet++以及 Matwo-CapsNet 网络的锁骨分割准确率迭代曲线比较接近，ConvUCaps 网络的锁骨分割准确率迭代曲线明显高于其他网络模型，在训练初期能快速定位至锁骨部分，并能迅速收敛，这主要是卷积模块和胶囊模块进行结合带来的效果，而基准模型 U-Net 网络在大约 2000 次迭代后才开始出现对锁骨的分割，在迭代曲线后期分割准确率上下浮动也比较大。心脏在胸部 X 片中，也是较难分割的部位。由于大致位置是固定的，因此，各个网络模型在训练初期都能迅速收敛，如图 3-10(b)所示，各条迭代曲线在最开始重合度较高。同时图中可以看出，U-Net 网络和 UNet++网络迭代曲线上下起伏较大，无法稳定地对心脏进行准确分割，Matwo-CapsNet 网络和 ConvUCaps 网络能利用胶囊网络的优势稳步提高对心脏的分割。




图 3-10 不同网络模型对锁骨以及心脏分割准确率迭代曲线

本文进一步将 ConvUCaps 网络与其他医学图像分割模型在编解码器组成、参数量、推理时间以及分割准确率 (Dice 相似系数和平均交并比) 上进行了对比, 如表 3-8 所示, 其中推理时间统计的是对所有测试集样本进行分割所消耗的时间。U-Net 网络编码器与解码器部分均是由卷积块组成, 其推理时间是最短的, 但是分割准确率是最低的。UNet++网络是对 U-Net 网络的改进, 编码器与解码器部分同样是由卷积块组成, 相比 U-Net 网络, 分割准确率得到了提高, 但推理时间变长, 特别是参数量增加了很多。Matwo-CapsNet 网络的编码器与解码器部分均是由胶囊组成, 胶囊层的参数量明显少于卷积层, 但由于动态路由的迭代计算, 其计算量高于卷积层, 故 Matwo-CapsNet 网络的推理时间明显高于其他网络模型。本文提出的 ConvUCaps 网络模型, 在编码器部分同时使用卷积模块和胶囊模块来提取特征, 在解码器部分使用卷积块来还原特征图大小。与 U-Net 网络和 UNet++网络相比, ConvUCaps 网络虽然推理时间变长, 但减少了参数量, 特别是显著提高了分割准确率; 与基于胶囊网络的 Matwo-CapsNet 网络相比, ConvUCaps 网络能在显著减少推理时间的同时, 提高模型的分割准确率。

表 3-8 不同网络模型编解码器组成、参数量、推理时间与分割准确率对比

网络模型	编码器			解码器		参数量	推理时间 (s)	分割准确率	
	卷积	胶囊	卷积&胶囊	卷积	胶囊			Dice(%)	IoU(%)
U-Net	✓	×	×	✓	×	2.12×10^6	47	90.39	87.60
U-Net++	✓	×	×	✓	×	9.05×10^6	56	92.10	89.41
Matwo-CapsNet	×	✓	×	×	✓	4.30×10^4	184	92.59	89.77
ConvUCaps	×	×	✓	✓	×	1.28×10^6	80	94.35	90.84

3.3.6 实验结论

通过实验发现, 本文提出的基于卷积胶囊网络的 ConvUCaps 模型在胸部 X 片的分

割准确率上要明显高于基于卷积神经网络的 U-Net 网络以及 U-Net 变体 UNet++网络、基于胶囊网络的分割模型 Matwo-CapsNet 网络，并且具有更快的收敛速度。同时与单纯基于胶囊网络的分割模型相比，显著减少了推理时间。

通过在 JSRT 测试集样本上的分割结果可以看出，对于左右肺部的分割，各个网络模型整体实现了较好分割，不过在细节部分，比如与锁骨出现重叠的肺顶部，各网络模型分割效果会有所差别；对于心脏的分割，容易造成过分割，但基本可以实现分割任务；然而，在分割识别困难、重叠程度高的锁骨部分，各网络模型的分割效果差别较大，结合了 U-Net 和胶囊网络的 ConvUCaps 在训练初期就能快速准确定位锁骨，实现对锁骨的较好分割。综合以上分析，基于卷积胶囊网络的 ConvUCaps 网络，使用卷积模块学习低层特征并建模局部关系，然后通过胶囊模块学习高层特征并建模局部与整体之间的关系，从而保存目标的位置、姿态等信息，缓解了重叠程度高带来的分割困难，在保持模型参数量和推理时间均较低的情况下，提高对胸部 X 片的分割效果。

3.4 本章小结

本章针对医学图像中待分割结构之间重叠程度高而导致的分割困难问题，提出了一种基于 U-Net 和胶囊网络的医学图像分割模型 ConvUCaps。该模型引入胶囊网络对 U-Net 的编码器部分进行改进，使用卷积模块学习低层特征，并建模局部关系，然后通过胶囊模块学习高层特征，并建模局部与整体之间的关系，从而保存目标的位置、姿态等信息，缓解了重叠程度高带来的分割困难。

然而，在有些医学图像中，待分割结构之间的重叠表现并不明显，对分割效果影响不大。这些图像更显著的特点是待分割结构边界模糊、形状和大小变化较大，这严重影响了分割效果。例如，在腹部 CT 图像中，肝脏的边界不清晰，而且由于切片位置的不同，肝脏的形态和大小变化较大，这使得肝脏难以被准确分割。因此，下一章将重点讨论如何解决待分割结构边界模糊、形状和大小多变带来的分割困难问题。

4 基于多尺度特征和注意力机制的医学图像分割模型

4.1 引言

在第三章中,使用胶囊编码模块对 U-Net 网络进行改进,有效解决了医学图像因为待分割结构之间重叠程度过高带来的分割困难问题。然而,在部分医学图像中,待分割结构之间的重叠并不明显,对分割效果影响不大。这些图像主要表现出边界模糊、形态和大小变化较大的特点,这导致现有的 U-Net 模型在处理这类医学图像时,难以准确分割出待分割结构。其原因主要是:1)虽然跳跃连接操作把低层特征图中包含的边缘细节信息保存了,但同时带来了大量的冗余信息,并没有加强对边缘细节信息的关注;2)没有考虑不同感受野大小对分割效果的影响。不同的感受野大小对器官的敏感度不同,使得所提取到的特征图在语义上存在差异,这有助于模型检测出尺度变化较大的对象。

针对上述不足,本章提出一种基于多尺度特征和注意力机制的分割模型 RAE-U-Net。本章工作主要包含以下几个方面:

- 1)采用残差卷积模块代替 U-Net 网络中的普通卷积模块,避免梯度消失或爆炸,并提高特征信息的利用率;
- 2)引入通道注意力机制,并基于此提出多尺度通道注意力模块 MCAB。在使用跳跃连接将下采样部分输出的低层特征图与对应的上采样特征图进行拼接前,该模块首先利用高低层特征图生成注意力权重,然后对低层特征图各通道进行加权,从而加强对边缘细节信息的关注并抑制无关信息的干扰;
- 3)在编码器与解码器之间引入改进的 DenseASPP 模块。该模块采用不同空洞率的密集空洞卷积获得不同大小的感受野,使网络能捕获到不同层次的特征,获得多尺度上下文信息,从而更好地判定图像中像素所属的类别,克服形状和大小多变带来的分割困难。

4.2 RAE-U-Net 网络模型

4.2.1 整体网络结构设计

RAE-U-Net 网络模型结构如图 4-1 所示。RAE-U-Net 模型以 U-Net 为基础,除了常规的跳跃连接、最大池化、上采样等操作之外,还集成了残差卷积模块 Res-block、多尺度通道注意力模块 MCAB 和密集空洞空间金字塔池化模块 DenseASPP,接下来的各小节会依次对各个模块进行具体介绍。




图 4-1 RAE-U-Net 网络模型结构图

在 RAE-U-Net 网络中，输入图像尺寸大小 $512 \times 512 \times 1$ ，在经过四次残差卷积模块和四次最大池化操作后，得到尺寸为 $32 \times 32 \times 256$ 的特征图。然后将得到的特征图送入 DenseASPP 模块，其采用不同空洞率的卷积进行操作，来增大感受野提取更丰富的特征信息，DenseASPP 模块输出特征图大小为 $32 \times 32 \times 512$ 。再将上采样得到的特征图与编码器部分对应层的特征进行连接，但是在通道维度进行拼接时，需要通过 MCAB 模块来调整跳跃连接过来的低层特征图各个通道的权重，加强对低层边缘等细节信息的关注程度，抑制无用信息，然后再送入残差卷积模块进行特征融合，在依次经过四次上采样、MCAB 模块以及残差卷积模块操作之后，得到尺寸为 $512 \times 512 \times 32$ 的特征图，此时尺寸大小已恢复至与输入图像大小一致。接下来使用 1×1 卷积对通道信息进行聚合，得到尺寸大小为 $512 \times 512 \times 2$ 的特征图，最后通过使用 *softmax* 函数来得到最终的分割结果。表 4-1 详细列出了 RAE-U-Net 网络的参数设置。

表 4-1 RAE-U-Net 网络参数设置

Block Type	Layer Type	Kernel	Stride	Output Size
Input	Data	-	-	$512 \times 512 \times 1$
Encoder	Res-block1	3×3	1	$512 \times 512 \times 32$
	Max pooling1	2×2	2	$256 \times 256 \times 32$
	Res-block2	3×3	1	$256 \times 256 \times 64$
	Max pooling2	2×2	2	$128 \times 128 \times 64$
	Res-block3	3×3	1	$128 \times 128 \times 128$
	Max pooling3	2×2	2	$64 \times 64 \times 128$
	Res-block4	3×3	1	$64 \times 64 \times 256$
	Max pooling4	2×2	2	$32 \times 32 \times 256$
	DenseASPP	3×3 ,Ds-conv, Rate=1,2,5,7	1	$32 \times 32 \times 512$

Block Type	Layer Type	Kernel	Stride	Output Size
Decoder	Upsample1	2×2	2	64×64×256
	MCAB1	-	-	64×64×512
	Res-block5	3×3	1	64×64×256
	Upsample2	2×2	2	128×128×128
	MCAB2	-	-	128×128×256
	Res-block6	3×3	1	128×128×128
	Upsample3	2×2	2	256×256×64
	MCAB3	-	-	256×256×128
	Res-block7	3×3	1	256×256×64
	Upsample4	2×2	2	512×512×32
	MCAB4	-	-	512×512×64
	Res-block8	3×3	1	512×512×32
Output	Conv	1×1	1	512×512×2

4.2.2 残差卷积模块—Res-block

在传统的深度卷积神经网络中，随着网络层数的增加，模型的训练难度和时间复杂度都会大大增加，同时，网络中存在的梯度消失问题也会限制网络的深度，导致模型的性能达不到理论上的极限。残差网络（Residual Network, ResNet）是 2015 年由何凯明等^[63]提出的一种深度卷积神经网络，其主要目的是解决深度网络训练中的梯度消失和过拟合问题，提高网络的表达能力和泛化能力。

ResNet 网络的核心部分是残差结构，如图 4-2 所示，图中右侧的连接线表示恒等映射。假设网络的输入为 x ， x 在连续经历两次卷积运算并激活后得到输出 $F(x)$ ，即：

$$F(x) = \sigma(W_2 \sigma(W_1 x)) \quad (4-1)$$

其中， σ 代表 ReLU 激活函数， W_1 和 W_2 代表两个连续卷积层的权重矩阵，公式中省略了偏置项。 $F(x)$ 与输入值 x 相加后得到 $H(x)$ ，最后对 $H(x)$ 使用 ReLU 函数激活后输出。这样的残差连接方式使得网络学习的内容转换成了对残差函数 $F(x) = H(x) - x$ 的学习。当 $F(x) = 0$ 时， $H(x) = x$ ，网络只剩下了恒等映射 x ，使得有无冗余层的网络效果相同，从而很大程度上缓解了网络性能退化的问题；当 $F(x) \neq 0$ 时， $F(x) = H(x) - x$ ，则网络又能学习到新的特征。对 $H(x)$ 进行链式求导，结果如下：

$$\frac{\partial H(x)}{\partial x} = \frac{\partial [F(x) + x]}{\partial x} = \frac{\partial F(x)}{\partial x} + 1 \quad (4-2)$$

可以看出，残差连接相当于给每个训练参数的导数加上了一个常数项 1，即使导数 $\frac{\partial F(x)}{\partial x}$ 的值很小，趋近于 0，反向传播依然能正常进行，同时也能避免梯度消失或爆炸的问题。




图 4-2 残差连接结构图

受 ResNet 中残差结构的启发，本文在 RAE-U-Net 网络模型中加入了 Res-block 模块。如图 4-3 所示，本文使用带有残差结构的卷积模块（图 4-3(b)）代替原始 U-Net 网络模型中的普通卷积模块（图 4-3(a)）。带有残差结构的卷积模块 Res-block 除了仍然使用两个卷积核大小为 3×3 的卷积层进行特征信息的提取，在残差连接中加入了一个 1×1 卷积用来调整输入特征图的通道数。此外，Res-block 模块中使用的批量归一化（Batch Normalization, BN）操作，也能在一定程度上避免梯度消失或爆炸，加快网络的收敛速度。




图 4-3 普通卷积模块与残差卷积模块结构图

4.2.3 多尺度通道注意力模块—MCAB

深度学习中的注意力机制与人类视觉系统类似，能够自然高效地关注到图像中的重要信息。Hu 等^[54]首次提出了基于通道域注意力机制的 SENet 网络模型，其核心是通过挤压-激励 SE 模块来获取特征图通道的注意力权重，具体在相关理论知识 2.3 小节介绍过。Wang 等^[56]基于 SE 模块进行改进，提出了 ECA-Net 网络模型，该论文认为 SE 模块中采用的两次全连接操作会对获取通道之间的依赖关系产生负面影响，并且效率较低，因此提出了一种高效通道注意力（Efficient Channel Attention, ECA）模块，使用一维卷积代替全连接操作来进行跨通道交互，卷积核大小确定了跨通道交互的范围，ECA 模块结构图如图 4-4 所示。ECA 模块在通过全局平均池化操作之后，使用一维卷积来获取通道之间的依赖关系，然后通过 Sigmoid 函数得到最终的注意力权重。该模块提出了一种自适应方法确定卷积核大小 k ，这使得 k 与特征图的通道数成正比例关系，避免了手动调整其大小。




图 4-4 ECA 模块结构图

受 ECANet 的启发，本文以 ECA 模块为基础，提出了一种新颖的多尺度通道注意力模块—MCAB 模块，它利用高低层特征图来建立通道之间的相互依赖关系，能自动从大量信息中加强对重要特征信息的选择。低层特征图含有丰富的边缘信息，但同时含有大量冗余信息，使得网络无法高效利用边缘细节信息。MCAB 模块能够调节通过跳跃连接传递过来的低层特征图中各个通道的权重，加强对边缘细节信息的关注并抑制其他冗余信息。MCAB 模块的完整结构如图 4-5 所示。




图 4-5 MCAB 模块结构图

接下来详细描述 MCAB 模块，首先使用全局平均池化操作来聚合每个通道，低层特征图 XL_{input} 和高层特征图 XH_{input} 分别通过全局平均池化操作得到统计量 Z_1 和 Z_2 。 Z_1 和 Z_2 的第 c 个元素分别由公式(4-3)和(4-4)计算得到，如下所示：

$$Z_{c1} = F_{Lsq}(XL_{input}) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W u_c(i, j) \quad (4-3)$$

$$Z_{c2} = F_{Hsq}(XH_{input}) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W u_c(i, j) \quad (4-4)$$

其中， H 和 W 分别代表特征图的高度和宽度， u_c 代表第 c 个通道的特征图， $XL_{input} \in \mathbb{R}^{H \times W \times C}$ ， $XH_{input} \in \mathbb{R}^{H \times W \times C}$ ，两者具有相同的通道数。

随后，经过包含一维卷积层和 Sigmoid 激活函数的瓶颈层，瓶颈层可以控制模型的复杂度并捕获 S_1 和 S_2 的通道依赖关系，表达式依次如下：

$$S_1 = F_{Lex}(Z_1, k) = \delta(C1D_k(Z_1)) \quad (4-5)$$

$$S_2 = F_{Hex}(Z_2, k) = \delta(C1D_k(Z_2)) \quad (4-6)$$

其中， δ 代表 Sigmoid 激活函数， $C1D_k$ 代表一维卷积操作， k 是卷积核大小，其大小的确定如公式(4-7)所示：

$$k = \psi(C) = \left\lfloor \frac{\log_2(C)}{\gamma} + \frac{b}{\gamma} \right\rfloor_{odd} \quad (4-7)$$

其中， C 代表特征图通道数， γ 和 b 为常数，分别取值 2 和 1， $|t|_{odd}$ 代表最接近于 t 的奇数。

然后，使用 F_{add} 函数将来自高层和低层特征图得到的权重进行结合，如公式(4-8)所示：

$$S = F_{add}(S_1, S_2) = S_1 + S_2 \quad (4-8)$$

再将融合得到的权重 S 与来自跳跃连接的低层特征图通过 F_{scale} 函数进行结合，来调节各个特征图的权重，达到增强重要信息，抑制无用信息的目的，表达式如下所示：

$$x_c = F_{scale}(u_c, s_c) = s_c \cdot u_c \quad (4-9)$$

其中， F_{scale} 函数指的是 XL_{input} 的第 c 个通道的特征图和来自 S 中的标量 s_c 之间的乘积，得到 $XL_{output} = [x_1, x_2, \dots, x_c]$ 。

最后，将得到的 XL_{output} 和高层特征图 XH_{input} 通过通道叠加的方式得到输出 X_{output} 。

4.2.4 密集空洞空间金字塔池化模块—DenseASPP

空洞空间金字塔池化（Atrous Spatial Pyramid Pooling, ASPP）是一种在语义分割任务中常用的特征提取技术，由 Chen 等^[64]在 DeepLab V2 网络中提出，旨在扩大感受野，捕获多尺度上下文信息，但过大的空洞率以及不恰当地使用会导致大量信息没有被利用。Yang 等^[65]提出 DenseASPP 对其进行改进，将 DenseNet 网络中密集连接的思想应用到 ASPP 中，在获得更丰富的多尺度上下文信息同时，显著增加了参数量和计算量。

基于此，本文提出的 DenseASPP 具有如下特点：

- 1) 引入通道域注意力机制 ECA 模块来调整输入特征图各个通道的权重，增强对有用信息的关注；
- 2) 使用深度可分离卷积代替标准卷积运算，以有效减少参数量和计算量，加快训练速度；
- 3) 使用密集的空洞卷积，并通过对空洞率大小的设置避免连续使用空洞卷积带来的问题。

接下来先介绍深度可分离卷积和空洞卷积，再详细介绍本文提出的 DenseASPP 模块。

（1）深度可分离卷积

深度可分离卷积^[66]是在标准卷积运算的基础上进行的改进，旨在减少参数量和计算量。它将标准卷积操作分解成两个步骤：深度卷积（Depthwise Convolution）和逐点卷积（Pointwise Convolution）。深度卷积只考虑每个通道内的信息，对每个通道进行独立的卷积运算，这样可以减少卷积核的参数量。逐点卷积则是对深度卷积的输出进行全局卷积操作，以实现不同通道之间的信息交互，其卷积核大小为 1×1 。

对于标准卷积操作，假设输入特征图的维度为 $H_{in} \times W_{in} \times C_{in}$ ，卷积核大小为 $k_h \times k_w$ ，输出特征图维度为 $H_{out} \times W_{out} \times C_{out}$ ，则该卷积层需要的参数量为 $k_h \times k_w \times C_{in} \times C_{out}$ （忽略偏置），计算量为 $2C_{in} \times k_h \times k_w \times C_{out} \times H_{out} \times W_{out}$ （不忽略偏置）。在深度可分离卷积中，首先由深度卷积对每个通道进行独立运算，得到的特征图通道数与输入通道数一致，因此深度卷积操作需要的参数量为 $k_h \times k_w \times C_{in}$ ，计算量为 $2k_h \times k_w \times C_{in} \times H_{out} \times W_{out}$ 。在处理完所有通道后将得到的输出特征图进行 1×1 逐点卷积，得到

最终的输出特征图，逐点卷积操作的参数量为 $C_{in} \times C_{out}$ ，计算量为 $2C_{in} \times C_{out} \times H_{out} \times W_{out}$ 。综上分析可知，一次深度可分离卷积所需参数数量与一次标准卷积所需参数数量之比为：


$$\frac{k_h \times k_w \times C_{in} + C_{in} \times C_{out}}{k_h \times k_w \times C_{in} \times C_{out}} = \frac{1}{C_{out}} + \frac{1}{k_h \times k_w} \quad (4-10)$$

计算量之比为：

$$\frac{2k_h \times k_w \times C_{in} \times H_{out} \times W_{out} + 2C_{in} \times C_{out} \times H_{out} \times W_{out}}{2C_{in} \times k_h \times k_w \times C_{out} \times H_{out} \times W_{out}} = \frac{1}{C_{out}} + \frac{1}{k_h \times k_w} \quad (4-11)$$

在本文中， $k_h \times k_w$ 的大小为 3×3 ，而在深度卷积神经网络中， C_{out} 的取值往往远大于 $k_h \times k_w$ ，此时深度可分离卷积操作所需的参数数量和计算量是标准卷积操作的 $1/9$ ，因此，在网络模型中使用深度可分离卷积能有效减少模型的参数数量和计算量。

为了减少 DenseASPP 模块的参数数量以及降低计算复杂度，在该模块中使用深度可分离卷积代替 3×3 卷积操作。如图 4-6(a)所示，标准卷积模块由 3×3 卷积、BN 层以及 ReLU 激活函数组成；深度可分离卷积模块由 3×3 深度卷积、 1×1 逐点卷积以及分别加上 BN 层与 ReLU 激活函数组成，如图 4-6(b)所示。



(a) 标准卷积模块 (b) 深度可分离卷积模块

图 4-6 标准卷积模块与深度可分离卷积模块

(2) 空洞卷积

空洞卷积^[67]通过在卷积核内部加入空洞（添加零值），使得通过卷积操作得到的特征图包含更大范围的信息，能够实现在不增加参数数量的条件下获得与大尺寸卷积核相同的感受野。在卷积神经网络中，感受野通常是指网络中每一层神经元所能感受到的输入图像区域大小。较大的感受野意味着提取到的特征中包含更多的上下文信息，可以提取更加丰富的、语义层次更高的特征，较小的感受野可以包含更多的细节与局部信息。

空洞卷积通过空洞率来控制卷积核中插入空洞的间隔大小，进而影响感受野的大小。

设常规卷积的卷积核大小为 k ，则空洞卷积（空洞率设置为 r ）的卷积核大小 k' 计算公式如下所示：

$$k' = k + (k - 1) \times (r - 1) \quad (4-12)$$

空洞卷积能够在保持特征图分辨率不变的情况下扩大感受野，有助于精确定位目标，并且设置不同的空洞率可以获得不同大小的感受野，有助于捕获多尺度上下文信息。当连续使用空洞卷积时，能够使得感受野呈指数级增长，但也会存在网格效应。如图 4-7 所示，卷积核大小均设置为 3×3 ，图 4-7(a)是连续使用空洞率为 2 的效果图，图 4-7(b)的空洞率大小设置为[1, 2, 3]，两者连续堆叠后具有相同的感受野大小，均为 13×13 ，但是图 4-7(a)中有很多像素点没有参与到中间红色像素点的计算，这导致经过空洞卷积操作得到的某一层的特征图，相邻像素点是从相互独立的像素点经过卷积操作得到的，它们之间缺少依赖，从而造成局部信息丢失。此外，由于空洞卷积的稀疏采样，远距离卷积操作得到的结果之间缺乏相关性，从而影响分割效果。




图 4-7 固定空洞率与可变空洞率堆叠效果对比

通过堆叠使用具有不同空洞率的空洞卷积，可以避免上述问题，保证对图片特征信息的全覆盖，此时的设计遵循混合空洞卷积 HDC^[68]的设计原则，具体如下：

- 1) 堆叠的空洞卷积的空洞率之间最大公约数为 1；
- 2) 空洞率设计成锯齿状结构；
- 3) 假设总共连续堆叠 n 个空洞卷积，卷积核大小均为 $k \times k$ ，则需要满足以下关系式：

$$\begin{cases} M_i = \max(M_{i+1} - 2r_i, M_{i+1} - 2(M_{i+1} - r_i), r_i) \\ M_n = r_n \end{cases} \quad (4-13)$$

其中， r_i 代表第 i 层空洞卷积的空洞率， M_i 代表第 i 层空洞卷积中两个非零值之间的最大距离，则最后一层的最大距离 M_n 为该层空洞卷积的空洞率大小 r_n ，并且能让 $M_2 \leq k$ ，即

第二层的最大距离 M_2 不超过该层的卷积核大小。

按照混合空洞卷积 HDC 的设计原则, 本文的 DenseASPP 模块中使用的空洞率依次设置为[1, 2, 5, 7], 由于是密集连接, 相当于包含四个分支, 第一个分支是卷积核大小为 3×3 以及空洞率为 1 的卷积 (即普通卷积操作), 能够保留特征图中的细节信息; 第二个分支以 3×3 卷积为基础, 空洞率为[1, 2]; 第三个分支以 3×3 卷积为基础, 空洞率为[1, 2, 5]; 第四个分支以 3×3 卷积为基础, 空洞率为[1, 2, 5, 7]。DenseASPP 通过密集堆叠空洞卷积来获得更大的感受野, 提取更深层次的特征信息, 各个分支按照通道维度将捕获到的不同感受野大小的特征信息进行特征融合, 实现了多尺度特征信息的提取。




图 4-8 DenseASPP 模块结构图

接下来详细介绍本文使用的密集空洞空间金字塔池化模块—DenseASPP。如图 4-8 所示, DenseASPP 上半部分采用的是基于通道域注意力机制的 ECA 模块对输入特征图进行权重调整, 得到输出特征图 $y^{(0)}$, 其计算公式如下所示:

$$y^{(0)} = \delta \left(C1D_k(GAP(x)) \right) \cdot x \quad (4-14)$$

其中, x 代表 DenseASPP 模块的输入特征图, $GAP(x)$ 代表全局平均池化操作, $C1D_k$ 代表一维卷积操作, 如 4.2.3 小节介绍, 卷积核大小 k 由输入特征图通道数确定, δ 代表 Sigmoid 激活函数。

DenseASPP 模块下半部分由密集的带有空洞率的深度可分离卷积构成, 卷积核大小均为 3×3 , 每一层深度可分离卷积操作都会把之前所有层的输出特征图作为输入, 空洞率大小依次设置为[1, 2, 5, 7], 能避免出现网格化效应。每一层深度可分离卷积操作的输入特征图如下所示:

$$\begin{cases} x^{(1)} = x \\ x^{(2)} = x^{(1)} \oplus D_{1,1}(x^{(1)}) \\ x^{(3)} = x^{(2)} \oplus D_{2,2}(x^{(2)}) \\ x^{(4)} = x^{(3)} \oplus D_{3,5}(x^{(3)}) \end{cases} \quad (4-15)$$

其中, $D_{l,r}$ 代表第 l 层的深度可分离卷积操作, 并且空洞率设置为 r 。因此, 可以得到每一层的输出, 如下所示:

$$\begin{cases} y^{(1)} = D_{1,1}(x^{(1)}) \\ y^{(2)} = D_{2,2}(x^{(2)}) \\ y^{(3)} = D_{3,5}(x^{(3)}) \\ y^{(4)} = D_{4,7}(x^{(4)}) \end{cases} \quad (4-16)$$

然后将上半部分得到的输出 $y^{(0)}$ 与四层深度可分离卷积操作得到的输出进行拼接, 如公式(4-17)所示:

$$y = y^{(0)} \oplus y^{(1)} \oplus y^{(2)} \oplus y^{(3)} \oplus y^{(4)} \quad (4-17)$$

其中, $\oplus$ 代表将特征图按照通道维度进行拼接, 得到输出 y 。最后通过 1×1 卷积调整输出通道数, 得到 DenseASPP 模块的最终输出。

DenseASPP 模块对输入特征图采用不同空洞率的卷积进行操作, 来获得不同感受野大小并增加了感受野范围, 同时使用深度可分离卷积来减少参数量, 能够优化网络模型, 提高网络的训练速度。DenseASPP 模块的输出包含了比原始输入更丰富的信息, 有助于解决形状以及大小变化较大的器官分割问题。

4.2.5 加权损失函数设计

本文采用二元交叉熵损失函数 (Binary Cross Entropy Loss, BCE) 和 Dice 损失函数相结合方式来监督训练。

二元交叉熵损失函数计算简单, 并且能够迅速地减少模型输出和真实标签之间的差距, 使得模型训练收敛更快, 其计算公式如下:

$$L_{BCE} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] \quad (4-18)$$

其中, y_i 代表像素 i 的标签值, 取值为 0 或 1, p_i 代表像素 i 与标签值一致的预测概率。

Dice 损失函数计算公式如下:

$$L_{Dice} = 1 - \frac{2 \sum_{i=1}^N y_i p_i + \varphi}{\sum_{i=1}^N y_i + \sum_{i=1}^N p_i + \varphi} \quad (4-19)$$

其中, φ 代表平滑因子, 取值范围为 0 到 1, 用来避免分母的值出现 0 的情况, 在本实验中, φ 取值为 $1e-5$ 。

本文将二元交叉熵和 Dice 损失函数相结合来优化模型的训练过程, 最终的加权损失函数计算公式如下所示:

$$L_{all} = L_{Dice} + \alpha L_{BCE} \quad (4-20)$$

其中, α 表示权重系数, 用来平衡 Dice 损失函数和二元交叉熵损失函数所占的比例。在本实验中, 当 α 取值为 0.5 时, 能够得到最好的分割结果。

4.3 实验结果与分析

4.3.1 实验环境与配置

本文使用的实验环境硬件具体配置与 3.3.1 节所述一致, 而软件环境使用 Pytorch 深度学习框架, python 版本为 3.6.5, CUDA 版本为 10.0。网络训练的超参数具体设置如表 4-2 所示, 其中学习率按照公式 $lr = initial_lr \times \gamma^{epoch/step_size}$ 进行更新, 其中, $initial_lr$ 的值为表 4-2 中设置的学习率, 即 0.0001, γ 的值设为 0.5, $step_size$ 的值设为 10。

表 4-2 网络训练超参数

名称	值
批次(Epoch)	200
批量(Batch Size)	4
学习率(Learning Rate)	0.0001
优化器(Optimizer)	Adam
动量(Momentum)	0.9
权重衰减(Weight Decay)	0

4.3.2 数据集与预处理

本文使用 LiTS 2017 数据集^[69]来对各个网络模型进行评估, 该数据集总共包含 131 份可供下载的、包含人工标注标签的腹部 CT 图像样本供研究使用 (另外 70 份数据样本的真实标注结果并不公开), 每张 CT 图像和标签的分辨率大小为 512×512 像素。每份 CT 图像样本在收集之前, 均会由三位独立的、经验丰富的放射科医生进行肝脏与肝脏肿瘤具体部位的标注, 用来消除标注者主观因素而导致的标注标签结果的不一致性, 其中, 标注图片中背景用像素值 0 表示, 而肝脏和肝脏肿瘤的像素值分别设置为 1 和 2。除此之外, LiTS 数据集中的数据来源于不同的临床站点, 由于不同站点成像采集设备具有差异, 从而导致数据集中 CT 图像样本的二维切片厚度从 0.45mm 到 6.0mm 之间不等, 且平面分辨率也存在差异, 范围在 0.55mm 到 1.0mm 之间, CT 图像样本的切片数量最小为 42 张, 而最多可达到 1016 张。

本文对 LiTS 2017 数据集中包含的 131 份 CT 图像样本做以下预处理:

- 1) 由于数据集本身是三维数据, 需要将 CT 数据进行切片, 在切片过程中, 将肝脏 (包含肿瘤) 占比非常小的切片进行去除 (阈值设置为 1.5%);

2) 本数据集肝脏区域的 CT 值集中在-200~200HU 之间, 因此对切片进行窗口化处理, 并调整窗宽以及窗位, 采用范围为[-200, 200]的 HU 值进行截断, 能够增强腹部区域和背景的对比度;

3) 对切片数据进行窗口化处理后, 需要进行归一化处理, 将像素值映射至-1 到 1 之间, 这能够减小同性质组织之间的差异, 有助于网络较快收敛。

数据集经过以上一系列预处理操作后, 共得到 15780 张图像数据。本文将序号为 28 到 47 的 CT 图像作为测试集, 预处理后共包含 1720 张图像数据, 剩下的 14060 张图像数据大致按照 9:1 的比例划分为训练集和验证集。此外, 本文只进行肝脏的分割, 故将肝脏肿瘤划归为肝脏, 即将其标签图像中像素值改为 1。可视化后的标签图像 (背景灰度值为 0, 肝脏区域灰度值为 255) 如图 4-9(右)所示。




图 4-9 LiTS 2017 数据集原始图像(左)与标签图像(右)

4.3.3 评价指标

本文选用了 Dice 相似系数 (Dice Similarity Coefficient, DSC)、体积重叠误差 (Volume Overlap Error, VOE) 以及相对体积差异 (Relative Volume Difference, RVD) 三个评价指标进行评估。

1) Dice 相似系数在上一章节已经详细描述过, 是一种用于评估预测分割区域与真实分割区域之间相似程度的指标, 计算公式如下所示:

$$DSC = \frac{2|T \cap P|}{|T| + |P|} \quad (4-21)$$

其中, T 代表真实分割结果, P 代表网络模型分割出来的预测结果。

2) 体积重叠误差代表的是错误率, 该评价指标本质上与交并比 IoU 是一致的, 取的是交并比的补数, 其取值范围在 0 到 1 之间, 数值越小则代表分割结果与真实分割结果越接近, 当取值为 0 时, 表示预测分割结果与真实分割结果相同, 分割效果最好。其计算公式如下所示:

$$VOE = 1 - \frac{|T \cap P|}{|T \cup P|} \quad (4-22)$$

3) 相对体积差异是预测分割结果与真实分割结果之间差异的百分比, 可以当作不

对称的衡量标准,取值范围在-1 到 1 之间,数值越接近于 0,代表分割结果越好。当 RVD 取值为 0 时,表示预测分割结果与真实分割结果相同,分割效果最好;当 RVD 为正数时,表示预测分割结果大于真实分割结果,反之则表示预测分割结果小于真实分割结果。RVD 计算公式如下所示:

$$RVD = \frac{|P| - |T|}{|T|} \quad (4 - 23)$$

4.3.4 消融实验


本文利用消融实验来评估 RAE-U-Net 模型在 LiTS 2017 数据集上肝脏分割性能的有效性,以此来验证 RAE-U-Net 网络模型中的 Res-block、MCAB 以及 DenseASPP 三个模块在提升肝脏分割精度方面的效果。为了评估各网络模型的分割性能,统计了 Dice 相似系数、VOE、RVD 三个评价指标在测试集上的平均值,并将传统的 U-Net 网络作为基准模型,以此为基础,逐步增加各个模块进行对比。在消融实验中各个网络模型的分割性能如表 4-3 所示。

表 4-3 RAE-U-Net 网络模型的消融实验结果

模型	Dice(%)	VOE(%)	RVD(%)	Parameters
U-Net (a)	92.61	11.24	5.17	7.8×10^6
U-Net+Res-block (b)	94.36	10.35	3.85	8.1×10^6
U-Net+Res-block+MCAB (c)	95.23	9.14	2.91	8.1×10^6
U-Net+Res-block+DenseASPP (d)	95.70	8.02	2.31	5.8×10^6
RAE-U-Net (e)	96.60	6.50	1.45	5.8×10^6

本文在消融实验中进行了多轮对比,从表 4-3 的结果可以看出,结合了各个模块的 RAE-U-Net 网络模型获得了最好的分割性能,同时,分别带有 Res-block、MCAB 以及 DenseASPP 模块的 U-Net 网络在肝脏分割精度方面也均得到了提升,说明了各个模块的有效性。带有 Res-block 模块的 U-Net 网络相比基准模型虽然带来了一定参数量的增加,但 Dice 相似系数提高了 1.75 个百分点,VOE 和 RVD 指标也分别降低了 0.89 和 1.32 个百分点,这表明残差卷积模块虽然结构简单,但能提高特征信息的利用率,促使网络学习更深层的特征,提高分割效果。在加有 Res-block 模块的 U-Net 网络上再增加 MCAB 模块,基本不会带来参数量的增加,但能利用多尺度特征信息和通道注意力机制,对跳跃连接过来的低层特征进行加权,自适应增强对肝脏边缘细节信息的关注程度,并抑制无关信息来提高分割效果。在加有 Res-block 模块的 U-Net 网络上再增加 DenseASPP 模块,不仅减少了参数量,而且各个分割评价指标均得到了改善,其中参数量的减少得益于 DenseASPP 模块中使用深度可分离卷积代替常规卷积,DenseASPP 模块中通道注意

力 ECA 模块对细节信息的保留再加上采用不同空洞率的密集空洞卷积来增大感受野并提取多尺度上下文信息，使得网络提取到了更加丰富的特征信息，来应对肝脏在 CT 图像中的各种变化，从而提升了分割性能。本文提出的 RAE-U-Net 网络模型，在 U-Net 网络的基础上，集成了 Res-block、MCAB 以及 DenseASPP 三大模块，平均 Dice 相似系数为 96.60%，相比基准模型 U-Net 网络提升了 3.99 个百分点，体积重叠误差和相对体积差异指标分别为 6.50%、1.45%，相比基准模型 U-Net 网络分别降低了 4.74 和 3.72 个百分点，获得了最好的分割效果，并且有效减少了参数量。图 4-10 展示了消融实验中部分肝脏 CT 图像切片的分割结果。






图 4-10 不同网络模型分割效果

4.3.5 与经典网络模型对比

本文将 RAE-U-Net 网络模型与医学图像分割中经典网络模型 U-Net、Attention U-Net 以及 UNet++网络进行对比，以此来说明 RAE-U-Net 网络在肝脏 CT 图像分割方面的优越性。所有对比的模型均是在 LiTS 2017 数据集上进行训练、验证与测试的，实验环境与设置都相同。各网络模型在测试集上的分割结果对比如表 4-4 所示。

表 4-4 与经典网络模型分割结果对比

模型	Dice(%)	VOE(%)	RVD(%)
U-Net	92.61	11.24	5.17
Attention U-Net	94.65	10.55	2.85
UNet++	94.47	10.16	2.37
RAE-U-Net	96.60	6.50	1.45


由对比结果可知，本文提出的 RAE-U-Net 网络模型的 Dice 相似系数是最高的，VOE 和 RVD 评价指标是最低的，具有最好的分割效果。Attention U-Net 网络和 UNet++网络均是基于 U-Net 网络进行的改进，具体在相关基础知识 2.1 小节介绍。Attention U-Net

网络通过在 U-Net 网络中加入注意力门，与 U-Net 网络相比，Dice 相似系数增加了 2.04 个百分点，VOE 和 RVD 分别降低了 0.69 和 2.32 个百分点。同样地，UNet++网络与 U-Net 网络相比，各项分割指标均得到了改善。Attention U-Net 网络与 UNet++网络分割结果比较接近，其中，Attention U-Net 网络在 Dice 相似系数上略高 0.18 个百分点，而在 VOE 和 RVD 指标结果上稍逊于 UNet++网络，分别比其高 0.39 和 0.48 个百分点，这两个指标值是越接近于 0 代表分割效果越好。

表 4-5 与经典网络模型训练时间、推理时间以及参数量对比

模型	训练时间	推理时间	参数量
U-Net	23h 26min	65s	7.8×10^6
Attention U-Net	30h 18min	83s	7.8×10^6
UNet++	41h 48min	131s	9.1×10^6
RAE-U-Net	35h 24min	94s	5.8×10^6

表 4-5 统计了各个网络模型在 LiTS 2017 数据集上的训练时间、推理时间（测试时间）以及模型参数量大小。U-Net 网络的训练以及推理时间是最短的，其他三个模型均是在 U-Net 网络的基础上进行的改进，由于增加了新的模块，对应训练以及推理时间均变长了。UNet++网络由于是多个不同深度的 U-Net 网络的集合，网络中含有大量的短连接，导致其参数量大小、训练时间以及推理时间均是最大的。本文提出的 RAE-U-Net 网络模型，具有最小的参数量，同时由于 Res-block 模块、MCAB 模块以及 DenseASPP 模块的引入，导致训练以及推理时间比 U-Net 网络和 Attention U-Net 网络更长，但也使得网络能够提取更多的特征信息，换来了分割效果的提升。此外，RAE-U-Net 网络模型的训练以及推理时间并没有慢很多。图 4-11 展示了各个网络模型对部分肝脏 CT 图像切片的分割结果。






图 4-11 不同网络模型分割效果

4.3.6 与其他网络模型对比

本文除了利用消融实验来验证各个模块的有效性以及与经典分割网络模型进行对比之外，也将 RAE-U-Net 网络与其他先进网络模型进行比较，以证明其在肝脏 CT 图像分割中的鲁棒性和优越性，具体如表 4-6 所示。

表 4-6 与其他先进网络模型分割结果对比

模型	Dice(%)	VOE(%)	RVD(%)
H-DenseUNet ^[70]	96.10	7.02	1.53
MA-Net ^[71]	96.00	8.00	-3.00
SAR-U-Net ^[72]	95.71	9.52	-0.84
RAE-U-Net	96.60	6.50	1.45

分别对 Dice 相似系数、VOE 以及 RVD 指标进行了统计。从表中分割结果可以看出, RAE-U-Net 网络的 Dice 相似系数为 96.60%, 与其他先进网络模型相比, 具有最高的分割精度。在 VOE 指标上, 值越小代表效果越好, 本文提出的 RAE-U-Net 网络模型得到的值是最小的, 比最高的 SAR-U-Net 网络低 3.02 个百分点。在 RVD 指标上, 越接近于 0 代表效果越好, RAE-U-Net 网络得到的结果为 1.45%, 说明整体分割上属于过分割, 即预测分割区域略微大于真实肝脏区域, 效果最好的是 SAR-U-Net 网络, 为负值说明整体分割上属于欠分割。综合来看, 本文的 RAE-U-Net 网络在肝脏 CT 图像上分割效果最好, 具有竞争优势。

4.4 本章小结

本章提出了一种基于多尺度特征和注意力机制的分割模型 RAE-U-Net, 该模型以 U-Net 网络为基础, 通过使用 MCAB 模块加强对低层特征中边缘细节信息的关注以及使用 DenseASPP 模块捕获多尺度上下文信息, 有效解决了医学图像中待分割结构边界模糊、形状和大小多变而难以准确分割的问题。

5 总结与展望

5.1 工作总结

利用深度学习的方法对医学图像中的各个器官组织、病灶区域等进行分割,可以辅助医生进行病情诊断并制定治疗方案,从而实现“早发现、早治疗”。然而,医学图像中存在待分割结构之间重叠程度高或者待分割结构边界模糊、形状和大小多变的特点,这导致分割效果不佳。本文以 U-Net 网络为基准模型,在此基础上进行改进,所提出的分割方法能有效解决医学图像分割中的难点,显著提高各器官组织结构的分割效果,对计算机辅助诊断应用在医学实际中具有重大意义。本文的主要工作总结如下:

(1) 针对医学图像中待分割结构之间存在重叠程度高的情况而导致的分割困难,本文提出了一种基于卷积胶囊网络的分割模型 ConvUCaps。由于 U-Net 网络无法准确且全面地获取局部与整体之间的关系,而胶囊网络以向量的形式进行编码,并通过动态路由算法动态地调整各个部分对整个对象的贡献,能够更好地建模局部与整体之间的关系,因此本文提出的 ConvUCaps 模型结合 U-Net 和胶囊网络,对 U-Net 的编码器部分进行改进,先使用卷积模块学习低层特征并建模局部关系,然后通过胶囊模块学习高层特征并建模局部与整体之间的关系,从而保存目标的位置、姿态等信息,有效解决了待分割部位之间因重叠程度过高而带来的分割困难问题;

(2) 针对医学图像中因待分割结构存在边界模糊、形状和大小多变的情况而导致的分割困难,本文提出了一种基于多尺度特征和注意力机制的分割模型 RAE-U-Net。该模型以 U-Net 网络为基础,设计残差卷积模块代替其中的普通卷积,提高特征信息的利用率;设计多尺度通道注意力模块 MCAB,通过利用高低层多尺度特征信息生成注意力权重,来调节跳跃连接过来的低层特征中各个通道的权重,自适应加强了对边缘细节信息的关注并抑制了无关信息的干扰;设计改进的密集空洞空间金字塔池化模块 DenseASPP,通过采用不同空洞率的密集空洞卷积获得不同大小的感受野,使网络能捕获到多尺度上下文信息,从而更好地判定图像中像素所属的类别,克服待分割结构形状和大小多变带来的分割困难。

5.2 未来工作展望

医学图像分割是计算机辅助诊断中的关键技术之一,为医生进行临床诊断与分析提供了非常重要的信息,故其准确性会直接影响到诊断和治疗的效果。本文以 U-Net 网络为基准模型,在此基础上进行改进,实验证明了所提出的分割方法能有效解决医学图像分割中的难点。但医学图像分割在临床诊断等实际应用中是十分复杂的任务,准确分割出各器官组织的区域仍然是具有挑战性的课题,需要大量研究者提出更多的创新方法来提高医学图像的分割效果。未来可以从以下几个方面进行深入研究和改进:

(1) 本文首先针对医学图像中待分割结构之间重叠程度高导致的分割困难问题,提出了基于卷积胶囊网络的医学图像分割模型;然后针对医学图像中待分割结构边界模糊、形状和大小多变导致的分割困难问题,提出了基于多尺度特征和注意力机制的医学图像分割模型,两个模型都取得了较好的效果。但是医学图像中还会存在更加复杂的情况,比如同时存在上述特点导致分割困难,因此下一步可以同时融合本文第三章和第四章提出的各个模块,以更好地解决复杂医学图像的分割问题。

(2) 目前医学数据采集的手段越来越多样,数据的形式也越来越丰富,医生对于各种疾病的诊断,不再依赖于某一项检测数据进行分析,而是加入了更多的检测数据来得到最终的诊断结果。因此,如何利用多模态信息实现对医学图像的准确分割是未来重要的研究方向,在后续的研究中,希望能够利用多模态信息提高医学图像的分割效果。

(3) 医学图像数据虽然丰富,但是人工标注的医学图像数据却十分稀少,而目前大部分分割模型需要依赖有标注的数据来提高分割效果。未来的医学图像分割研究可以朝向只需要少量标注数据的弱监督学习或者不需要标注数据的无监督学习方向发展。

(4) 近期,Meta 推出了名为 SAM (Segment Anything Model)^[73] 的图像分割模型。该模型通过构建超大型分割数据集进行训练,并通过零样本迁移 (zero-shot transfer) 应用于新任务,是一种无监督学习的模型。SAM 是面向通用场景的图像分割模型,是为通用性和使用广度而设计的,目的是提供一个计算机视觉领域的基础模型,因此应用在具体的医学图像分割任务上时, SAM 的分割效果并不如目前的医学图像分割模型,但其类似于半监督方式构建数据集的方法,可以用来构建超大型医学图像数据集,此外,其中基于 prompt 的策略也可以用来提高医学图像的分割效果。

综上所述,将基于 U-Net 模型的医学图像分割方法应用到临床实际中,来辅助医生进行诊断,具有十分重大的临床实践意义。如何提高分割模型的分割精度、鲁棒性以及多适应性等是未来值得研究的课题方向。

参考文献

- [1] OTSU N.A threshold selection method from gray-level histograms[J].IEEE transactions on systems, man, and cybernetics,1979, 9 (1): 62-66.
- [2] XIE M, GAO J, ZHU C, et al.A modified method for MRF segmentation and bias correction of MR image with intensity inhomogeneity[J].Medical & biological engineering & computing,2015, 53: 23-35.
- [3] XIAO Y, TIAN Z, YU J, et al.A review of object detection based on deep learning[J].Multimedia Tools and Applications,2020, 79: 23729-23791.
- [4] RAWAT W, WANG Z.Deep convolutional neural networks for image classification: A comprehensive review[J].Neural computation,2017, 29 (9): 2352-2449.
- [5] MINAE S, BOYKOV Y, PORIKLI F, et al.Image segmentation using deep learning: A survey[J].IEEE transactions on pattern analysis and machine intelligence,2021, 44 (7): 3523-3542.
- [6] LONG J, SHELHAMER E, DARRELL T. Fully convolutional networks for semantic segmentation[C].Proceedings of the IEEE conference on computer vision and pattern recognition,2015: 3431-3440.
- [7] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation[C].International Conference on Medical image computing and computer-assisted intervention,2015: 234-241.
- [8] OKTAY O, SCHLEMPER J, FOLGOC L L, et al.Attention u-net: Learning where to look for the pancreas[J].arXiv preprint arXiv:1804.03999,2018.
- [9] ZHOU Z, RAHMAN SIDDIQUEE M M, TAJBAKHS N, et al. Unet++: A nested u-net architecture for medical image segmentation[C].Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support: 4th International Workshop, DLMIA 2018, and 8th International Workshop, ML-CDS 2018, Held in Conjunction with MICCAI 2018, Granada, Spain, September 20, 2018, Proceedings 4,2018: 3-11.
- [10] YAHYATABAR M, JOUVET P, CHERIET F. Dense-Unet: a light model for lung fields segmentation in Chest X-Ray images[C].2020 42nd Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC),2020: 1242-1245.
- [11] SONG L, GEOFFREY K, KAIJIAN H.Bottleneck feature supervised U-Net for pixel-wise liver and tumor segmentation[J].Expert Systems with Applications,2020, 145: 113131.
- [12] LE N, BUI T, VO-HO V-K, et al.Narrow band active contour attention model for medical segmentation[J].Diagnostics,2021, 11 (8): 1393.

- [13] LE N, YAMAZAKI K, QUACH K G, et al. A multi-task contextual atrous residual network for brain tumor detection & segmentation[C].2020 25th International Conference on Pattern Recognition (ICPR),2021: 5943-5950.
- [14] ROTH H, ODA M, SHIMIZU N, et al. Towards dense volumetric pancreas segmentation in CT using 3D fully convolutional networks[C].Medical Imaging 2018: Image Processing,2018: 59-64.
- [15] BAJWA I S, ASGHAR M N, NAEEM M A. Learning-based improved seeded region growing algorithm for brain tumor identification: Improved seeded region growing algorithm for brain tumor identification[J].Proceedings of the Pakistan Academy of Sciences: A. Physical and Computational Sciences,2017, 54 (2): 127–133-127–133.
- [16] BENSON C, LAJISH V, RAJAMANI K. Brain tumor extraction from MRI brain images using marker based watershed algorithm[C].2015 International Conference on advances in computing, communications and informatics (ICACCI),2015: 318-323.
- [17] MAHMOOD N, SHAH A, WAQAS A, et al. Image segmentation methods and edge detection: An application to knee joint articular cartilage edge detection[J].Journal of Theoretical and Applied Information Technology,2015, 71 (1): 87-96.
- [18] MARTEL A L, GALLEGÓ-ORTIZ C, LU Y. Breast segmentation in MRI using Poisson surface reconstruction initialized with random forest edge detection[C].Medical Imaging 2016: Image Processing,2016: 351-356.
- [19] MACQUEEN J. Classification and analysis of multivariate observations[C].5th Berkeley Symp. Math. Statist. Probability,1967: 281-297.
- [20] KUMBHAR A D, KULKARNI A. Magnetic resonant image segmentation using trained k-means clustering[C].2011 World Congress on Information and Communication Technologies,2011: 530-534.
- [21] BEZDEK J C, EHRLICH R, FULL W. FCM: The fuzzy c-means clustering algorithm[J].Computers & geosciences,1984, 10 (2-3): 191-203.
- [22] ADHIKARI S K, SING J K, BASU D K, et al. Conditional spatial fuzzy C-means clustering algorithm for segmentation of MRI images[J].Applied soft computing,2015, 34: 758-769.
- [23] SHI C, XIAN M, ZHOU X, et al. Multi-slice low-rank tensor decomposition based multi-atlas segmentation: Application to automatic pathological liver CT segmentation[J].Medical image analysis,2021, 73: 102152.
- [24] JIMENEZ-CARRETERO D, BERMEJO-PELÁEZ D, NARDELLI P, et al. A graph-cut approach for pulmonary artery-vein segmentation in noncontrast CT images[J].Medical image analysis,2019, 52: 144-159.
- [25] LO S-C, LOU S-L, LIN J-S, et al. Artificial convolution neural network techniques and applications for lung nodule detection[J].IEEE transactions on medical imaging,1995, 14 (4): 711-718.

- [26] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60 (6): 84-90.
- [27] ZHOU S K, GREENSPAN H, DAVATZIKOS C, et al. A review of deep learning in medical imaging: Imaging traits, technology trends, case studies with progress highlights, and future promises[J]. Proceedings of the IEEE, 2021, 109 (5): 820-838.
- [28] HUANG G, LIU Z, VAN DER MAATEN L, et al. Densely connected convolutional networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 4700-4708.
- [29] ZHANG J, ZHANG Y, JIN Y, et al. Mdu-net: Multi-scale densely connected u-net for biomedical image segmentation[J]. Health Information Science and Systems, 2023, 11 (1): 13.
- [30] XIAO X, LIAN S, LUO Z, et al. Weighted res-unet for high-quality retina vessel segmentation[C]. 2018 9th international conference on information technology in medicine and education (ITME), 2018: 327-331.
- [31] HUANG H, LIN L, TONG R, et al. Unet 3+: A full-scale connected unet for medical image segmentation[C]. ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2020: 1055-1059.
- [32] JIN Q, MENG Z, PHAM T D, et al. DUNet: A deformable network for retinal vessel segmentation[J]. Knowledge-Based Systems, 2019, 178: 149-162.
- [33] DAI J, QI H, XIONG Y, et al. Deformable convolutional networks[C]. Proceedings of the IEEE international conference on computer vision, 2017: 764-773.
- [34] ALOM M Z, YAKOPCIC C, TAHA T M, et al. Nuclei segmentation with recurrent residual convolutional neural networks based U-Net (R2U-Net)[C]. NAECON 2018-IEEE National Aerospace and Electronics Conference, 2018: 228-233.
- [35] CHEN C, LIU X, DING M, et al. 3D dilated multi-fiber network for real-time brain tumor segmentation in MRI[C]. Medical Image Computing and Computer Assisted Intervention–MICCAI 2019: 22nd International Conference, Shenzhen, China, October 13–17, 2019, Proceedings, Part III 22, 2019: 184-192.
- [36] LOU A, GUAN S, LOEW M. DC-UNet: rethinking the U-Net architecture with dual channel efficient CNN for medical image segmentation[C]. Medical Imaging 2021: Image Processing, 2021: 758-768.
- [37] IBTEHAZ N, RAHMAN M S. MultiResUNet: Rethinking the U-Net architecture for multimodal biomedical image segmentation[J]. Neural networks, 2020, 121: 74-87.
- [38] ALBISHRI A A, SHAH S J H, LEE Y. CU-Net: Cascaded U-Net model for automated liver and lesion segmentation and summarization[C]. 2019 IEEE International Conference on Bioinformatics and Biomedicine (BIBM), 2019: 1416-1423.

- [39] CHEN W, ZHANG Y, HE J, et al. W-net: Bridged u-net for 2d medical image segmentation[J]. arXiv preprint arXiv:1807.04459, 2018, 52.
- [40] JHA D, RIEGLER M A, JOHANSEN D, et al. Doubleu-net: A deep convolutional neural network for medical image segmentation[C]. 2020 IEEE 33rd International symposium on computer-based medical systems (CBMS), 2020: 558-564.
- [41] LIU T, TIAN Y, ZHAO S, et al. Automatic whole heart segmentation using a two-stage u-net framework and an adaptive threshold window[J]. IEEE Access, 2019, 7: 83628-83636.
- [42] HINTON G E, KRIZHEVSKY A, WANG S D. Transforming auto-encoders[C]. Artificial Neural Networks and Machine Learning—ICANN 2011: 21st International Conference on Artificial Neural Networks, Espoo, Finland, June 14-17, 2011, Proceedings, Part I 21, 2011: 44-51.
- [43] SABOUR S, FROSST N, HINTON G E. Dynamic routing between capsules[J]. Advances in neural information processing systems, 2017, 30.
- [44] HINTON G E, SABOUR S, FROSST N. Matrix capsules with EM routing[C]. International conference on learning representations, 2018.
- [45] RIBEIRO F D S, LEONTIDIS G, KOLLIAS S. Capsule routing via variational bayes[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020: 3749-3756.
- [46] MOBINY A, VAN NGUYEN H. Fast capsnet for lung cancer screening[C]. Medical Image Computing and Computer Assisted Intervention—MICCAI 2018: 21st International Conference, Granada, Spain, September 16-20, 2018, Proceedings, Part II 11, 2018: 741-749.
- [47] HE Y, QIN W, WU Y, et al. Automatic left ventricle segmentation from cardiac magnetic resonance images using a capsule network[J]. Journal of X-ray Science and Technology, 2020, 28 (3): 541-553.
- [48] LALONDE R, BAGCI U. Capsules for object segmentation[J]. arXiv preprint arXiv:1804.04241, 2018.
- [49] BONHEUR S, ŠTERN D, PAYER C, et al. Matwo-capsnet: a multi-label semantic segmentation capsules network[C]. Medical Image Computing and Computer Assisted Intervention—MICCAI 2019: 22nd International Conference, Shenzhen, China, October 13–17, 2019, Proceedings, Part V 22, 2019: 664-672.
- [50] JADERBERG M, SIMONYAN K, ZISSERMAN A. Spatial transformer networks[J]. Advances in neural information processing systems, 2015, 28.
- [51] WANG X, GIRSHICK R, GUPTA A, et al. Non-local neural networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018: 7794-7803.
- [52] HU J, SHEN L, ALBANIE S, et al. Gather-excite: Exploiting feature context in convolutional neural networks[J]. Advances in neural information processing systems, 2018, 31.
- [53] LI X, ZHONG Z, WU J, et al. Expectation-maximization attention networks for semantic segmentation[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 9167-9176.

- [54] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C].Proceedings of the IEEE conference on computer vision and pattern recognition,2018: 7132-7141.
- [55] GAO Z, XIE J, WANG Q, et al. Global second-order pooling convolutional networks[C].Proceedings of the IEEE/CVF Conference on computer vision and pattern recognition,2019: 3024-3033.
- [56] WANG Q, WU B, ZHU P, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks[C].Proceedings of the IEEE/CVF conference on computer vision and pattern recognition,2020: 11534-11542.
- [57] WOO S, PARK J, LEE J-Y, et al. Cbam: Convolutional block attention module[C].Proceedings of the European conference on computer vision (ECCV),2018: 3-19.
- [58] ROY A G, NAVAB N, WACHINGER C. Concurrent spatial and channel ‘squeeze & excitation’ in fully convolutional networks[C].Medical Image Computing and Computer Assisted Intervention–MICCAI 2018: 21st International Conference, Granada, Spain, September 16-20, 2018, Proceedings, Part I,2018: 421-429.
- [59] PARK J, WOO S, LEE J-Y, et al. Bam: Bottleneck attention module[J].arXiv preprint arXiv:1807.06514,2018.
- [60] SHIRAISHI J, KATSURAGAWA S, IKEZOE J, et al. Development of a digital image database for chest radiographs with and without a lung nodule: receiver operating characteristic analysis of radiologists' detection of pulmonary nodules[J].American Journal of Roentgenology,2000, 174 (1): 71-74.
- [61] VAN GINNEKEN B, STEGMANN M B, LOOG M. Segmentation of anatomical structures in chest radiographs using supervised methods: a comparative study on a public database[J].Medical image analysis,2006, 10 (1): 19-40.
- [62] NOVIKOV A A, LENIS D, MAJOR D, et al. Fully convolutional architectures for multiclass segmentation in chest radiographs[J].IEEE transactions on medical imaging,2018, 37 (8): 1865-1876.
- [63] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C].Proceedings of the IEEE conference on computer vision and pattern recognition,2016: 770-778.
- [64] CHEN L-C, PAPANDREOU G, KOKKINOS I, et al. Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs[J].IEEE transactions on pattern analysis and machine intelligence,2017, 40 (4): 834-848.
- [65] YANG M, YU K, ZHANG C, et al. Denseaspp for semantic segmentation in street scenes[C].Proceedings of the IEEE conference on computer vision and pattern recognition,2018: 3684-3692.
- [66] HOWARD A G, ZHU M, CHEN B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J].arXiv preprint arXiv:1704.04861,2017.
- [67] YU F, KOLTUN V. Multi-scale context aggregation by dilated convolutions[J].arXiv preprint arXiv:1511.07122,2015.

- [68] WANG P, CHEN P, YUAN Y, et al. Understanding convolution for semantic segmentation[C].2018 IEEE winter conference on applications of computer vision (WACV),2018: 1451-1460.
- [69] BILIC P, CHRIST P, LI H B, et al.The liver tumor segmentation benchmark (lits)[J].Medical Image Analysis,2023, 84: 102680.
- [70] LI X, CHEN H, QI X, et al.H-DenseUNet: hybrid densely connected UNet for liver and tumor segmentation from CT volumes[J].IEEE transactions on medical imaging,2018, 37 (12): 2663-2674.
- [71] FAN T, WANG G, LI Y, et al.Ma-net: A multi-scale attention network for liver and tumor segmentation[J].IEEE Access,2020, 8: 179656-179665.
- [72] WANG J, LV P, WANG H, et al.SAR-U-Net: Squeeze-and-excitation block and atrous spatial pyramid pooling based residual U-Net for automatic liver segmentation in Computed Tomography[J].Computer Methods and Programs in Biomedicine,2021, 208: 106268.
- [73] KIRILLOV A, MINTUN E, RAVI N, et al.Segment anything[J].arXiv preprint arXiv:2304.02643,2023.