

分类号 TP309

U D C

密级 公开

编号 10486

武汉大学

硕士学位论文

基于注意力机制和图卷积网络的心
电图多标签分类方法研究

研究生姓名： 贺煜航

学号： 2019202210017

指导教师姓名、职称： 陈刚 教授

专业名称： 网络空间安全

研究方向： 医学图像处理

二〇二二年四月

Multi-label classification method of electrocardiogram based on attention mechanism and graph convolutional network

By
He Yuhang

Supervised by
Prof. Gang Chen

Wuhan University
Wuhan, 430079 P.R.China

April, 2022

摘要

心电图分析是一种被广泛应用的、重要的心血管疾病诊断方法，具有重要的研究意义。传统的心电图分析严重依赖医生的个人水平，易出现误诊、漏诊现象，且效率较低。近年来，大量基于卷积神经网络的心电图自动分类技术被提出，取得了较好的效果。然而目前基于深度学习的心电图分析研究面临着两个挑战：第一，由于空间维度信息建模忽略了不同信号间的差异，对心电图存在高频信息挖掘和利用不充分；第二，单一的卷积神经网络受感受野的限制和权重共享，不能很好地利用全局信息，及对特征空间邻域中的其他样本提供的信息利用不够。现有的心电图分析方法在提取鲁棒的、有效的信息方面存在缺陷，仍需进一步研究。

针对以上问题，同时考虑到多标签分类能够更加细致地刻画心血管疾病的复杂具体情况，本论文进行了充分的研究并提出了解决方案，主要研究内容和成果如下：

1. 针对心电图中存在高频信息挖掘和利用不充分的问题，本文提出并构建了基于高通滤波器的注意力机制模块。该模块通过高通滤波器来突出原始信号的高频位置，生成注意力图，然后将注意力图嵌入到原始信号，从而增强了网络关注心电图高频信号的能力。结合残差神经网络构建了注意力机制 CNN（Convolutional Neural Network）网络，提取更有效的心电图特征并应用于心电图多标签分类。
2. 针对对特征空间邻域中的其他样本提供的信息利用不充分的问题，本文在注意力机制 CNN 网络的基础上，提出了一种新型的基于自适应图卷积的心电图多标签分类模型 MLECG-AGCN（Multi label classification of Electrocardiogram based on attention mechanism and graph convolutional network）。该模型首先利用注意力机制 CNN 的特征提取模块提取心电信号特征，然后提出一种自适应的方案构建图卷积神经网络的边，实现了非局部的上下文信息聚合，有效利用特征空间全局信息和邻域样本信息协助样本进行分类，提高分类结果的准确率。
3. 为了验证注意力机制 CNN 网络及 MLECG-AGCN 的分类效果，本文在 PTB-XL 数据集中，设计了相关实验并与部分已有的网络模型进行对比。实验结果表明，注意力机制 CNN 和 MLECG-AGCN 均取得了较好的分类结果，

其中注意力机制 CNN 特征提取模块与自适应图卷积结合的 MLECG-AGCN 在多项评估指标中表现最优，宏平均 AUC 值达到 0.943，有效提升了心电图分类精度。

关键词：心电图；图卷积神经网络；残差神经网络；注意力机制；多标签分类；PTB-XL；

Abstract

ECG analysis is a widely used and important diagnostic method for heart disease, which has important research significance. Traditional electrocardiogram analysis has two obvious shortcomings: one is that it relies heavily on the diagnostic level of the doctor, which is prone to misdiagnosis and missed diagnosis, and its efficiency is low. In recent years, a large number of ECG automatic classification techniques based on convolutional neural networks have been proposed, and good results have been achieved. However, the current ECG analysis research based on deep learning faces two challenges: first, for the spatial dimension information modeling ignores the differences between different signals, there is insufficient mining and utilization of high-frequency information in the ECG; second, a single convolutional neural network cannot make good use of global information and information from other samples due to receptive field limitation and weight sharing. Existing ECG analysis methods are flawed in extracting robust, valid information, and further research is needed.

In view of the above problems, and considering that multi-label classification can precisely describe heart disease in more detail, we have conducted sufficient research and extracted solutions. The main research contents and achievements are as follows:

1. Aiming at the problem of insufficient high-frequency information mining and utilization in ECG, we propose and construct an attention mechanism module based on high-pass filter. The module uses a high-pass filter to highlight the high-frequency positions of the original signal, generates an attention map, and then embeds the attention map into the original signal, thereby enhancing the network's ability to pay attention to the high-frequency signal of the ECG. Combined with residual neural network, an attention mechanism CNN (Convolutional Neural Network) network is constructed to extract more effective ECG features and apply them to ECG multi-label classification.

2. Aiming at the problem of insufficient utilization of the information provided by other samples in the feature space neighborhood, based on the attention

mechanism CNN network, we propose a novelty electrocardiogram multi-label classification method via adaptive graph convolution network named MLECG-AGCN (Multi label classification of Electrocardiogram based on attention mechanism and graph convolutional network) . The model first uses the attention mechanism CNN to extract the ECG signal features, and then proposes an adaptive scheme to build the edges of the graph convolutional neural network, realizes the aggregation of non-local context information, and effectively utilizes global information and feature space neighborhood samples The information assists in the classification of samples and improves the accuracy of the classification results.

3. In order to verify the classification effect of the attention mechanism CNN network and MLECG-AGCN, related experiments are designed in the PTB-XL dataset and compared with some existing network models. The experimental results show that both the attention mechanism CNN and MLECG-AGCN have achieved good classification results, and the MLECG-AGCN combined with the attention mechanism CNN feature extraction module and adaptive graph convolution performs the best in multiple evaluation indicators, macro average AUC value reaches 0.943, effectively improve the classification accuracy of ECG.

Key words: Electrocardiogram; Graph Convolutional Neural Network; Residual Neural Network; Attention Mechanism; Multi-label Classification; PTB-XL.

目 录

1. 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	3
1.2.1 基于机器学习的心电图分类方法.....	3
1.2.2 基于深度学习的心电图分类方法.....	4
1.3 本文主要研究内容.....	5
1.4 本文章节安排.....	7
2. 相关理论与技术	9
2.1 心电信号相关知识概述.....	9
2.1.1 心电信号产生机理.....	9
2.1.2 心电图.....	9
2.1.3 心电导联.....	11
2.2 多标签分类.....	12
2.3 卷积神经网络与残差神经网络	13
2.3.1 卷积神经网络.....	13
2.3.2 一维卷积.....	15
2.3.3 残差神经网络.....	17
2.4 注意力机制.....	18
2.5 图卷积神经网络.....	18
2.6 本章小结.....	19
3. 心电图分类现存问题与本研究解决方法	21
3.1 心电图多标签分类.....	21
3.1.1 心电图多标签分类意义.....	21
3.1.2 基于特别设计损失函数及评价指标的解决方法	21
3.2 心电图高频信息利用问题	21
3.2.1 心电图高频信息利用不充分问题.....	21
3.2.2 基于空间注意力的解决方法.....	22
3.3 心电图特征空间全局信息和邻域样本信息利用问题	22
3.3.1 心电图特征空间全局信息和邻域样本信息利用不充分问题	22
3.3.2 基于样本间上下文信息聚合的解决方法	22
3.4 本章小结.....	23
4. 基于空间注意力的心电图高频信息挖掘及分类方法	24
4.1 引言.....	24

4.2 基于空间注意力的心电图高频信息挖掘及分类方法算法	25
4.2.1 注意力机制 CNN 网络结构	25
4.2.2 心电图基本特征提取模块	26
4.2.3 注意力机制模块	28
4.2.4 损失函数	29
4.3 实验与分析	30
4.3.1 数据集	30
4.3.2 实验环境	33
4.3.3 对比模型设计	33
4.3.4 训练超参数配置	33
4.3.5 评价指标	33
4.3.6 实验结果	35
4.4 本章小结	39
5. 基于自适应图卷积的心电图样本间上下文信息聚合及分类方法	40
5.1 引言	40
5.2 基于自适应图卷积的心电图样本间上下文信息聚合及分类方法 算法	41
5.2.1 MLECG-AGCN 网络结构	41
5.2.2 自适应 GCN 模块	43
5.3 实验与分析	46
5.3.1 实验说明	46
5.3.2 实验结果	46
5.4 本章小结	50
6. 总结与展望	52
6.1 总结	52
6.2 展望	53
参考文献	55

1. 绪论

1.1 研究背景及意义

近年来,随着世界经济的蓬勃发展,人们的物质水平和日常生活质量得到了较大的提升,然而与此同时,人们也面对着更大的精神和身体负荷。在市场经济蓬勃发展的大背景下,人们肉眼可见得更加忙碌,需要投入大量的时间和精力到工作中,可以自由生活的时间和精力大大减少,而这样快节奏的生活也导致人们的压力与日俱增。生活节奏、社会压力、个人习惯等方面原因,导致越来越多的人受到心血管疾病的影响。心血管疾病(Cardiovascular disease, CVD)是心脏和血管方面疾病的统称。近年来,CVD 越来越成为全世界大部分地区最普遍的致死原因之一。根据世界卫生组织的研究报告显示^[1],仅 2013 年一年内,因为 CVD 而死的总人数就达到了约 1730 万,在总死亡人数中占比高达 31.1%。

在我国,心血管疾病诊疗工作还面对着很多困难,需要专家和医护人员去逐一克服。根据相关部门发布的 2018 年中国 CVD 情况有关资料,我国现阶段的 CVD 防治工作还任重而道远,尤其是该类疾病的患病比例还有死亡比例,与往年相比,中国仍没有明显减少。据报告可知,中国目前的 CVD 患病数量达到 2.9 亿人,而且在患病人群中,因 CVD 致死的人数和比例都较高;在所有导致中国民众死亡的病症类型中,因 CVD 致死的比例也很高,超过了总死者数的 40%。由此可见,心血管疾病对人类,尤其是我国人民的健康乃至生命都存在着极大的威胁。

CVD 有很多类型,其中大多数心血管疾病在发作之前,往往伴随着晕厥、心悸、气短、胸痛等明显的心血管功能异常症状。若能在上述疾病早期症状发作时,精确诊断所患疾病,介入治疗,将有助于控制疾病发展。

心电图(Electrocardiogram, ECG)是一种在临床使用的 CVD 辅助诊疗工具。这是一种无创伤的诊疗手段,主要的诊断步骤如下:首先将电极放置在身体不同部位的指定位置,不同电极组合对应不同导联,再通过这些电极连接采集心电信号,将所采集信号描记出来。自 20 世纪问世以后,由于其操作简便,记录过程中对人体没有损伤,并且记录精确,ECG 逐渐变成了 CVD 诊疗的主要方式之一并被广泛应用。传统心电图诊断需要医生人工分析被测量者的心电图,判断被测量者的病情。但传统心电图分析严重依赖医生的个人水平,由于心脏疾病种类多

样、隐匿性心脏病的存在等，易出现误诊、漏诊现象，且效率较低。同时，现有研究成果证实，心电图中的高频信息对心脏的健康状况可以做出更全面的解析[2-4]。

在深度学习之前，已有多种机器学习算法在心电图自动分类问题中得到了普遍的使用。机器学习方法进行心电图自动分类的主要模式是，首先从心电图人工提取特征，然后将提取特征输入到决策树、支持向量机等判别模型中进行分类预测。这些方法的实际表现依赖于人工提取特征的质量和判别模型。而人工提取质量存在着一定的不足：部分人工提取特征难以准确的表示心电图信息，易导致错误；同时其需要大量的专业医学知识用于特征工程，这会降低整体效率。

近年来，在人工智能领域，深度学习越来越成为其核心话题，并逐渐被用来进行心电图分类任务的研究。和机器学习方法不同，深度学习利用网络模型对特征信息实现自主抽取，从而有效地克服了传统机器学习方法中人工抽取特征的限制。其中，以卷积神经网络（Convolutional Neural Network，CNN）为基础的模型被越来越多地使用于心电图分类并取得了一定成果。深度学习模型在进行心电图分类时的流程主要是：首先对心电图进行降噪、重采样等预处理操作，得到统一维度数据，再将其作为整个模型的输入，输送到深度学习网络模型中；之后深度神经网络对心电图进行特征提取，相较于人工提取特征，深度神经网络能够自动提取更多维度的心电图特征，同时通过后续的多轮训练提高所提取特征的质量，以此有效地解决了人工提取特征所面临的诸多问题；最后，将提取的特征输入分类识别模块，得到整个神经网络的输出，这个输出结果一般是心血管疾病的具体类别，由此便可以得到整个神经网络对于患者心血管情况的预测结果。在整个过程中，如果所提取的特征质量较高，能够包含心电图各个波形所蕴含的病理信息，搭配合适的分类识别方式，那么按照心血管疾病分类准则就可以对患者的心血管状况得到较为准确的预估结果。

现有的基于 CNN 的模型在进行心电图分类时，均通过适当的方法使模型拥有更强的特征表达能力，进而提取出更有效的心电图特征，并将其应用在分类中，多项研究证明，这一类方法有着不错的分类效果。但现有方法少有针对心电图高频部分进行充分信息利用的结构，存在着对心电图高频信息利用不充分的问题。同时，单一的卷积神经网络由于受到感受野的限制和权重共享的影响，不能很好地利用全局信息，对特征空间邻域中的其他样本提供的信息利用不够。而通过卷

积操作提取心电图样本特征后,样本特征与其在特征空间上的邻域样本特征存在结构相似性和丰富的上下文关系,这些关系在 CNN 模型中尚未被很好的利用。这影响了分类结果的准确率。而且另一方面,在实际的病例中,心血管疾病患者经常同时出现多种症状,而且部分症状是不独立的。而目前的大部分网络模型倾向于关注一种或几种心血管疾病,而并没有对多标签问题进行分析研究。

本文针对心电图特征,首先以提取更有效的心电图特征为目标,针对心电图的高频信号能够对心血管的健康情况进行更全面分析的特点,设计了基于空间注意力的网络结构-注意力机制 CNN 来提取更有效的心电图特征,并从多标签角度考虑分类。同时,针对单一的卷积神经网络不能很好地利用全局信息,对特征空间邻域中的其他样本提供的信息利用不够的问题^[5],本文在注意力机制 CNN 的基础上,创新性地心电图多标签分类问题中将注意力机制 CNN 特征提取模块与自适应图卷积网络相结合,提出了一种心电图多标签分类模型 MLECG-AGCN。这种网络更有效地利用了高频信号,改善了单一的卷积神经网络由于受感受野的限制和权重共享所造成的问题^[5],更有效的利用了特征空间中的全局信息和邻域信息^[5]。注意力机制 CNN 和 MLECG-AGCN 在 PTB-XL 数据集^[6]上进行相关实验,均取得了很好效果,提供了心电图多标签分类的新思路。

1.2 国内外研究现状

由于心血管疾病在世界范围内的重要性和普遍性,多年来已有许多学者针对心电信号的处理以及心电图分类问题展开了全面的研究。传统使用心电图进行诊断的方法需要医生根据自己的经验知识对患者的心电图进行分析,从而判断患者的病情。但是在实际诊疗中,由于心血管疾病种类的多样性、隐匿性心脏疾病的存在等客观问题,面对大量的心电图,人工分析的方法因受到人力资源的限制,容易导致误诊和漏诊等问题的出现。为了提高诊断准确率;同时协助专业医生进行心电图分析节省人力投入,如何进行高效准确的心电图自动分类是一个值得深入研究探讨的话题。

1.2.1 基于机器学习的心电图分类方法

21 世纪以来,随着计算机技术的快速发展,已有多种机器学习技术被用来行心电图的自动分类研究。2009 年,Ceylan 等人^[7]设计并构建了用来进行心电图心律失常自动分类的诊断系统,该诊断系统针对心律失常问题,首先使用离散

小波变换(discrete wavelet transform, DWT)对提取心电图 RR 间期的特征向量;再对提取特征使用模糊聚类算法和神经网络完成分类,实验在数据集 MIT-BIH 上的分类精确度达到 96.7%。Nasiri 等人^[8]于 2009 年提出了一项利用 DWT 技术进行心电波去噪,并利用遗传算法实现特征提取,再通过支持向量机完成最终的分类的方法,该方法在 MIT-BIH 上的精确度取得了 93.46%。Zidelmal 等人^[9]2013 年提出了一种心电图分类方法,该方法使用具有双铰链损失的支持向量机分类器对心电图进行分类,其所提出的分类器拒绝不能以足够置信度分类的样本,该方法流程是:首先对输入心电图进行预处理、特征选择和提取,然后构建基于拒绝或错误分类样本的成本的决策规则进行决策,实验准确率在 MIT-BIH 上达到 97.2%。Kumar 等人^[10]于 2017 年提出了一种使用灵活解析小波变换(flexible analytic wavelet transform, FAWT)自动诊断心电图心肌梗塞(Myocardial Infarction, MI)的方法,该方法首先对心电图按节拍进行划分,之后将 FAWT 应用于各个节拍,将它们分解为子带信号;再从这些子带信号计算样本熵并馈送到随机森林、决策树、反向传播神经网络(BPNN)和最小二乘 SVM 等分类器中,实验表明,LS-SVM 取得了最好的效果,在所选取数据集上达到了 99.31% 的准确率。传统机器学习方法依赖于从心电图中人工提取特征,然后将提取特征输入到生成或判别模型中进行分类预测。所提取特征通过各种基于机器学习算法的分类器完成最终分类。一般而言,机器学习方法的训练时间相较于深度学习更短,因算法本身体量相对较小,有着更快的运行速度,且对计算资源的要求相对而言比较低。但是其不足之处在于,对于人工提取的特征而言,其质量很难定量地计量,有效性较高的特征数量有限,这很可能会导致整个机器学习算法的预测分类效果存在一定的瓶颈。同时,心电图研究作为一个专业的医学研究领域,需要大量的医学知识作为基础。如果使用传统机器学习方法进行研究,则需要使用专业的医学知识进行大量的特征提取和特征工程工作,这会大大降低效率。

1.2.2 基于深度学习的心电图分类方法

自深度学习出现以来,已有多项研究将其应用于心电图分类任务。在深度学习方法中,深度神经网络能够自动进行特征提取并将所提取特征应用于分类,即特征提取和分类阶段一起执行,而不需要人工提取特征,有效解决了传统机器学习方法中特征数量较少、质量参差不齐的问题。近年来,基于 CNN 的图像识别、

处理方法逐渐成为深度学习的热门研究方向,并在各个类型的图像任务中都有着很好的效果。CNN 以卷积层为基础,结合池化层、非线性激活函数层等提取图像的有效信息,然后再将所获得信息输入分类器中,从而实现对输入图像的分类过程。由于 CNN 在特征提取方面的强大能力,以及一维卷积与心电信号的适配性等,近年来,以 CNN 为基础的模型在多项研究中被用来进行心电图自动分类,并取得了一定的成果。Han 等人^[11]针对心血管疾病中的心肌梗塞问题,提出了一种检测和定位 MI 的新方法,该方法将多导联残差神经网络结构与残差块结合,并通过 12 导联 ECG 记录进行特征融合,然后将融合特征作为全局特征并用于 MI 二分类问题,实验在 PTB (Physikalisch-Technische Bundesanstalt) 数据集上的 MI 检测准确率达到 95.49%。CAI 等人^[12]于 2020 年提出了以残差神经网络 (Residual neural network, ResNet) 为基础的 Multi-ECGNet 模型。该模型在构建中还结合了深度可分离卷积的思想以及挤压-激励 (Squeeze-and-Excitation, SE) 模块,模型在所使用的“天池合肥高科杯心电图人机智能大赛”数据集上取得了较好的分类效果。Wang 等人^[13]在 2021 年发明和建立了基于非局部卷积注意模块的卷积神经网络模型 Automated-ECG,并利用非局部注意力,获取 ECG 数据在空间、通道以及时间上的信息,再使用学习矩阵进行融合,学习矩阵在上述三类信息中挖掘关系信息并最终完成分类^[5],该研究在多个数据集上进行了相关实验,均得到了较好结果。

深度学习通过其强大的运算能力,结合其能够自动提取特征并应用于分类的特点,挖掘样本更深层次的特征,进而使得分类预测更加准确。本文基于深度学习在心电图自动分类中的已有研究,针对心电图特点,设计了注意力机制 CNN 网络,提取更有效的心电图特征并应用于分类。在此基础上,考虑现有的单一的卷积神经网络由于受感受野的限制和权重共享的影响,不能很好地利用全局信息,对特征空间邻域中的其他样本提供的信息利用不够的问题,将自适应图卷积网络与注意力机制 CNN 特征提取模块结合,同时从多标签角度考虑问题,提出了一种心电图多标签分类的新思路。

1.3 本文主要研究内容

本文以心血管疾病心电图为研究对象,以对其进行分类识别为研究目标,研究任务为针对大量心电图的心血管疾病多标签分类问题,具体研究内容主要包括:

1. 本文针对心电图特点，构建基于拉普拉斯滤波器和 SE 模块的注意力机制模块，并结合以优化的残差神经网络为基础的心电图基本特征提取模块，构建并实现了基于空间注意力的网络模型-注意力机制 CNN 网络。该网络将注意力机制应用于心电图特征提取，增强网络关注心电图高频信号的能力，提取更有效的心电图特征并应用于心电图多标签分类。
2. 本文针对心电图多标签分类问题，提出了 MLECG-AGCN 模型，该模型创新性的在心电图分类任务中将注意力机制 CNN 与自适应图卷积结合，利用图卷积网络强大的结构表示能力，改善了单一的卷积神经网络由于受感受野的限制和权重共享所造成的问题，加强了对特征空间中的全局信息和邻域样本信息的有效利用；结合注意力机制 CNN 特征提取模块提取的心电图特征，完成整体分类模型的构建。在 PTB-XL 数据集上进行多标签分类实验，与复现的其余 7 种方法进行了对比实验，实验表明，MLECG-AGCN 模型取得了更好的分类结果。
3. 本文从实际病例出发，考虑实际病例中心血管疾病患者常同时出现多种症状，且部分症状不独立的实际情况，使用针对数据集标签分布特别设计的损失函数和适用于多标签情况的分类模型评价指标来从多标签角度考虑分类。
4. 本文使用 PTB-XL 数据集对该模型分类效果进行验证，并使用多个评价指标，从多个维度对实验结果进行比较，对各对比模型进行全面的对比和分析。实验结果如下：注意力机制 CNN 网络主评价指标-宏平均受试者工作特征（receiver operating characteristic curve, ROC）曲线下面积（Area Under Curve, AUC）值达到 0.941；副评价指标标签集排序损失（ranking loss, RL）值 0.026，最大概率预测标签错误率（One Error, OE）值 0.249，全覆盖偏差（coverage error, Cov）3.036。MLECG-AGCN 网络主评价指标宏平均 AUC 值达到 0.943；副评价指标标签集排序损失值 0.025，最大概率预测标签错误率值 0.229，全覆盖偏值 3.063。与其他对比模型相比，注意力机制 CNN 网络在宏平均 AUC 值以及副评价指标 RL、OE 值上取得次好结果，在 Cov 值上取得最好结果；MLECG-AGCN 在宏平均 AUC 值以及副评价指标 RL、OE 值上均取得最好结果。

1.4 本文章节安排

本文共包含六大部分的内容，每一部分的详细内容如下：

第一章：绪论部分。从研究背景和意义角度，描述了心血管疾病的普遍性和重要性，心电图的基本知识和其在心血管疾病诊疗中的重要性，CVD 诊断和治疗所面临的困难，心电图自动分类技术的迫切需求和实际意义。介绍了国内外传统机器学习算法以及深度学习应用于心电图自动分类任务的研究现状，描述了两方式的优缺点。简单介绍了本文各个部分的主要内容及整体脉络，阐述了本文研究所针对的问题和总体思路。

第二章：相关的基础理论与技术部分。简单概述了心电信号、数据集、多标签分类、深度学习相关理论及知识。对心电信号的整体机制、ECG、导联相关知识、12 导联 ECG 等进行了简单的介绍。介绍了本文使用的 PTB-XL 数据集，详细描述了多标签分类相关知识。简单介绍了本文涉及的卷积神经网络结构、ResNet 网络结构、注意力机制的定义及优势等；对图卷积神经网络的定义和构建方式进行了简单介绍，描述了其在节点间关系建模、结构表示上的强大能力，为后续研究的开展做基础铺垫。

第三章：心电图分类现存问题与本研究解决方案。详细描述了心电图多标签分类的意义，即为什么要使用多标签的心电图数据集进行分类问题研究，并概述了本文针对多标签问题特征的解决方法。详述了现有研究中的心电图高频信息利用问题，概述了针对此问题，本文提出的基于空间注意力的解决方法。详述了单一 CNN 对心电图特征空间全局信息和邻域样本信息的利用不足问题，概述了针对此问题，本文提出的基于样本间上下文信息聚合的解决方法。概述了第四章所设计的基于空间注意力的注意力机制 CNN 模型和第五章设计的 MLECG-AGCN 模型之间的联系。

第四章：基于空间注意力的心电图高频信息挖掘及分类方法。本章内容首先以网络结构图为主题，细致的讲解了注意力机制 CNN 网络模型的设计原理和网络结构。构建网络的核心模块有：心电信号预处理模块、心电图基本特征提取模块和心电图注意力机制模块。经过上述模块的预处理、特征提取、特征增强等运算过程后，通过线性分类器，最终完成对输入心电图的多标签分类任务。简单介绍了本研究所使用的 PTB-XL 数据集数据；介绍了实验环境、对比模型、训练超

参设置等。详细介绍了针对多标签分类任务，本研究所选取的评价指标，重点介绍了评价指标宏平均 AUC 值的定义及其在多标签分类任务中的优势。为检验本文设计的注意力机制 CNN 模型的分类有效性，在该章节中，将注意力机制 CNN 模型与复现的其余 5 种基准模型进行对比实验，以特别设计的基于多标签问题的评价指标评估模型的分类效果，并进行了详细的对比分析。

第五章：基于自适应图卷积的心电图样本间上下文信息聚合及分类方法。本章详细介绍了基于自适应图卷积的心电图多标签分类模型 MLECG-AGCN。本研究从自适应图卷积网络入手，针对单一 CNN 网络由于受感受野的限制和权重共享的影响，对特征空间中的全局信息和邻域信息利用不够的问题，设计了一种基于注意力机制 CNN 和自适应图卷积的心电图多标签分类模型 MLECG-AGCN。MLECG-AGCN 模型主要包括特征提取网络部分和自适应 GCN 多标签分类部分。特征提取网络部分，结合本文第四章已有的实验基础，MLECG-AGCN 考虑已有的实验结果，选择分类效果最好的注意力机制 CNN 网络中的心电基础特征提取模块和注意力机制模块的组合进行特征提取，获取质量较高的心电图特征。提取特征作为输入进入自适应 GCN 网络，完成最终的心电图多标签分类。在该章节中，将 MLECG-AGCN 与复现的其余 7 种基准模型进行对比实验，以特别设计的多标签分类指标对模型进行分类效果评价，并对比分析了各个模型的多标签分类性能。

第六章：总结与展望。对本研究设计的两种基于深度学习的心电图多标签分类模型的效能进行了总结，并且结合目前心电图多标签分类任务的发展趋势，思考分析了现有研究的可优化之处，展望了未来的研究发展方向。

2. 相关理论与技术

2.1 心电信号相关知识概述

2.1.1 心电信号产生机理

心脏在人体生命的正常运转中，起着非常关键的作用，心脏通过推导人体循环系统的血管血液正常流动，从而供应给人体氧气和营养，并能帮助人体处理掉新陈代谢产生的冗余物。各种各样的心肌细胞共同完成了心脏这一人体核心器官的组织、构建。心肌细胞按照功用属性，可分为两类：工作心肌细胞和自律心肌细胞。工作心肌细胞主要承担完成心脏收缩的任务，从细胞角度而言，它同时具备了自主、传导和兴奋的细胞性质；而自律心肌细胞除具备传导和兴奋这两种细胞特性外，还有着自律这一特殊性质，因此心脏特殊传导系统的组成、运转也离不开自律心肌细胞。在接受到电指令后，普通工作心肌从静息电位向动作电位转变，经过一个除极、复极的过程，使心脏进行规律性地跳动，能够完成输送血液的功能。当心肌细胞处在静息态时，由于其细胞膜两侧正负离子的浓度不同产生电势差；而在除极、复极的过程中，膜内外正负离子运动也会导致人体体表产生电势差，这就是心脏在整个运动周期中发出可被记录的规律心电信号的原因。

2.1.2 心电图

如 2.1.1 章节所述，心脏运动过程中会产生心电信号，使用专业装置采集这些信号，并通过心电图机以波形曲线的形式对其进行展示，使用这种模式描画、记录出来的波形图被称为心电图。自 20 世纪问世以后，ECG 逐渐变成了 CVD 诊疗的主要方式之一并被广泛应用。

心电图是通过采集人体体表的电势差绘制而成，尽管每个人的心电波形存在着不同，但是，从整体上看，单个正常的心脏跳动间期的常规 ECG 波形如图 2.1 所示，是由 P 波、QRS 波群、T 波、一定概率可见的 U 波组成的；图 2.1 中还标注了常用的 PR 间期，PR 段和 ST 段间隔等。在心电图中，各段波形代表着心脏运动的各个阶段，下面我们将对各个波形的含义进行简单的介绍。




图 2.1 心电信号示意图

1. P 波：如图 2.1 最左侧所示，在单个完整 ECG 波形图中，P 波是第一个出现的，且其振动幅度较小。其主要对应着左右心房间除极的过程。P 波的常规时限为 0.12 秒，高度为 0.25mv。
2. PR 间期：PR 间期的计算从 P 波出现时开始，直到 Q 波即将出现前停止。该时间段内的波形对房室结功能的正常与否有着表象意义。其正常时间长度在 0.12-0.2 秒之间，如果该时间段太长，则可能标志着心房到心室的传导存在一定障碍。
3. PR 段：这一阶段的计算从 P 波结束后开始，直到 Q 波出现前停止，表示心电信号向心室传导的过程。正常状态下，PR 段时间在 0.05-0.12 秒，且在临床中，对心血管疾病的诊疗有相当大的意义。
4. QRS 波群：该波群由 Q 波、R 波以及 S 波复合构成，代表了左右心室快速去极化的过程。常规状态下，时限是 0.08 秒-0.12 秒。当其出现形态异常或时限超出常规状态下时限，可能代表着传导受阻或心室扩大、肥厚。
5. ST 段：S 波最末尾到 T 波前的连接段，记录心室逐渐复极过程。如果出现 ST 段偏移，那么表明心肌细胞可能出现缺血或坏死。ST 段的正常间期为 0.08-0.12 秒。
6. T 波：该波形是记录左右心室快速复极时产生的电势差而来的。T 波出现倒置现象且低于健康状态时高度时，代表着心肌缺血症状。当存在急性心肌梗死等病症时，T 波呈现高耸型。T 波的正常时限为 0.16 秒。

7. U 波：U 波在部分导联上可以被看到，位置在 T 波的后面，振幅很低，目前研究表明，其可能与心室的复极相关。

2.1.3 心电导联

绘制 ECG 时，首先需要把电极放在被测量者躯体的不同部位上，然后使用导联线，把电极与心电图机电流表的正负二极连接，以便形成该 ECG 的电路连接。标准 12 导联是临床中被普遍应用的一种国际导联标准。12 导联 ECG 中各个导联间的空间关系如图 2.2 所示，在测量时需要设置 10 个电极，并分别安置于被测量者的各个部位；其中 RA 对应的电极位置在右臂，LA 为 RA 对称位置的左臂，RL 对应电极位置在右腿，LL 对应电极位置在 RL 对称位置的左腿；V1-V6 被叫做胸导联电极，它们都被直接放置在胸壁的不同位置上。




图 2.2 12 导联位置关系图

如图 2.2 所示，其中的导联 I，II 和 III 又被称为肢体导联，计算公式如式 2.1 所示：

$$\begin{aligned} I &= LA - RA \\ II &= LL - RA \\ III &= LL - LA \end{aligned} \quad (2.1)$$

相对应的，还存在着一组加压肢体导联，为图 2.2 中的导联 aVR, aVL 和 aVF，计算公式如式 2.2 所示：

$$\begin{aligned} aVR &= RA - \frac{1}{2}(LA + LL) \\ aVL &= LA - \frac{1}{2}(RA + LL) \end{aligned} \quad (2.2)$$

$$aVF = LL - \frac{1}{2}(RA + LA)$$

剩下的六个导联被称作胸导联，其共包含 V1-V6 六种，其电极安置于胸壁的不同位置，由于它们的电极与心脏非常近，因此它们无需加压，且可以从水平面观察心脏的电生理。

2.2 多标签分类

在机器学习和深度学习发展的过程中，分类任务一直是其致力于解决的一项重要的基础任务。以深度学习而言，其已被应用于新闻分类、情感分类、图像分类、视频分类、评论分类等多项分类任务。目前，已有越来越多研究从多标签角度考虑心电图分类^[13-15]。

深度学习在进行分类任务时，通常的模式是首先建立模型，通过训练集对模型进行训练，从而形成了一种由输入空间 X 到输出空间 Y 的映射，其中 X 包含数据集样本的输入值， Y 包含各个类别的标签，形式上一般表现为离散值。按照输出类别（标签）的不同，分类任务又可被区分为以下三类：二分类任务，多分类任务和多标签分类任务。下面对多标签分类任务进行简单的介绍，重点描述多标签分类任务的定义以及其与其他分类任务的区别。

单标签多分类任务中，每个样本标签被设置为 $[0,1,2, \dots, n]$ 中的唯一一个；而在多标签分类任务中，每个样本标签可被设置为 $[0,1,2, \dots, n]$ 中的一个或多个。各样本对应标签个数的不同导致了两类问题在解决时存在一定的差异，多标签分类任务和常规的单标签分类任务相比，有三个主要特征：

1. 不同的数据集，可能有的数据集中被标记有多个标签的样本比例较高；而有的数据集中被标记为多标签的样本数比较少，在总体数据集所占的比例较低，大部分数据依然只对应一个标签。因此，不同数据集的多标签程度存在差异。
2. 标签之间是有着一定关联的，而不是完全独立的。由于多标签的存在，输出空间会因为标签间的排列组合方式的多样性变得非常巨大。由于上述原因，怎样充分挖掘各个标签之间的关联性并用来完成分类任务是此类问题的重点之一。

3. 数据不均衡问题。在多标签中，由于标签之间的不同组合方式会出现不同的标签集合，而有的标签集合对应样本数较多，有的标签集合中所包含的数据数量较少，因此会出现针对标签集合的数据不均衡问题。

综上所述，因为多标签分类任务的显著特点，需要针对其自身特征，使用一种适合于此类任务的方法。深度学习方法在解决此类任务时，主要通过使用合适的损失函数去适配样本可能对应多个标签的情况；以及适用于多标签的分类评估方法来更好地解决此问题。根据不同分类任务，即二分类、多分类、多标签分类等需要采用不同的损失函数和激活方法，其对应关系如表 2.1 所示：

表 2.1 分类任务函数

任务	激活函数	损失函数
二分类	Sigmoid	binary crossentropy loss
单标签多分类	Softmax	categorical crossentropy loss
多标签分类	Sigmoid	binary crossentropy loss

2.3 卷积神经网络与残差神经网络

2.3.1 卷积神经网络

卷积神经网络的概念，是由 Yann Lecun 在 1998 年首先提出的^[16]，从主要结构上来讲，它可以被理解成是一个拥有多个层次的感知机，而且总体来说，其有着更深的网络层次。典型的端到端 CNN 网络中，第一层为输入层，输入数据经过数据预处理操作转化为标准化数据进入输入层；输入层数据经过 CNN 特征提取部分得到高层特征；所提取特征再经过输出层，输出模型的预测结果。整个神经网络通过训练，不断提升网络的特征提取能力，让网络能够逐步得到质量更高的提取特征，并最终提升整体网络模型输出结果的预测精度。其中，CNN 特征提取部分常常由一个或多个卷积层、池化层、激活层、全连接层等堆叠而成，各层的结构和作用如下：

1. 卷积层：卷积层给定若干组卷积核，称为 kernel，输入经过卷积层后，输出一组平行的特征图。卷积核包含几个重要的参数：kernel 自身尺寸(kernel size)，深度(depth)，个数，步长(stride)，填充值(padding)。卷积核的尺寸由网络设置时人为指定，在二维图像处理中通常包含长(height)和宽(width)两个维度，常用的尺寸为 3*3, 5*5 等；卷积操作即是卷积核在输入特征图

(feature map) 上滑动，通过卷积运算（相乘后再相加）获取到局部特征，kernel 作为窗口在整个输入 feature map 上滑动完成后，得到输出。卷积核的深度可以用来描述层中含有多少个 kernel，通常与输入 feature map 的通道数 (channel) 相同，当计算时，将该层中的各个卷积与输入 feature map 中对应通道的 feature 进行卷积操作，最后相加输出该层卷积运算后的特征。卷积核的个数代表了输入经该层卷积后输出 feature map 的个数。stride 表示 kernel 作为窗口单次滑动所前进的距离，常用值为 1 或 2。填充值是为了解决在卷积操作过程中，由于卷积核与输入 feature map 在特征图边缘进行卷积操作时有局限性，导致输出 feature map 维度与输入 feature map 相比较小的问题而出现的，常用的 padding 方法有两种：（1）不填充 (valid padding)：即不进行处理，直接使用原始图形且规定卷积核不能超出原始图像的边界；（2）进行填充 (same padding)：进行填充，卷积核不受原始图像边界的限制，并使卷积操作后的输出 feature map 大小与输入 feature map 一致。




图 2.3 卷积操作示意图

2. 池化层：池化层一般在 CNN 的网络结构中，周期性地穿插于卷积层之间，本质性上是采取了一个非线性的形式，对卷积后特征进行降采样。常见的池化函数有：最大池化函数和平均池化函数，其运算方式如图 2.4 所示。池化操作的实现将会进一步的降低数据空间的大小，从而导致整个模型的参数量和计算量得到显著的减少，这同时还在一定程度上控制了过拟合。




图 2.4 池化操作示意图

3. 全连接层：全连接层通常出现在整个模型的最末端，模型通过全连接层来进行推理，实现网络的线性分类。全连接层中，输出层神经元和前层的全部激活后神经元相连，而上层输入则通过全连接层后传递到输出层。从功能上而言，全连接层建立已提取的隐形特征和样本标签之间的映射关系，即实现分类的过程。
4. 激活层：非线性的激活函数层通常紧跟卷积层出现，其主要功能是增强模型的鲁棒性和非线性表达能力，并消解梯度弥散等问题。常见的非线性激活函数包括 ReLU, tanh, Sigmoid 等，其中在卷积神经网络中最常见的是 ReLU 函数。

2.3.2 一维卷积

心电图数据在形态上表现为一维波形，从数据角度来看，其是一组时序信号值。而在计算机视觉任务中，常规 CNN 多被应用于二维图像的特征提取，因此如何对常规 CNN 进行调整，进而有效地对一维波形进行特征提取是使用 CNN 的基础。

通过一维卷积代替常规 CNN 中的二维卷积是解决上述问题的合适方法。Zhang 等人^[17]及 Chen 等人^[18]在其研究中论述了卷积应用于一维时序信号数据分类任务的合理性，并通过实验进行验证。Kiranyaz 等人^[19]详细描述了一维卷积应用于心电图识别的有效性和具体方式，实验表明一维卷积可以非常有效地提取心电图特征并最终完成分类任务。Pan 等人^[20]及 Cai 等人^[12]在其研究中使用一维卷积 CNN 用于心电图分类任务，取得较好的结果，Cai 等人对一维卷积的合理性进行了进一步的说明。

如图 2.5 所示，异常的心电图中，异常信号经常出现在心电图的局部区域，这些局部异常信号能够反映心电图的空间特征，这与二维图像中图像识别的原理类似。与此同时，卷积操作的重要作用是对图像进行特征提取，对于心电图这样

的一维波形，一维卷积很适合对其进行特征提取，这与二维图像中的卷积操作作用一致，都是用来提取特征，因此具有可类比性。




图 2.5 异常心电波形图

图 2.6 详细描述了一维卷积的原理和计算方式。




图 2.6 一维卷积计算过程

PTB-XL 数据集中心电图数据为 12 导联心电图，12 导联心电图输入数据形如 $X \in R^{N \times C \times L}$ ，其中 N 为心电图数据集样本总数；C 为通道数，对应 12 导联；L 为单个样本单导联的时序信号值长度。而一维卷积所要求的输入形为 $X' \in R^{N \times C_{in} \times L}$ ，与多导联心电图输入数据对应，因此多通道一维卷积对多导联心电图特征提取具有良好的适配性。综合上述原因及已有研究的实验论证^[12, 17-20]，一维卷积可以非常有效的提取心电图中的特征信息并应用于最终分类。这也是本研究特征提取网络模型设计的理论基础。

2.3.3 残差神经网络

ResNet 最早发表于 2016 年的 CVPR^[21],其如今大量应用于心电图分类任务。ResNet 的创新点是:提出了残差学习的理论,同时特别构建了不同深度的网络结构。ResNet 网络基于这样一种想法,假定计划完成的网络设有最优的结构,通常在实际构建的深层网络结构中,网络中的部分层是并不需要的,ResNet 网络的想法是,能否找到一种方案来使这些并不需要的层可以实现恒等映射,从而确保输入在经过这个网络层后得到的输出,还能和输入保持一致。具体实现中,ResNet 通过残差单元技术,使上层特征可以经过短路连接直接作为输入进入下层网络,从而拟合恒等映射,有效的克服了网络衰退问题。(图 4 为残差单元结构)




图 2.7 残差单元结构^[21]

ResNet 作为在图像分类任务中效果最好的网络结构之一,启发了大量研究者去思考并调整其网络结构,从而应用于心电图分类。Zhou^[22]等人提出了一种基于 ResNet 的注意力机制网络进行心电图数据分类,使用 MIT-BIH 数据集以及 PTB 数据集进行实验并且都取得了出色的效果。Park^[23]等人提出了一种 SE-ResNet 模型,设计了以 ResNet 网络为基础,结合了挤压-激励模块的残差网络,其性能优于 ResNet 基线模型。Han^[11]等人提出了一种多导联残差神经网络模型 (ML-ResNet),其结构包含三种残差块和特征融合模块,并在 12 导联心电图记录监测和定位心肌梗塞任务中取得较好的效果。

上述研究表明,相较于传统 CNN 模型,以 ResNet 为基础的模型有效解决了网络模型的退化,并且已有研究将其成功用来进行心电图分类任务且有着很好的实验表现,这对本研究有着一定的指导意义。

2.4 注意力机制

注意力机制（attention mechanism）最初被用于机器翻译^[24]，经过近几年的发展，逐渐成为深度学习中的重要内容之一。在计算机视觉中，注意力机制主要的想法就是通过一定的方式，使得模型能够学习到注意力，即模型能够自动的去关注大量信息中一些需要重点关注的重要信息，而可以自主的忽略掉一些并不是那么重要的信息。神经网络中，通常来说，如果一个模型的参数量越大，那么整个模型就有着更强的表达能力，其信息存储量也相应的更大，但是过多的信息量可能会造成信息的过载和冗余。注意力的出现，即是为了使得模型在大量的输入信息中能够重点关注其中对当前任务最核心的信息，减少网络对于一些不那么重要的信息的关注度，甚至能够直接过滤掉一些不相关的信息，通过这种方式来处理信息过载的问题，并提高任务处理的效率和准确性。

近几年，已有研究尝试将注意力机制应用于计算机视觉领域。Max 等人在^[25]中给出了一个将注意力运用到空间域的图像分类模型，这个模型使用了基于注意力的空间转换器模块，替代了池化层，在图片原始空间和另一空间之间完成图片信息的转换并聚焦其中的关键部分，提升了图像分类准确率。Hu^[26]等人设计并构建了一种显式建模通道间相互依赖性，实现对于不同通道注意力机制的图像分类模型（Squeeze-and-Excitation Networks，SENet），在所使用数据集上获得高于基线模型的效果。CAI 等人^[12]设计的 Multi-ECG 网络模型中，也使用了 SE 模块增强网络对于通道的注意力并应用于心电图分类，实验结果验证了其有效性。

由此可见，将注意力机制应用于心电图特征提取网络，增强网络关注心电图局部重点区域的能力，提取更有效的心电图特征是一个优化模型的方向，这也是本文研究的一项重要内容。

2.5 图卷积神经网络

在很多的机器学习问题中，输入可以被组织成图，为了对图结构数据进行更好的处理分析，图神经网络应运而生，其中图卷积网络（Graph convolutional network，GCN）因为其把卷积算法从传统数据推广到图数据的特性，越来越受到人们的关注。图卷积网络相较于普通卷积网络的特点是，其不仅关注当前节点的信息，同时关注邻域节点的信息，提升了网络关注空间全局信息的能力。近年来，大量的研究工作^[27-31]致力于设计用于图结构数据的卷积神经网络。根据图数

据卷积的定义，GCN 可分为光谱法和空间法。基于光谱的 GCN^[27-29]一般化基于图傅里叶变化（Graph Fourier Transform）的卷积，而基于空间的 GCN^[30, 31]直接对图节点及其邻域节点进行人工定义的卷积。在应用方面，GCN 可以同时处理转换设置^[28, 29]和归纳设置^[30, 31]问题。在转换设置中，训练数据和测试数据是同一固定图中的节点，而在归纳设置中，模型需要跨不同的图进行推理。

图卷积网络自提出以来，相关研究大多将其应用于图结构数据的节点分类及连接预测任务。但近年来，随着 GCN 的发展成熟，部分研究开始将 GCN 应用于图像分类任务和图像聚类任务并取得了不错的效果。GCN 在分类及聚类任务中的特点是：其在分类、聚类时不仅考虑图中单个节点的特征，同时考虑该节点邻域节点与该节点间的结构相似性和上下文关系。2019 年，Wang^[32]等人对人脸聚类任务提出了一种基于 GCN 的可学习聚类方法，该文章通过实验表明，和最先进的方案相比，该方法也是精确的，而且在计算复杂度方面可以进一步的进行扩展。2021 年，Ding^[33]等人对高光谱图像分类任务提出了一种基于自适应概率图卷积的网络模型，该模型能够更好的编码同质结构，并能自适应地学习图结构和输出特征。该研究在四个公开的高光谱图像数据集上评估所设计模型，验证了模型的有效性。

由此可见，GCN 在原理上适用于特征空间中节点间关系的建模，并可以应用于分类任务，提高分类精度。现有以 CNN 为基础的分类模型在进行心电图分类时，各个样本数据只能根据自身所提取特征进行分类，而无法更全面的应用特征空间中的全局信息、及特征空间邻域中的其他样本特征来协助完成分类任务。而通过卷积操作提取心电图样本特征后，样本特征与其在特征空间上的邻域样本特征存在结构相似性和丰富的上下文关系，这些关系在 CNN 模型中尚未被很好的利用。而在图卷积网络中，网络不仅考虑当前节点的信息，也考虑其邻域节点的信息，这种特性为解决上述问题提供了解决思路。因此，如何将 GCN 与 CNN 特征提取网络相结合，获取特征空间中节点与邻域节点的上下文关系并用于心电图多标签分类，是本文研究实现的重点。

2.6 本章小结

本章介绍了本文涉及的理论和技术。首先介绍了心电信号是怎样产生并且被记录的；ECG 绘制的原理还有常规心电图波形各个部分的生物学含义；导联的

定义以及 12 导联 ECG 中各导联心电信号的测量、计算方式。通过这部分内容，主要描述了 12 导联心电图作为常规辅助诊疗手段的作用原理，详细描述了其在心血管疾病临床诊断中的重要性。

因本研究使用的心电图数据集 PTB-XL 中数据为多标签，本研究需要完成多标签分类任务，因此在本章简单介绍了多标签分类的定义，其与多分类任务的不同，以及深度学习中针对多标签分类任务在损失函数上的相关知识。

介绍了卷积神经网络的简单原理；详细描述了一维卷积以及其适用于心电图分类的原因，一维卷积如何应用于心电图数据特征提取的原理，对已有的一维卷积应用于心电图分类任务的研究做了简单介绍；简述了残差神经网络的定义和优势，对现有应用残差神经网络对心电图进行分类的研究做了简单介绍。

围绕注意力机制，介绍了其定义和优势，以及深度学习计算机视觉相关任务中已有的相关应用研究。

简介了图卷积神经网络的基本概念，阐述了图卷积神经网络的定义和构建方式，描述了其在节点间关系建模、结构表示上的强大能力，并概述了已有的结合图卷积神经网络并将其应用于图像的有关研究成果，阐述了图卷积神经网络在优化心电图分类模型上的可行性和有效性。

3. 心电图分类现存问题与本研究解决方法

3.1 心电图多标签分类

3.1.1 心电图多标签分类意义

在心血管疾病的临床诊断中存在着这样一种现实情况，即在很多实际的病例中，心血管疾病患者常同时出现多种不同类型的心血管疾病症状，且部分症状是不独立的。然而现有的大部分网络模型更倾向于关注一种或几种心血管疾病，并没有从多标签的角度对其进行分析和研究。针对上述实际情况，同时考虑到多标签分类能够更加细致地刻画心血管疾病的复杂具体情况，且已有越来越多研究从多标签角度考虑心电图分类^[13-15]，因此，多标签心电图的自动分类问题有着较高的研究意义和价值，这也是本研究选择从多标签角度研究心电图分类问题的原因。

为了从多标签角度考虑心电图的自动分类问题，本研究选择了多标签的心电图数据集 PTB-XL 作为模型训练、测试的数据集。多标签分类任务存在数据不平衡、评判标准不统一等问题，这也是本文针对多标签需要解决的问题。

3.1.2 基于特别设计损失函数及评价指标的解决方法

在 3.1.1 章节中，详细描述了本文选择从多标签角度考虑心电图分类的原因，并描述了在多标签分类任务中需要本文解决的问题。针对数据不平衡问题，本文使用特别设计的损失函数来缓解其影响，搭配适用于多标签分类问题的激活函数解决相关问题，损失函数的详细内容在章节 4.2.4 阐述。针对评判标准问题，本文参考已有心电图多标签分类研究^[13, 14]，以及其他多标签分类相关研究^[34-37]，选择了多项多标签评价指标对模型的分类效果进行全方位的衡量，具体内容在章节 4.3.5 阐述。

3.2 心电图高频信息利用问题

3.2.1 心电图高频信息利用不充分问题

已有研究表明，在心电图中，其中的高频部分对心血管的健康情况能够进行更全面的分析^[2, 3]。从形态上来看，心电图的高频部分在波形上表现为非平稳信号，包括 P 波、QRS 波群、T 波等都有着这样的波形表现，这部分波形相较于其余部分的较平稳波形，包含着更丰富的信息。而现有的深度学习方法少有针对心电图高频部分进行充分信息利用的结构，存在着对心电图高频信息利用不充分

的问题。为了提高诊断准确率和效率，如何在心电图分类中更好的利用其中的高频信息是一个亟需解决的问题。

3.2.2 基于空间注意力的解决方法

针对 3.2.1 章节中现有研究对心电图高频信息利用不充分的问题，本文通过构建基于空间注意力的注意力机制 CNN 网络模型，来更好的利用心电图高频信息。该网络中的注意力机制模块通过高通滤波器来突出原始信号的高频位置，生成注意力图，然后将注意力图嵌入到原始信号，从而增强网络关注心电图高频信号的能力。第四章对该解决方法所提出设计的网络模型、实验结果等进行了详细的阐述。

3.3 心电图特征空间全局信息和邻域样本信息利用问题

3.3.1 心电图特征空间全局信息和邻域样本信息利用不充分问题

在心电图分类任务中，现有的基于单一卷积神经网络的模型，均通过适当的方法增强模型的表征能力，进而提取更有效的心电图特征用于分类，并取得了不错的效果。但单一的卷积神经网络因为受到感受野的限制和权重共享，不能很好地利用全局信息，及对特征空间邻域中的其他样本提供的信息利用不够。而通过卷积操作提取心电图样本特征后，样本特征与其在特征空间上的邻域样本特征存在结构相似性和丰富的上下文关系，这些关系因单一 CNN 的限制尚未被很好的利用，这影响了分类结果的准确率。为了进一步提高分类效果，如何在心电图分类中更好的利用特征空间中的全局信息和邻域样本信息并应用于最终分类是一个很有研究价值的问题。

3.3.2 基于样本间上下文信息聚合的解决方法

针对 3.3.1 章节中的问题，本文构建了基于心电图样本间上下文信息聚合的 MLECG-AGCN 网络模型。该模型首先利用基于空间注意力的注意力机制 CNN 模型中的特征提取模块提取心电信号特征，然后构建图卷积模块，并提出一种自适应的方案构建图卷积神经网络的边，实现了非局部的上下文信息聚合，有效利用特征空间全局信息和邻域样本信息协助样本进行分类，提高分类结果的准确率。第五章对该解决方法所提出设计的网络模型、实验结果等进行了详细的阐述。

3.4 本章小结

本章重点介绍了心电图分类的现存问题，并对应各问题简述了本文的解决方法，为后面两章进行了铺垫，后两章所提出模型的关系如图 3.1 所示：




图 3.1 注意力机制 CNN 模型与 MLECG-AGCN 模型关系图

第四章和第五章的具体内容及关系为：

1. 第四章：针对心电图高频信息利用问题，依照本章 3.2.2 章节提出的基于空间注意力的解决方法，设计并构建了注意力机制 CNN 网络，依照本章 3.1.2 章节提出的解决方法从多标签角度考虑问题，并进行了相关实验验证所设计模型的有效性并与多个现有模型进行对比实验。
2. 第五章：针对单一 CNN 对特征空间全局信息和邻域样本信息利用问题，为了进一步提高分类效果，在第四章所提出的注意力机制 CNN 网络的基础上，首先使用注意力机制 CNN 网络特征提取部分提取有效性较高的心电图特征，再依照本章 3.3.2 章节提出的基于样本间上下文信息聚合的解决方法，综合起来设计并构建了 MLECG-AGCN 网络，并进行了相关实验验证设计模型的有效性并与包含注意力机制 CNN 在内的多个对比模型进行对比实验。

4. 基于空间注意力的心电图高频信息挖掘及分类方法

4.1 引言

基于 CNN 网络的心电图分类模型通过以卷积为基础的神经网络对输入的原始心电图进行特征提取，对所提取特征使用线性分类器完成模型的分类预测。但是现有的大多数基于 CNN 网络的心电图分类模型，由于在空间维度信息建模时忽略了不同信号间的差异，存在对心电图中高频信息挖掘和利用不充分的现象，这在一定程度上影响了模型整体的分类精度。

针对以上不足，本文设计并构建了基于空间注意力的网络模型-注意力机制 CNN。构建网络的核心模块包含：心电信号预处理模块、心电图基本特征提取模块和心电图注意力机制模块。经过上述模块的预处理、特征提取、特征增强等步骤，然后通过线性分类器，最终完成对输入心电图的多标签分类任务。

注意力机制 CNN 网络中，本文主要提出并设计了三个模块来对心电图进行多标签分类，它们分别是：心电信号预处理模块、心电图基本特征提取模块和心电图注意力机制模块。心电信号预处理模块主要是为心电信号提供预处理，将其标准化为统一格式的输入数据，并做训练集和测试集的划分。心电图基本特征提取模块以 ResNet101 为基础设计，通过堆叠特别设计的深度可分离残差单元完成整体模块的构建，对心电图基本特征进行提取。心电图注意力机制模块通过高通滤波器来突出原始信号的高频位置，生成注意力图，然后将注意力图嵌入到原始信号，从而增强了网络关注心电图高频信号的能力，再通过堆叠特别设计的 RES Attention Module 对其进行高层特征提取，以此实现对心电图高频信号的注意力增强，并得到增强后的心电图高层特征。注意力机制 CNN 网络通过级联操作拼接增强后的心电图高层特征和心电图基本特征，全面保留了信息增强后的心电图高层特征和心电图提取的基本特征，将拼接后特征作为后续模型的输入，有效地利用了先验信息，增加了提取特征的信息量。

为检验本文设计的注意力机制 CNN 模型的分类有效性，本章实验中，将该模型与复现的其余 5 种基准模型进行对比实验，以章节 4.3.5 中所述的多标签分类指标评估模型的分类效果，实验表明，基于注意力机制 CNN 的心电图分类的主评价指标值达到 0.941，高于其余对比模型，且副评价指标值也有很好表现。

4.2 基于空间注意力的心电图高频信息挖掘及分类方法算法

4.2.1 注意力机制 CNN 网络结构

心电图数据首先经过数据预处理模块，此模块使用麻省理工学院发布的针对波形数据库的解析工具 WFDB 库读取心电图数据，并做训练集和测试集的划分。经过预处理后，得到形如 $X \in R^{N \times C \times L}$ （ N 为训练集样本总数； C 为通道数道数； L 为时序信号长度）的数据，作为注意力机制 CNN 网络的输入。

该网络模型流程如图 4.1 所示。

该网络结构由两部分组成：特征提取模块和线性分类器模块。特征提取模块主要由两个分支模块组成：一个是心电图基本特征提取模块，主要用来提取输入心电图的基本特征，其结构如图 4.1 左侧分支所示，具体结构在 4.2.2 章节详细描述。另一个是注意力机制模块，主要用来增强心电图中的高层特征，其结构如图 4.1 右侧分支所示，具体结构在 4.2.3 章节详细描述。 X 经过特征提取模块进行特征提取后输出经过信息增强的特征 $X_{out} \in R^{N \times d_{out}}$ ， X_{out} 经过线性分类器模块，得到多标签分类结果。




图 4.1 注意力机制 CNN 网络模型

4.2.2 心电图基本特征提取模块

心电图基本特征提取模块结构如图 4.1 左侧分支所示,第一层为常规卷积层,输入为经过预处理的形如 $X \in R^{N \times C \times L}$ 的多通道一维心电信号,进过卷积核为 7 的一维卷积层;一维批归一化层 (Batch Normalization Layer, BN Layer); 非线性激活函数层;最大池化层得到高层特征 $X_1 \in R^{N \times C_1 \times d_1}$ 。 X_1 作为输入进入下层网络,网络此部分以 ResNet101 为基础设计实现,堆叠多个深度可分离残差单元,其中每个残差单元的结构如图 4.2 RES Module 所示。 X_1 经过堆叠的特别设计残差单元进行特征提取后,输出高层特征 $X_2 \in R^{N \times C_2 \times d_2}$,最后, X_2 经过维度展平得到心电图基本特征提取模块的输出 $X_{feature} \in R^{N \times d_{feature}}$ 。

图 4.2 为该模块中 RES Module 的详细结构,该单元对输入特征进行特征提取。在具体设计中,考虑现有研究成果,RES Module 以 ResNet101 中的残差单

元为基本结构，且考虑到深度可分离卷积（Depthwise Separable Convolution, DSC）能够更好的减少参数量，并可以同时搭配 BN 层和非线性激活函数层提高模型的非线性表达，RES Module 使用 DSC 对普通卷积进行了替换。DSC 的结构如图 4.3 所示，DSC 包含两步：深度方向卷积（depthwise conv, DWC）和逐点卷积（pointwise conv, PWC）。其中，DWC 对各通道仅使用单个卷积核运算，完成各通道特征提取。PWC 使用长度为 1 的卷积核，经 DWC 输出的特征图与长度为 1 的卷积运算后，DSC 可以自由改变输出通道的数量；同时对 DWC 输出的各通道的特征图进行融合。用长度为 1 的 kernel 的另一个优点是：能够在保证特征图尺度恒定的状态下，通过后接的非线性激活函数来大幅度提高非线性表征能力，有助于增加网络深度。因 DSC 的 DWC 操作为各通道间单独进行，因而可以显著降低参数量，与此同时 PWC 操作能够完成普通卷积中通道特征融合的任务，在该层后添加 BN 层和 ReLU 激活函数层增加所提取特征的非线性。




图 4.2 RES Module 结构图




图 4.3 深度可分离卷积^[38]

4.2.3 注意力机制模块

在心电图中，大多数疾病均与心电图中的高频信号（即非平稳信号）相关。这部分波形相较于心电图其他部分，有着波形突变性强的特征。而拉普拉斯滤波器的特点是：可以突出图像中强度出现快速变化的区域。且拉普拉斯滤波器已被应用于部分深度学习应用中，如边缘检测、语义分割等。综上所述，本文使用拉普拉斯滤波器完成对心电图高频信号的增强。

基于上述心电图特点，本文构建了针对心电图特点的注意力机制模块，其结构如图 4.1 右侧分支所示，注意力机制模块输入为经过预处理的形如 $X \in R^{N \times C \times L}$ 的多通道一维波形图，第一层为拉普拉斯滤波器层，对 X 中波形突变性较强的高频部分进行增强，得到更关注心电图高频信号的输出特征 $Y \in R^{N \times C \times L}$ 。拉普拉斯滤波器层使用一维高斯拉普拉斯（Laplacian of Gaussian, LoG）滤波器对输入进行滤波操作，LoG 第一步是完成对输入的降噪，通过一维高斯平滑滤波去除噪声；再使用一维拉普拉斯算子对降噪后的心电图进行滤波操作，针对一维波形图，选取离散卷积核 $[1, -2, 1]$ 进行拉普拉斯滤波，得到输出特征 Y 。 Y 经过卷积核为 7 的一维卷积层；一维 BN 层；非线性激活函数层；步长为 2、卷积核为 3 的最大池化层得到高层特征 $Y_1 \in R^{N \times C_1 \times d_1}$ 。 Y_1 经过堆叠的注意力机制残差单元得到更高层特征图 $Y_2 \in R^{N \times C_2 \times d_2}$ 。注意力机制残差单元结构如图 4.4 中 RES Attention Module 所示，其中的 SE 模块通过学习的方式自动为各个通道的重要程度打分，以此筛选网络对于通道的注意力。 Y_2 经池化层池化和维度展平后，得到注意力机制模块的输出 $Y_{att} \in R^{N \times d'}$ 。此特征 Y_{att} 与心电图基本特征提取模块所提取特征 $X_{feature}$ 进行拼接得到最终输出特征 $X_{out} \in R^{N \times d_{out}}$ ，以此实现对高频信息的注意力增强，同时又不丢失原始心电图提取的基本特征信息。




图 4.4 RES Attention Module 结构图

4.2.4 损失函数

本研究所针对的分类任务为多标签分类任务，标签总数达到 44 类，且数据集样本数据分布极不均衡。所以面对此类问题时，在实际的训练模型中必须采用不同的激活函数和损失函数，而通过章节 2.2 的说明，本文中选用了 sigmoid 作为激活函数，二元交叉熵函数则作为损失函数。考虑到因数据集分布不均匀可能导致的分类偏差问题，本研究采用加权的二元交叉熵函数（binary crossentropy loss with logits, BCEWithLogitsLoss）作为损失函数。损失函数表达式如式 4.1 所示，其中 c 表示该类别样本总数， N 为样本总数，在本研究中 $c > 1$ 表示样本为多标签， n 表示每个 *batch* 的样本数量， p_c 为该类别的权重系数。

$$l_c(x, y) = L_c = \{l_{1,c}, \dots, l_{N,c}\}^T \quad (4.1)$$

$$l_{n,c} = -w_{n,c} [p_c y_{n,c} \cdot \log \sigma(x_{n,c}) + (1 - y_{n,c}) \cdot \log(1 - \sigma(x_{n,c}))]$$

式 4.1 中的权重系数 p 计算方式如式 4.2 所示，其中 c 为当前类别， c_{num} 为该类别样本总数。总体而言，各类别 c 对应的权重系数 p_c 与其数量成反比，以此提高小样本类预测时对损失函数的影响，缓解数据集分布不均匀造成的影响，取得更好的分类效果。

$$p_c = 1/\log(c_{num} + 1) \quad (4.2)$$

4.3 实验与分析

4.3.1 数据集

本文的实验基于 PTB-XL 数据集进行。PTB-XL 是一个大型心电图数据集，包含来自 18885 名患者长度为 10 秒的 21837 个临床 12 导联 ECG。PTB-XL 数据库的采样频率为 500Hz。单条样本数据共 5000 个信号，单个信号由头文件(.hea)和数据文件(.dat)构成，在文件夹存储。本文针对数据集中的诊断类标签共 44 类，进行心电图多标签分类任务。在数据集数据的类别标记中，PTB-XL 使用超类和子类来对类别进行描述，共给出了 71 个不同的类别，其中包含有 44 个诊断类别。数据集样本信息通过 csv 文件存储，其中每个样本的心电图数据单个信号以.dat 和.hea 形式存储。经过数据预处理，得到形如 $X \in \mathbb{R}^{N \times C \times L}$ 的原始心电图数据，其中 N 为心电图数据集样本总数； C 为通道数； L 为单个样本单导联的时序信号值长度。

PTB-XL 提供一组标准化的 SCP_ECG 声明来描述一个样本的标签，简称为 scp_codes，形如 {'NORM': 100.0, 'SR': 0.0}。scp_codes 中共包含 71 条独立的 SCP_ECG 声明语句，数据集将这些声明语句分为三大类：诊断类声明语句（diagnostic statements）44 类，描述对样本的诊断性陈述；形式类声明语句（form statements）19 类，描述 ECG 信号形式，其中 4 类与诊断类声明语句重复；节律类声明语句（rhythm statements）12 类，描述样本的节律类型。样例中 NORM 即为诊断类声明，表示正常；SR 为节律声明，表示窦性心律（sinus rhythm）。数据集中对所有诊断类声明设置可能性范围为(0, 100]，表示心血管疾病专家的确定性。对于形式类声明和节律类声明，在无似然信息可用情况下，相应的似然值设置为 0。

数据集针对诊断类声明给出了超类（superclass）-子类（subclass）-具体类（specific class）的层次结构，表 4.1 给出了诊断类声明超类的定义。诊断类声明具体类（共 44 类）的定义及所包含样本数如表 4.2 所示。本研究针对样本的诊断类声明具体类别进行多标签分类，取样本的 scp_codes 中诊断类声明值大于 0 的类别为此样本的标签，将所研究问题转化为一个 44 类多标签分类问题。

表 4.1 诊断类超类声明

标签	SCP 声明描述
NORM	Normal ECG (正常心电图)
CD	Conduction Disturbance (传导干扰)
MI	Myocardial Infarction (心肌梗塞)
HYP	Hypertrophy (肥大)
STTC	ST/T change (ST/T 段改变)

表 4.2 诊断类声明具体类概述

标签	标签描述	样本数	标签所属超类
NDT	non-diagnostic T abnormalities	1829	STTC
NST_	non-specific ST changes	770	STTC
DIG	digitalis-effect	181	STTC
LNGQT	long QT-interval	118	STTC
NORM	normal ECG	9528	NORM
IMI	inferior myocardial infarction	2685	MI
ASMI	anteroseptal myocardial infarction	2363	MI
LVH	left ventricular hypertrophy	2137	HYP
LAFB	left anterior fascicular block	1626	CD
ISC_	non-specific ischemic	1275	STTC
IRBBB	incomplete right bundle branch block	1118	CD
IAVB	first degree AV block	797	CD
IVCD	non-specific intraventricular conduction disturbance (block)	789	CD
ISCAL	ischemic in anterolateral leads	660	STTC
CRBBB	complete right bundle branch block	542	CD
CLBBB	complete left bundle branch block	536	CD
ILMI	inferolateral myocardial infarction	479	MI
LAO/LAE	left atrial overload/enlargement	427	HYP
AMI	anterior myocardial infarction	354	MI
ALMI	anterolateral myocardial infarction	290	MI

表 4.2 (续表) 诊断类声明具体类概述

ISCIN	ischemic in inferior leads	219	STTC
INJAS	subendocardial injury in anteroseptal leads	215	MI
LMI	lateral myocardial infarction	201	MI
ISCIL	ischemic in inferolateral leads	179	STTC
LPFB	left posterior fascicular block	177	CD
ISCAS	ischemic in anteroseptal leads	170	STTC
INJAL	subendocardial injury in lateral leads	148	MI
ISCLA	ischemic in lateral leads	142	STTC
RVH	right ventricular hypertrophy	126	HYP
ANEUR	ST-T changes compatible with ventricular aneurysm	104	STTC
RAO/RAE	right atrial overload/enlargement	99	HYP
EL	electrolytic disturbance or drug (former EDIS)	97	STTC
WPW	Wolff-Parkinson-White syndrome	80	CD
ILBBB	incomplete left bundle branch block	77	CD
IPLMI	inferoposterolateral myocardial infarction	51	MI
ISCAN	ischemic in anterior leads	44	STTC
IPMI	inferoposterior myocardial infarction	33	MI
SEHYP	septal hypertrophy	30	HYP
INJIN	subendocardial injury in inferior leads	18	MI
INJLA	subendocardial injury in lateral leads	17	MI
PMI	posterior myocardial infarction	17	MI
3AVB	third degree AV block	16	CD
INJIL	subendocardial injury in inferolateral leads	15	MI
2AVB	second degree AV block	14	CD

4.3.2 实验环境

设备:CPU使用的是4核32GB内存,GPU使用Tesla-V100-SXM-32GB*1。

环境:Pytorch1.7.1+ cuda10.0

4.3.3 对比模型设计

本研究分别基于下列基线模型进行对比实验:

1. ResNet18^[21]: 使用了残差结构的CNN网络,总结构共18层,是ResNet系列网络中层数最少、参数量最低的网络,针对心电图特点进行结构优化,将二维卷积替换为一维卷积。
2. ResNet101^[21]: 使用了残差结构的深度CNN网络,相较于ResNet18,残差块中卷积核不同,且网络深度更深,同样针对心电图特点,将二维卷积替换为一维卷积。
3. Multi-ECGNet^[12]: 以残差神经网络为基础,使用一维卷积,结合深度可分离卷积、自定义的挤压-激励模块构建残差块。
4. XceptionNet^[39]: 使用深度可分离卷积在InceptionNet V3的基础上进行改进的CNN网络,同样针对心电图特点,将二维卷积替换为一维卷积。
5. InceptionNet^[40]: 通过各个尺寸不同的卷积核获得图像中各个尺度的特征,并最终融合成特征信息用于分类的CNN网络,同样针对心电图特点,将二维卷积替换为一维卷积。

4.3.4 训练超参数配置

在模型训练的过程中,本文通过pytorch完成相关实验,其中为各个模型配置的超参数值如表4.3的超参数配置表所示:

表 4.3 超参数配置表

超参数	配置值
Optimizer	Adam
Learning Rate	1e-3 with decay
Batchsize	16, 32
Epoch for CNN model	50
egularization strategy	Earllystopping

4.3.5 评价指标

本研究所针对的分类任务为多标签分类任务,根据多标签分类问题研究^[34],并参考其他关于心电图多标签分类研究中所使用的指标^[13, 14],本研究选择宏平均AUC值作为判断模型分类效果的主评价指标。该指标可以重点关注基于模型的软分类器输出,对分类结果进行评估而无需进行阈值处理,可以更完整的了解

给定分类模型的判别能力。现对主评价指标即宏平均 AUC 值的计算方式及含义做简单介绍。

AUC 值全称为 ROC 曲线下面积。在分类任务中,各类别可根据样本中针对该类的预测情况绘制相应的 ROC 曲线。ROC 曲线的主要特点是:因为它同时兼顾了两个指标真正例率(True Positive Rate, TPR)和假正例率(False Positive Rate, FPR),并且兼顾了样例中的预期正例和预期负例,所以是一个相对平衡的评价方式;同时,由于 ROC 曲线的两项指标 TPR 和 FPR 各自只考虑了正例和负例,所以这两个指标不依赖于具体的类别分布,不随正例和负例的百分比变化而引起大幅变动。

基于 AUC 值的性能度量方法是一种高效的、基于排序的算法,它可以为我们提供 ROC 曲线的相关信息。AUC 即 ROC 曲线下面积,AUC 值涵盖了 ROC 曲线以各个分类阈值进行分类的结果,从而提供了一种各个分类阈值下的分类器综合性能度量方法。从评估结果而言,如果某个类别的 AUC 值越大,则分类器对于这个类别有着更好的分类效果。

因本研究任务为多标签分类,在 AUC 值计算时,需要从多标签角度考虑问题。具体方式为:将 n 个类别的多标签分类问题看作是 n 个二类分类问题。首先,计算各种类别在不同分类阈值下的 TPR 和 FPR,再绘制各种类别的 ROC 曲线,计算各类别 AUC 值,之后使用宏平均的方式对各个类别的 AUC 值进行计算,得到整个分类器对于所有类别的宏平均 AUC 值(macro auc)。宏平均 AUC 值因为在平均时假设所有类别有着相同的重要性,因此对小类别的影响比较敏感,与此同时,该指标可以重点关注基于模型的软分类器输出,对分类结果进行评估而无需进行阈值处理,可以更完整的了解给定分类模型的判别能力。

另外,本研究还使用三种常见的多标签分类评价指标作为副评价指标,包括标签集排序损失(label ranking loss, RL);最大概率预测标签错误率(One Error, OE);全覆盖偏差(covrage error, Cov),各评价指标计算公式即详细说明如表 4.4 所示:

表 4.4 评价指标说明表

评价指标	计算公式&说明
RL	$RL_D(f) = \frac{1}{n} \sum_{i=1}^n \frac{1}{ Y_i \bar{Y}_i } - \{(y_1, y_2) f(x_i, y_1) \leq f(x_i, y_2), (y_1, y_2) \in Y_i \times \bar{Y}_i\} $ 计算标签集中的排序损失，计算方式为（标签集中为 1 的标签的概率小于标签集中为 0 的概率的标签个数）/（标签为 1 的标签个数乘以标签为 0 的标签个数）
OE	$OE_D(f) = \frac{1}{n} \sum_{i=1}^n \left[\left[\operatorname{argmax}_{y \in Y} f(x_i, y) \right] \notin Y_i \right]$ 计算每个样本标签集中预测概率最大的标签是否为该样本真实标签之一
Cov	$Cov = \frac{1}{N} \sum_{i=1}^N \max_{\lambda \in y_i} \operatorname{rank}(\lambda) - 1$ 计算每个样本预测标签集中，按照概率降序排序，需要多少个预测标签将真实标签中真值为 1 的标签全覆盖

4.3.6 实验结果

本章给出了注意力机制 CNN 模型在 PTB-XL 数据集采样频率为 500Hz 数据及采样频率为 100Hz 数据上的实验结果，并在使用相同数据集和数据预处理方法的前提下，使用章节 4.3.3 中的对比模型进行了对比实验，使用章节 4.3.5 的评价指标评估各个模型的分类效果。

在训练和测试数据的划分中，因为 PTB-XL 数据集提供了推荐的训练集及测试集划分，其中训练集数据为 19267 条，测试集数据 2163 条，推荐的测试集数据拥有高质量的标签且数据分布于训练集数据类似，因此各项实验均采用推荐的数据集划分进行。

注意力机制 CNN 模型在 PTB-XL 数据集 500Hz 采样频率数据中的各个类别的分类主评价指标值（宏平均 AUC）值如图 4.5 所示，其中左侧部分为各类别名称，右侧为测试集上该类别取得的主评价指标值。如实验结果所示，注意力机制 CNN 模型在二度房室传导阻滞（2AVB）、下壁导联心内膜下损伤（INJIN）、间隔肥大（SEHYP）等类别上均取得了大于 0.97 的主评价指标值，其中 INJIN、2AVB 等类别样本数量较小，同时在正常（NORM），下壁心肌梗塞（IMI）等样本数量较大的类别上分别取得了 0.942、0.935 的 AUC 值，这也从侧面证明了本研究所使用的损失函数在提高小样本分类准确率上的作用，且在此基础上保证了样本数较大的类别的分类预测准确性。从总体来说，注意力机制 CNN 模型在大部分类别的分类中有着较好的表现结果。




图 4.5 注意力机制 CNN 模型各类别 AUC 值

注意力机制 CNN 网络在测试集上的 AUC 值及其他评价指标值随训练轮数变化如表 4.5 所示：

表 4.5 注意力机制 CNN 网络训练过程实验结果

训练轮数	测试集多标签分类指标					
	AUC(↑)	RL(↓)	OE(↓)	Cov(↓)	train loss	test loss
1	0.794586	0.0739	0.43828	5.725381	0.015744	0.033989
5	0.842863	0.057496	0.36847	4.955617	0.014764	0.021009
10	0.881312	0.047806	0.311604	4.446602	0.008380	0.022848
20	0.926771	0.030341	0.255663	3.331484	0.007194	0.018926
50	0.935521	0.028263	0.249824	3.208044	0.012384	0.016644
best	0.941612	0.0260838	0.249190	3.036061	0.017819	0.016318

注意力机制 CNN 网络在训练过程中，因为网络模型深度较深，收敛速度较快；同时因为训练集数据量较大，按照 batch_size 为 32 进行划分后，有多个 batch 的数据依次输入模型对模型进行训练。因为以上两个原因，在 1 个 epoch 后，训练集损失和测试集损失就已经达到了较低的数值，如表中所示，训练集损失达到 0.015744，测试集损失达到 0.033989，此时测试集损失相较于训练集损失较大，同时在多标签分类评价指标方面，主评价指标值为 0.794586，其余副评价指标值如表 4.5 第一行所示，各个值除 AUC 值越高表示模型分类效果越好外，其余均

为值越低表示模型分类效果越好，可以看到在 1 个 epoch 后，模型已经学习到了一定的分类知识，但是总体分类效果仍有很大的提高空间。5 个 epoch 后，训练集损失略有降低，来到 0.014764，与此同时测试集损失有了明显的下降，值为 0.21009，这说明模型逐渐学习到了分类所需要的知识，从分类指标上来看，主评价指标值达到 0.842863，且副评价指标值相较于 1 个 epoch 时有了明显的下降，说明这个阶段模型的训练状态较好。10 个 epoch 后，训练集损失逐渐降低，同时测试集损失也逐步减小，但是训练集损失相比于测试集的损失过大，这也意味着模型中存在了一定的过拟合现象，在本实验中，通过增加 dropout 来降低了模型过拟合情况的出现，相较于第 5 个 epoch 的实验结果，该 epoch 的主评价进一步升高，达到 0.881312，此时模型已经具备不错的分类能力。经过 20 个 epoch 后，模型主评价指标进一步上升至 0.926771，训练集损失及测试集损失也进一步下降。经过 50 个 epoch 的训练后，模型的主评价指标达到 0.935521，对比第 10 轮和第 20 轮的训练测试结果，50 个 epoch 时训练集损失和测试集损失更加接近，说明后续的模型训练中，通过进一步的学习调整，模型的过拟合情况得到了改善，最后达到了比较好的学习效果。在整个训练过程中，最优模型出现在第 37 个 epoch 后，主评价指标值达到 0.941612，其余各项指标也均达到最优，且测试损失达到最低值 0.16318，表明模型在测试集上也有着较好的表现。在整个迭代训练中，虽然出现了一定的过拟合现象，但总体而言，通过 dropout 等措施，在迭代过程中模型逐渐呈现稳定状态，主评价指标值缓慢上升，副评价指标也逐步趋于最优。

表 4.6 展示了使用数据集中采样频率为 500Hz 的数据进行对比实验的结果：

表 4.6 PTB-XL 500Hz 心电图对比实验结果

网络结构	测试集多标签分类指标			
	AUC (↑)	RL (↓)	OE (↓)	Cov (↓)
ResNet18	0.923(218)	0.034(415)	0.276(930)	3.561(719)
ResNet101	0.934(911)	0.029(161)	0.257(975)	3.237(170)
Xception	0.938(097)	0.027(718)	0.254(738)	3.155(339)
Multi-ECGNet	0.935(813)	0.0314(224)	0.285(714)	3.352(288)
InceptionNet	0.885(799)	0.039(297)	0.296(347)	3.892(279)
注意力机制 CNN	0.941(612)	0.0260(838)	0.249(190)	3.036(061)

在本研究设计的对比实验中，将注意力机制 CNN 与 ResNet18, ResNet101, XceptionNet, Inception, Multi-ECGNet 进行了对比。从实验结果来看，ResNet101 相较于 ResNet18 有更好的主评价指标值，达到 0.934，提升了 0.11，同时副评价指标值也更高，这说明了 ResNet101 相较于 ResNet18 能够提取更有效的心电图特征，也侧面验证了本研究选择以 ResNet101 为基础设计心电图基本特征提取模块和心电图注意力机制模块的合理性。如表 4.6 第三行所示，XceptionNet 也取得了很好的主评价指标及副评价指标值，AUC 值达到 0.938。为进一步证明 DSC 结构的有效性与效果，将 XceptionNet 与 IncetionNet 进行对比，发现 AUC 值提高了 0.053。此外，将本文设计的注意力机制 CNN 网络与 Multi-ECGNet 对比，本文设计的注意力机制 CNN 网络取得了更好的结果，AUC 值达到 0.941，验证了本文设计的心电图基本特征提取模块和注意力机制模块的作用。

为了更全面地验证注意力机制 CNN 模型对不同类型心电图数据的多标签分类能力，本文还使用 PTB-XL 数据集中采样频率为 100Hz 的心电图数据对各模型进行了对比实验，结果如表 4.7 所示。从结果来看，注意力机制 CNN 相比其他对比模型取得了最高的主评价指标值，达到 0.924，同时其他指标值也略优于对比模型。实验结果进一步验证了注意力机制 CNN 模型中以拉普拉斯滤波器和 SE 模块为核心构建的注意力机制的作用。

表 4.7 PTB-XL 100Hz 心电图对比实验结果

网络结构	测试集多标签分类指标			
	AUC (↑)	RL (↓)	OE (↓)	Cov (↓)
ResNet18	0.916(994)	0.035(016)	0.292(186)	3.625(057)
ResNet101	0.920(764)	0.035(614)	0.296(809)	3.569(579)
Xception	0.918(718)	0.035(817)	0.293(060)	3.586(962)
Multi-ECGNet	0.920(755)	0.040(698)	0.320(850)	3.815(071)
InceptionNet	0.911(346)	0.035(675)	0.312(306)	3.713(361)
注意力机制 CNN	0.924(927)	0.032(408)	0.291(724)	3.404(530)

4.4 本章小结

本章中采用了注意力机制 CNN 网络模型，对 PTB-XL 数据集中采样频率为 500Hz 的数据和采样频率为 100Hz 的数据分别进行了多组对比实验。在实验中，通过使用针对多标签分类的多项评价指标对注意力机制 CNN 模型以及其他对比模型在数据集中的分类表现进行评估。

从实验结果来看，注意力机制 CNN 模型在训练损失变化、测试集结果等方面均有着较好的表现。其在多项多标签分类指标上均取得了较优的结果，相较于对比模型，其分类准确率有了一定的提升，这进一步验证了以一维卷积为基础，通过特别设计的注意力机制优化的注意力机制 CNN 网络能够胜任心电图多标签分类任务。相较于已有的研究，注意力机制 CNN 模型通过以拉普拉斯滤波器为核心的注意力机制模块，提高了网络关注心电图高频信号的能力，并应用于最终的多标签分类任务，取得了较好的效果。但注意力机制 CNN 网络从结构上讲，仍然是单一的 CNN 网络，虽然其通过合理的方法提高了网络关注心电图高频信号的能力，取得了不错的分类效果，但其由于受感受野的限制和权重共享的影响，仍不能很好地利用全局信息^[5]，对特征空间邻域中的其他样本提供的信息利用不够^[5]。基于上述问题，本研究在本章设计的注意力机制 CNN 模型的基础上，探求一种能够更好利用特征空间全局信息和邻域中的其他样本的网络模型。

5. 基于自适应图卷积的心电图样本间上下文信息聚合及分类方法

5.1 引言

基于单一 CNN 网络的心电图分类模型在进行分类时，均通过适当的方法增强模型的特征表达能力，提取更有效的心电图特征用来分类，且取得了不错的效果。但是单一的卷积神经网络受感受野的限制和权重共享，不能很好地利用全局信息，及对特征空间邻域中的其他样本提供的信息利用不够。现有的基于单一 CNN 的心电图分析方法在提取鲁棒的、有效的信息方面存在缺陷，这在一定程度上影响了心电图分类的准确率。

针对上述问题，本文提出了一种基于自适应图卷积的心电图样本间上下文信息聚合及分类模型 MLECG-AGCN。MLECG-AGCN 模型通过其强大的结构表示能力，有效的建模了样本间的依赖关系，构建了样本间的结构相似性和上下文关系，提高了模型的分类效果。MLECG-AGCN 模型主要由两个模块构成：特征提取模块和自适应 GCN 多标签分类模块。其中，特征提取模块对输入心电图进行特征提取。自适应 GCN 模块将所提取特征组织为图，以该图为输入，经过堆叠的自适应图卷积层、非线性激活函数层、等维映射层，输出包含上下文信息的特征，最终通过线性分类器层完成分类。

MLECG-AGCN 模型中，本文主要设计并构建了两个模块，分别是：基于第四章内容设计的特征提取模块和构建样本间上下文关系并进行信息聚合的自适应 GCN 模块。特征提取模块的设计结合本文第四章已有的实验基础，选择分类效果最好的注意力机制 CNN 网络中的心电基础特征提取模块和注意力机制模块的组合进行特征提取，获取质量较高的心电图特征。自适应 GCN 模块采用了构建原始图的方法，将从波形数据中提取出的各样本特征组织成图 G_{in} 并以此为输入，自适应 GCN 模块通过基于 GCN 的映射函数，在输入 G_{in} 中学习相互依赖的对象分类器 $Z_{out} \in R^{N \times D}$ ，其中 D 表示分类总数， N 表示样本总数。与标准 GCN 不同，本文的自适应 GCN 模块中将邻接矩阵 A 设置为参数自适应更新，自适应地调整邻域节点的权重，在多次迭代中有着更好的效果。基于 GCN 的映射函数在构建中通过级联操作拼接输入节点特征信息和邻域节点聚合信息，充分地利用了节点特征空间中的邻域样本信息，同时又不丢掉节点自身的信息。GCN 网络

中通过每一个 GCN 层更新节点状态，每一个节点对应一个样本的分类器，经过两个堆叠的 GCN 层后，最终节点的特征向量长度达到总类别数 D ，再通过 sigmoid 完成分类。

为检验本文设计的 MLECG-AGCN 模型的分类有效性，在本章实验中，将该模型和已复现的其他其中基准模型进行了比较实验，并按照章节 4.3.5 中所述的评价指标来评定模型的分类有效性，实验结果表明，基于自适应图卷积的心电图分类方法在各项指标上相较于注意力机制 CNN 网络有了进一步的提高，取得了最好的实验结果。

5.2 基于自适应图卷积的心电图样本间上下文信息聚合及分类方法算法

5.2.1 MLECG-AGCN 网络结构

MLECG-AGCN 模型主要由两部分网络组成：（1）用于提取心电图特征的注意力机制 CNN 网络；（2）用于心电图多标签分类的自适应 GCN 网络。MLECG-AGCN 网络的流程如图 5.1 所示。

心电图数据经过数据加载模块后，得到输入数据 $X \in R^{N \times C \times L}$ （ N 为训练集样本总数； C 为通道数； L 为时序信号长度），作为 MLECG-AGCN 的输入。

如图 5.1 所示，phase1 为注意力机制 CNN 网络，主要用来进行心电图重要特征的提取。该网络结构使用本文第四章构建的注意力机制 CNN 网络的特征提取部分，主要包含两个分支，一个是心电图基本特征提取模块（phase1 左侧分支），用来提取心电图基本特征；另一个是注意力机制模块（phase1 右侧分支），用来增强心电图高层特征。 X 经过 phase1 输出信息增强后的特征 $X_{out} \in R^{N \times d_{out}}$ ，作为 phase2 的输入。

如图 5.1 所示，phase2 为自适应 GCN 网络，用来构建、提取样本的上下文信息特征并应用于分类。其中的每个节点为每个心电图样本数据经过特征提取网络后提取的特征向量，即一个节点代表一个样本，节点对应的值为样本经特征提取网络后提取的特征向量。图的构建使用转换设置的方式，即数据集中所有样本（包含训练集、测试集）都构建在同一图 G_{in} 中，使用掩码来划分训练集以及测试集。图 G_{in} 经过自适应 GCN，输出包含样本上下文信息的特征 $Z_{out} \in R^{N \times D}$ （ D

为类别总数),最后经过 sigmoid 完成分类。自适应 GCN 网络的具体结构将在 5.2.2 章节中进行详细描述。




图 5.1 MLECG-AGCN 网络结构图

MLECG-AGCN 模型的设计中，总体结构主要由两个模块构成，第一个模块是构建基于拉普拉斯滤波器的注意力机制 CNN 网络，以此增强网络对心电图高频信号的注意力，更有效地利用心电图高频信号中包含的信息，提高网络的表征能力。第二个模块是自适应图卷积模块，这个模块通过构建原始图的方式，对样本间的相互依赖关系进行建模，以图结构的形式显示建模样本在特征空间上的关系，进而能够捕获特征空间的拓扑结构。从模型的角度考虑，MLECG-AGCN 模型通过将心电图样本经注意力机制 CNN 提取的有效特征作为节点组织成图，并使用自适应图卷积网络构建节点间关系，通过图卷积网络中自适应更新的邻接矩阵，吸收邻域中相关节点的信息对节点特征进行更新。经过多轮训练，MLECG-AGCN 模型学习得到各个样本的分类器，这些分类器更有效地考虑了样本间的结构相似性和上下文关系，对特征空间中的全局信息和邻域样本信息有更高的利用率，并且可以通过模型直接应用于心电图特征进而进行分类，进一步优化了心电图多标签分类的效果。

5.2.2 自适应 GCN 模块

自适应 GCN 模块中，输入为原始图 G_{in} ， G_{in} 由节点特征矩阵和邻接矩阵构成，其中的节点特征矩阵表示为 $X_{out} \in R^{N \times d}$ （ N 为样本总数， d 为样本特征向量的维度），而原始图的邻接矩阵则表示为 $A \in R^{N \times N}$ ，代表原始图中的边。原始图的构建过程如表 5.1 所示，通过构建原始图，将图中每个节点与和其具有结构相似性以及丰富上下文关系的邻域节点相连，由自适应 GCN 网络捕获此关系用于分类。

表 5.1 原始图构建流程

流程 1	原始图构建
输入：	输入为心电图数据 $X \in R^{N \times C \times L}$ （ N 为心电图数据集样本总数； C 为通道数； L 为单个样本单导联的时序信号值长度），其中 $N = N_1 + N_2$ ， N_1 为训练集样本总数， N_2 为测试集样本总数
输出：	输出节点特征矩阵 $X_{out} \in R^{N \times d}$ ；邻接矩阵 $A \in R^{N \times N}$ ；训练集数据掩码 trainmask；测试集数据掩码 testmask
1	输入训练集数据 $X_{train} \in R^{N_1 \times C \times L}$ ，经注意力机制 CNN 特征提取网络输出训练集样本节点特征矩阵 $X_{out_train} \in R^{N_1 \times d}$ ；输入测试集数据 $X_{test} \in R^{N_2 \times C \times L}$ ，经注意力机制 CNN 特征提取网络输出测试集样本节点特征矩阵 $X_{out_test} \in R^{N_2 \times d}$ ；训练集节点特征矩阵与测试集节点特征矩阵拼接得到节点特征矩阵 $X_{out} \in R^{N \times d}$
2	新建 trainmask，testmask 为布尔型向量，trainmask 前 N_1 项为 True，其余为 False，标记训练集数据样本；testmask 后 N_2 项为 True，其余为 False，标记测试机样本
3	新建 $M \in R^{N \times N}$ 矩阵，记录节点特征向量间的欧氏距离 $\text{dist}(X, Y) = \sqrt{\sum_{i=1}^n (X_i - Y_i)^2}$
4	新建邻接矩阵 $A \in R^{N \times N}$ ，初始化为 0 矩阵
5	根据 KNN 算法选择各节点邻域节点，在 A 中进行记录，各节点对应行中的邻域节点位置设置值为 1（不包括自身节点）
6	遍历数据集中节点，更新邻接矩阵 A ，保存原始图边的信息
7	输出节点特征矩阵 $X_{out} \in R^{N \times d}$ ；邻接矩阵 $A \in R^{N \times N}$ ；训练集数据掩码 trainmask；测试集数据掩码 testmask

原始图 G_{in} 的构造中，在邻接矩阵 A 的构造中需要使用 KNN 算法确定各节点的邻域节点，而 KNN 算法即 K 最近邻算法（KNN，K-NearestNeighbor），是数据挖掘分类技术中的基本方法之一，其通过选择某节点样本空间中最近邻的 K 个节点作为该节点在样本空间中最相似的节点。在本文研究中，通过 KNN 算法

构建邻接矩阵的具体步骤如图 5.2 所示，首先进行数据采集，然后根据 KNN 算法寻找样本点的邻域节点并与样本点相连，最后遍历图中各个节点，初始化整个邻接矩阵。




图 5.2 邻接矩阵构建流程图

进行了原始图 G_{in} 的构建之后，自适应 GCN 网络以 G_{in} 作为输入，第一层是图卷积层，图卷积层以节点特征矩阵 $X \in R^{N \times d}$ (N 为样本总数， d 为样本特征向量的维度) 和邻接矩阵 $A \in R^{N \times N}$ 作为输入，输出变换后的节点特征矩阵 $Z_1 \in R^{N \times d_1}$ (d_1 为输出特征维度) 和邻接矩阵 $A_1 \in R^{N \times N}$ 。

图卷积层的基本想法是，通过在节点之间传递信息来更新节点的表示，和标准卷积模型不同，GCN 的基本目标可理解为学习图 g 上的函数 $f(\cdot, \cdot)$ ， g 以特征描述 $H^l \in R^{N \times d}$ 和矩阵 $A \in R^{N \times N}$ 为输入，更新节点特征为 $H^{l+1} \in R^{N \times d'}$ ，每一个 GCN 层都可以表示为一个非线性函数：

$$H^{(l+1)} = f(H^l, A) \quad (5.1)$$

通过卷积运算， $f(\cdot, \cdot)$ 可以表示为：

$$H^{(l+1)} = h(\hat{A}H^l W^l) \quad (5.2)$$

其中 $W^l \in R^{d \times d'}$ 学习变化矩阵， $\hat{A}$ 为归一化的相关矩阵 A ， $h(\cdot)$ 为非线性运算，GCN 以此对节点间复杂的相互关系进行构建和学习。

MLECG-AGCN 中，第一层图卷积层的计算公式如式 5.3 所示：

$$Z_1 = \sigma([X_{out} \parallel G X_{out}]W) \quad (5.3)$$

其中， $G = g(X_{out}, A)$ 表示大小为 $N \times N$ 的聚合矩阵，每行和都为1， $g(\cdot)$ 是 X_{out} 和 A 的一个函数。操作符 $\parallel$ 则表示沿着特征维度进行拼接。 W 矩阵是权重矩阵，维度为 $2d \times d_1$ ； $\sigma(\cdot)$ 为非线性激活函数。图卷积层运算主要包括两步。第一步为 X_{out} 与 G 相乘，对节点邻域节点的信息进行聚合；然后输入节点特征 X_{out} 与邻域聚合信息 $G X_{out}$ 在特征维度上进行拼接。第二步则是对融合特征使用一组线性滤波器实现转换，其参数是可学习的权重矩阵 W 。经图卷积层，输出图 G_1 ，包含变换后的节点特征矩阵 $Z_1 \in R^{N \times d_1}$ （ d_1 为输出特征维度）和邻接矩阵 $A_1 \in R^{N \times N}$ 。 Z_1 中各节点特征在提取时，同时考虑自身节点的特征以及其邻域节点特征，以此隐式地获取自身节点玉林玉节点的结构相似性和上下文关系，并将此特征融入高层特征 Z_1 中。同时，设置邻接矩阵 A 为参数自适应更新，自适应的调整邻域节点的权重，以在多次迭代中取得更好的效果，经过一层图卷积后邻接矩阵 A 自适应调整为邻接矩阵 A_1 。

自适应 GCN 的第二层为非线性激活层，通过使用 ReLU 激活函数对其进行激活，以此提高模型的非线性表达能力， Z_1 经非线性激活层激活输出 $Z_2 \in R^{N \times d_2}$ ，邻接矩阵 A_1 保持不变。

自适应 GCN 网络第三层为图卷积层，该层图卷积的计算公式如式 5.4 所示：

$$Z_3 = \sigma([Z_2 \parallel G_1 Z_2]W_1) \quad (5.4)$$

该层图卷积层的运算方式与第一层图卷积的模式类似，通过如上式所示的图卷积操作后，输出节点高层特征矩阵 $Z_3 \in R^{N \times d_3}$ 和更新后邻接矩阵 $A_2 \in R^{N \times N}$ 。

自适应 GCN 网络第四层为非线性激活层，通过使用 ReLU 函数对其进行激活，以增强模型的非线性表达能力， Z_3 经非线性激活层激活输出 $Z_4 \in R^{N \times d_4}$ 。

自适应 GCN 网络第五层为线性层，特征图 Z_4 通过线性层进行等维映射，得到特征图 $Z_5 \in R^{N \times d_5}$ 。

自适应 GCN 网络第六层为非线性激活层，使用 ReLu 函数进一步增强非线性表达能力， $\mathbf{Z}_5$ 经非线性激活层激活输出 $\mathbf{Z}_6 \in R^{N \times d_6}$ 。

网络最后一层为线性分类器层，线性分类器层的输出维度与类别总数相同，输出 $\mathbf{Z}_{out} \in R^{N \times D}$ (D 为类别总数)，最后经过 sigmoid 完成分类。

5.3 实验与分析

5.3.1 实验说明

本章实验所使用的数据为 PTB-XL 数据集中采样频率为 500Hz 和 100Hz 的心电图数据，具体介绍见章节 4.3.1。

实验环境为：

设备：CPU 使用的是 8 核 32GB 内存，GPU 使用 Tesla-V100-SXM-32GB *2。

环境：Pytorch1.7.1+ cuda10.0

对比模型在 4.3.3 章节对比模型的基础上，增加了第四章中的注意力机制 CNN 网络模型，以及注意力机制 CNN+非自适应 GCN 网络。

训练超参数配置如表 5.2 所示：

在模型训练的过程中，本文通过 pytorch 完成相关实验，其中为 MLECG-AGCN 模型配置的超参数值如表 5.2 的超参数配置表所示：

表 5.2 超参数配置表

超参数	配置值
Optimizer	Adam
Learning Rate	1e-3 with decay
Batchsize	16
Epoch for Adaptive GCN model	4000
egularization strategy	Earllystopping

本章实验多使用评价指标与第四章实验中相同，各项指标详见 4.3.5 章节。

5.3.2 实验结果

本章给出了 MLECG-AGCN 模型在 PTB-XL 数据集采样频率为 500Hz 数据及采样频率为 100Hz 数据上的实验结果，并在使用相同数据集和数据预处理方法的前提下，使用章节 5.3.1 中的对比模型进行了对比实验，实验结果使用章节

5.3.1 的评价指标评估各个模型的分类准确性。各项实验均采用 PTB-XL 及其推荐的数据集划分进行。

图 5.3 展示了 MLECG-AGCN 模型各类别的分类主评价指标值（宏平均 AUC），其中左侧部分为各类别名称，右侧为测试集上该类别取得的主评价指标值。如实验结果所示，MLECG-AGCN 模型在下外侧导联心内膜下损伤（INJIL），三度房室传导阻滞（3AVB）等样本数量较小的类别上均取得了大于 0.99 的 AUC 值，同时在 NORM，IMI 等样本数量较大的类别上分别取得了 0.946，0.935 的 AUC 值，这从侧面验证了本研究所使用的损失函数的合理性。模型在左心房超负荷/扩大（LAO/LAE），非特异性脑室内传导障碍（IVCD）等个别类上表现不佳，这可能是由于该类样本数量过少；或其在高频心电图图中与其他疾病相似度过高等原因导致，但总体来说，MLECG-AGCN 模型在绝大多数类别的分类中表现出的结果较好。




图 5.3 MLECG-AGCN 模型各类别 AUC 值

自适应图卷积网络测试集上的 AUC 值及其他评价指标值，训练集及测试集 loss 随训练轮数变化如表 5.3 所示。不同于 CNN 模型的训练方式，自适应图卷积网络在训练时，需要构建原始图，以原始图为输入进行训练。自适应图卷积网络每一个 epoch 只对模型进行一次更新，因此需要更多的迭代轮数以使 loss 收敛。本研究设置 epoch 为 4000 轮，可以看到，MLECG-AGCN 在数据训练开始之后快速收敛，相对较快，并未欠拟合或过拟合。初始 20 至 50 轮迭代中，AUC 值

从 0.661 快速提升至 0.684；经 500 轮迭代，AUC 值提升至 0.87，500 轮前模型尚未稳定，AUC 值的提升较快。经 2000 轮迭代，AUC 值达到 0.934，已经接近 ResNet101 基准模型的最高值；4000 轮迭代结束后，AUC 值为 0.941，训练中测试集 AUC 最高值达到 0.943，在这部分的迭代中，模型趋于稳定，AUC 值缓慢上升。

表 5.3 自适应图卷积网络训练过程实验结果

训练轮数	测试集多标签分类指标					
	AUC (↑)	RL (↓)	OE (↓)	Cov (↓)	train loss	test loss
20	0.661 (893)	0.294 (620)	0.556 (634)	16.335 (182)	0.665184	0.636235
50	0.684 (095)	0.110 (429)	0.553 (398)	7.540 (453)	0.167537	0.167485
200	0.780 (469)	0.076 (414)	0.383 (726)	6.037 (447)	0.031537	0.032279
500	0.870 (701)	0.043 (553)	0.253 (351)	4.217290	0.027042	0.027152
2000	0.934 (484)	0.030 (341)	0.250 (577)	3.345 (353)	0.021148	0.021396
4000	0.941 (773)	0.027 (022)	0.235 (783)	3.114 (193)	0.018397	0.019410
best	0.943 (639)	0.025 (699)	0.229 (311)	3.063 (337)	0.017819	0.016318

表 5.4 展示了使用 PTB-XL 数据集中采样频率为 500Hz 心电图数据进行对比实验的结果。从结果来看，本文设计的基于空间注意力的注意力机制 CNN 网络 AUC 值达到 0.941，优于其余以单一 CNN 为基础的对比模型。将本文第四章提出的注意力机制 CNN 与本章的进阶模型 MLECG-AGCN 对比，可以看到 AUC 值进一步提高 0.002，达到最高的 0.943，在副评价指标 RL 上，MLECG-AGCN 相较于注意力机制 CNN 下降了 0.001，验证了本章所设计模型的总体分类效果；与此同时，MLECG-AGCN 取得的 OE 值下降了 0.02，说明 MLECG-AGCN 对测试样本中最大概率的标签预测效果要优于注意力机制 CNN。以上结果从多个角度验证了 MLECG-AGCN 中自适应 GCN 模块的作用，证明了基于样本间上下文信息聚合的解决方法在进一步提升模型分类效果上的有效性。基于 MLECG-AGCN 模型与注意力机制 CNN+非自适应 GCN 相比，使用自适应 GCN 的 MLECG-AGCN 模型取得了更好的效果，验证了邻接矩阵参数自适应更新的作用。同时，注意力机制 CNN+非自适应 GCN 的 AUC 值也高于注意力机制 CNN，这也再次验证了图卷积模块在解决特征空间全局信息及邻域样本信息利用不足

问题上的作用，以及其在注意力机制 CNN 网络基础上，进一步优化分类效果的能力。

表 5.4 PTB-XL 500Hz 心电图对比实验结果

网络结构	测试集多标签分类指标			
	AUC (↑)	RL (↓)	OE (↓)	Cov (↓)
ResNet18	0.923 (218)	0.034 (415)	0.276 (930)	3.561 (719)
ResNet101	0.934 (911)	0.029 (161)	0.257 (975)	3.237 (170)
Xception	0.938 (097)	0.027 (718)	0.254 (738)	3.155 (339)
Multi-ECGNet	0.935 (813)	0.0314 (224)	0.285 (714)	3.352 (288)
InceptionNet	0.885 (799)	0.039 (297)	0.296 (347)	3.892 (279)
注意力机制 CNN	0.941 (612)	0.0260 (838)	0.249 (190)	3.036 (061)
注意力机制 CNN+	0.942 (294)	0.025 (974)	0.231 (160)	3.072 (584)
非自适应 GCN				
MLECG-AGCN	0.943 (639)	0.025 (699)	0.229 (311)	3.063 (337)

为更全面地验证 MLECG-AGCN 模型对不同类型心电图数据的多标签分类能力，本文还使用 PTB-XL 数据集中采样频率为 100Hz 的心电图数据对各模型进行了对比实验，结果如表 5.5 所示。从结果来看，MLECG-AGCN 取得了最高的 AUC 值，达到 0.930，同时其他指标值也略高于对比模型。实验结果表明，MLECG-AGCN 模型通过图卷积网络可以更有效的利用特征空间中的全局信息和邻域信息，提高分类准确率。

表 5.5 PTB-XL 100Hz 心电图对比实验结果

网络结构	测试集多标签分类指标			
	AUC (↑)	RL (↓)	OE (↓)	Cov (↓)
ResNet18	0.916(994)	0.035(016)	0.292(186)	3.625(057)
ResNet101	0.920(764)	0.035(614)	0.296(809)	3.569(579)
Xception	0.918(718)	0.035(817)	0.293(060)	3.586(962)
Multi-ECGNet	0.920(755)	0.040(698)	0.320(850)	3.815(071)
InceptionNet	0.911(346)	0.035(675)	0.312(306)	3.713(361)
注意力机制 CNN	0.924(927)	0.032(408)	0.291(724)	3.404(530)
注意力机制 CNN+ 非自适应 GCN	0.926(013)	0.0303(144)	0.251(502)	3.385(575)
MLECG-AGCN	0.930(404)	0.029(448)	0.245(030)	3.299(583)

综合上述实验结果，MLECG-AGCN 模型取得了最高的主评价指标值，达到 0.943，优于 CAI 等人提出的 Multi-ECGNet 模型^[12]，以及以 ResNet18，ResNet101，Xception 等为代表的基准模型。同时，MLECG-AGCN 模型除了在 500Hz 数据上的 Cov 指标值略低于注意力机制 CNN 外，其余指标值均优于注意力机制 CNN，验证了本章进阶模型在分类效果提升方面的作用。相较于其他 CNN 模型，本研究模型针对心电图特点，首先通过注意力机制 CNN 增强了模型关注心电图高频信号的能力，结合特别设计的自适应图卷积网络构建样本间的结构相似性和上下文关系，提供了一种效果更好的心电图多标签分类方法，且模型在 PTB-XL 数据集中得到了验证。

5.4 本章小结

本章中采用了 MLECG-AGCN 网络模型，对 PTB-XL 数据集中采样频率为 500Hz 的数据和采样频率为 100Hz 的数据分别进行了多组对比实验。在实验中，通过使用针对多标签分类的多项评价指标对 MLECG-AGCN 模型以及其他对比模型在数据集中的分类表现进行评估。

MLECG-AGCN 网络在第四章设计的注意力机制 CNN 网络模型的基础上，将自适应图卷积网络与注意力机制 CNN 特征提取网络结合，有效地解决了单一

CNN 网络对特征空间中的全局信息和邻域中的其他样本中的信息利用不足的问题。MLECG-AGCN 中，使用注意力机制 CNN 网络中的特征提取模块，而注意力机制 CNN 网络在特征提取时，通过级联操作拼接增强后的心电图高层特征和心电图基本特征，全面保留了信息增强后的心电图高层特征和心电图提取的基本特征。将拼接后特征作为 MLECG-AGCN 模型自适应图卷积模块的输入，有效的利用了先验信息，增加了提取特征的信息量。从实验结果来看，MLECG-AGCN 网络与单一注意力机制 CNN 网络的对比说明，MLECG-AGCN 网络通过图卷积构建样本特征间的结构相似性和上下文关系、对此关系进行建模并应用于分类任务的方法，进一步提高了分类指标值，可以更有效的利用特征空间中的全局信息和邻域样本信息。MLECG-AGCN 在 500Hz 数据上的主评价指标值达到 0.943，100Hz 数据上的主评价指标值达到 0.930，在全部模型中有着最好的表现，且其副评价指标值也比多数对比模型更优，验证了其在不同数据上的有效性。总结而言，MLECG-AGCN 通过本文设计的注意力机制 CNN 增强了模型关注心电图高频信号的能力，结合特别设计的图卷积网络构建样本间的结构相似性和上下文关系，提供了一种效果更好的心电图多标签分类方法，且模型在 PTB-XL 数据集中得到了验证。

6. 总结与展望

6.1 总结

据世界卫生组织的相关报告，心血管疾病已变成全世界最主要的死亡原因，困扰了许多患者的生活，对许多家庭造成了极大的影响。心血管疾病中部分疾病发病快、致死率高、发病后期难以彻底医治，且近年来患病人数持续增高。与此同时，虽然心血管疾病的治疗费用因类别而有所不同，但是整体的治疗费用都是比较高的。因此针对心血管疾病的相关研究有着重要的现实意义，如果能够在心血管疾病发病早期症状出现时，精确诊断患者所患心血管疾病的具体类型，介入治疗，将有助于控制疾病发展。心电图检测自 20 世纪建立以来，由于其操作简便，记录过程中对人体没有损伤，并且记录精确，逐渐变成了心血管疾病诊疗的主要方式之一并被广泛应用。但由于心血管疾病种类多样、隐匿性心脏病的存在等客观问题，面对大量的心电图数据，人工分析的方式难免会出现误诊、漏诊等现象。为了提高诊断准确率，以及协助专业医生进行心电图分析，如何进行高效、准确的心电医学图像自动分类是一个急需解决的问题。基于以上研究意义，本文将心电图的多标签自动分类方法作为主要研究对象。

本文分别使用注意力机制 CNN 网络模型和基于自适应图卷积的 MLECG-AGCN 模型，给出了心电图心血管疾病多标签分类方法，总结本文主要工作如下：

设计并实现了一种基于空间注意力的心电图分类方法。该分类方法中，本文使用 2020 年发布的大型公开数据集 PTB-XL 作为实验数据，首先对数据进行了预处理，将其标准化为形如 $X \in \mathbb{R}^{N \times C \times L}$ 的原始心电图数据，其中 N 为心电图数据集样本总数； C 为通道数； L 为单个样本单导联的时序信号值长度。注意力机制 CNN 网络针对心电图高频信号中包含更多信息的特点进行设计，包含两个主要模块，分别是心电图基本特征提取模块和注意力机制模块。其中心电图基本特征提取模块以 ResNet101 为基础进行优化改进，通过一维卷积、特别设计的深度可分离残差单元等进行优化，提取更有效的心电图基本特征。注意力机制模块中，通过构建基于拉普拉斯滤波器的心电图高频信号提取单元，以及特别设计的基于深度可分离卷积和 SE 模块的残差单元，并结合以优化的残差神经网络为基础的心电图基本特征提取模块，将注意力机制应用于心电图特征提取，增强网络关注

心电图高频部分的能力,提取有效性更高的心电图特征。最后,注意力机制 CNN 网络通过级联操作拼接增强后的心电图高层特征和心电图基本特征,全面保留了信息增强后的心电图高层特征和心电图提取的基本特征并应用于分类。通过相关实验,验证了注意力机制 CNN 网络在心电图多标签分类任务中的效果。

在注意力机制 CNN 网络的基础上更进一步,设计并实现了基于自适应图卷积的 MLECG-AGCN 分类方法。该分类方法中,本文创新性地的心电图分类任务中将注意力机制 CNN 与自适应图卷积结合,利用图卷积网络强大的结构表示能力,改善了单一的卷积神经网络由于受感受野的限制和权重共享所造成的问题,更有效的利用了特征空间中的全局信息以及邻域样本信息;结合注意力机制 CNN 提取的心电图特征,完成整体分类模型的构建。在 PTB-XL 数据集上进行多标签分类实验,与已复现的其他 7 种方法进行了比较实验,实验结果表明,MLECG-AGCN 模型获得了更好的分类结果。

6.2 展望

本文设计并构建了两个深度学习模型对心电图数据集进行了多标签分类,所设计的方法虽然能够完成分类任务且在分类效果上有了一定的提升,但是仍然存在着可以改进和进一步提升的地方:

首先,在注意力机制 CNN 网络模型中,目前使用的是基于拉普拉斯滤波器的方法,其聚焦于心电图高频信号,提取更有效的心电图特征。而在针对心电图分类任务的传统机器学习方法中,还有使用包括小波变换、小波包分解保留特定频段;希尔伯特变换获取特定频段等聚焦心电图特定频段的方法。针对更加具体的心血管疾病分类任务,能否使用以及如何使用这些传统机器学习方法结合深度学习模型关注心电图重点区域并应用于预测诊疗,是一个值得研究的任务。

在基于自适应图卷积网络构建的心电图多标签分类模型 MLECG-AGCN 中,目前的方案是首先将心电图数据输入注意力机制 CNN 特征提取网络,提取的特征再作为自适应图卷积网络的输入构建原始图,并完成后续的多标签分类任务。此方案虽然取得了较好的分类效果提升,但其整体步骤也更繁琐复杂,且特征提取网络部分和自适应图卷积网络部分需要单独训练,降低了模型整体效率。目前在部分基于图卷积的图像任务中,已有研究通过自定义损失函数、特殊的图卷积自适应方式等,实现了特征提取网络和图卷积网络的端到端结合,也为我们的后

续研究提供了思路。在未来的研究中，我们计划探索图卷积网络在心电图多标签分类问题中与以卷积为核心的特征提取网络的端到端结合方法。

参考文献

- [1] ZHOU M, WANG H, ZENG X, et al. Mortality, morbidity, and risk factors in China and its provinces, 1990–2017: a systematic analysis for the Global Burden of Disease Study 2017 [J]. *The Lancet*, 2019, 394(10204): 1145-58.
- [2] FLOWERS N C, HORAN L G, THOMAS J, et al. The anatomic basis for high-frequency components in the electrocardiogram [J]. *Circulation*, 1969, 39(4): 531-9.
- [3] ABBOUD S, ZLOCHIVER S. High-frequency QRS electrocardiogram for diagnosing and monitoring ischemic heart disease [J]. *Journal of electrocardiology*, 2006, 39(1): 82.
- [4] REYNOLDS JR E W, MULLER B F, ANDERSON G J, et al. High-frequency components in the electrocardiogram: a comparative study of normals and patients with myocardial disease [J]. *Circulation*, 1967, 35(1): 195-206.
- [5] 贺煜航,刘桢,陈刚.基于自适应图卷积网络的心电图多标签分类方法[J/OL]. *计算机工程*:1-10[2022-05-30].DOI:10.19678/j.issn.1000-3428.0063524.
- [6] WAGNER P, STRODTHOFF N, BOUSSELJOT R D, et al. PTB-XL, a large publicly available electrocardiography dataset [J]. *Sci Data*, 2020, 7(1): 154.
- [7] CEYLAN R, ÖZBAY Y, KARLIK B. A novel approach for classification of ECG arrhythmias: Type-2 fuzzy clustering neural network [J]. *Expert Systems with Applications*, 2009, 36(3): 6721-6.
- [8] NASIRI J A, NAGHIBZADEH M, YAZDI H S, et al. ECG arrhythmia classification with support vector machines and genetic algorithm; proceedings of the 2009 Third UKSim European Symposium on Computer Modeling and Simulation, F, 2009 [C]. IEEE.
- [9] ZIDELMAL Z, AMIROU A, BELOUCHRANI A. Heartbeat classification using support vector machines (SVMs) with an embedded reject option [J]. *International Journal of Pattern Recognition and Artificial Intelligence*, 2012, 26(01): 1250001.
- [10] KUMAR M, PACHORI R B, ACHARYA U R. Automated diagnosis of myocardial infarction ECG signals using sample entropy in flexible analytic wavelet transform framework [J]. *Entropy*, 2017, 19(9): 488.
- [11] HAN C, SHI L. ML-ResNet: A novel network to detect and locate myocardial infarction using 12 leads ECG [J]. *Comput Methods Programs Biomed*, 2020, 185: 105138.
- [12] CAI J, SUN W, GUAN J, et al. Multi-ECGNet for ECG Arrhythmia Multi-Label Classification [J]. *IEEE Access*, 2020, 8: 110848-58.
- [13] WANG J, QIAO X, LIU C, et al. Automated ECG classification using a non-local convolutional block attention module [J]. *Comput Methods Programs Biomed*, 2021, 203: 106006.

- [14] STRODTHOFF N, WAGNER P, SCHAEFFTER T, et al. Deep learning for ECG analysis: Benchmarks and insights from PTB-XL [J]. IEEE Journal of Biomedical and Health Informatics, 2020, 25(5): 1519-28.
- [15] 胡梦秋. 基于深度学习的心电图分类方法研究与系统实现 [D]; 电子科技大学, 2021.
- [16] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition [J]. Proceedings of the IEEE, 1998, 86(11): 2278-324.
- [17] ZHANG Y, WALLACE B. A sensitivity analysis of (and practitioners' guide to) convolutional neural networks for sentence classification [J]. arXiv preprint arXiv:151003820, 2015.
- [18] CHEN Y. Convolutional neural network for sentence classification [D]; University of Waterloo, 2015.
- [19] KIRANYAZ S, INCE T, GABBOUJ M. Real-Time Patient-Specific ECG Classification by 1-D Convolutional Neural Networks [J]. IEEE Trans Biomed Eng, 2016, 63(3): 664-75.
- [20] 潘辉, 郑威, 张莹莹. 基于改进残差网络对心电信号的识别 [J]. 数据采集与处理, 2020, 35(4): 682-92.
- [21] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition; proceedings of the Proceedings of the IEEE conference on computer vision and pattern recognition, F, 2016 [C].
- [22] ZHOU Y, ZHANG H, LI Y, et al. ECG heartbeat classification based on ResNet and Bi-LSTM; proceedings of the IOP Conference Series: Earth and Environmental Science, F, 2020 [C]. IOP Publishing.
- [23] PARK J, KIM J-K, JUNG S, et al. ECG-Signal Multi-Classification Model Based on Squeeze-and-Excitation Residual Neural Networks [J]. Applied Sciences, 2020, 10(18).
- [24] BAHDANAU D, CHO K, BENGIO Y. Neural machine translation by jointly learning to align and translate [J]. arXiv preprint arXiv:14090473, 2014.
- [25] JADERBERG M, SIMONYAN K, ZISSERMAN A. Spatial transformer networks [J]. Advances in neural information processing systems, 2015, 28: 2017-25.
- [26] HU J, SHEN L, SUN G. Squeeze-and-excitation networks; proceedings of the Proceedings of the IEEE conference on computer vision and pattern recognition, F, 2018 [C].
- [27] ESTRACH J B, ZAREMBA W, SZLAM A, et al. Spectral networks and deep locally connected networks on graphs; proceedings of the 2nd International Conference on Learning Representations, ICLR, F, 2014 [C].
- [28] DEFFERRARD M, BRESSON X, VANDERGHEYNST P. Convolutional neural networks on graphs with fast localized spectral filtering [J]. Advances in neural information processing systems, 2016, 29: 3844-52.
- [29] KIPF T N, WELLING M. Semi-supervised classification with graph convolutional networks [J]. arXiv preprint arXiv:160902907, 2016.

- [30] VELIČKOVIĆ P, CUCURULL G, CASANOVA A, et al. Graph attention networks [J]. arXiv preprint arXiv:1710.10903, 2017.
- [31] HAMILTON W L, YING R, LESKOVEC J. Inductive representation learning on large graphs; proceedings of the Proceedings of the 31st International Conference on Neural Information Processing Systems, F, 2017 [C].
- [32] WANG Z, ZHENG L, LI Y, et al. Linkage based face clustering via graph convolution network; proceedings of the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, F, 2019 [C].
- [33] DING Y, CHONG Y, PAN S, et al. Spatial-Spectral Unified Adaptive Probability Graph Convolutional Networks for Hyperspectral Image Classification [J]. IEEE Trans Neural Netw Learn Syst, 2021, PP.
- [34] ZHANG M-L, ZHOU Z-H. A Review on Multi-Label Learning Algorithms [J]. IEEE Transactions on Knowledge and Data Engineering, 2014, 26(8): 1819-37.
- [35] JAIN H, PRABHU Y, VARMA M. Extreme multi-label loss functions for recommendation, tagging, ranking & other missing label applications; proceedings of the Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, F, 2016 [C].
- [36] CHEN W, LIU T-Y, LAN Y, et al. Ranking measures and loss functions in learning to rank [J]. Advances in Neural Information Processing Systems, 2009, 22: 315-23.
- [37] ZHANG M-L, ZHANG K. Multi-label learning by exploiting label dependency; proceedings of the Proceedings of the 16th ACM SIGKDD international conference on Knowledge discovery and data mining, F, 2010 [C].
- [38] CIV. 卷积神经网络之深度可分离卷积 (Depthwise Separable Convolution) [Z]. 2020
- [39] CHOLLET F. Xception: Deep learning with depthwise separable convolutions; proceedings of the Proceedings of the IEEE conference on computer vision and pattern recognition, F, 2017 [C].
- [40] SZEGEDY C, VANHOUCKE V, IOFFE S, et al. Rethinking the inception architecture for computer vision; proceedings of the Proceedings of the IEEE conference on computer vision and pattern recognition, F, 2016 [C].