

分类号 TP391

密级 公开

U D C 004.8

编号 10486

武汉大学

硕士学位论文

基于深度学习的医学 图像分割模型研究

研究生姓名：王文欣

学号：2018202110125

指导教师姓名、职称：陈刚 教授

专业名称：网络安全

研究方向：医学图像分割

二〇二一年五月

Research of Medical Image Segmentation Model Based on Deep Learning

By

Wang Wenxin

Supervised by

Prof. Gang Chen

Wuhan University

Wuhan, 430079 P.R.China

May, 2021

论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的研究成果。除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

学位论文作者（签名）：

年 月 日

摘 要

医学图像分割在医学诊断中有着举足轻重的地位。近年来,随着深度学习的不断发展,各种网络模型在医学图像分割领域百花齐放。其中,2015 年提出的 U-Net 网络在图像分割领域受到广泛关注。本文分析了深度学习模型在医学图像分割领域的应用,探索了胶囊网络在医学图像分割领域应用的可能性。本文的主要工作如下:

(1) 分析基于卷积神经网络的 U-Net 医学图像分割模型存在的问题,针对性选择相关数据集,设计实验并证明其存在的问题。

(2) 分析胶囊网络原理,设计提出了基于胶囊网络的 UCaps 医学图像分割模型。并提出了适用于胶囊分割网络的胶囊上采样算法与损失评估算法。证明其能够解决卷积神经网络存在的问题。

(3) 分析动态路由算法原理与矩阵胶囊构造,设计了适用于 UCaps 网络的三种路由算法即:动态路由算法、动态双路由算法与 EM 路由算法。

在对胸肺 x 射线图像的肺部、锁骨、心脏的分割任务中,通过设计和编码,分别使用 U-Net 网络、动态路由算法的 UCaps 网络、动态双路由算法的 UCaps 网络与使用 EM 路由算法的 UCaps 网络进行对比实验。实验结果表明,在医学图像分割中,结合 UCaps 网络结构与胶囊上采样算法,以及 EM 路由算法,不仅有效提升了医学图像分割的准确率,还有着更快的收敛速度。证明了胶囊网络在医学图像分割领域能够取代卷积神经网络。

关键词: 深度学习; 医学图像分割; 卷积神经网络; 胶囊网络; 高斯混合模型; EM 路由算法

ABSTRACT

Medical image segmentation plays a pivotal role in medical diagnosis. In recent years, with the continuous development of deep learning, various network models have blossomed in the field of medical image segmentation. Among them, the U-Net network proposed in 2015 has received much attention in the field of image segmentation. In this paper, we analyze the application of deep learning models in the field of medical image segmentation and explore the possibility of the application of capsule networks in the field of medical image segmentation. The main work of this paper is as follows.

(1) Analyze the problems of U-Net medical image segmentation model based on convolutional neural network, select relevant datasets purposefully, design experiments and prove the problems.

(2) Analyze the principle of capsule network, design and propose the UCaps medical image segmentation model based on capsule network. And the capsule up-sampling algorithm and loss evaluation algorithm applicable to the capsule segmentation network are proposed. It is proved that it can solve the problems existing in convolutional neural networks.

(3) The principle of dynamic routing algorithm and matrix capsule construction are analyzed, and three routing algorithms, namely: dynamic routing algorithm, dynamic dual routing algorithm and EM routing algorithm, are designed for the UCaps network.

In the task of segmentation of lungs, clavicle and heart of chest and lung x-ray images, comparative experiments are conducted by designing and coding a U-Net network, a UCaps network with dynamic routing algorithm, a UCaps network with dynamic dual routing algorithm and a UCaps network using EM routing algorithm, respectively. The experimental results show that the combination of UCaps network

structure with capsule up-sampling algorithm and EM routing algorithm in medical image segmentation not only effectively improves the accuracy of medical image segmentation, but also has a faster convergence speed. It is proved that the capsule network can replace the convolutional neural network in the field of medical image segmentation.

Keywords: Deep Learning; Medical Image Segmentation; Convolutional Neural Network; Capsule Network; Gaussian Mixture Model; EM Routing algorithm

目录

摘 要.....	I
ABSTRACT.....	II
1 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 传统图像分割方法.....	2
1.2.2 基于深度学习的图像分割方法.....	4
1.3 本文研究内容.....	6
1.4 本文结构安排.....	7
2 相关原理及理论.....	8
2.1 深度学习概述.....	8
2.2 神经网络概述.....	9
2.3 卷积神经网络（CNN）概述.....	12
2.4 基于卷积神经网络的图像分割模型 U-Net 概述.....	16
2.5 胶囊网络概述.....	17
2.6 本章小结.....	18
3 U-Net 网络模型在医学图像分割上的效果分析.....	19
3.1 卷积神经网络存在的问题.....	19
3.2 数据集与预处理.....	22
3.3 U-Net 医学图像分割网络模型设计.....	23
3.3.1 网络结构设计.....	23
3.3.2 相关算法设计.....	25
3.3.3 训练流程设计.....	27
3.4 实验分析.....	28
3.4.1 实验结果.....	29
3.4.2 结果分析.....	31

3.5	本章小结.....	32
4	基于胶囊网络的医学图像分割模型.....	33
4.1	胶囊结构.....	33
4.2	胶囊间协议路由.....	34
4.3	基于胶囊网络的医学图像分割模型设计.....	38
4.3.1	胶囊设计.....	39
4.3.2	上采样胶囊算法.....	40
4.3.3	损失函数设计.....	41
4.3.4	基于动态路由的胶囊矩阵 UCaps-Dynamic.....	41
4.3.5	基于动态双路由的胶囊矩阵方法 UCaps-Dual.....	42
4.3.6	基于 EM 路由的胶囊矩阵方法 UCaps-EM	42
4.4	实验分析.....	46
4.4.1	对比实验结果分析.....	47
4.4.2	性能分析.....	50
4.4.3	实验结论.....	52
4.5	本章小结.....	52
5	总结与展望.....	54
5.1	总结.....	54
5.2	展望.....	55
	参考文献.....	57
	致谢.....	62

1 绪论

1.1 研究背景及意义

随着国家越发强调创新,随着我们综合国力的大幅提升,人民的生活品质有了十分大改善。但随之而来的,还有是繁忙的工作与学习,这也在如今社会中产生了较为严重的健康问题。同时也对医学技术提出了全新的要求。作为辅助医生诊断最佳手段的医学图像,在近年来也得到了极大的进步。人们去医院看病,往往都被要求去“拍个片”。医生通过获取患者患处医学影像的方法,往往能够快速、简单、直接地了解病因病情。伴随着 X-射线、计算机断层扫描、核磁共振等技术地逐步出现,我们可以通过使用不同的技术手段,无害地获取病人体内影像,并借此更准确地帮助医生确认治疗方案。借助医学影像手段的医疗诊断体系,已然成为医院医师不可或缺的诊断方法。在获取医学图像后,往往需要医生对医学图像分析,这要求医生能够精确分析出各类数据。前提就在于需要利用图像分割方法分割出待分析的组织器官。

图像分割是指将一幅图像分成多个性质相似区域的过程^[1]。传统的分割方法包括但不限于阈值分割、边缘检测、聚类、遗传算法、深度学习等^[2]。医学影像分割(Medical Image Segmentation)^[3]作为医学影像分析中最为核心的任务,往往需要医生凭借丰富的经验对器官、病灶等进行精准地识别、分割。在当前的医学影像分割中,语义目标识别主要的任务就是对主要骨结构(肋骨、椎骨、头骨等)、主要器官(肺部、心脏、肝脏等)以及一些解剖标记点(如肝脏顶部、主动脉弓)的分割、识别和配准。与普通图片相比,医学影像主要在形状、纹理、灰度与空间等多方面信息上,有着十分复杂的成像方式。往往形状复杂,大小不一、纹理界限比较模糊、相邻区域灰度差异不大、空间位置复杂多变等多种特点。往往医学课本中的影像与实际也有较大差异,医生难以评判诊断。无形中,加大了医生对患者的病因诊断难度,也加剧了医患关系的矛盾。因此,如何在没有丰富经验的医生的情况下,实现对病灶位置的精准分割诊断,如何提升医学影像分割精度,是直接关系到推动医疗水平进步、发展,具有相当重要的医学与社会价

值。基于阈值、区域和边缘的方法是传统图像分割的主流方法。传统方法往往针对特定问题提出的特定算法，没有完善的衡量优劣的标准。没有哪种算法能解决所有通用的复杂情况下的医学影像分割问题。

随着深度学习和大数据时代的到来，“互联网+医疗”成为了在深度学习赋能背景下最热、应用最深的领域。将深度学习的方法应用于医学影像分割，可以很好解决传统医学影像分割算法带来的不足。但是，深度学习往往是通过大量的样本数据进行模型的训练。医学图像往往受制于其来源，其样本通常十分稀少，从而导致训练十分容易过拟合，同样也降低了训练模型的泛化性，即模型会过度跟样本重叠，导致当进行相同任务的其他图像无法适用。那么，研究设计一个通过小样本数据就能训练出相对应模型并通过测试检验的深度学习模型，是我们将深度学习应用于医学影像分割任务时必须要做到的。此外，医学上处理问题通常需要解释分割模型的算法是基于一种什么样的理论，十分注重中间结果的可解释性。但深度学习因为其不可解释性，往往在医学诊断中只能做到辅助诊断。

此外，基于深度学习的医学图像分割往往使用的是目前最为热门的卷积神经网络，而卷积神经网络由于其自身存在的弊端已经被证明在目前的图像分割领域存在问题。国内外也多基于此问题进行了大量的“补救”手段。

因此，一个基于小样本数据、并相对有着更高解释性、模型训练结果更加精确的、可以适用于多数分割任务、能够从原理上解决卷积网络存在问题的全新的深度学习模型，对于医学影像分割任务而言，有着十分重大的意义。

1.2 国内外研究现状

医用图像分割技术在深度学习应用中起着重要作用。近年来，进行了很多研究。本节总结了国内外医用图像分割的研究情况。传统的研究成果分为传统的图像分割法和基于深度学习的图像分割法两个类别。

1.2.1 传统图像分割方法

(1) 基于阈值的图像分割方法^[4]

作为出现最早、应用最广的传统图像分割算法，其原理是将图像各个像素的灰度值与阈值进行对比，其结果属于哪个区间，即被分到哪一类。有着全局阈值与自适应两种类别。其主要使用方法有迭代阈值法、直方图变换、最小误差等方

法。灰度值阈值的选取十分重要，很大程度决定了分割结果的准确性。但阈值选择的过程中，只考虑到了图像像素的灰度信息，在空间上，丢失了其像素的分布，因此结果通常受到噪声影响较大。

(2) 基于边缘的分割方法^[7]

称每个区域边界上的点组成的像素集为边缘。基于边缘的分割方法是利用前景图像和背景图像像素值在图像的两个不同区域差异较大的特征，利用差分算子检测边缘。在检测过程中，图像通常与模板进行卷积。但这种卷积的方式对噪声十分敏感。若图像有噪声的干扰，就会产生分割错误的结果。

(3) 基于区域的分割方法^[5]

基于区域的分割方法通常根据相似性准则按照亮度通过聚类算法将像素归类，进而将图像分为各种区域。其中区域合并分裂方法、种子区域生长法是其主流的方法。其中，种子区域生长法是最早也是较广泛运用在图像分割中的算法。这种方法通过将相似属性的像素归集到同一区域并进行合并，形成一个同质区，进而实现图像的分割。采用小波变换的变分法^[42]，选择合适的像素作为一粒粒“种子”，将相似的种子合并至同一地方。这种方法高度依赖对种子的正确选择。一旦选择错误就毫无意义了。

(4) 基于特征空间的分割方法^[6]

该方法基于图像的分类思想。通过聚类算法，将相同分布的像素归类。C-Means 算法^[9]和 FuzzyC-Means(FCM)算法^[10]在实际运用中被广泛使用。此外还有运用科学统计方法。先使用直方图的形式进行投影并统计分析。再设置阈值，就可以满足一般情况下的分割任务。

(5) 基于图论的分割方法^[8]

通过将图像转换成图论当中的带权图，将带权图的每一条边的权值作为图像中各像素点之间的联系，顶点即像素点。相当于在一张图像中画出一张带权无向图。从而通过计算边的权重来获得分割结果。利用的是贪心选择方法产生的分割结果。

(6) 其他分割方法

常用的图像分割方法除了上文提到的几种，还包含基于物理模型、模糊技术等方法。传统图像分割手段十分之广，但是它们多是针对性得解决某一类问题。受制于各种因素，没有一种广泛通用的分割方法。随着计算机技术的发展，用户

对图像技术的需求也日益个性化,需要被解决的问题也越来越复杂^[42]。总的来说,图像分割方法如今正面临挑战,需要各个研究人员共同探究出新的分割方法。

1.2.2 基于深度学习的图像分割方法

2015 年,全卷积神经网络(FCN)语义分割算法被提出^[11]。FCN 提供对语义级别划分问题的满意答案,FCN 网络用一维卷积核的卷积层替代全连接层而得名。通过反卷积对在最底层卷积的特征图像进行上采样进而恢复与原始图像的相同的尺寸。因此,能够生成图像的各像素的预测。同时,FCN 还可以存储原始图像的空间信息特征,用于预测原始图像,并逐像素地进行分割分类。




图 1.1 FCN 网络结构

在 2015 年,出现了一个应用于医学图像领域分割的全卷积神经网络结构 U-Net^[12]。U-Net 网络在图像分割问题上将跨越连接的思想应用其中,通过对低层信息与高层信息的补充,解决了 FCN 在抽象特征与图像细节间不兼容的问题,使分割精度大大提升的同时保证了图像的细节不丢失。U-Net 结构也因此成为了医学图像分割中的核心框架,在此之上,各类图像分割网络应运而生。在心脏和大血管分割的问题上,则又出现了名为稠密连接的卷积网络(DenseNet)^[13],DenseNet 通过连接任意两层网络降低参数的同时,以最大程度保障信息流和梯度流。




图 1.2 带有 3 个 Dense Block 的 DenseNet

2018 年,《UNet++: A Nested U-Net Architecture for Medical Image Segmentation》^[15]作为 U-Net 网络的增强版 U-Net++, 解决了 U-Net 在医学图像分割中表现不如自然图像分割的缺点。将图像分割过程中每一层 U-Net 连接起来, 以获得最全的特征信息, 并通过训练, 选择最重要的特征信息。这样做有助于防止在池化过程中产生的信息丢失问题。




图 1.3 UNet++结构

2017 年 10 月, Sara Sabour、Nicholas Frost、Geoffrey E.Hinton 在 NIPS2017 上发表了名为《Dynamic Routing Between Capsules》^[16]的论文。Hinton 提出了包括反向传播算法, 深度置信网络、ReLU 激活函数, Dropout 过拟合处理、受限玻尔兹曼机等多项足以推动整个行业进步的理论, 可以说在神经网络这一领域是绝对的领航者。包括前文在图像分割领域最受欢迎的 U-Net 网络, 其核心原理编码器-解码器, 也是 Hinton 提出的。可以说, 胶囊网络的提出, 在深度学习领域引起了很大的震动, 许多专家学者也纷纷投入到对胶囊的研究中。




图 1.4 基于动态路由的胶囊网络

胶囊这一概念早在 2011 年的一篇名为《Transforming Auto-Encoders》^[17]的论文中早已提出。但在如今 GPU 对矢量的计算到达了前所未有的高度之后, CapsNet 才得以实现。

简单理解，胶囊就是将传统神经网络标量的神经元改为向量或者矩阵+标量的形式。相比于标量，胶囊的形式包含的信息可以更多，也可以说，胶囊是多个神经元的聚合体（例如：旋转 10 度的脸，旋转 90 度的脸）。理论上说，胶囊的结构应该是最理想的形态，即每个特征内包含的并不只有底层特征有哪些，也包含了底层特征的位置、姿态等信息。

CapsNet 在 MNIST 数据集上的结果十分出色，凭借胶囊的特点，尤其在高度重叠的、肉眼也难分辨的手写体数字面前，取得了一骑绝尘的成果。胶囊擅长处理实体的位姿、速度、反射率、纹理等信息。在重叠图像识别方面，由于是底层胶囊可以预测高层胶囊的结果，因此识别性能也十分的优秀。

此后，在 Hinton 《Matrix capsules with EM routing》一文中^[18]，对胶囊结构与路由方式进行了大规模改动，可以称之为“胶囊 2.0”。文章将胶囊从计算十分耗时的多维向量，改为矩阵+激活值的方式。除此之外，还提出了使用高斯混合模型的 EM 算法作为胶囊间路由的新方法。但由于实现起来较为困难，目前少有人在 EM 路由算法上进行实验与发掘。




图 1.5 基于 EM 路由的胶囊网络

1.3 本文研究内容

传统的算法依然有着较大的改进空间，但受制于对不同图像的分割，本文的工作重点是探究胶囊原理。并设计提出一个适用于医学图像分割的胶囊网络。在此过程中参考 U-Net 网络结构，并对提出的新型网络模型进行实验与评估。以 CNN 为核心的图像分割模型近年来均取得了较为出色的成绩，但是 CNN 本身包含着对图像的压缩与池化，并忽略了目标间的位置关系。

本文以 X 射线胸透影像为例，开展对医学图像分割问题的探索。未来可推广于所有的医学图像中，有着较大的应用空间。对医学图像分割领域，提供较为不错的方法借鉴。

本文开展对 U-Net 分割网络、胶囊网络、EM 算法高斯混合模型的研究，分别对其各自结构，训练过程与特性，加以改造，提出一种更为优秀的网络模型。在医学图像分割任务中获得更为优秀的表现。

1.4 本文结构安排

第二章主要对文中出现的概念进行简要描述，对文中出现的深度学习、卷积神经网络、胶囊网络等概念进行概述。方便读者获得对概念的初步印象。

第三章主要对卷积神经网络存在的问题进行详细探讨，并选择合适的数据集，设计基于卷积神经网络的 U-Net 医学图像分割模型进行相关实验，探讨在模型训练过程中存在的弊端与问题。

第四章主要介绍胶囊网络原理、胶囊间协议路由方法、矩阵胶囊与 EM 路由方法。并针对医学图像分割，结合胶囊网络原理与 U-Net 网络结构，提出并设计了 UCaps 胶囊网络。结合相关研究，设计了适用于 UCaps 版本的动态路由、动态双路由、EM 路由方法。提出了上采样胶囊结构与更适合 EM 路由方法的损失函数。设计 UCaps 胶囊网络的相关实验，并将其与第三章所设计的实验进行对比分析。证明基于胶囊网络原理的医学图像分割网络能够解决卷积神经网络当前存在的问题。

第五章对本文做出总结，并对本文提出的 UCaps 模型结构存在的问题进行思考与展望。

2 相关原理及理论

本章主要介绍了深度学习相关理论基础。对后文使用的卷积神经网络、胶囊网络的原理与其主要特点进行阐述说明。

2.1 深度学习概述

当提到深度学习时，不同的人脑海里出现的都是不同的词汇，人工智能、支持向量机、机器学习学习。所以，我们需要先认识这几者之间的关系。如图 2.1 所示：




图 2.1 AI 关系图

图 2.1 十分直观的向我们展示了各种“学习”之间的联系。那么什么是机器学习？机器学习并没有一个过于明确的定义，总体上是指通过使用统计技术而让计算机“学习”有用的数据。利用数据训练模型并借此预测数据。涵盖了计算机视觉，自然语言处理等各领域。分为监督、无监督、半监督、强化学习等种类。

监督学习：对于每一个数据集中单一的数据通过其特征向量来判断标签。^[19]简单解释就是让机器学习已知答案的问题从而训练出经验并创建模型，那么当接受一个没有答案的问题的时候就会通过模型预测答案。常见监督学习算法有：线性回归算法、神经网络等。**无监督学习：**无监督学习简单理解起来是一些没有确定答案的数据，比如新闻、音乐等等，我们无法判断对错，只能将其归类是哪一类的新闻、音乐。所有的数据只有特征却没有标签，此时将相似类型聚集在一起，这种将无标签数据按照分类聚集在一起的方法称之为聚类。常见无监督学习有聚类算法与降维算法。还有一类特殊算法，称之为推荐算法。

本文主要使用的方法为人工神经网络中的深度学习的部分，深度学习近年来炙手可热。随着“互联网+”的提出，社会上许多行业或多或少都希望能够得到深度学习“赋能”。与机器学习一样，深度学习不需要人工定义“规则”，而是通过学习结果来推导规则。但是这也是深度学习被人诟病的“解释性”问题之所在。我们很难从一个样本，去询问深度学习网络推导出结果背后的一系列原因。因为随着发展，其隐藏层越来越庞大，很多特征，也只有模型本身“看”得懂。

早在 1943 年得时候，神经学家麦卡罗特和数学家皮兹就一起合作建立了被认为是人工神经网络(ANN)开端的神经网络模型 MCP；1986 年，辛顿提出了 BP（反向传播）算法。2012 年，他还带领研究团队参加 ImageNet 图像识别竞赛。通过提出了性能远超同代的 CNN 网络 AlexNet 而打开了深度学习时代的大门。AlexNet 率先使用激活函数解决梯度消失问题，并使用 GPU 加速模型计算。随着 2020 年新冠肺炎疫情的蔓延，对人们地出行造成很大影响，传统线下各行业也纷纷投身线上，进一步加速了深度学习的发展。

深度学习主要在图像识别、自然语言处理以及图像分割领域应用广泛。而 CNN（卷积神经网络）在近些年在深度学习领域扮演了一个十分重要的角色。

2.2 神经网络概述

神经网络（Neural Network）这个名字来源于人类的大脑结构，神经指的是神经元，简单来说神经网络就是一个函数。输入是上一层所有 Neural 的输出，输出则是一个概率值。由于其全连接的特点，也称之为全连接网络。在 MNIST 数据集中，一张手写体数字图片中含有 28×28 个像素，也就是 784 个神经元。神经元的值是一个标量，大小代表像素的灰度，这个数被称为激活值。在最后一层的神经元共有 10 个，代表手写的各个数字，此时神经元的标量值即为输出的预测值。预测值代表着概率，预测值越高则是这个数的可能性越大。此外，神经网络除了输入图片像素，输入预测概率以外，中间还有隐藏层。隐藏层中的每个神经元代表着前一层所有神经元对它所表示的特征的一个认可度。认可程度越高意味着前一层神经元可能就是当前神经元所表示特征中的一份子。例如，一个班上有多个国家的人，这时候老师说中国的同学站到左边来，那么作为中国学生对这个特点的认可度就十分高。这里认可度高的体现就是心里的归属感，神经网络中称之为权重。




图 2.2 神经网络

784 个神经元放在一起判断进而能够识别一幅图像，显然是不现实的，所以需要隐藏层的参与。当我们人类识别数字时，我们实际上是在组合数字的各个部分(如图 2.3 所示)：




图 2.3 如何识别数字

通过对组成数字“组件”的匹配，就能够得到某一个激活值接近 1 的神经元，也就是输出的数字结果。这样一来，就只需要学习哪些特征能够组合出哪个数字。两个圆形部件可以组成一个数字“8”。同理，可以将一个特征的形状拆分成若干个“小特征”（如图 2.4）：




图 2.4 拆分

若干小特征相互拼接组合，可以构成更大的特征，更大的特征通过组合可以构成最终要识别的物体。通过类比，虽然神经网络并不完全像这样工作，但这对于理解神经网络是非常重要的。接下来，将 784 个 0-1 浮点数中的每一个都乘以

一个权重值。当某一个点属于我们要找的“组件”的一部分，这个需要找到的点就会被“高亮”——其权重为正，将不属于特征的点对特征的权重值设置为 0，代表不感兴趣。如果，这个点周围的非关注点权重为负，那么就类似鹤立鸡群一般，将被选中的点“更加高亮”出来。此时，加权和可以达到最大值。但是此时，权值和大小可以是任意值。但是我们对一件事发生的预测在 0（绝对不可能发生）到 1（肯定会发生）范围内，因此要将函数将权值和作为 0-1 范围内的结果。这就需要使用激活函数，图 2.5 为常用激活函数 sigmoid 函数和 ReLU 函数：




图 2.5 激活函数（左为 Sigmoid 函数，右为 ReLU 函数）

通过激活函数计算得到的激活值，代表对一个加权和的同意程度，加权和越大，表明底层神经元越想激活某个上级神经元，但不是所有的加权和大于 0 的时候，他们都想激活这个神经元，而是这个加权和可能需要大于某个值才能激活神经元，也就是说，神经元过早被激活可能是出现了一定的偏差，因此这个时候需要一个 bias 值，通过将加权和与 bias 值加到激活函数上激活就可以达到目的。一般来说，权重是被激活的神经元对它们所看到的相应模式的一种倾向，bias 值表明权重和有多大才有意义。当一层的每个神经元与下一层的单个神经元之间的连接附加一个权值时，下一层的每个神经元将在获得权值和时添加自己的偏移值。然后通过激活函数得到最终的激活值。

训练之初，会将所有权重和偏置值初始化。此时输出层的预测结果就会出现数值很接近而无法判断的情况。此时需要定义一个“代价”来告诉计算机，正确的激活值应该是只有一个是 1，其余值都接近 0 才对。那么通过数学表达，就是用输出的值与想要的值的结果之差的平方，再相加，得到的结果就是训练单个样本的代价（cost），也称作损失（Loss）。当网络可以正确分类的时候，这个损失就比较小，反之则会很大。通过求出上万个样本通过学习后损失的平均值，就可以用来评价一个神经网络有多糟糕。故而损失函数取决于神经网络对上万个训练数据的综合表现，其输入为所有的权重值和偏置值，输出为一个平均损失。

2.3 卷积神经网络（CNN）概述

卷积神经网络（CNN）是使用卷积操作，含有卷积层，并使用反向传播算法优化未知参数的深度前馈神经网络。

卷积神经网络拥有多种结构，并在各种计算机视觉应用中均有着突破性的性能，例如对象识别、检测和分割问题。卷积神经网络主要包括了以下五个结构：输入、卷积、池化、全连接和输出。其中卷积与池化循环作用，是 CNN “深度”之所在。卷积层是卷积网络的核心。卷积神经网络通过使用卷积操作提取代表性特征来学习输入图像中像素之间的关系。卷积网络通过卷积操作合并，并提出具有代表性的特征，浅层卷积层提取的多为简单的细节特征，例如颜色、纹理等。深层的卷积层则提取高层语义特征，例如这个人在笑、在哭。

卷积层由一系列二维矩阵构成的滤波器组成，这些滤波器被称为卷积核。卷积核与图像进行卷积操作即可以达到产生输出图像的目的。卷积操作，即为将图像的某一位置覆盖上卷积核，并将其值与卷积核一一相乘，将结果再相加，就得到了卷积后的像素值。最后将卷积核对图像中各个位置进行“扫描”。即可完成一次卷积操作。如图 2.6。如果继续推导，最终会将一个 8×8 的二维矩阵卷积成 6×6 的二维矩阵。通常来说，输入图像与输出图像大小尺寸相同最好。因此，我们在输入图像四周填一圈 0，可以发现，卷积核在每行就需要额外进行两次“过滤”，刚好填补了之前因卷积而减少的大小。这种方法称之为零填充。不使用任何填充，直接进行卷积操作的方法称为“有效”填充。零填充巧妙地解决了卷积可能存在输入输出尺寸无法对齐的问题，是一个十分通用的方法。




图 2.6 卷积计算

不同的卷积核会对图像产生不同的影响，进而使图像变成某种特征格外“显眼”的样子。图 2.7 展示了不同卷积核对图像滤波后的影响。




图 2.7 不同卷积核对图像的影响

简单定义卷积核，可以使我们将图像抽象出边缘等特征，那么 we 想识别一张人脸的眼睛应该怎么办呢？答案呼之欲出，通过设定数个特定卷积核可以直接

提取某一个特征。在论文《Visualizing and Understanding Convolutional Networks》^[21]中，对每一层特征进行了可视化，如图 2.8。可以看出，Layer1 和 Layer2 学习到的可能有边缘、颜色等还可以理解的特征，从 Layer3 开始就变得复杂起来，例如纹理特征，再之后 Layer4 和 Layer5 就是更高级的特征例如有区别性的或者关键特征。因此可以发现，通过浅层的卷积学习到的更多是表观上的特征（如颜色、纹理等）。在通过深层卷积层学习到的则是深层语义上的特征（例如笑、哭）。




图 2.8 特征可视化

图像的二维矩阵注定是巨大的，遇到较大图像时，一直卷积往往会空耗时间，无法将特征聚焦。此时需要在卷积之后适当减少图像大小，加速高级语义信息的抽取。同时也防止过拟合的发生，也加快了训练的速度与效率。因此，引入池化层就十分有必要了。

池化层的主要目的就是为下一层卷积时压缩图像大小，试想图 2.8 的任务中，不使用池化层，需要多少层的卷积才能识别到最深层的抽象特征？池化操作降低复杂度的同时也尽可能保留了特征信息。池化层需要选择适当的池化区域范围，步长(stride)和适当的填充。




图 2.9 最大池化

如图 2.9，使用最大池化方式池化处理 4x4 输入图像数据，池化区域为 2*2，步长设置为 2。在第一个“窗口”中，4 个元素中最大值是 6，因此检索到的元素的值是 6。依此类推，我们可以进一步从原始特征图中提取主要特征。如此，数据量被成功从 4*4 变成 2*2，且依然保留了特征值。

公式 2.1 是通过池化层后，求解激活值的计算方法。其中， a_j^l 为池化层输出的第 j 个单位的激活值， $down()$ 即为池化函数， b_j^l 为偏置值。 β_j^l 为乘数残差， M^l 为池化区域尺寸大小。若使用非重叠池，则图像大小将缩小 M^l 倍。

$$a_j^l = f(b_j^l + \beta_j^l down(a_j^{l-1}, M^l)) \quad (2.1)$$

在全连接神经网络中，每一层之间的所有神经元提供相应权值并相互连接。全连接层与全连接神经网络原理一致，通常出现在卷积神经网络的最后部分。全连接层将上层神经元全部连接在一起，将二维图像直接计算成一维。类似于用一个 1 维卷积核进行的卷积操作。但这也是跟卷积层完全不同的地方。从本质上讲，全连接层将输入信息进行内容提取，并生成对分类分割结果的预测。这个过程通常包括实现特征向量的一维表示，并将卷积层的特征图中的信息展开成一维矩阵，输入到全连接层。全连接层的输出多是预测类的标签

同时，它也作为网络的“分类器”而存在。全连接层输出一个代表分类数量 $1*N$ 的矩阵，也就是 N 维向量。这个矩阵中的每一个元素都代表着网络对某一类别预测的概率。全连接层可以将上层的输出特征图联系到输出类别，从而显示哪些特征与哪些类别最相关。

全连接层的总数称为全连接层的长度，全连接的层越长，模型越复杂，卷积神经网络的非线性表示就越高，因此多个全连接层可解决非线性问题。然而，全连接层的长度太长会引起过拟合问题，并且算法的复杂度变高会增加计算时间的成本并降低效率。

2012 年 Hinton 的论文《ImageNet classification with deep convolutional neural networks》^[20]中实现了 AlexNet 架构,是 CNN 发展浪潮的开端。图 2.10 为 AlexNet 卷积神经网络结构示意图:




图 2.10 AlexNet 神经网络结构

2.4 基于卷积神经网络的图像分割模型 U-Net 概述

FCN 网络首先提出将卷积神经网络中的全连接层更改成卷积层,因此得名。这样更改的目的是使 CNN 网络能够应用于图像分割任务中。传统全连接层获得的结果是对分类结果的预测,多应用于语义识别任务。而 FCN 通过上采样操作、跨越链接方法,通过卷积层获得图像像素级别的分类预测。也就是说,FCN 就是对图像中每个像素进行分类任务,从而得到全局的分类结果,也就是分割结果。

U-Net 网络是 FCN 网络在图像分割领域的改进和延伸。FCN 网络对图像每一层卷积后的特征通过跨越链接全部叠加在一起,这种叠加是将特征进行了加法。并且最“高级”的语义信息通过上采样操作会导致分割结果十分“模糊”。而在医学图像分割中,需要精确到像素级别的分割结果。因此,U-Net 选择进行多尺度特征的拼接,通过大量上采样操作与跨越链接将每一层的卷积特征与语义信息精准融合。并且在链接过程中使用通道的拼接而不是简单的叠加。这样使得提炼出“高级”语义信息的图像能够逐步的与图像信息进行“还原”,大大提升了分割的精度。因此,U-Net 网络是在需要精确分割的医学图像分割领域中最受欢迎的网络结构。实验证明,U-Net 网络结构能在训练样本不多的情况下也得到十分优秀的分割结果。

通常使用的上采样方法是反卷积,也称为上卷积或转置卷积。与卷积恰好相反,如图 2.11 所示,如果没有填充,卷积操作会将图像压缩,卷积核将多个值转

为一个值。但是在反卷积中，需要将一个像素值还原为多个值，并且还需要尽可能地与原图相仿。当然，从理论上讲，卷积-池化操作不可逆。因此，称之为转置卷积更为贴切。卷积过程并没有反过来，反而，为了将输出尺寸翻倍，需要在输入图像周围填充多层 0、或者将原图像每个值的周边插满 0 元素，再进行常规卷积操作。可以理解为将高级抽象特征“稀释了”，并认为这样稀释的方式可以尽可能还原原始图像。通过反向传播算法，对反卷积核进行训练，进而尽可能还原出卷积-池化之前的图像。




图 2.11 卷积与反卷积

卷积-池化操作在 U-Net 中反复进行，最终使得抽象特征极富有概括性与代表性。但同时，也将图像抽象成我们看不懂的样子。跳跃连接则是在每层池化之前，将现有特征图进行保存。在上采样过程“稀释”了抽象特征后，与同等尺寸的原特征图进行拼接并通过卷积融合。让抽象特征保留的同时，也保证了细节特征不会损失太多。可以说反卷积只有搭配跳跃连接，才能使 U-Net 取得巨大成功。

2.5 胶囊网络概述

Hinton 在《Dynamic Routing Between Capsules》一文后，进行了“*What is wrong with CNN*”与“*Does the Brain do Inverse Graphics*”的两场演讲。并提出了胶囊网络这一概念。胶囊网络本质上就是要“革 CNN 的命”。尽管 CNN 不断崛起突破，在各大比赛收获荣誉。但本质上，当前主流的深度学习网络与生物中的神经网络存在着很大差异。例如，我们人类孩童时期，学习看图 2.12，看左边图时，大人会告诉我们，这是一只鸟喙。那么当我们看到右边图的时候，就会举一反三，这是也一只鸟喙，只不过跟左图鸟喙的朝向不同，其本质上属于同一个标签。但是在 CNN 中，我们学习到的标签可能就是两种：鸟喙（向左），鸟喙（向右）。

只有通过大量的数据集充分地训练后，CNN 才会“学会”，这都是鸟喙。换言之，当物体姿态、位置、光照等条件发生改变时，人类往往能通过空间的推理做到“举一反三”，但是 CNN 的识别缺少这种推理能力，究其原因，主要在池化过程中，减少数据量的同时，扩大了神经元的感受范围，却忽略了压缩后位置的改变。因而，在 CNN 大行其道的今天，“深度学习之父”Hinton 已经开始思考，如何让神经网络更具有可解释性，能够在神经元层面包含更多信息呢？于是，胶囊应运而生。




图 2.12 胶囊原理举例

胶囊作为一个向量（或者矩阵）包含了一个实例的各种姿态、位置信息。不仅优化了 CNN 存在的问题，并且有着更好的解释性。胶囊网络自提出，多被应用于图像分类任务中。但在图像分割领域，仍有着较大的空白。

2.6 本章小结

本章主要介绍了深度学习、卷积神经网络、胶囊网络相关概念，解释了卷积神经网络的基本结构与作用。简要介绍了胶囊网络诞生的背景。

3 U-Net 网络模型在医学图像分割上的效果分析

本章重点探讨了卷积神经网络存在的问题，尤其在医学图像分割领域。针对性选择了 JRST 数据集，设计实现了一个基于卷积神经网络的 U-Net 医学图像分割网络模型。通过实验，对其相关结果与数据进行探讨，发现其在训练过程和原理上存在的弊端。

3.1 卷积神经网络存在的问题

在卷积神经网络里，数据在经历各卷积层的过程中，初步的卷积解决的是较为简单的特征，随着卷积层的加深，经历过多次池化操作的数据也保留着更高层次的特征。而高层次特征往往通过低级特征简单组合而来。多简单？存在即可。因此，组成高层特征的低层特征彼此之间是没有关联的。即“在哪不重要，是一家人就行。”这种粗暴的组合方式让底层间的位置姿态关系彻底被破坏。CNN 解决此问题的方式便是使用 max-pooling 或者后续卷积来减少数据的大小，从而可以让上层神经元可以“看”到的更多，从而检测出大区域的高阶语义特征或者说，整体特征（比如，就是一张脸）。这样的做法可取，有时候甚至超越了人类本身对图像的识别能力。但是，最大池化依然会损失很多有价值的信息。总结来看，整个卷积神经网络使用了多层本地并可以在空间内复制的特征检测器，其空间覆盖在更高层中更大。这些特点都是卷积神经网络表现十分突出的地方。但真正的问题就在于其卷积层（特征提取）与池化层（采样）相互交错，而采样时池化了相近的特征检测输出。这就是卷积神经网络中最大的问题所在。

从生物神经角度来看。作为拟合人类神经网络的神经网络模型，人类在认知物体的时候首先会对物体选取坐标框。关于坐标框如图 3.1 所示：




图 3.1 坐标系的选取影响了对图片语义的识别

图 3.1 左边是一块大陆，我们一眼看上去首先肯定想到的是澳洲大陆，因为形状看上去挺像的。但当我们旋转这个图片会发现，这其实是非洲大陆。为什么？因为我们看到这张图的时候会下意识建立一个水平和垂直的坐标系，但其实这张图的坐标系是旋转过的。而 CNN 并没有这一坐标框，甚至池化层还破坏了这一坐标框架。

其次有关等变性与不变性。CNN 所追求的不变性，是指在物体发生很小的变化的时候，CNN 依旧能够识别出来。一张纸，旋转 90° 依旧是一张纸，这本身没有错。但是 CNN 依旧忽略了 90° 这个参数。如果是一张静态图片，这样考虑无可厚非，CNN 直接忽略了空间关系，只针对对象识别。这种方法虽然显著提高了识别率。但现实生活真的如此么？对于视频这样动态的图片集合、或者当我们不仅知道“这是什么”，还想知道它从哪到哪了的时候。我们可以了解一下 CNN 的做法。

在 CNN 分类同一类图像时，经常需要对同一目标内不同角度的变化，进行正确的分类过程。




图 3.2 不同特征方向的脸部

CNN 在训练过程中，对同一张面部的所有方向、角度以及同一张面部内所有器官的方向角度进行足够充分的学习，才能识别出旋转后的面部。而人类学习的过程往往能够“举一反三”，所以，CNN 是深度学习，但可能并不“智能”。




图 3.3 视角变换时子特征也随之变换

为解决不同角度的次级特征问题，CNN 添加了更多的卷积层和特征图。然而，这种方法倾向于穷举某个数据集所有的可能结果，而不是一个概括性的解决方案。在最基本的 MNIST 数据集中，对手写体数字有着近 55000 个数据。显然，当我们人类记忆的时候是不需要那么多样本进行学习的。因此，CNN 在利用数据这一方面效率太低。其原理没有能高度概括某一特征的所有可能变形。

而相对的，人脑在识别静态与动态图像的时候，通过神经学研究，使用的是同一套视觉系统。因此等变性不会丢失位置等信息。它是对内容的不同体现。如何体现等变性呢？对于空间中动态的物体，通常我们会有两种表示方法：一种是动态物体的静态位置表示（即某一时刻的位置）；另一种是动态物体的动态速率表示（即物体运动速度）。对应的，位置编码和速率编码正是我们体现等变性的方式。在物理学中，我们求得速率的方式是通过位置差。对应的，在想体现等变性的网络结构中，高层的 domain 覆盖更广，体现着从底层的位置编码到高层的速率编码的变化。如果设计出一种神经网络，能够用一个模型，同时对静态与动态图像识别，是否会更像人类的大脑？

CNN 在同一层神经元之间，并没有建立联系，也没有考虑空间位置关系。可能在过去的 10 年里，它发展势头非常强。但终究我们还是要追逐真正的“智能”。Hinton 也曾公开表示 pooling 操作会是 CNN 最大的败笔。池化能够减少训练的村数量，但如今，我们需要正视 CNN 存在的问题。当我们将人脸的五官与脸部打乱时（如图 3.4）CNN 同样会认为是同一类别。然而我们可以明显看到，下图并不称得上是人类的脸。




图 3.4 当人脸五官打乱时，CNN 仍可以识别

以上例子说明，如果图片中存在两个眼睛一个鼻子一个嘴巴，还不能判断图中存在的是一张人脸。我们还需要了解五官的相对位置关系，才能够综合判断结果。

如图 3.5，在图像中添加几乎肉眼不可察的底噪，就可以让 CNN 完全被“愚弄”，因此 CNN 在面对攻击样本时，同样也存在着安全隐患。




图 3.5 CNN 无法对抗干扰

在医学图像分割领域中，往往缺少大量的数据。且由于不同的人体构造的差异，往往数据样本间差异性较大。尤其是部分需要分割的部位在截面上往往会产生重叠，而应用于分割任务的 CNN 网络其本质“学习”的过程是对于各像素点对分类结果的预测。在处理重叠关系时，往往各像素之间没有充分地进行关联。进而导致在分割过程中需要大量的样本进行反复迭代训练。而且，由于在医学图像中，往往拍摄时角度，亮度等因素有着明显差异。在传统使用 CNN 的医学图像分割模型中，需要将样本进行数据增强，即旋转、位移、调整亮度等工作。这样的方式可以说是“不智能的”。我们人类大脑往往会对一个相互重叠的部分进行一个推测，也就是会思考某一种形状对应重叠部分是否合理。如果合理，我们将通过某种注意力因素排除掉其他可能，再去观察另一部分是否合理。

3.2 数据集与预处理

针对上一节所探讨的 CNN 在医学图像分割中存在的问题，需要选择一个合适的实验进行设计与验证。其首要目标是选择一个有着重叠部分，其内部各数据间有着一定差异，足够“暴露出”CNN 问题的数据集。

本文选择的数据集是 JSRT (Japanese Society of Radiological Technology) 数据库^[28]。该数据库是由日本放射技术协会 (JSRT) 与日本放射学会 (JRS) 合

作创建的有无胸肺结节的标准数字图像构成。共有 154 张带结节与 94 张不带结节的图像。原始图像分辨率为 2048*2048，像素尺寸为 0.175mm。而标签图像则是取自 B. V. Ginneken 等人在论文^[29]中对 JSRT 数据集手动标注的肺部、心脏和锁骨的标签图。将其图像与标签压缩至 128*128 像素。对标签进行融合处理，将各标签汇总在一张图，并通过不同灰度颜色加以区分（如图 3.6 左）。

在训练时，因为不需要我们肉眼去观察标签，只要保证计算机“看得懂”即可。需要对各标签值按顺序赋值 0-5，分别为：其他、左肺、右肺、左锁骨、右锁骨、心脏。方便计算。

该数据集在左右锁骨上与肺部高度重叠，哪怕凭借肉眼，我们都难以在重叠部分精确找到其区域轮廓。此外，心脏的轮廓形状与位置在标签上差异性较大。其数据在拍摄过程中的位置、亮度也各有不同。因此，选择该数据集可以更好地看出基于 CNN 的医学图像分割网络所存在的问题。




图 3.6 实验数据集标签（左）图像（右）

3.3 U-Net 医学图像分割网络模型设计

本节设计了在卷积神经网络中最受欢迎，也往往作为医学图像分割任务 baseline 的网络模型——U-Net，用来实现对 JRST 数据集的分割任务。

3.3.1 网络结构设计

设网络结构设计如图 3.7：共计使用 18 个卷积层，4 个下采样层，4 个上采样层，1 个分类卷积层。整体结构分为 Encoder 部分（左半部分）与 Decoder 部分（右半部分）。其中，通过卷积-卷积-池化操作实现下采样，实现各个尺度的特征抽象（Encoder 部分）。中间层使用两次卷积操作实现。通过反卷积-跨越链接-

卷积-卷积实现上采样，将图像逐倍放大回原始尺寸并实现多尺度特征拼接操作。在拼接过程中，将同尺寸图像的语义特征与细节信息进行维度上的拼接。进而在卷积后能获得更加全面的分割结果。最后，通过卷积层进行各像素对各分割部分的分类预测。进而得到最终的分割结果。其中，每一步卷积使用 3×3 的卷积核，并使用 ReLU 函数作为激活函数。




图 3.7 U-Net 网络结构

具体结构设置如下表：

表 3.1 U-Net 结构设置

卷积层	输入	输出	卷积核大小	激活函数	池化/反卷积	跨越链接
Conv0	128*128*1	128*128*16	3*3	Relu		
Conv1	128*128*16	128*128*16	3*3	Relu		1
Down1	128*128*16	64*64*16	3*3	Relu	Max-Pooling	
Conv2	64*64*16	64*64*16	3*3	Relu		
Conv3	64*64*16	64*64*16	3*3	Relu		2
Down2	64*64*16	64*64*16	3*3	Relu	Max-Pooling	
Conv4	32*32*16	32*32*16	3*3	Relu		
Conv5	32*32*16	32*32*16	3*3	Relu		3
Down3	32*32*16	16*16*16	3*3	Relu	Max-Pooling	
Conv6	16*16*16	16*16*16	3*3	Relu		
Conv7	16*16*16	16*16*16	3*3	Relu		4
Down4	16*16*16	8*8*16	3*3	Relu	Max-Pooling	
Conv8	8*8*16	8*8*16	3*3	Relu		
Conv9	8*8*16	8*8*16	3*3	Relu		
Up1	8*8*16	16*16*16	3*3	Relu	反卷积	
Conv10	16*16*32	16*16*16	3*3	Relu		4
Conv11	16*16*16	16*16*16	3*3	Relu		

Up2	16*16*16	32*32*16	3*3	Relu	反卷积	
Conv12	32*32*32	32*32*16	3*3	Relu		3
Conv13	32*32*16	32*32*16	3*3	Relu		
Up3	32*32*16	64*64*16	3*3	Relu	反卷积	
Conv14	64*64*32	64*64*16	3*3	Relu		2
Conv15	64*64*16	64*64*16	3*3	Relu		
Up4	64*64*16	128*128*16	3*3	Relu	反卷积	
Conv16	128*128*32	128*128*16	3*3	Relu		1
Conv17	128*128*16	128*128*16	3*3	Relu		
Class	128*128*16	128*128*6	1*1	Relu		

3.3.2 相关算法设计

1、损失函数设计

交叉熵损失函数可以应用于分类分割问题，“熵”通常被用来表示事物的混乱程度，例如：混乱的厨房的“熵”就要比干净整洁的厨房的“熵”要高得多。某件事物的某种概率越不确定，则其“熵”越大。例如三点一线的人的熵就远小于四处乱逛的人。所以交叉熵适合用来作为类似问题的损失函数。

对于某个元素的预测分类结果的交叉熵损失函数可以表示为公式 3.1：

$$L_i = - \sum_{c=1}^M y_{ic} \log(p_{ic}) \quad (3.1)$$

其中 M 表示分类的类别数量， y_{ic} 为指示 0-1 变量，如果该样本 i 预测分类的类别和该类别 c 相同，则其取值为 1；如果该样本 i 预测分类的类别与 c 不相同，则取值为 0， p_{ic} 表示样本 i 预测结果属于某一类的概率。

2、反向传播算法应用

在前向传播阶段通过梯度下降法可以快速求得局部最优解，从而将损失值降到最低。梯度下降法需要求解一个值的负梯度值。在 U-Net 医学图像分割网络设计中，需要对卷积、池化、反卷积进行反向传播计算。当输入图像数据时，其最终输出对像素分类的预测结果在训练不完全时，不可能全部集中在一个结果上，像素其他分类类别也会有（甚至更大）的预测值。此时我们不能调整结果，只能通过改变训练中间来调整“函数”。

在期望状态下，我们希望某一激活值变大，其他数值变小，并且变动大小与当前值和目标值之间的差成正比，即差值越大越重要。在反向传播过程中，需要解决如下几个问题：

（1）池化层的反向传播。

池化在训练的前向传播中，对输入进行了压缩。那么在反向传播中已知池化层输出的误差 δ^l ，推导其输入的误差 δ^{l-1} 。在 U-Net 医学图像分割网络中，使用最大池化的方法进行前向传播，获得区域内数值中的最大数，通过记录次数在区域中的位置。在池化反向传播过程中，将误差 δ^l 的矩阵还原为池化前的尺寸，将最大值对应原尺寸位置的误差也为 δ^l ，其余部分误差为 0。这个过程即为 up-sample。因此得出池化层反向传播公式：

$$\delta_k^l = \left(\frac{\partial a_k^l}{\partial z_k^l}\right)^T \frac{\partial J(w,b)}{\partial a_k^l} = \text{upsample}(\delta_k^{l+1}) \odot \sigma'(z_k^l) \quad (3.2)$$

(2) 卷积层的反向传播：

对于卷积操作的反向传播，由于误差即为当前层中损失函数对于净输入的导数，通过链式求导，得出 l 层中图像坐标为 (x, y) 的误差 $\delta^l(x, y)$ ：

$$\begin{aligned} \delta^l(x, y) &= \frac{\partial C}{\partial z^l(x, y)} = \sum_x \sum_y \frac{\partial C}{\partial z^{l+1}(x', y')} \frac{\partial z^{l+1}(x', y')}{\partial z^l(x, y)} \\ &= \sum_{x'} \sum_{y'} \delta^{l+1}(x', y') \frac{\partial z^{l+1}(x', y')}{\partial z^l(x, y)} \end{aligned} \quad (3.3)$$

在 $l+1$ 层中，有多个点 (x', y') 被前一层所影响，因此需要叠加各种影响，即：

$$z^{l+1}(x', y') = \sum_a \sum_b \sigma(z^l(x' + a, y' + b)) w(a, b) + b^{l+1} \quad (3.4)$$

将其展开化简可以得到：

$$\delta^l(x, y) = \sum_a \sum_b \delta^{l+1}(x - a, y - b) w(a, b) \sigma'(z^l(x, y)) \quad (3.5)$$

进而得出：

$$\delta^l(x, y) = \sum_{a'} \sum_{b'} \delta^{l+1}(x + a', y + b') w(-a', -b') \sigma'(z^l(x, y)) \quad (3.6)$$

最后，可以得出：

$$\delta^l = \delta^{l+1} * \text{ROT180}(w^{l+1}) \odot \sigma'(z^l) \quad (3.7)$$

(3) 反卷积层反向传播

反卷积又被称为转置卷积，通过其定义可知，反卷积操作就是卷积过程的逆运算。相对的，卷积的前向传播过程即为反卷积的反向传播。卷积的反向传

播过程正是反卷积的前向传播。反卷积或者说转置卷积，其本质并不是将卷积操作逆向，即反卷积其本质依然为卷积操作，只是输入输出尺寸参数的变化。

反向传播算法的理念就是：为得到一串对上一层神经元改动的变化量，我们需要加上所有期待的改变。然后从后往前，直到第一层神经元。再将所有样本通过反向传播，记录下样本想怎样修改权重和偏置值，最后再取平均。但是如果每一个样本集中在一起一个一个反向传播再计算负梯度，这会导致计算速度的大幅降低。因此将数据集打乱并分成一个一个的 batch，通过对一个 batch 的训练，逐渐找到最小值，如图 3.5 显示，不划分 batch 的时候，所有样本通过反向传播计算负梯度，虽然下降精准，但是数据太多则会太慢，而且其结果也容易“陷入”局部最小值。划分 batch 之后，虽然整体样本的路径变复杂了，但是每一段 batch 计算速度更快，可以快速多次下降直到最小值。这样划分 batch 的方法是随机梯度下降法。

3.3.3 训练流程设计

- 1、对网络初始化，设定表 3.2 所示的医学图像分割网络结构设置卷积核大小，零填充大小，步幅，设置 [2,2] 的最大池化。设置 `keras.layers.UpSampling2D()` 函数中参数 `size=(2, 2)` 即分别重复数据 `size[0]` 行, `size[1]` 列。选择激活函数 ReLU。对网络中各个卷积核 W ，偏置值 b 随机初始化。设置迭代次数 `epoch=30000`，设定训练 batch 为 5，学习率为 $\eta = 0.00001$ 。
- 2、从训练数据集中获取一个 batch 的数据。
- 3、在一个 batch 中获取其中一个图像 $input$ 与标签 $label$ 。
- 4、将输入图像 $input$ 带入设定好的网络结构中，获得输出结果 $output$ 和各中间层参数 z^l 与参数 a^l 。
- 5、通过交叉熵损失函数 L_i ，输出结果 $output$ ，标签值 $label$ 计算损失 $loss$ 。
- 6、计算输出值与损失函数间的误差 δ^l 。
- 7、从后往前递推各层的误差。

$$\text{反卷积/卷积层: } \delta^l = \delta^{l+1} * ROT180(w^{l+1}) \odot \sigma'(z^l) \quad (3.7)$$

$$\text{池化层: } \delta_k^l = \text{upsample}(\delta_k^{l+1}) \odot \sigma'(z_k^l) \quad (3.2)$$

8、根据步骤 7 中所求误差，求得损失函数对当前层参数的导数。

$$\frac{\partial C}{\partial w^l} = \delta^l * \sigma(z^{l-1}), \frac{\partial C}{\partial b^l} = \sum_x \sum_y \delta^l \quad (3.8)$$

9、将步骤 8 所求导数与当前 batch 的各图像所求导数和相加。重复执行步骤 3，直到该 batch 训练结束。

10、将步骤 9 中获得的当前 batch 各图像所求导数和，使用梯度下降法更新参数。

$$W^l = W^l - \frac{\eta}{\text{batch_size}} \sum \frac{\partial C}{\partial w^l} \quad (3.9)$$

$$b^l = b^l - \frac{\eta}{\text{batch_size}} \sum \frac{\partial C}{\partial b^l} \quad (3.10)$$

11、执行步骤 2，直到达到迭代次数 epoch。

3.4 实验分析

按照训练流程设计进行，编码，运行实验，实验环境是 Tensorflow 平台，版本为 1.13.1，根据其版本，使用 cuda 版本为 10.0，对应 cudnn 版本为 7.4.5。使用的是浪潮云平台运行代码。其 CPU 配置为 Intel Xeon Gold 6248@2.5GHz，该 CPU 为 4 核 32GB 内存，GPU 使用一块 Tesla-V100-SXM，其显存为 32GB。

在编码过程中，使用了 Keras 框架。Keras 框架是一个高级神经网络 API，由 python 编写。作为深度学习工具，Keras 提供了两种模型搭建方式，其中，序列化模型搭建方式可以直接通过 add 方法不指定层 API，而是通过序列类添加层对象。此外还有函数化模型搭建，主要是用以搭建非序列化模型，支持子类继承，进而获得更好的可拓展性。本文主要使用 Keras 中内置的转置卷积构建方法。Keras 框架有如下优点：

1、Keras 作为 Tensorflow 的高层封装，其 API 十分的简洁。因此在使用过程中上手十分迅速，可以方便计算实验参数。

2、由于 Keras 的 API 可以与 Tensorflow 无缝集成，提供了模块化的调用，在使用过程中，可以跟 Tensorflow 无缝切换。方便使用和理解。

3.4.1 实验结果

通过实验，得到不同迭代轮次中，得到测试集平均预测结果如表 3.2:

表 3.2 U-Net 医学图像分割网络各器官在不同迭代次数下测试集准确率					
网络结构	不同训练次数下测试集准确率				
	500	1000	5000	10000	30000
左肺	79%	85%	90%	92%	98%
右肺	84%	88%	93%	94%	95%
左锁骨	0%	0%	27%	54%	84%
右锁骨	0%	0%	37%	61%	87%
心脏	50%	67%	80%	89%	92%
平均	42.6%	48%	65.4%	78%	91%

模型测试集预测结果如图 3.8，分别为：原始图像、标签、预测结果以及三幅图两两相互叠加对比的效果图。




图 3.8 U-Net 模型对 JPCNN075 测试样本预测结果

通过按像素评估预测结果对于标签的准确率，U-Net 模型在 JPCNN075 样本测试中对左肺分割准确率为 98.2835%，对右肺分割准确率为 96.0216%，对左锁骨分割准确率为 86.8901%，对右锁骨分割准确率为 83.9665%，对心脏分割准确率为 89.831%，平均分割识别准确率为 91.0345%。对于全部 77 张测试样本，模型平均对左肺分割准确率为 97.9089%，对右肺分割准确率为 95.7978%，对左锁

骨分割准确率为 83.9624%，对右锁骨分割准确率为 87.3623%，对心脏分割准确率为 92.2103%，平均分割识别准确率为 91.4483%。

训练过程中，模型对测试集各器官分割准确率如图 3.9。可以看出，在训练开始后，左右肺部、心脏其正确率上升较快，2000 轮迭代后基本稳定。但在左右锁骨的分割准确率上，参考其测试集还原结果不难看出，直到 12000 轮迭代后，模型才基本锁定左右锁骨位置。




图 3.9 U-Net 医学图像分割模型在测试集对各器官分割准确率变化

总体而言，在经过多次迭代后，模型可以基本完整地分割出对应器官，且误差保持在一个较低的水平。取得了不错的成绩。但是也可以发现，在重叠度较高的锁骨部分，模型的分割并不尽如人意。此外在各个分割器官的边缘部分，相对于标签还是存在轮廓不清晰的现象。图 3.10 为分别在 2000 轮、10000 轮与 20000 轮训练后，同一张测试图片的分割结果。此外，图 3.11 是在训练 30000 轮后，从结果看，精度较高，但实际上存在“漏洞”，或者模糊等一系列问题的数据。




图 3.10 不同迭代次数下 U-Net 医学图像分割模型对 JPCNN054 数据测试分割结果对比
(从左至右依次为 2000 轮, 10000 轮与 20000 轮)




图 3.11 迭代 30000 次后依然存在各种“问题”的结果

3.4.2 结果分析

通过实验可以看出, 分割结果在较少迭代次数下确实取得了不错的成绩。但是在器官重叠度很高的锁骨部分, 尤其是锁骨的边缘部分, 分割模型在有限的迭代轮次下无法获得很高的精度。主要因为基于卷积神经网络的 U-Net 网络模型在面对重叠的器官时使用池化的方法, 丢失了部分信息, 失去了像素间关联的一致性。在后续的补充实验中, 依然可以发现多次迭代后依旧会存在边缘不清晰问题与重叠部分会有漏掉的点以及分割图片出现“漏洞”。

综上所述, 我们需要对 CNN 进行一个修改: 第一, 集合多个神经元组成一组(容器)用来表示一个物体不同的信息; 第二, 去掉池化层, 以免位置信息

被打乱；第三，训练一种算法，能够实现对每一个“容器”的相关参数学习；第四，解决高层“容器”如何向低层“容器”获取信息的问题。

3.5 本章小结

本章重点分析设计了基于卷积神经网络的 U-Net 网络模型在 JRST 数据集上的医学图像分割模型，进行了相关实验，通过实验可以得出，U-Net 网络模型在医学图像分割上确实有着十分优秀的表现。且能够在较少的迭代轮次中取得比较满意的成绩。但于此同时，也可以发现，由于池化操作对图像细节信息的压缩，导致了虽然跨越链接能够保证一定的语义信息和图像信息并存。但是在重叠的锁骨部分和器官的边缘部分，依然存在轮廓不清晰的问题。此外，在心脏部分也存在着定位不准确的问题。整个网络所如何更好解决这些问题，将是后文研究的关键所在。

4 基于胶囊网络的医学图像分割模型

胶囊网络作为一种全新的理念，已经在传统语义识别的多个分类数据集上得到了充分的验证。理论上说，胶囊的结构与胶囊间路由的思想在图像分割领域也十分适用。本文首先从胶囊结构与胶囊间路由两个方面论证了胶囊网络在医学图像分割任务中能够取代卷积神经网络的可行性。设计了能够代替 U-Net 网络的胶囊医学图像分割网络——UCaps，结合胶囊间路由算法设计出适用于 UCaps 的路由算法。通过实验，证明了在同样结构与参数设置下的 UCaps 网络能够在多个方面解决 U-Net 网络在训练过程中存在的问题，并有着更为优秀的性能。

4.1 胶囊结构

当胶囊作为包含多种信息的载体，有着矩阵和向量两种形式。其每个元素（或者分量）表现了某一特征的各类属性。这些属性可以包含多个参数，例如位姿（即，位置，方向等），速度，纹理等等。整个胶囊向量输出的长度在 0-1 之间，即为胶囊对特征出现的概率。

可以理解为：我们使用每个胶囊表示的是某一实体的各个属性，以往，通过标量表明特征出现概率（例如，是否存在嘴巴，那么这个标量的值即为存在嘴巴的概率）。胶囊的出现即通过向量表示单个特征的多种属性（例如，嘴巴在鼻子下面，嘴巴是红色的等）。是一个从是否存在，到以什么样的形式存在的问题转化。




图 4.1 低层胶囊与高层胶囊的联系

以向量胶囊为例，假设 u_1 代表某一底层特征（比如耳朵），那么作为其上层特征 v_1, v_2, v_3, v_4 （例如狗，猫，狐狸，），单看 u_1 ，对 v_1, v_2, v_3, v_4 的概率为：

$$(p_{1|1}, p_{2|1}, p_{3|1}, p_{4|1}) = \frac{1}{z_1} (e^{\langle u_1, v_1 \rangle}, e^{\langle u_1, v_2 \rangle}, e^{\langle u_1, v_3 \rangle}, e^{\langle u_1, v_4 \rangle}) \quad (4.1)$$

那么遍历完 u_2, u_3, u_4, u_5 (例如眼睛, 嘴巴, 毛发, 鼻子) 后, 获得了多个对上级特征的预测值, 将多个底层特征对 v 的概率分布累加融合, 得到对上级特征的预测结果。进而, 我们可以认为胶囊的核心就是在于输出是输入聚类后的结果。

$$v_j = \text{squash} \left(\sum_i p_{j|i} u_i \right) = \text{squash} \left(\sum_i \frac{e^{\langle u_i, v_j \rangle}}{z_i} u_i \right) \quad (4.2)$$

计算底层特征 u 对上层特征 v_j 的预测过程, 使用了 squash 激活算法, 即通过算法将向量的模进行压缩, 使胶囊向量的模能够代表其所有底层胶囊对其预测的概率值。或者说, 是代表某一特征的“显著程度”。

4.2 胶囊间协议路由

一个胶囊层由许多胶囊组成, 一个 Capsule 可以理解成是一个一张图片中的每一个像素所包含的函数。这个函数在特定的位置和方向预测目标的存在性。以向量形式解释胶囊网络原理, 会较为贴切。用图形解释如图 4.2:




图 4.2 胶囊激活

如图包含了 50 个 Capsule。颜色、箭头方向、长度分别表示形状、被检测实体所旋转的角度、被检测实体存在的概率。当 Capsule 没有检测到物体时, 其对应方向就是随机的, 箭头长度也十分短。图 4.2 中可以看到有两个长箭头, 说明此处的胶囊检测到了他们分别对应的实体。并相应的激活。

在二维的案例中, 向量的方向指的是被检测实体旋转的角度。但是, 真在实际现实中, 一个胶囊向量是多维度的, 也包含了更多维的参数比如颜色、大小、厚度、扭曲等等。我们使用一个卷积层, 将输出一个数组, 这个数组包含了很多特征映射, 表示其位置。再通过激活函数压缩其长度的同时保留了矢量方向。

能够把位置与姿态的信息完整记录下来，是胶囊的一大重要特性。激活向量的 Equivariance 意味着胶囊的视角会随着实体 pose 的变化而变化。前文提到，CNN 中的 pooling 操作会减少很多的参数量，也让图片得以更快运行，进而之保留语义信息，而忽略了细节。Capsule 则解决了丢失细节信息的这一问题。如图 4.4，图像仍然是矩形与三角形，但与之前不同的是，此时两者之间构成的新形态是一艘船。根据其属性，是一艘有着 18 度倾角的船。




图 4.3 船




图 4.4 房子

在以上两张图像中，船和房子的组成元素向同，但却构成了两种截然不同的实体。类似于铁可以用来制作农具也可以用来制作兵器一样。放在 CNN 里，有可能检测出这两张图是同一个物品。由于胶囊保存了三角形和矩形的姿态信息，因此我们通过找到这个旋转角度就可以进一步可以判断它是船还是房子。

当高层只有两个胶囊房子和船时。底层矩形胶囊在图片中找到了一个矩形，那么房胶囊和船胶囊都会“发现”这个矩形，并评估自身与它的状态关系。由于两个形状的角度都是 16 度，因此这个矩形 Capsule 会带着权重（角度）激活下一层胶囊——房子/船。。




图 4.5 Capsule 预测

计算机需要“学习”变换矩阵 W_{ij} ，先求解所有上层胶囊激活函数与变换矩阵的点积之和，其结果带入下一层激活函数。进而可以求出下一层胶囊的激活值。通俗来说就是学习部分与整体之间的数学关系。

三角形胶囊会产生一个倾向，例如是否是房子？此后，胶囊会根据三角形的姿态推理出一个倒置的房子，同理，船胶囊会推理出一艘旋转 16 度的船。




图 4.6 三角形 Capsule 的预测

由此得到了四个预测输出，1、已检测出来的三角胶囊对船的推理：一个 16 度倾角的船；2、已检测出来的三角胶囊对房子的推理：一个倒置的房子；3、已检测到的矩形胶囊对船的推理：一个 16 度倾角的船；4、已检测到的举行胶囊对房子的推理：一个倾角 16 度正立着的房子。而在图 4.6 中红色框体部分可以看到，矩形胶囊与三角形胶囊关于对船的预测是一样的：一个 16 度倾角的船。因此两个低层胶囊对于高层胶囊的投票时一致的；反观另一边，矩形胶囊与三角胶囊分别根据自身对矩形和三角行的姿态，对房子的预测是相反的。因此，两个胶囊产生了冲突，进而高级的房子胶囊不会被激活。并且由于两个胶囊预测这个是船的一个部分。那么矩形胶囊和三角胶囊的输出就不会被发送到其他下一层的除了船胶囊外的其他胶囊。这就是胶囊间的动态协议路由。

使用动态协议路由方法的好处就是：

1、下一层 Capsule 得到的输入更加准确清晰，因为前一层 Capsule 产生的输出只会去指定的 Capsule。

2、可以很轻松查看部件层级。

3、当识别对象重叠的时候，Capsule 分别提供不同的预测，从而早早就可以分开重叠部分。

图 4.7 中，每一个点都代表着底层胶囊对其上层胶囊形态的预测。例如对于船胶囊这一上层胶囊，底层的矩形胶囊会根据自身的角度去推测船胶囊的角度。当底层的胶囊变多的时候，就会有更多预测的结果是用来推测上层胶囊的状态。




图 4.7 动态路由实现原理

通过计算点积，求得每个向量到平均值的远近，进而计算预测的平均值并更新权重。此后，再次进行如上计算，反复迭代，就可以得到聚类结果。图 4.7 中点的颜色深度代表着对应胶囊权重大小，距离越近，权重越大。

胶囊计算过程中，点积越大，是因为胶囊对其预测的结果表示越肯定，进而对正确的预测会使得权重也更大。当点积很小的时候，胶囊对预测也就没那么确定了，因此权重的更新也不会太多。多次迭代后，再进行激活使其预测值在 0-1 之间。然后进入下一层。

图 4.8 展示了胶囊网络在处理重叠问题上的优势，通过观察，该重叠图像可以看作上面是房、下面是船。但是在重叠的图像中，仍然可以找到一个倒置的房子。但如果这个倒置的房胶囊对应被激活了，那么剩下的图形就没法构成高级胶囊。更何况，四个底层胶囊的投票时间是一致的。底层胶囊就会更加认可上面是个房子，下面是一艘船。

当然，处在中间的矩形胶囊与三角形胶囊也一定对倒置的房胶囊进行了肯定的投票。但是剩下两个胶囊的“意见”同样也十分重要很重要。胶囊网络通过协

议路由将胶囊的倾向转换成了预测，当每个底层胶囊都对上一层胶囊有着同样的看法时，就可以获得对上层胶囊更好的预测。进而消除重叠部分的歧义。



图 4.8 处理重叠

一般来说，胶囊是一个“容器”，是一个多维向量，信息通过重合分割在层间传递。至于巧合的划分，简单的理解是一种“从众”的选择。就好比有两个人在讨论某个地方发生的事情。如果路过，肯定会忽略。但是当你发现路上的每一个人都在谈论这个地方发生的事情时，你就会知道有什么大新闻了。高维空间中向量的激活概率很低，可以筛选出这种符合。这种方式是聚类判断置信度。矢量作为神经元的输入和输出并不是胶囊所独有的。但它提出了一个新的传输方案，这个方案在很大程度上是可以解释的。一层胶囊可以通过变换矩阵预测更高层胶囊的实例化参数。

4.3 基于胶囊网络的医学图像分割模型设计

网络总体结构如下如图 4.9：输入一个图像，第一层 Primary CapsNet 输入训练图片。通过常规卷积操作，将输入的图像输出为包含有 $[4, 4]$ 的姿态矩阵和 1 个标量激活值的 $(H \times W \times C)$ 个胶囊。进入下一个胶囊层，通过 `kernel_tile` 将胶囊展开进行深度可分离卷积并使用 `mat_transform` 函数将展开的胶囊乘上视角不变矩阵的变换矩阵 W 得到投票矩阵 V ，最后通过 EM 算法计算父胶囊的输出姿态矩阵和激活值，并保存结果到 `skip` 中用来准备后面的 `skip-connection` 操作。之后进入下采样胶囊层，通过步长为 2 的 W 矩阵。依次通过步长分别为 1 和 2 的胶囊层后，输入到上采样胶囊层——DeCaps 层，DeCaps 层则类似 UNet 中上采样的过程，使用了全新的上采样胶囊算法。之后再行深度可分离卷积。使得输出胶囊数量增加，之后同样计算投票矩阵 V ，通过 EM 算法更新父胶囊。进行 `skip-connection` 操作，将 `skip` 胶囊与输出胶囊在第四维度拼接，即将 Caps 层输出添加进 DeCaps 层的 `channel` 中。并作为下一个 Caps 层的输入，经过三个上

采样层与胶囊层，最后将结果输入 Class Caps 层，输出图片中每一个像素对应的胶囊对分割标签类别的预测投票。进而得到整体图像的分割预测。

此处值得注意之处在于，我们很容易把下采样过程当作是胶囊池化。其实这是有比较大误区的。一度质疑过上采样与下采样算法是否适用于胶囊网络。后认真研读胶囊相关论文发现。这里将每个像素视为一个底层胶囊单元，输出应为每个胶囊单元对分割结果的投票，或者说，顶层胶囊分割分类结果所包含的底层胶囊单元。因此，结构上看，是像素在逐渐减少，图片尺寸在降低。但实际上，第一层训练之后，就可以将整个网络结构视为都是胶囊的相互路由作用。




图 4.9 UCaps 网络结构设计

4.3.1 胶囊设计

使用矩阵+激活值的形式，如下图：




图 4.10 胶囊矩阵

4.3.2 上采样胶囊算法

上采样胶囊层相比普通胶囊层，添加了一个胶囊层上采样算法：

算法1	胶囊层上采样算法
输入：	输入胶囊[<i>Length</i> , <i>Width</i> , <i>Channel</i> , <i>Pose</i> + <i>Activation</i>], 上采样卷积核 w_size , 上采样倍数 N 。
输出：	输出上采样后胶囊 [$Length \times N + \frac{w_size-1}{2}$, $Width \times N + \frac{w_size-1}{2}$, <i>Channel</i> , <i>Pose</i> + <i>Activation</i>]
1	获取胶囊的 $Length$ 维度、 $Width$ 维度大小
2	创建索引 <i>indices_1</i> 用于列出需要插入的位置为 <i>shape</i> [0][0]
3	创建 <i>update_1</i> 为 $[\frac{w_size-1}{2}, 1]$ 维 0 矩阵
4	胶囊在 $Length$ 维度按照 <i>indices_1</i> , 用 <i>update_1</i> 进行稀疏
5	胶囊转置为 [$Width$, $Length + \frac{w_size-1}{2}$, <i>Channel</i> , <i>Pose</i> + <i>Activation</i>]
6	胶囊在 $Width$ 维度按照 <i>indices_1</i> , 用 <i>update_1</i> 进行稀疏。
7	创建索引 <i>indecas_2</i> , 每相邻两行间标记索引
8	创建 <i>update_2</i> 为 $[shape[0] \times (N - 1), shape[1] \times (N - 1)]$ 维 0 矩阵
9	胶囊在 $Width$ 维度按照 <i>indices_2</i> , 用 <i>update_2</i> [0] 进行稀疏。
10	胶囊转置为 [$Length + \frac{w_size-1}{2}$, $Width \times N + \frac{w_size-1}{2}$, <i>Channel</i> , <i>Pose</i> + <i>Activation</i>]
11	胶囊在 $Length$ 维度按照 <i>indices_2</i> , 用 <i>update_2</i> [1] 进行稀疏。
12	返回上采样后胶囊

胶囊上采样过程公式为：

$$R_{ij} = \begin{cases} 0 & (i = 2m - 1, j = 2n - 1) \\ x_{mn} & (i = 2m, j = 2n) \end{cases} \quad n \in [1, W], m \in [1, H] \quad (4.3)$$




图 4.11 胶囊上采样过程

4.3.3 损失函数设计

使用如下公式作为损失函数的计算方法：

$$\text{loss} = \frac{1}{L \times W} \sum_{i=1}^L \sum_{k=1}^T \sum_{i=t}^{i=t} \left(\max \left(0, \text{margin} - (\text{act}_{jkt} - \text{act}_{jki}) \right) \right)^2 \quad (4.4)$$

其中，随着训练次数的增加，margin 值也会逐渐增大。act_i 作为最终胶囊的激活值，在训练早期值会很小，意味着其通过聚类后预测处于均匀分布。其 margin 值不宜过大，进而使损失值随其影响过多。随着训练次数的增加，act_i 会越来越大，意味着胶囊的激活值越来越接近 1，margin 值随之增大，用来稳定损失值。

4.3.4 基于动态路由的胶囊矩阵 UCaps-Dynamic

动态路由算法原理较为简单，即输出即为输入聚类的结果，而聚类需要进行反复迭代。因而就产生了动态路由算法。在 Hinton 所撰论文^[16]中，动态路由算法如下图所示：

```

procedure ROUTING( $\hat{\mathbf{u}}_{j|i}, r, l$ )
    for all capsule  $i$  in layer  $l$  and capsule  $j$  in layer  $(l + 1)$ :  $b_{ij} \leftarrow 0$ .
    for  $r$  iterations do
        for all capsule  $i$  in layer  $l$ :  $\mathbf{c}_i \leftarrow \text{softmax}(\mathbf{b}_i)$  ▷ softmax computes Eq. 3
        for all capsule  $j$  in layer  $(l + 1)$ :  $\mathbf{s}_j \leftarrow \sum_i c_{ij} \hat{\mathbf{u}}_{j|i}$ 
        for all capsule  $j$  in layer  $(l + 1)$ :  $\mathbf{v}_j \leftarrow \text{squash}(\mathbf{s}_j)$  ▷ squash computes Eq. 1
        for all capsule  $i$  in layer  $l$  and capsule  $j$  in layer  $(l + 1)$ :  $b_{ij} \leftarrow b_{ij} + \hat{\mathbf{u}}_{j|i} \cdot \mathbf{v}_j$ 
    return  $\mathbf{v}_j$ 
    
```

图 4.12 动态路由算法

首先，我们需要知道所有的预测胶囊，迭代次数 r 以及当前输入胶囊层数 l 。之后，定义一个初始值为 0 的参数 b ，开始迭代如下内容 r 次：

计算胶囊 i 所有路由权重值 c_i ，保证所有 c_i 非负，且和为 1，即需要通过对 b 求 *softmax* 压缩其值。对预测胶囊加权求和得到 s_j 。此后，通过 *squash* 函数将 s_j 压缩为 v_j 。将胶囊 j 的输出 v_j 进行点积，进而预测胶囊，并加上原有权重 b ，更新 b 权重值，开始下一轮迭代。（点积操作是为了检测输入与输出的相似性）

经过 r 次迭代后，返回输出胶囊 v_j 。

4.3.5 基于动态双路由的胶囊矩阵方法 UCaps-Dual

将胶囊结构改为矩阵+矩阵的形式，即位姿矩阵 P （包含特征在空间中的相对位置关系的矩阵）与外观矩阵 A （包含特征中颜色、光照等因素的矩阵）。使用动态路由算法分别对位姿矩阵与外观矩阵进行动态路由迭代，并通过矩阵乘法将其组合。

4.3.6 基于 EM 路由的胶囊矩阵方法 UCaps-EM

前文提到，我们要将输入聚类才能得到一个上层的胶囊结构，聚类通常需要的就是迭代算法。在胶囊网络中所指的就是动态路由算法。但是理论上来说，其他的聚类迭代算法也是可行的。动态路由算法可以将其视为一个 **K-means** 聚类算法的简化版。

作为向量，胶囊结构也有着它的缺点，最典型的，就是在训练时，一个 16 维的向量需要 16×16 的变换矩阵来训练，但如果将 16 维向量修改为 4×4 的矩阵，则仅仅需要另一个 4×4 的变换矩阵就可以对其进行训练，这大大减少了计算量。

因此，使用矩阵+激活值的方法，代替向量作为胶囊的基本结构，但其原理依然不变。此外，使用高斯混合模型与 EM 算法代替原本的动态路由，可以称之为 EM 路由。EM（期望最大化）路由的目的是使用集群方法（EM）对整体进行封装，形成部分与整体之间的关系。在机器学习中，通过 EM 方法将数据聚类成高斯分布。通过低层胶囊分别对可能是其父胶囊的 **Pose Matrix** 进行预测。如果一些子胶囊鼻子、嘴巴、眼睛都认为面部胶囊是他们的预测，则将其聚集形成面部胶囊。

下图为根据与矩阵胶囊达成协议的路由可视化，可以看到，当 **mouth** 胶囊的姿态矩阵乘视角不变矩阵后，得到对 **face** 胶囊的一个预测值。这个值作为

face 胶囊姿态矩阵中。同样，nose 胶囊的 Pose Matrix 乘 nose 的视角不变矩阵 W ，同样得到一个对 face 胶囊的预测。当两个预测值近似时，可以认为，mouth 和 nose 胶囊都是 face 胶囊的子胶囊之一。具有相似票数的胶囊经过视角不变矩阵的转换来分组胶囊。




图 4.13 路由可视化



图 4.14 变换矩阵具有视角不变性

当观察视角发生了改变时，Pose Matrix 对父胶囊的预测也会随之而变换。如图 4.14，当人脸发生移动时，我们的投票也会随之发生改变。但任何一个子胶囊对其父胶囊的看法，都是不变的。（因为视角不变矩阵的作用）。因此面对类似旋转等一些变换时，我们仅仅需要调整视角不变矩阵和父胶囊即可。




图 4.15 低层胶囊激活上层胶囊

如图 4.15, EM 路由是通过对胶囊进行分组、聚合, 从而构造出高级胶囊。例如, 手胶囊并没有被面部胶囊所包含。那么这种发生的概率就是受到胶囊激活程度的影响。如果这张图像中嘴巴被挡住了话, 嘴部的胶囊有没能被激活。算得出的概率即为 0。

高层胶囊表示其上一层低层胶囊的高斯分布的期望, 通过高斯混合模型, 拟合其最小化的损失函数。同层间不同的高斯混合模型反映了相同低层胶囊对不同高层胶囊的倾向性, 即高斯混合模型“高亮”了高层胶囊中的低层信息。通过训练视角不变的变换矩阵 W , 使得高层胶囊不仅包含了低层胶囊的特征, 同时保存了低层胶囊间的位置信息。即使当图片发生旋转, EM 路由仍然能将相同位置关系的低层胶囊聚类。

在前文中, 我们已知输出即为输入聚类的结果, 并使用了动态路由算法。然而, 理论上, 这种聚类可以应用各种聚类算法。其中, 结合高斯混合模型的 EM(Expectation Maximization)路由旨在利用聚类技术将胶囊分组, 构造整体与部分的关系。Hinton 等人指出, 高层胶囊表示其上一层低层胶囊的高斯分布的期望, 通过高斯混合模型, 拟合其最小化的损失函数。同层间不同的高斯混合模型反映了相同低层胶囊对不同高层胶囊的倾向性, 即高斯混合模型“高亮”了高层胶囊中的低层信息。通过训练视角不变的变换矩阵 W , 使得高层胶囊不仅包含了低层胶囊的特征, 同时保存了低层胶囊间的位置信息。即使当图片旋转, EM 路由仍然能将相同位置关系的低层胶囊聚类。原理上, EM 算法与高斯混合模型更加适合胶囊网络。

定义 Capsule i 到 Parent Capsule j 的投票值 v_{ij} (其中: v_{ij}^h 即为 v 的第 h 个元素)。

通过高斯概率密度函数 $P(x)$ 计算 v_{ij}^h 属于胶囊 j 的高斯概率 p 。

$$p_{ij}^{\lambda} = \frac{1}{\sqrt{2\pi(\sigma_j^{\lambda})^2}} \exp \left(-\frac{(v_{ij}^{\lambda} - \mu_j^{\lambda})^2}{2(\sigma_j^{\lambda})^2} \right) \quad (4.5)$$

取其对数 $\ln(p)$ 即:

$$\begin{aligned} \ln(p_{ij}^{\lambda}) &= \ln \frac{1}{\sqrt{2\pi(\sigma_j^{\lambda})^2}} \exp \left(-\frac{(v_{ij}^{\lambda} - \mu_j^{\lambda})^2}{2(\sigma_j^{\lambda})^2} \right) \\ &= -\ln(\sigma_j^{\lambda}) - \frac{\ln(2\pi)}{2} - \frac{(v_{ij}^{\lambda} - \mu_j^{\lambda})^2}{2(\sigma_j^{\lambda})^2} \end{aligned} \quad (4.6)$$

下个胶囊激活与否与成本成负相关。其成本越容易被激活。因此, 成本 $cost_{ij}$ 应为 p 自然对数的负值:

$$cost_{ij}^{\lambda} = -\ln(p_{ij}^{\lambda}) \quad (4.7)$$

根据 r_{ij} 按比例计算成本, 即可求得所有低层胶囊应有成本为:

$$\begin{aligned} cost_j^{\lambda} &= \sum_i r_{ij} cost_{ij}^{\lambda} \\ &= \sum_i -r_{ij} \ln(p_{ij}^{\lambda}) \\ &= \sum_i r_{ij} \left(\frac{(v_{ij}^{\lambda} - \mu_j^{\lambda})^2}{2(\sigma_j^{\lambda})^2} + \ln(\sigma_j^{\lambda}) + \frac{\ln(2\pi)}{2} \right) \\ &= \frac{\sum_i r_{ij} (\sigma_j^{\lambda})^2}{2(\sigma_j^{\lambda})^2} + \left(\ln(\sigma_j^{\lambda}) + \frac{\ln(2\pi)}{2} \right) \sum_i r_{ij} \\ &= \left(\ln(\sigma_j^{\lambda}) + k \right) \sum_i r_{ij} \text{ which } k \text{ is a constant} \end{aligned} \quad (4.8)$$

那么, 可以用如下公式确定胶囊 j 是否会被激活: 其中, λ 是一个特殊参数。即当 r_{ij} 越来越优, 则 λ 变大, 则 sigmoid 曲线梯度变大, 进而对原本差异很小的投票值也十分敏感, 差异很大。借此, 可以更好调整 r_{ij} 。

$$a_j = \text{sigmoid} \left(\lambda \left(b_j - \sum_k cost_j^{\lambda} \right) \right) \quad (4.9)$$

通过交替迭代的 EM 算法的 E-Step 和 M-Step, 将分配概率与高斯混合模型反复更新。高斯混合模型中的 μ 值, 即为父胶囊姿态矩阵的一个元素值。

```

procedure EM ROUTING( $\mathbf{a}, V$ )
     $\forall i \in \Omega_L, j \in \Omega_{L+1}: R_{ij} \leftarrow 1/|\Omega_{L+1}|$ 
    for  $t$  iterations do
         $\forall j \in \Omega_{L+1}: \text{M-STEP}(\mathbf{a}, R, V, j)$ 
         $\forall i \in \Omega_L: \text{E-STEP}(\mu, \sigma, \mathbf{a}, V, i)$ 
    return  $\mathbf{a}, \hat{M}$ 
    
```

图 4.16 EM 路由算法

算法中，上层胶囊的激活值 $\mathbf{a}$ 即为 EM 路由公式中 act_j ， V 即为子胶囊对父胶囊姿态矩阵的投票。在训练初，使用均匀分布表示子胶囊对父胶囊的倾向性一致。随后根据高斯混合模型分布与 EM 算法进行训练。

$$\begin{aligned}
 \text{M-Step: } \left\{ \begin{array}{l}
 R_{ij} \leftarrow R_{ij} * act_i \\
 r_{ij} \leftarrow \frac{R_{ij}}{\sum_i R_{ij}} \\
 M_j = \mu_j \leftarrow \sum_i r_{ij} V_{ij} \\
 \sigma_j^2 \leftarrow \sum_i r_{ij} (V_{ij} - \mu_j)^2 \\
 p_{ij} = P(C_i | C_j) \leftarrow N(V_{ij}; \mu_j, \sigma_j^2) \\
 cost_j = \sum_i -r_{ij} \ln(p_{ij}) \\
 act_j = \text{logistic}(\lambda(\beta_\alpha - (\beta_\mu + \sum_{l=1}^d \ln \sigma'_j) \sum_i r_{ij}))
 \end{array} \right. \quad (4.10)
 \end{aligned}$$

$$\text{E-Step: } R_{ij} \leftarrow \frac{act_j p_{ij}}{\sum_j act_j p_{ij}}$$

4.4 实验分析

按照前文设计的 UCaps 网络结构、UCaps 路由方法与上采样算法进行编码并实验。为便于对比实验，统一实验环境与配置。仍选择使用 Tensorflow1.13.1，cuda10.0，cudnn7.4.5 的实验环境配置。硬件上依然选择 4 核 32GB 的 Intel Xeon Gold 6248CPU 处理器与 32GB 显存的 Tesla-V100-SXM 显卡。

将基于动态路由的矩阵胶囊 UCaps-Dynamic 模型、基于双动态路由的 UCaps-Dual 模型与基于 EM 路由的 UCaps-EM 模型进行相同环境下的对比实验。分别统计其在 30000 次训练后的在测试集上的表现、各器官在不同训练次数下分割结

果的表现。并综合实验数据，与基于卷积的 U-Net 医学图像分割网络实验结果进行对比，得出结论。

4.4.1 对比实验结果分析

各模型测试集预测结果分别如下图，分别为：原始图像、标签、预测结果以及三幅图两两相互叠加对比的效果图。




图 4.17 UCaps-Dynamic 模型对 JPCLN124 测试样本预测结果

UCaps-Dynamic 模型在 JPCLN124 样本测试中对左肺分割准确率为 98.2835%，对右肺分割准确率为 98.6138%，对左锁骨分割准确率为 97.0636%，对右锁骨分割准确率为 88.4678%，对心脏分割准确率为 87.2523%，平均分割识别准确率为 94.0811%。对于全部 77 张测试样本，模型对左肺分割准确率为 98.0876%，对右肺分割准确率为 96.2713%，对左锁骨分割准确率为 96.9554%，对右锁骨分割准确率为 84.6592%，对心脏分割准确率为 83.8757%，平均分割识别准确率为 92.24%。




图 4.18 UCaps-Dual 模型对 JPCLN124 测试样本预测结果

UCaps-Dual 模型在 JPCLN124 样本测试中对左肺分割准确率为 98.5461%，对右肺分割准确率为 97.7285%，对左锁骨分割准确率为 97.6818%，对右锁骨分割准确率为 92.4493%，对心脏分割准确率为 88.3707%，平均分割识别准确率为 94.8882%。对于全部 77 张测试样本，模型对左肺分割准确率为 98.1764%，对右肺分割准确率为 96.3348%，对左锁骨分割准确率为 97.4014%，对右锁骨分割准确率为 86.593%，对心脏分割准确率为 85.3936%，平均分割识别准确率为 92.9891%。






图 4.19 UCaps-EM 模型对 JPCLN014 测试样本预测结果

UCaps-EM 模型在 JPCLN014 样本测试中对左肺分割准确率为 98.8369%，对右肺分割准确率为 96.8205%，对左锁骨分割准确率为 98.2677%，对右锁骨分割准确率为 89.236%，对心脏分割准确率为 88.841%，平均分割识别准确率为 94.7263%。对于全部 77 张测试样本，模型对左肺分割准确率为 98.7453%，对右肺分割准确率为 97.679%，对左锁骨分割准确率为 97.5569%，对右锁骨分割准确率为 90.8931%，对心脏分割准确率为 86.9253%，平均分割识别准确率为 94.32%。

对比实验结果如下：

表 4.1 对比实验结果（30000 次训练）

网络结构	测试集分割准确率					
	左肺	右肺	左锁骨	右锁骨	心脏	平均
UNet	97.91%	95.80%	83.96%	87.36%	92.21%	89.45%
UCaps-Dynamic	98.09%	96.27%	96.96%	84.66%	93.88%	92.24%
UCaps-Dual	98.18%	96.33%	97.40%	86.59%	95.39%	92.99%
UCaps-EM	98.84%	97.68%	97.56%	90.89%	96.93%	94.32%

实验结果来看：基于 EM 路由方法的 UCaps 网络的分割精度最高。在数据训练之后开始快速收敛，相对较快。无论是训练集还是测试集 loss 中都分布合理，并未出现欠拟合或者过拟合。在左右肺这种原始图片中十分突出的部分分割精度十分高，左右锁骨次之，而在心脏部分的分割表现略微差强人意（准确率约为 87%）。通过仔细分析数据集的构造，不难发现是因为心脏在图像中的位置相对不固定，其形状结构差异性较大。想要通过肉眼分辨心脏具体位置的难度都十分大。因此，整体实验的结果还是十分理想的。

4.4.2 性能分析

由于各种模型最终结果差异性不明显。为探寻各模型间更为全面的差异，将训练过程聚焦于初期。在训练初期，几种网络模型都快速收敛，但在将每一个分割部位进行准确度测算时，左右锁骨部分跟双肺重叠，根本无法定位（如图 5.6 左一）。双肺分割精度收敛非常迅速，心脏则由于图像中位置关系不准确，导致精度也很低。但相比而言，使用 EM 路由的 UCaps 网络能在很短时间通过位置关系，定位锁骨与心脏。使其相比于对照组，在训练前期有着相当优异的表现。当使用像素为单位整体评价准确率的时候，几种网络测试集准确率差距不明显。但使用分割后的各部位单独进行对比的时候，UCaps 表现十分优异。本文认为，这是因为 UCaps 的胶囊网络结构保证了各部分间的位置形态关系，此外，EM 路由与高斯聚类算法则保证 UCaps 能在很少的数据集中有着更为出色的表现。表 4.2 与表 4.3 分别为相同训练数据量的情况下，各网络在右锁骨与右肺的分割精度对比，可以看出，在对右肺分割时各网络很快就基本保证了精度，但右锁骨在训练初期精度差距较大。

表 4.2 右肺在不同网络不同训练次数下的分割结果

网络结构	右肺在不同训练次数下测试集准确率		
	500	1000	2000
U-Net	79%	88%	90%
UCaps-Dynamic	84%	91%	93%
UCaps-Dual	84%	90%	94%
UCaps-EM	86%	93%	96%

表 4.3 右锁骨在不同网络不同训练次数下的分割结果

网络结构	右锁骨在不同训练次数下测试集的准确率						
	200	500	1000	2000	5000	10000	30000
U-Net	0%	0%	2%	3%	28%	57%	87%
UCaps-Dynamic	9%	9%	17%	47%	68%	79%	84%
UCaps-Dual	10%	19%	31%	52%	68%	79%	86%
UCaps-EM	12%	18%	28%	59%	71%	81%	91%



图 4.20 从左至右依次为：U-Net，UCaps-Dynamic，UCaps-EM 在 4000 次训练下测试集测试结果

图 4.20 则能直观反映同轮次下分割结果，可以看出，U-Net 在分割重叠度较大且图像分割困难的锁骨部位，训练时很难保证分割精度，且训练初期几乎无法正常分割。但是相比而言，带有胶囊结构的三种医学图像分割模型在重叠的锁骨部位有着相当不错的表现。收敛速度相当快。如图 4.21 是 UCaps-EM 模型与 U-Net 模型在 4000 轮迭代内测试集各器官平均分割准确率。可以明显看到在左右锁骨的分割中，胶囊网络有着相比于 U-Net 更为优秀的表现。




图 4.21 U-Net 与 UCaps-EM 在 4000 次训练中测试集各器官分割准确率的对比（依次为左肺、右肺、心脏、左锁骨、右锁骨）

但是于此同时，由于胶囊结构将原本是标量的神经元变成了矩阵。在训练过程中参数量十分巨大。在使用矩阵+激活值的两种路由方案的模型（UCaps-Dynamic 和 UCaps-EM）中，平均训练一张图片的时间约为 0.52 秒。而使用 pose 矩阵+appearance 矩阵的双路由方案（UCaps-Dual）实验过程中，其平均一张图片

的训练速度达到了 6 秒。而相对而言,使用卷积神经网络的 U-Net 结构医学图像分割模型平均训练一张图片的速度在 0.02 秒。

综合来看,结合了 EM 路由的 U 型胶囊网络 UCaps 在训练的时候拥有最好的分割精度和较快的收敛速度,同时也保证了一个较为合理的训练速度。结合了 EM 路由的 UCaps 网络收敛速度远高于其他网络模型。

4.4.3 实验结论

通过实验发现,在基于胶囊网络的 UCaps 医学图像分割模型在整体分割精度上都要明显高于基于卷积神经网络的 U-Net 医学图像分割模型。在设置卷积与胶囊两种网络的过程中,对应网络结构与迭代次数等参数基本保持一致。通过对比分割测试集结果可以明显看出,在左右肺部、心脏部位的分割,四种网络模型表现都很不错。均有着较高的分割精度。可以基本实现分割任务。

然而,在面对重叠程度高,识别困难的锁骨部分,结合了胶囊网络原理的 UCaps 网络在训练初期就能保证较为优秀的训练效果。主要由于胶囊网络中路由部分相比于 CNN 的权重乘法更适合处理对高度重叠部分的分割。尤其在结合了高斯混合模型的 EM 聚类算法的 EM 路由方法,在分割任务中取得了最好的效果。此外,同样也由于胶囊与神经元在构建上的差异,导致了其训练参数量相对更大,尤其是使用双矩阵的胶囊网络,虽然有着更快更好的收敛速度,但同时也极大增加了训练的时间。综合来看,基于 EM 路由的胶囊医学图像分割网络在综合上取得了更加优秀的成绩。

4.5 本章小结

本章主要对 U-Net 网络模型、基于 U-Net 结构的胶囊网络 UCaps 模型进行实验,并使用动态路由、双路由、EM 路由三种胶囊间路由方式进行研究。可以看出,通过实验,UCaps 网络在训练损失变化、收敛速度、测试集结果方面有着不错的表现。尤其在网络结合 EM 路由算法之后,其收敛速度有着显著的提高。此外,由于锁骨与肺部的高度重合,导致多数网络在前期都很难正常分割。但这恰好是胶囊网络所擅长的。因此可以得出,UCaps,尤其是结合了 EM 路由算法的 UCaps 网络在右锁骨的识别上有着显著得优势。UCaps 在本文选择数据集上取得了十分优秀地表现。尤其在对比三种路由方案后,基于高斯混合模型得 EM 路由

算法的确更适合图像分割。此外，本文提出的评价损失函数和胶囊上采样算法同样取得了不错的效果。成功将胶囊网络应用在图像分割领域。

因此，本章得出的结论是，在相同网络结构下，使用了胶囊原理与协议路由算法的网络模型，其性能不仅高于基于卷积神经网络的网络模型。而且在处理重叠问题上有着更加突出的表现。在迭代次数较少的情况下，基于胶囊网络与 EM 路由的 UCaps 网络模型能够在重叠部分进行更快的识别与分割，并且对数据集有着更强的鲁棒性。但是，胶囊网络由于其自身结构的原因，导致其训练参数量较大，且计算时间较长。综合来看，胶囊网络的确很好地从原理上解决了 CNN 存在的不足与弊端，但局限于算力，其在处理更大图片或者三维医学图像的时候显得有些“捉襟见肘”。

5 总结与展望

5.1 总结

本文通过对卷积神经网络和胶囊网络的研究与探索,分析了卷积神经网络在医学图像分割领域存在的问题。证明了胶囊网络不仅解决了卷积神经网络存在的问题,也证明了其在医学图像分割领域也能有十分重要的作用。本文提出了一种全新的基于 EM 路由的 U 型结构胶囊医学图像分割网络,并取得了相当不错的成果。足够证明胶囊网络与 EM 路由在结合 U-Net 网络结构之后能够胜任在医学图像多标签分割任务中的工作。此外,文章提出的上采样胶囊算法确实可以作为胶囊网络在上采样过程中的一个关键步骤,进而替代反卷积。本文提出了更适合 EM 路由的损失计算。实际实验结果表明 UCaps 结合 EM 路由算法确实收敛更快,更为优秀。本文提出的基于 EM 路由的 UCaps 网络在 JSRT 数据集上取得了不错的成绩。对本文的工作总结如下:

(1) 本文首先对医学图像分割工作进行相关背景介绍与总结,对国内外当前在深度学习医学图像分割领域的进展进行介绍。通过实际工作发现了 CNN 在医学图像分割上存在的问题。

(2) 理论论证基于 CNN 的 U-Net 网络在医学图像分割上存在的问题,并针对性选取相关数据集进行实验。实验结果表明, U-Net 在训练初期面对重合度较高的锁骨部分分割效果十分不明显。需要多轮迭代才能够逐渐识别。在心脏这种在数据集中显示位置差异性较大且同样有一定程度重叠的部分也存在分割精度低的问题。

(3) 通过对胶囊网络原理解析,对照 U-Net 网络结构设计了 UCaps 医学图像分割胶囊网络模型,并提出替代反卷积的上采样算法。通过对动态路由、动态双路由及 EM 路由在 UCaps 网络上的应用与实现,通过相同的 JSRT 数据集进行实验。实验结果表明, UCaps 网络在训练初期就能够定位并识别锁骨部分。尤其是结合了高斯聚类的 EM 路由方法,在整体识别速度、整体精度上都有着最为优秀的表现。

通过对比试验分析,证明胶囊网络在医学图像分割领域较于 CNN 有着更为优秀的表现,基于胶囊网络的 UCaps 在近乎相同的网络结构下相比于 U-Net 有着更快的收敛速度,且在训练初期就能够快速定位识别出重叠度较高的锁骨部分。在相同的迭代次数下,UCaps 取得了更为优秀的成绩。可以作为 U-Net 的替代,成为医学图像分割模型的 Baseline 进行拓展。

但是,由于胶囊网络的原理十分超前,现有的 GPU 算力无法支撑起像素级别的胶囊计算。尤其当数据集分辨率提升到 1024×1024 后,训练进度几乎无法继续。本文优化了相关结构,使用了矩阵胶囊来代替向量,但是仍扬汤止沸。但是纵观深度学习发展历程,从 1986 年 Hinton 提出反向传播算法,再到 2012 年的 AlexNet,深度学习沉浮多年才终于迎来爆发。随着算力的提升, CNN 才带着多样的结构打开新时代的大门。算力会继续提升,但我们更应该充分探索胶囊与其网络结构的价值,充分挖掘胶囊网络的潜力。尤其是探索胶囊网络在医学影像上的潜能。对医学而言,目前的医学图像所应用的场景较为单一,也更多是辅助诊断。但是,随着胶囊网络的可解释性融入医学图像领域,深度学习在医学图像上的未来,能够被更多医生认可,能更多承担着诊断作用。

5.2 展望

本文通过对卷积神经网络与胶囊网络在图像分割领域的探索与研究,设计了 UCaps 网络结构。但拘于算力不足,所处理的数据大小仍未达到预期。除了日后等待算力提升,我认为日后的工作中还可以聚焦在更多的分割网络,充分挖掘其与胶囊网络之间的联系。例如将注意力机制引入网络结构^[39],或者探索 PSPNet 中金字塔池化在胶囊结构中如何重新定义实现^[41],此外 Google 实验室提出的 DeepLab. v3 同样针对图像分割网络进行了不错的探索。日后的工作方向应当主要是针对胶囊网络参数量过大的问题,需要结合更新更优秀的理论去优化。

基于胶囊网络的 UCaps 网络仅仅在原理上对 U-Net 进行了进步,因此,在未来可以结合基于 U-Net、FCN 的最新网络结构对 UCaps 同样进行拓展。进一步探索胶囊网络在医学图像分割领域的应用。此外,随着网络结构的优化与计算机算力的进一步提升。我还将积极探索三维医学图像、CT、MR 影像分割的可能性。将胶囊网络更好得与医学图像相契合。进而在医学领域与深度学习领域取得更加优异的成绩。收集考证相关资料时,不禁也在思考。我们现在的提升是一定要

度从 99.9%到 99.999%么？诚然更高的准确率确实能产生更少的失误，但一味追求超高的精度去无限堆叠卷积层真的就是未来的出路么？每当算力突破瓶颈，又会出现更为复杂、更为巨大的网络模型。但这真的就是深度学习的进步么？我认为，对深度学习的探索还应当如 Hinton 那般，探索原理，深挖内核，改造本质。我认为聚类作为胶囊间路由方式，仍不是胶囊网络最终的目的地。抛开徒增小数点位数的精度，如何让深度学习网络保证一定精度的同时，有着更为丰富的内涵与逻辑。才是深度学习打破瓶颈的终极方向。

参考文献

- [1] 邓文超. 基于卷积神经网络的图像分割算法. 图像与多媒体技术, 2019.
- [2] 徐蔚波, 刘颖, 章浩伟. 基于区域生长的图像分割研究进展[J]. 北京生物医学工程 2017 年 36 卷 3 期, 317-322 页, ISTIC, 2017:上海市教委重点课程项目、上海理工大学微创励志创新基金.
- [3] 翁璇, 郑小林, 彭承林. 医学图像分割方法研究[J]. 中国医疗器械信息, 2006, 12(6):24-26.
- [4] 张建光, 李永霞. 基于阈值的图像分割方法[J]. 福建电脑, 2011, 27(8):86-86.
- [5] 潘春雨, 卢志刚, 秦嘉. 基于区域阈值的图像分割方法研究[J]. 火力与指挥控制, 2011, 36(001):118-121.
- [6] 汤可宗, 江新姿, 张磊, 等. 一种基于空间特征矢量的图像分割方法[J]. 电子技术应用, 2007, 33(10):69-71.
- [7] 沈志忠, 王硕, 曹志强, 等. 基于边缘检测的图像分割方法及其在机器鱼中的应用[J]. 机器人, 2006(04):361-366.
- [8] 曹建农, 方丹霞. 基于图论的图像分割方法及其局限性研究[J]. 测绘技术装备, 2006, 8(002):12-15.
- [9] Kanungo T , Mount D M , Netanyahu N S , et al. An efficient k-means clustering algorithm: analysis and implementation[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2002, 24(7):881-892.
- [10] Bezdek J C , Ehrlich R , Full W . FCM: The fuzzy c -means clustering algorithm[J]. Computers & Geosciences, 1984, 10(2 - 3):191-203.
- [11] Long J , Shelhamer E , Darrell T . Fully Convolutional Networks for Semantic Segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 39(4):640-651.

- [12] Ronneberger O , Fischer P , Brox T . U-Net: Convolutional Networks for Biomedical Image Segmentation[J]. Springer, Cham, 2015.
- [13] Huang G , Liu Z , Laurens V , et al. Densely Connected Convolutional Networks[J]. IEEE Computer Society, 2016.
- [14] Chen L C , Papandreou G , Kokkinos I , et al. DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 40(4):834-848.
- [15] Zhou Z , Siddiquee M , Tajbakhsh N , et al. UNet++: A Nested U-Net Architecture for Medical Image Segmentation[J]. 4th Deep Learning in Medical Image Analysis (DLMIA) Workshop, 2018.
- [16] Sabour S, Frosst N, Hinton G E. Dynamic routing between capsules[J]. Advances in neural information processing systems, 2017, 30: 3856-3866.
- [17] Transforming Auto-Encoders[C]// Artificial Neural Networks & Machine Learning-icann -international Conference on Artificial Neural Networks. Springer, Berlin, Heidelberg, 2011.
- [18] Sabour S, Frosst N, Hinton G. Matrix capsules with EM routing[C]//6th international conference on learning representations, ICLR. 2018: 1-15.
- [19] 郭丽丽, 丁世飞. 深度学习研究进展[J]. 计算机科学, 2015, 042(005):28-33.
- [20] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]// International Conference on Neural Information Processing Systems. Curran Associates Inc. 2012:1097-1105.
- [21] Fleet D , Pajdla T , Schiele B , et al. [Lecture Notes in Computer Science] Computer Vision - ECCV 2014 Volume 8689 || Visualizing and Understanding Convolutional Networks[J]. 2014, 10.1007/978-3-319-10590-1 (Chapter 53):818-833.

- [22] Rumelhart D E , Hinton G E , Williams R J . Learning Internal Representation by Errop Propagation[M]. MIT Press, 1986.
- [23] 王秋萍, 张志祥, 朱旭芳. 图像分割方法综述[J] . 信息记录材料, 2019, 20 (07): 12-14.
- [24] 林瑶, 田捷. 医学图像分割方法综述[J]. 模式识别与人工智能, 2002, 15(002):192-204.
- [25] Zhou K . Medical Image Recognition, Segmentation and Parsing[M] Academic Press, 2015.
- [26] Khened M , Alex V , Krishnamurthi G . Densely Connected Fully Convolutional Network for Short-Axis Cardiac Cine MR Image Segmentation and Heart Diagnosis Using Random Forest[M]// Statistical Atlases and Computational Models of the Heart. ACDC and MMWHS Challenges. 2018.
- [27] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [28] Giri D, Acharya U R, Martis R J, et al. Automated diagnosis of coronary artery disease affected patients using LDA, PCA, ICA and discrete wavelet transform[J]. Knowledge-Based Systems, 2013, 37: 274-282.
- [29] Mobiny A, Van Nguyen H. Fast capsnet for lung cancer screening[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Springer, Cham, 2018: 741-749.
- [30] He Y , Qin W , Wu Y , et al. Automatic left ventricle segmentation from cardiac magnetic resonance images using a capsule network[J]. Journal of X-Ray Science and Technology, 2020, 28(3):1-13.
- [31] LaLonde R, Bagci U. Capsules for object segmentation[J]. arXiv preprint arXiv:1804.04241, 2018.

- [32] Jordan M , Jacobs R . Hierarchical Mixtures of Experts and the EM Algorithm[J]. Neural Computation, 1994, 6(2):181-214.
- [33] Shiraishi J , Katsuragawa S , Ikezoe J , et al. Development of a digital image database for chest radiographs with and without a lung nodule: receiver operating characteristic analysis of radiologists' detection of pulmonary nodules.[J]. American Journal of Roentgenology, 2000, 174(1):71-74.
- [34] Ginneken B V , Stegmann M B , Loog M . Segmentation of anatomical structures in chest radiographs using supervised methods: a comparative study on a public database. [J]. Medical Image Analysis, 2006, 10(1):19-40.
- [35] Bonheur S, Štern D, Payer C, et al. Matwo-capsnet: a multi-label semantic segmentation capsules network[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Springer, Cham, 2019: 664-672.
- [36] Patrick M K, Adekoya A F, Mighty A A, et al. Capsule networks - a survey[J]. Journal of King Saud University-Computer and Information Sciences, 2019.
- [37] 杨巨成, 韩书杰, 毛磊, 等. 胶囊网络模型综述[J]. 山东大学学报 (工学版), 2019, 49(6).
- [38] Huang H , Lin L , Tong R , et al. UNet 3+: A Full-Scale Connected UNet for Medical Image Segmentation[J]. ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2020.
- [39] Song J , Tian S , Yu L , et al. AC-Caps: Attention Based Capsule Network for Predicting RBP Binding Sites of LncRNA[J]. Interdisciplinary Sciences Computational Life Sciences, 2020(3).
- [40] Mobiny A , Nguyen H V . Fast CapsNet for Lung Cancer Screening[M]. 2018.

- [41] 高丹, 陈建英, 谢盈. A-PSPNet:一种融合注意力机制的 PSPNet 图像语义分割模型.
- [42] 杨志巧. 基于小波变换的变分法在图像分割中的应用[D]. 武汉大学, 2018.
- [43] Bengio Y , Lecun Y , Lecun Y . Pattern Recognition and Neural Networks[C]// Handbook of Brain Theory & Neural Networks. 1996.
- [44] He K , Gkioxari G , P Dollár, et al. Mask R-CNN[C]// IEEE. IEEE, 2017.
- [45] Huang W , Zhou F . DA-CapsNet: dual attention mechanism capsule network[J]. Scientific Reports, 2020, 10(1).
- [46] Glorot X , Bengio Y . Understanding the difficulty of training deep feedforward neural networks[J]. Journal of Machine Learning Research, 2010, 9:249-256.
- [47] V Mazzia, Salvetti F , Chiaberge M . Efficient-CapsNet: Capsule Network with Self-Attention Routing[J]. 2021.
- [48] Jaiswal A , Abdalmageed W , Yue W , et al. CapsuleGAN: Generative Adversarial Capsule Network[J]. 2018.

致谢

短短三年，转瞬即逝，转眼即将硕士毕业。回望三年硕士生涯，唯有感恩二字。现在还记得去计算机学院拿录取通知书的那天，还记得第一次来到实验室那天，还记得第一次代表网安出场比赛的那天，还记得搬来网安新基地的那天。虽然短短三年，但注定是我印象最深刻的一段记忆。

首先感谢武汉大学国家网络安全学院对我的无私培养，我会终身以武大网安人为荣！感谢我的硕士导师陈刚教授这三年来对我的教诲、包容与照顾，老师无形中帮我们遮风挡雨。我会永远记住本部的 12 楼与新迦楼的 427。感谢三年来培育我的老师们，感谢瞿成雄书记、金晨老师、刘丹老师对我三年来学院生活的照顾和关心。感谢胡楚迪博士在各方面对我的照顾，尤其在资格论文撰写期间帮我答疑解惑。

感谢父母对我的支持与鼓励，十余年读书生涯，更苦的是父母。感谢他们培养，更感谢他们教我做人，培养正确的道德观、价值观。感谢我的女朋友伍莉晶在这三年来的理解与照顾，在学习生活中作为最坚定的后盾，在我苦闷的时候会给予我开导。感谢我的同门、兼舍友、兼兄弟的徐俊轩，这三年多有打扰，也感谢照顾，一辈子的好兄弟又多了一个。感谢 427 实验室的贺煜航、王劲平、刘桢、邓希泉、龚稳、张殊梵对我的帮助与关怀，让我感受到实验室的温情与温暖。感谢研究生三年三届网安篮球队的全体队友，跟大家一起强身健体真的很棒，还想跟大家一起打球。

说起来我跟 CapsNet 真的很有缘分，本科毕业论文认识的它，如今三年过去，原来我也从一个看论文一头雾水的本科生，变成可以探索它的奥秘与乐趣的研究生了。可能，未来不会继续科研，但是我还是感谢 Hinton 和他的 CapsNet，一步一步教会了我什么是科研，什么是探索精神。

我也不曾想到，我会如此幸运来到武汉大学，进入国家网络安全学院。可能我未来的规划会与代码渐行渐远，但是我永远也不会忘记，我是一个熬夜写代码就会效率飞起的程序猿，不会忘记我曾有如此精彩的硕士生涯，也不会忘记从生命中路过的每一个人。